UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr.Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr.Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM. 28

LISTA DE TABELAS

Tabela 1 – Síntese dos trabalhos sobre extração de *features* discutidos nesta seção. . . . 21
Tabela 2 – Síntese dos trabalhos sobre redes híbridas discutidos nesta seção. 27

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RGB	*Red, Green, Blue*
ViT	*Vision Transformer*

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 13

2 OBJETIVOS 14

3 FUNDAMENTAÇÃO TEÓRICA 15

3.1 Extração de *Features* 15

3.1.1 Descritores clássicos (*handcrafted*) 15

3.1.1.1 Matriz de coocorrência de níveis de cinza (GLCM) 16

3.1.1.2 Espectro de textura e padrões binários locais (LBP) 16

3.1.1.3 Histograma de gradientes orientados (HOG) 17

3.1.1.3.1 Papel como métodos comparativos. 17

3.1.2 Extração por aprendizado profundo 18

3.1.3 Extração de *features* sequenciais com redes recorrentes 19

3.1.4 *Features* topológicas a partir de redes complexas 20

3.1.5 Síntese 20

3.2 Redes Complexas 20

3.3 RNN na extração de *features* topológicas 23

3.4 Redes Híbridas para Extração de *Features* Espaciais 23

3.4.1 Contexto local e contexto global 23

3.4.2 Estratégias de integração entre convolução e atenção 24

3.4.3 CoAtNet 24

3.4.4 MobileViT e variantes leves 25

3.4.5 Ramos paralelos e arquiteturas multirramo 25

3.4.6 Evidências comparativas e cautelas 26

3.4.7 Embedding espacial e uso no modelo proposto 26

3.5 Fusão Tardia e MLP 27

4 METODOLOGIA 28

5 RESULTADOS E DISCUSSÃO 29

6 CONCLUSÃO 30

REFERÊNCIAS 31

1 INTRODUÇÃO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional ao permitir a extração de características semânticas complexas com alta precisão. Contudo, no domínio da saúde, a aplicação dessas técnicas frequentemente esbarra na escassez de imagens médicas anotadas, decorrente de rigorosos protocolos de privacidade, altos custos e da necessidade de especialistas para rotulação (Litjens et al., 2017). Para mitigar essa limitação, o aumento de dados (*Data Augmentation*) consolidou-se como uma etapa essencial. Ao expandir o espaço amostral, essas técnicas atuam como fortes regularizadores, reduzindo o sobreajuste (*overfitting*) e viabilizando o treinamento de modelos complexos em domínios restritos (Perez; Wang, 2017; Shorten; Khoshgoftaar, 2019).

Além das abordagens convencionais de transformação de imagem, a modelagem topológica oferece uma via promissora para o enriquecimento estrutural dos dados. Fundamentada na teoria dos grafos (Euler, 1736), a abstração de Redes Complexas mapeia a dinâmica de sistemas intrincados (Boccaletti et al., 2006). Trabalhos pioneiros (Backes; Casanova; Bruno, 2013) demonstraram que, ao modelar os pixels de uma textura como vértices e estabelecer arestas baseadas em um raio de distância euclidiana r, obtêm-se descritores topológicos robustos. A literatura evoluiu para incorporar o peso dessas arestas a partir de diferenças de intensidade (**??**). Contudo, diferentemente das abordagens clássicas de análise de textura – que comumente operam sobre imagens em escala de cinza, o presente projeto inova ao estender essa modelagem topológica para imagens RGB originais, capturando a complexa relação estrutural entre os canais de cor presentes em exames médicos.

A expansão progressiva do raio r gera uma sequência ordenada de descritores, caracterizando uma dinâmica análoga a uma série temporal na qual as macroestruturas dependem da organização das microestruturas. Para capturar essa evolução espacial histórica, as Redes Neurais Recorrentes (RNNs) (Hochreiter; Schmidhuber, 1997; Cho et al., 2014) emergem como a solução ideal, interpretando a variação do grafo como passos sequenciais e gerando representações altamente discriminatórias.

Para integrar essas dinâmicas topológicas com os atributos semânticos explícitos da imagem, arquiteturas híbridas de dupla via (*Two-Stream Networks*) consolidaram-se como uma estratégia de alto impacto (Simonyan; Zisserman, 2014). A proposta deste trabalho é processar, em paralelo, as assinaturas estruturais (via RNN) e as características espaciais visuais da imagem (através de arquiteturas baseadas em convolução e atenção, inspiradas em modelos como a CoAtNet (Dai et al., 2021)). A união dessas vias por meio de fusão tardia (*Late Fusion*) e concatenação de *embeddings* visa estabelecer um classificador coeso e de precisão superior para cenários de dados limitados.

2 OBJETIVOS

3 FUNDAMENTAÇÃO TEÓRICA

3.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* (característica) é uma medida numérica que resume algum aspecto relevante do dado. No caso de imagens, esses aspectos incluem bordas, texturas, formas e padrões de cor, e a extração de *features* é o processo que mapeia a imagem bruta para uma representação de menor dimensão, sobre a qual o classificador opera (Ramos-Soto et al., 2025). Em imagens médicas, uma *feature* corresponde a uma característica ou padrão relevante para a tarefa diagnóstica, como forma, tamanho, textura, densidade ou intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A qualidade dessa representação influencia diretamente a capacidade de generalização do classificador, especialmente quando há poucos dados disponíveis (Ramos-Soto et al., 2025), cenário recorrente na área da saúde em razão de protocolos de privacidade, custos de aquisição e da necessidade de especialistas para a rotulação (Litjens et al., 2017).

Não existe um método de extração universalmente superior. Segundo Ahmed et al. (2023), a escolha depende de fatores como a disponibilidade e a dimensionalidade dos dados, a existência de rótulos e o paradigma de aprendizado (supervisionado ou não supervisionado). Nas subseções seguintes, os métodos são organizados em três famílias: (i) descritores clássicos, projetados manualmente; (ii) representações aprendidas por redes profundas sobre a imagem; e (iii) representações aprendidas sobre dados sequenciais por redes recorrentes, com destaque para as *features* de natureza topológica que motivam este trabalho.

3.1.1 Descritores clássicos (*handcrafted*)

Os descritores clássicos são calculados por procedimentos matemáticos fixados previamente, sem aprendizado a partir dos dados. Entre os mais utilizados em imagens médicas estão: estatísticas de primeira ordem (como média e desvio padrão da intensidade); a matriz de coocorrência de níveis de cinza (GLCM) e as *features* de Haralick (Haralick; Shanmugam; Dinstein, 1973), que descrevem a relação espacial entre pares de pixels; os padrões binários locais (LBP) e seu antecessor, o espectro de textura (He; Wang, 1989; Wang; He, 1990); o histograma de gradientes orientados (HOG) (Dalal; Triggs, 2005); os filtros de Gabor; e o SIFT (Ramos-Soto et al., 2025; Ahmed et al., 2023). Um conjunto frequentemente adotado em estudos de *radiomics* é o do pacote *pyradiomics*, que agrega estatísticas de primeira ordem e matrizes de textura (GLCM, GLSZM, GLRLM, NGTDM e GLDM), totalizando 93 *features* por imagem em Dehbozorgi, Ryabchykov & Bocklitz (2025). Quando o vetor resultante é grande, é comum aplicar seleção ou redução de dimensionalidade, por exemplo com análise de componentes principais (PCA) (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ahmed et al., 2023).

Três desses descritores (GLCM, LBP e HOG) são adotados neste trabalho como métodos comparativos da técnica proposta. Eles são amplos em uso na análise de imagens médicas: em Dehbozorgi, Ryabchykov & Bocklitz (2025), por exemplo, o conjunto de *features* estatísticas é composto por média, desvio padrão, LBP, GLCM e HOG, e Ramos-Soto et al. (2025) também os incluem entre os extratores clássicos de referência. Cada um é descrito a seguir.

3.1.1.1 Matriz de coocorrência de níveis de cinza (GLCM)

Haralick, Shanmugam & Dinstein (1973) propuseram caracterizar a textura de um bloco de imagem a partir de matrizes de dependência espacial de tons de cinza, hoje conhecidas como matrizes de coocorrência (GLCM). Cada elemento (i, j) da matriz registra quantas vezes um pixel de tom i ocorre como vizinho de um pixel de tom j, dada uma distância d e uma direção angular (0°, 45°, 90° ou 135°); normalizada, a matriz representa a distribuição de probabilidade conjunta desses pares. A partir de cada matriz, os autores definem 14 medidas de textura, entre elas o momento angular de segunda ordem, o contraste, a correlação, a variância, o momento da diferença inversa e a entropia, que refletem aspectos como homogeneidade, dependências lineares de tons de cinza, contraste, número e natureza das bordas e complexidade da imagem. O custo de cálculo de cada medida é proporcional ao número de células de resolução do bloco, razão pela qual foram chamadas de rapidamente computáveis. O método foi avaliado em fotomicrografias de arenitos (cinco classes), fotografias aéreas (oito categorias de uso do solo) e imagens de satélite (sete categorias), com acurácias de teste de 89%, 82% e 83%, respectivamente (Haralick; Shanmugam; Dinstein, 1973). Como limitações, He & Wang (1989) apontam que a matriz depende não só das relações espaciais entre tons de cinza, mas também da variação regional do fundo de intensidade da imagem, e que a escolha do vetor de deslocamento é problemática.

3.1.1.2 Espectro de textura e padrões binários locais (LBP)

O espectro de textura (*texture spectrum*) foi proposto por He & Wang (1989) a partir do conceito de unidade de textura (*texture unit*). Em uma vizinhança 3×3, cada um dos oito vizinhos do pixel central é codificado em um de três valores (0, 1 ou 2), de acordo com sua relação de intensidade com o pixel central, o que resulta em $3^8 = 6561$ unidades de textura possíveis. A distribuição de frequência dessas unidades ao longo da imagem, o espectro de textura, funciona como descritor, e imagens de texturas distintas apresentam espectros distintos (He; Wang, 1989). Segundo Wang & He (1990), a redução das intensidades a apenas três valores diminui o custo de cálculo e elimina a influência do fundo regional de intensidade e do ruído. Em Wang & He (1990), o espectro foi usado para classificar quatro texturas naturais do álbum de Brodatz com um classificador de distância mínima, baseado na soma das diferenças absolutas entre espectros, e obteve acurácia média de 97,5%. Os padrões binários locais (LBP) seguem a mesma ideia de codificar a relação entre o pixel central e seus vizinhos e de descrever a imagem

pelo histograma dos códigos obtidos, com uma codificação binária mais compacta que a do espectro de textura.

3.1.1.3 Histograma de gradientes orientados (HOG)

O HOG foi proposto por Dalal & Triggs (2005) para detecção de pessoas, e descreve a imagem pela distribuição local das direções de gradiente. A janela é dividida em pequenas regiões espaciais (células), e em cada célula acumula-se um histograma das orientações de gradiente ponderadas pela magnitude. Para ganhar invariância a iluminação e sombreamento, as respostas são normalizadas quanto ao contraste em blocos maiores e sobrepostos, e a concatenação dos histogramas normalizados forma o descritor, que alimenta um classificador (no trabalho original, uma SVM linear). A configuração padrão dos autores usa filtro de gradiente $[-1, 0, 1]$ sem suavização, nove *bins* de orientação entre 0° e 180°, blocos de 16×16 pixels formados por quatro células de 8×8 pixels, normalização L2-Hys e passo de 8 pixels entre blocos, em uma janela de 64×128 pixels. O descritor reduziu as taxas de falsos positivos em mais de uma ordem de magnitude em relação ao melhor detector baseado em *wavelets* de Haar e levou a separação quase perfeita no conjunto MIT de pedestres (Dalal; Triggs, 2005). Embora tenha sido concebido para um problema de detecção, o HOG é amplamente empregado como descritor de bordas e forma em imagens médicas (Ramos-Soto et al., 2025).

3.1.1.3.1 Papel como métodos comparativos.

GLCM, LBP e HOG descrevem a imagem a partir de relações locais entre pixels (pares de tons de cinza, códigos de vizinhança e orientações de gradiente), em escalas e vizinhanças definidas previamente e, em geral, sobre imagens em níveis de cinza. A técnica proposta neste trabalho, em contraste, modela a imagem RGB como um grafo e analisa a evolução de suas medidas topológicas à medida que o raio de conexão aumenta, de modo que a comparação com esses três descritores permite avaliar o ganho de uma representação topológica sequencial sobre as abordagens clássicas de textura e forma.

Esses métodos têm vantagens de interpretabilidade e baixo custo de treinamento, mas apresentam limitações importantes. De acordo com Ramos-Soto et al. (2025), eles capturam padrões locais simples (bordas e gradientes), mas têm dificuldade em representar características de alto nível, não modelam o contexto global da imagem, são sensíveis a ruído e artefatos e escalam mal para dados de alta dimensão. Em um estudo comparativo com imagens de histologia (H&E), raio-X de tórax e tomografia de coerência óptica (OCT) da retina, Dehbozorgi, Ryabchykov & Bocklitz (2025) observaram que as *features* estatísticas e de *radiomics* foram as mais lentas de extrair e as de menor desempenho: na base de H&E, a extração estatística levou cerca de uma hora e atingiu 90,8% de sensibilidade média, enquanto a ResNet50 reduziu o tempo em quatro vezes e elevou a sensibilidade a 96,9%. Resultado semelhante aparece fora do domínio de imagens: em detecção de arritmia por eletrocardiograma (ECG), Ye et al.

(2021) compararam descritores manuais (intervalos RR, FFT, *wavelets*, estatísticas de ordem superior e funções de Hermite) com a alimentação do sinal bruto em classificadores profundos, e concluíram que o sinal bruto superou as *features* manuais em todos os classificadores avaliados, embora os classificadores profundos tenham apresentado maior tempo de inferência.

3.1.2 Extração por aprendizado profundo

Redes neurais convolucionais (CNNs) aprendem, de forma hierárquica e a partir dos próprios dados, filtros que vão de bordas e texturas nas primeiras camadas a padrões semânticos nas camadas finais, o que as tornou a abordagem dominante em análise de imagens médicas (Litjens et al., 2017). Uma estratégia amplamente usada em domínios com poucos dados é a transferência de aprendizado (*transfer learning*), na qual uma rede pré-treinada em uma base grande, como a ImageNet, é empregada como extrator de *features*: a imagem é propagada pela rede e a ativação de uma camada intermediária ou final é usada como vetor de características. Em Dehbozorgi, Ryabchykov & Bocklitz (2025), cinco redes pré-treinadas (VGG16, ResNet50, DenseNet121, MobileNetV2 e InceptionV3) produziram entre 512 e 2048 *features* por imagem, com tempos de extração de aproximadamente 10 minutos (MobileNetV2, a mais rápida) a 15 minutos (DenseNet121), e em geral superaram os métodos estatísticos e de *radiomics* em sensibilidade nas três modalidades; na base de OCT, por exemplo, a DenseNet121 alcançou 98,6%, contra 91% do *radiomics*. Os autores destacam, porém, limitações do uso de redes profundas: necessidade de GPUs, dependência de grandes bases de dados e baixa interpretabilidade.

A necessidade de capturar dependências de longo alcance motivou o uso de *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) e de arquiteturas híbridas que combinam convolução e atenção, como a CoAtNet (Dai et al., 2021), discutidas em revisões sobre *transformers* em imagens médicas (Shamshad et al., 2023). Tanto CNNs quanto ViTs, contudo, tendem ao sobreajuste quando treinados em bases pequenas ou com alta variância intraclasse (Ramos-Soto et al., 2025). Para atenuar esse problema, Ramos-Soto et al. (2025) propuseram o MIAFEx, que utiliza o *token* de classificação ([CLS]) de um *Transformer* encoder como representação global da imagem e o refina por meio de pesos aprendíveis (multiplicação elemento a elemento sobre o vetor de dimensão 768), permitindo amplificar ou atenuar dimensões conforme sua relevância. As *features* resultantes podem alimentar classificadores tradicionais. Em bases médicas pequenas, o MIAFEx superou extratores clássicos, CNNs e ViTs; em contrapartida, os autores reportam que essa vantagem diminui à medida que o conjunto de dados cresce. Como exemplo, na base de biópsias histológicas com classificador SVM, o MIAFEx obteve 81,25% de acurácia, contra no máximo 56,25% dos descritores clássicos avaliados.

Outro aspecto relevante é a escala. Lesões e estruturas de interesse variam em tamanho e aparência, e extratores de escala única tendem a ter dificuldade em representá-las. No contexto de segmentação, a MMS-Net (Zhao et al., 2023) combina módulos de conexão de salto (*skip connection modules*), que extraem contexto multiescala local, com uma rede piramidal de *features* (FPN), que agrega informação multiescala global, e manteve resultados competitivos

mesmo com apenas 50% e 20% dos dados de treino. Essa ideia de analisar a imagem em vários níveis de vizinhança é análoga à variação progressiva do raio de conexão nos modelos de redes complexas discutidos adiante.

3.1.3 Extração de *features* sequenciais com redes recorrentes

Redes neurais recorrentes (RNNs) são projetadas para dados ordenados: a cada passo, o estado oculto combina a entrada atual com a memória dos passos anteriores. Variantes com portas, como a LSTM (Hochreiter; Schmidhuber, 1997) e a GRU (Cho et al., 2014), mitigam o problema do desaparecimento do gradiente e permitem modelar dependências mais longas (Jun et al., 2020). Para fins de extração de *features*, o estado oculto final (ou a saída de um codificador recorrente) funciona como um *embedding* que resume a sequência inteira em um vetor de dimensão fixa, que pode então ser usado por um classificador.

Essa estratégia tem sido explorada em diferentes domínios. Jun et al. (2020) utilizaram autoencoders recorrentes (LSTM AE e GRU AE) para extrair automaticamente *features* de sequências de esqueletos em reconhecimento de marcha anormal. O autoencoder é treinado para reconstruir a entrada, o que tende a reduzir informação irrelevante e redundante no código latente. As *features* extraídas foram mais discriminativas e robustas que os dados originais e que *features* manuais; o LSTM AE superou o GRU AE; e os modelos híbridos (autoencoder seguido de modelo discriminativo) atingiram maior acurácia com menos épocas de treinamento e menos parâmetros que o modelo único alimentado com os dados originais. Os autores também observaram que o treinamento em duas etapas foi mais eficaz que o treinamento ponta a ponta com o mesmo fluxo de dados. Em expressões faciais dinâmicas, Zhi & Wan (2019) propuseram uma LSTM com restrição de esparsidade (SLSTM), baseada no algoritmo ISTA, que aprende códigos esparsos de forma automática, zera pesos de *features* pouco úteis e reduz a complexidade computacional em relação à LSTM convencional, com avaliação em detecção de dor (BioVid) e microexpressões (CASME II e SMIC).

Quando a entrada são imagens, é comum combinar uma CNN, que extrai *features* espaciais por quadro, com uma RNN, que agrega a informação ao longo da sequência. Jeswani & Priyadharshini (2026) compararam três arquiteturas CNN–RNN para detecção de *deepfakes* em vídeo e obtiveram o melhor resultado com ResNeXt50 e LSTM (acurácia de 0,80, F1 de 0,75 e AUC-ROC de 0,80), embora em um conjunto de teste de apenas dez vídeos, limitação reconhecida pelos autores. Wu (2024) propuseram um modelo composto por CNN, RNN e mecanismo de atenção para dados complexos (imagens, textos e áudio) e reportaram desempenho superior ao de uma rede neural densa convencional nas curvas de treino e validação. Já S & Dharan (2025) empregaram uma RNN com atenção sobre os mapas de características de uma MobileNetV2 pré-treinada para gerar vetores de 512 dimensões para cada modalidade biométrica (face, impressão digital e íris), posteriormente combinados por um algoritmo de fusão e classificados por SVM, com acurácia de 99,50%. Esse último caso ilustra o princípio de gerar um *embedding* por via de processamento e integrá-lo em um estágio posterior, tema da Seção 3.5.

Em todos os trabalhos acima, a dimensão sequencial é o tempo (quadros de vídeo, amostras de ECG, posturas de esqueleto). Neste trabalho, a sequência é construída de outra forma: a expansão progressiva do raio de conexão de um grafo gera uma série ordenada de descritores topológicos, de modo que a RNN passa a modelar a evolução estrutural da imagem em vez de uma evolução temporal.

3.1.4 *Features* topológicas a partir de redes complexas

Uma terceira família de métodos extrai *features* da organização estrutural da imagem, modelando-a como uma rede complexa (Boccaletti et al., 2006). Em análise de textura, Backes, Casanova & Bruno (2013) representaram os pixels como vértices e conectaram aqueles cuja distância euclidiana é menor que um raio r, obtendo descritores a partir de medidas de vértice como o grau; Ribas et al. (2020) estenderam a abordagem para redes ponderadas e a combinaram com redes neurais aleatorizadas. A formulação detalhada de grafos e medidas topológicas é apresentada na Seção 3.2.

O trabalho que inspirou esta proposta (Ribas et al., 2024) leva essa ideia para imagens coloridas por meio da *Spatio-Spectral Network* (SSN), proposta originalmente por Scabini, Ribas & Bruno (2020), um grafo direcionado em que as conexões dentro de cada canal de cor (rede W) representam as características espaciais e as conexões entre canais (rede B) representam padrões espectrais. A partir de um conjunto de raios, calculam-se medidas de vértice (grau de saída, força de entrada e força de saída) e, com elas, treina-se uma rede neural aleatorizada (*Randomized Neural Network*), cuja camada oculta tem pesos sorteados e cuja camada de saída é resolvida por mínimos quadrados, para prever a dinâmica de evolução da rede. Os pesos aprendidos na camada de saída são então adotados como descritor da imagem. O método combina, portanto, uma modelagem manual (a SSN) com um aprendizado de representação (a rede neural), e superou diversas técnicas da literatura, inclusive CNNs profundas, em quatro bases de textura colorida. Os próprios autores apontam como limitação a interpretação física das representações aprendidas (Ribas et al., 2024).

3.1.5 Síntese

O Quadro 1 resume os trabalhos discutidos. Dois pontos orientam as escolhas metodológicas desta proposta. Primeiro, as evidências indicam que *features* aprendidas superam descritores manuais em desempenho e em tempo de extração (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ye et al., 2021), mas que modelos profundos treinados com poucos dados tendem ao sobreajuste (Ramos-Soto et al., 2025), o que justifica o uso de modelos pré-treinados, de arquiteturas com atenção e de regularização em bases médicas pequenas. Segundo, descritores topológicos oferecem uma representação estrutural complementar à aparência visual (Ribas et al., 2024), e redes recorrentes são adequadas para resumir sequências desses descritores em um *embedding* (Jun et al., 2020). Assim, este trabalho extrai dois *embeddings* em paralelo: um *embedding*

topológico, gerado por uma RNN sobre a sequência de descritores do grafo RGB em diferentes raios, e um *embedding* espacial, gerado por um modelo visual híbrido de convolução e atenção. A integração desses vetores é tratada na Seção 3.5.

Tabela 1 – Síntese dos trabalhos sobre extração de *features* discutidos nesta seção.

Trabalho	**Domínio**	**Extração de *features***	**Resultado reportado**
Haralick, Shanmugam & Dinstein (1973)	Fotomicrografias, fotos aéreas e imagens de satélite	GLCM e 14 medidas de textura	Acurácia de teste de 89%, 82% e 83% nas três bases
Wang & He (1990)	Texturas naturais (Brodatz)	Espectro de textura (3×3, 6561 unidades)	Acurácia média de 97,5% em quatro texturas, com distância mínima
Dalal & Triggs (2005)	Detecção de pessoas	HOG (células e blocos normalizados) e SVM linear	Redução de falsos positivos em mais de uma ordem de magnitude frente a descritores com *wavelets*
Dehbozorgi, Ryabchykov & Bocklitz (2025)	H&E, raio-X, OCT	Estatísticas, *radiomics* e CNNs pré-treinadas	*Features* profundas com maior sensibilidade e menor latência (OCT: 98,6% com DenseNet121 *vs.* 91% com *radiomics*)
Ramos-Soto et al. (2025)	Imagens médicas (bases pequenas)	ViT com refinamento do *token* [CLS]	Superou extratores clássicos, CNNs e ViTs em bases pequenas; vantagem diminui com mais dados
Zhao et al. (2023)	Segmentação médica	Multiescala (SCM e FPN)	Resultados competitivos com 50% e 20% dos dados de treino
Ahmed et al. (2023)	Mamografia e RM	Revisão (GLCM, Haralick, Gabor, LBP, PCA, LVQ)	Escolha do método depende dos dados e da tarefa
Ye et al. (2021)	ECG	*Features* manuais *vs.* sinal bruto	Sinal bruto em CNN foi o melhor, com maior tempo de inferência
Jun et al. (2020)	Marcha (esqueleto)	Autoencoder LSTM/GRU	*Features* do autoencoder superaram os dados originais; LSTM AE superou GRU AE
Zhi & Wan (2019)	Expressões faciais (vídeo)	LSTM esparsa (SLSTM)	Seleção automática de *features* e menor complexidade
Jeswani & Priyadharshini (2026)	*Deepfake* (vídeo)	CNN e GRU/LSTM	ResNeXt50 + LSTM: acurácia de 0,80 e F1 de 0,75 (10 vídeos de teste)
Wu (2024)	Dados complexos (imagem, texto, áudio)	CNN, RNN e atenção	Superior a uma DNN convencional (curvas de acurácia)
S & Dharan (2025)	Biometria multimodal	MobileNetV2 e RNN com atenção	Acurácia de 99,50% após fusão e SVM
Ribas et al. (2024)	Textura colorida	SSN e rede neural aleatorizada	Superou diversos métodos, inclusive CNNs profundas, em quatro bases

3.2 REDES COMPLEXAS

A teoria de Redes Complexas (CN - *Complex Networks*) atua como uma abstração para modelar sistemas naturais onde os elementos interagem de maneira não trivial. Na visão computacional e no processamento de imagens médicas, essas redes têm sido amplamente empregadas para modelar os pixels de uma imagem e suas adjacências, possibilitando que descritores baseados

em topologia quantifiquem propriedades de textura de forma muito discriminativa (Ribas et al., 2020; Ribas et al., 2024).

Para processar a imagem, a estrutura regular de *grid* de seus pixels é mapeada em um grafo direcionado ponderado $G = (V, E)$, no qual cada pixel na imagem original está associado a um vértice $v \in V$, e a relação entre um par de pixels define a formação de uma aresta e seu respectivo peso, $e \in E$ (Zerati et al., 2026). A formulação original de CNs direcionadas para imagens (Backes; Casanova; Bruno, 2013; Ribas et al., 2020) propõe mapear as conexões restritas a um raio circular de distância r, criando uma vizinhança na qual apenas os pixels dentro do raio r ao redor de um dado pixel se conectarão a ele, como descrito a seguir:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 < \rho_{ij}^2 \leq r^2. \tag{1}$$

Em que x e y representam as coordenadas do pixel correspondente ao nó v na imagem, e ρ descreve a distância euclidiana. Assim como o raio de conexão, a relação entre a intensidade do pixel formará o direcionamento do grafo, onde para $I(x_i, y_i) \geq I(x_j, y_j)$, a conexão torna-se direcionada do nó v_i de saída (*out*) para o nó v_j (Zerati et al., 2026; Ribas et al., 2024). E a aresta da rede será ponderada pela diferença modular de intensidade entre os vértices, resultando em descritores estruturais que modelam topologicamente o comportamento visual da imagem no raio r, de acordo com a Equação 2:

$$w_{ij} = \left| I(x_i, y_i) - I(x_j, y_j) \right|. \tag{2}$$

A extração de características da rede envolve computar medidas topológicas em diferentes raios. Neste estudo, foram empregados o grau (*degree*) (Backes; Casanova; Bruno, 2013) e a força (*force*) (Zerati et al., 2026) como medidas topológicas. Ambas foram utilizadas como grau de entrada, grau de saída, força de entrada e força de saída. Onde, a métrica de grau quantifica as incidências no vértice v_i, contabilizando a quantidade de conexões direcionadas <comment-tag:Substituí "cuja intensidade superam ou perdem para a do"para manter um tom mais formal e acadêmico, alinhado ao rigor do TCC.>cujas intensidades sejam superiores ou inferiores à do</comment-tag> vértice analisado.

Por outro lado, a medida força (Zerati et al., 2026) quantifica essas ligações de forma mais discriminativa, considerando as distâncias e intensidades de cada nó dentro do raio r. Cada medida pode ser computada da seguinte forma, levando em consideração também o peso de força que combina a diferença de intensidade normalizada com a distância espacial normalizada na Equação 3:

$$\omega_{ij}^{(r)} = \begin{cases} \dfrac{w_{ij}}{2L}, & r = 1, \\ \dfrac{1}{2}\left[\dfrac{w_{ij}}{L} + \dfrac{\rho_{ij}^2 - 1}{r^2 - 1}\right], & r \geq 2, \end{cases} \tag{3}$$

Sendo $L = 255$ o nível de intensidade máximo da imagem, e força de saída quantificada

acumulada do raio 1 ao raio r em:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{4}$$

Onde $\mathcal{N}_{out}^{(r)}(v_i)$ representa os nós v_j com ligação ao nó v_i. Logo a force$_{in}$ é computada com o $\mathcal{N}_{in}^{(r)}$.

Essas propriedades formam uma estrutura matemática análoga a matrizes densas ou imagens discretas (Ribas et al., 2024; Zerati et al., 2026). Dessa forma, com a quantificação das medidas topológicas sob variados raios de limitação, a representação da rede complexa descreverá o crescimento espacial topológico ao longo do tempo (variações da distância circular r) (Scabini et al., 2026; Ribas et al., 2024). Onde características estritamente locais no menor raio de conexão tornam-se de forma decrescente características mais globais.

Além de que, com o intuito de estender as matrizes das medidas topológicas aos três canais de luz que descrevem as imagens histopatológicas *RGB*, a estrutura das formulações também pode ser utilizada como *Between-channel*, *Within-channel* e *Full* (Scabini; Ribas; Bruno, 2020). Sendo a *Full* considerada neste trabalho para unificar os processos intra e inter-canais sob as mesmas métricas simultaneamente (Zerati et al., 2026).

3.3 RNN NA EXTRAÇÃO DE *FEATURES* TOPOLÓGICAS

3.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* ESPACIAIS

Na arquitetura proposta, a via visual é responsável por extrair, diretamente da imagem RGB, o *embedding* espacial que será combinado com o *embedding* topológico no estágio de fusão (Seção 3.5). Esta seção apresenta os fundamentos das redes híbridas, que combinam convolução e mecanismos de atenção, e discute como elas têm sido empregadas na análise de imagens médicas.

3.4.1 Contexto local e contexto global

As redes convolucionais (CNNs) são eficientes na extração de padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de longo alcance (Ma et al., 2026). Os *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) atacam esse problema por meio da autoatenção sobre sequências de *patches*, que permite modelar relações entre regiões distantes da imagem, e vêm sendo amplamente estudados em imagens médicas (Shamshad et al., 2023). Em contrapartida, a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). Além disso, como discutido na Seção 3.1, tanto CNNs quanto ViTs tendem ao sobreajuste em bases pequenas (Ramos-Soto et al., 2025).

As arquiteturas híbridas buscam combinar o viés indutivo local das CNNs com a capacidade de modelagem global dos *transformers*: em geral, blocos convolucionais extraem informação localizada e mecanismos de atenção integram o contexto global (Oliveira et al., 2025). Essa combinação é particularmente relevante em patologia computacional, em que a interpretação depende tanto de detalhes morfológicos finos quanto de padrões em escala de tecido (Oliveira et al., 2025).

3.4.2 Estratégias de integração entre convolução e atenção

A literatura descreve diversas formas de integrar CNNs e *transformers*. Oliveira et al. (2025) resumem duas taxonomias existentes: uma que distingue projetos paralelos, em que CNN e ViT operam de forma independente e têm suas saídas fundidas (por exemplo, por atenção cruzada), de projetos sequenciais, em que as *features* de um módulo alimentam o outro; e outra, mais granular, que inclui integração em camadas iniciais, laterais, em bloco, hierárquica, baseada em atenção e por reforço de canais. Os próprios autores propõem uma taxonomia por tarefa. Para classificação, as arquiteturas são compostas por um codificador de *features* (convolucional ou baseado em autoatenção), um estágio de adaptação que refina as *features* extraídas e um classificador final; para segmentação, por codificador, gargalo, decodificador e conexões de salto; e para detecção, por *backbone*, *neck* e *head*.

Na revisão de escopo de Oliveira et al. (2025), que analisou 39 estudos de histopatologia, a maioria dos trabalhos adota arquiteturas integradas ou sequenciais, e estratégias como aprendizado guiado cruzado e fusão por múltiplos caminhos são pouco exploradas. Os autores concluem que os modelos híbridos frequentemente superam abordagens convencionais, mas apontam limitações recorrentes: poucos estudos realizam validação externa, muitos usam bases pequenas e homogêneas, o aumento de dados é aplicado e relatado de forma inconsistente, a maioria emprega validação por *holdout* em vez de validação cruzada, apenas 35,9% utilizam técnicas de explicabilidade (em geral Grad-CAM) e a reprodutibilidade é prejudicada pela escassez de código público. Essas observações são consideradas no delineamento experimental deste trabalho, que prevê validação cruzada estratificada e comparação com modelos de via única.

3.4.3 CoAtNet

A CoAtNet (Dai et al., 2021) é uma arquitetura que empilha camadas convolucionais e de autoatenção. Conforme descrito por Zaidkilani, Garcia & Puig (2024), a rede possui cinco estágios: o primeiro é uma haste convolucional (duas convoluções 3×3 com normalização em lote e ativação GELU); o segundo e o terceiro empregam blocos MBConv, do tipo *inverted bottleneck* da MobileNetV2 (convolução 1×1 de expansão, convolução *depthwise* 3×3 e convolução 1×1 de projeção, com ramo residual); e os dois últimos aplicam blocos *Transformer*, formados por autoatenção com posição relativa seguida de uma camada *feed-forward*. Assim, as camadas iniciais, que operam sobre mapas de alta resolução, usam convoluções eficientes para

extrair *features* locais, enquanto as camadas finais usam atenção sobre mapas de baixa resolução para extrair *features* globais (Zaidkilani; Garcia; Puig, 2024). Esse desenho é a base da via visual proposta, que parte de uma rede híbrida de convolução e atenção inspirada na CoAtNet e ajustada por *fine-tuning*.

Como ilustração de uma extensão dessa arquitetura, Zaidkilani, Garcia & Puig (2024) substituem as camadas de atenção dos estágios finais por um fluxo duplo, em que blocos de convolução e de autoatenção atuam em paralelo e têm suas saídas integradas, de modo que as camadas finais também considerem a informação local dos mapas de baixa resolução. Na segmentação de imagens de ultrassom de mama, a melhor variante atingiu coeficiente Dice de 78,84% na base UDIAT, contra 73,83% da CoAtNet original, e de 77,91% na BUSI, valores que os autores reconhecem como ainda distantes do ideal.

3.4.4 MobileViT e variantes leves

Outra família de híbridos amplamente usada em imagens médicas é a baseada no MobileViT. No bloco MobileViT, conforme descrito por Ding et al. (2023), uma convolução $n \times n$ seguida de uma convolução pontual 1×1 gera uma representação local do tensor de entrada; essa representação é dividida em *patches* não sobrepostos, sobre os quais um *Transformer* codifica as relações entre *patches*; o resultado é reorganizado na forma espacial original, concatenado com a entrada e processado por uma nova convolução $n \times n$, que funde as informações local e global. O HI-MViT, proposto para classificação de lesões de pele, combina convolução comum, blocos Improved-MV2 (expansão 1×1, convolução *depthwise* separável e projeção 1×1, com conexão residual), blocos MobileViT, *pooling* global e camadas totalmente conectadas, e alcançou acurácia de 0,932 e F1 de 0,931 na base ISIC-2018 (Ding et al., 2023).

Outros trabalhos exploram o mesmo princípio com variações. O LightSE-MobileViT (Kabir et al., 2025) insere um bloco *Squeeze-and-Excitation* após a terceira camada convolucional de um *backbone* leve, seguido de um codificador MobileViT, para classificar câncer oral, e relata acurácia de 98,39% em um conjunto expandido por aumento de dados de 131 para 981 imagens; os autores reconhecem o tamanho e a diversidade limitados da base. Zou et al. (2023) combinam ResNet e MobileViT em um modelo de dupla entrada (imagem de ultrassom original e imagem de atenção), com módulo de fusão e função de perda guiada por *global average pooling* (GAP), e relatam desempenho superior a alguns métodos do estado da arte nas bases BUSI e BUSC. Em imagens de microscopia multiespectral de tecido (520, 600 e 630 nm), Wang et al. (2026) compararam DenseNet, EfficientNet, Swin-Transformer, ResNet e MobileViT e obtiveram a maior acurácia com o MobileViT (91,70%, contra 89,80% da ResNet e 88,00% da Swin-Transformer). Os autores o escolheram como base para otimização por combinar a extração local da CNN com a modelagem global do *Transformer* e por ter eficiência computacional superior à de *transformers* puros, e o ajustaram com perda focal ponderada por classe para lidar com o desbalanceamento da base.

3.4.5 Ramos paralelos e arquiteturas multirramo

Uma terceira estratégia consiste em processar a imagem por ramos paralelos, cada um responsável por um tipo de informação, e integrá-los em seguida. No CIHM, proposto para segmentação, a camada CiMC combina em paralelo um ramo de modelo de espaço de estados (Mamba), que captura dependências de longo alcance com complexidade linear, e um bloco convolucional com convolução em forma de T, que extrai detalhes locais; os autores reportam desempenho superior ao da U-Net e ao da U-Mamba com 40 e 345 vezes menos parâmetros, respectivamente (Ma et al., 2026). O GSAC-UFormer, também de segmentação, integra em paralelo convolução em grupos e autoatenção adaptada por CNN em seu bloco principal, e usa um módulo de atenção contextual guiada para refinar as relações espaciais e de canal, com coeficientes Dice de 91,6%, 94,61% e 82,24% nas bases MICCAI 2017 (lesão vermelha), PH2 e CVC-ClinicalDB (Garbaz et al., 2025). Já o TriGWONet (Kabir et al., 2026), voltado à classificação de câncer oral, é uma rede convolucional com três ramos paralelos (camadas *SeparableConv2D*, normalização em lote, ReLU e *global max pooling*, seguidas de camadas densas), inspirada em princípios de *transformers* e com hiperparâmetros otimizados por *Gray Wolf Optimization*; os autores relatam acurácia de 99,64% em uma base de 240 imagens e reconhecem que ela é modesta em tamanho.

3.4.6 Evidências comparativas e cautelas

Estudos comparativos ajudam a situar esses modelos. Sharma, Singh & Choudhury (2025) avaliaram 15 arquiteturas de classificação de mamografias (como ResNet50, EfficientNetB0 e ViT, além de modelos específicos para mamografia) em quatro bases públicas (CBIS-DDSM, INbreast, MIAS e VinDr-Mammo), com protocolos padronizados. Os modelos específicos para mamografia, em especial o ViT-Mammo (AUC de 0,961) e o FCCS-Net, superaram as arquiteturas de propósito geral, ao passo que modelos leves como EfficientNetB0 e DenseNet121 foram menos precisos, porém mais eficientes. Esses resultados indicam que o desempenho depende da adequação da arquitetura ao domínio e que há um compromisso entre acurácia e custo computacional.

Alguns cuidados devem ser tomados ao interpretar a literatura. Dois dos trabalhos citados reportam acurácias próximas de 100% em bases com poucas centenas de imagens (Kabir et al., 2025; Kabir et al., 2026), e Oliveira et al. (2025) alertam que a ausência de validação externa e de bases de referência comparáveis limita a generalização dos resultados. Por isso, neste trabalho esses valores são tomados como evidência da viabilidade de cada desenho arquitetural, e não como referência de desempenho esperado.

3.4.7 Embedding espacial e uso no modelo proposto

Em tarefas de classificação, o codificador híbrido produz, após uma etapa de *pooling* global ou do uso de um *token* de classificação, um vetor de dimensão fixa que resume a imagem e é

então encaminhado ao classificador (Ding et al., 2023; Ramos-Soto et al., 2025). Esse vetor é o *embedding* espacial. No modelo proposto, a via visual consiste em uma rede híbrida de convolução e atenção, inicializada com pesos pré-treinados e ajustada por *fine-tuning*, cuja cabeça de classificação própria é descartada para que o vetor imediatamente anterior a ela seja entregue à etapa de fusão tardia, onde é concatenado ao *embedding* topológico gerado pela RNN (Seção 3.5). Dessa forma, o *embedding* espacial captura padrões locais (via convolução) e globais (via atenção) da imagem, e o topológico captura a organização estrutural entre pixels e canais de cor ao longo de diferentes raios.

Tabela 2 – Síntese dos trabalhos sobre redes híbridas discutidos nesta seção.

Trabalho	**Tarefa e domínio**	**Estratégia híbrida**	**Resultado reportado**
Oliveira et al. (2025)	Revisão (histopatologia)	Taxonomia por tarefa; projetos sequenciais, paralelos e integrados	39 estudos; híbridos frequentemente superam abordagens convencionais, com lacunas de validação e explicabilidade
Zaidkilani, Garcia & Puig (2024)	Segmentação (ultrassom de mama)	CoAtNet com fluxo duplo de convolução e atenção	Dice de 78,84% (UDIAT) e 77,91% (BUSI)
Ding et al. (2023)	Classificação (lesões de pele)	Improved-MV2 e blocos MobileViT	Acurácia de 0,932 e F1 de 0,931 (ISIC-2018)
Kabir et al. (2025)	Classificação (câncer oral)	Bloco SE e codificador MobileViT	Acurácia de 98,39% (981 imagens após aumento de dados)
Zou et al. (2023)	Classificação (ultrassom de mama)	ResNet e MobileViT com dupla entrada e perda guiada por GAP	Superior a alguns métodos do estado da arte (BUSI e BUSC)
Wang et al. (2026)	Classificação (microscopia multiespectral)	MobileViT otimizada com perda focal ponderada	MobileViT com a maior acurácia entre cinco arquiteturas (91,70%)
Ma et al. (2026)	Segmentação (múltiplas modalidades)	Ramos paralelos Mamba e CNN	40 e 345 vezes menos parâmetros que U-Net e U-Mamba
Garbaz et al. (2025)	Segmentação (endoscopia e dermatoscopia)	Convolução em grupos e autoatenção em paralelo	Dice de 91,6%, 94,61% e 82,24%
Kabir et al. (2026)	Classificação (câncer oral)	CNN com três ramos paralelos e otimização por GWO	Acurácia de 99,64% (240 imagens)
Sharma, Singh & Choudhury (2025)	Classificação (mamografia)	Comparação de 15 modelos (CNNs, ViT e modelos específicos)	Modelos específicos superaram os de propósito geral (ViT-Mammo, AUC de 0,961)

3.5 FUSÃO TARDIA E MLP

4 METODOLOGIA

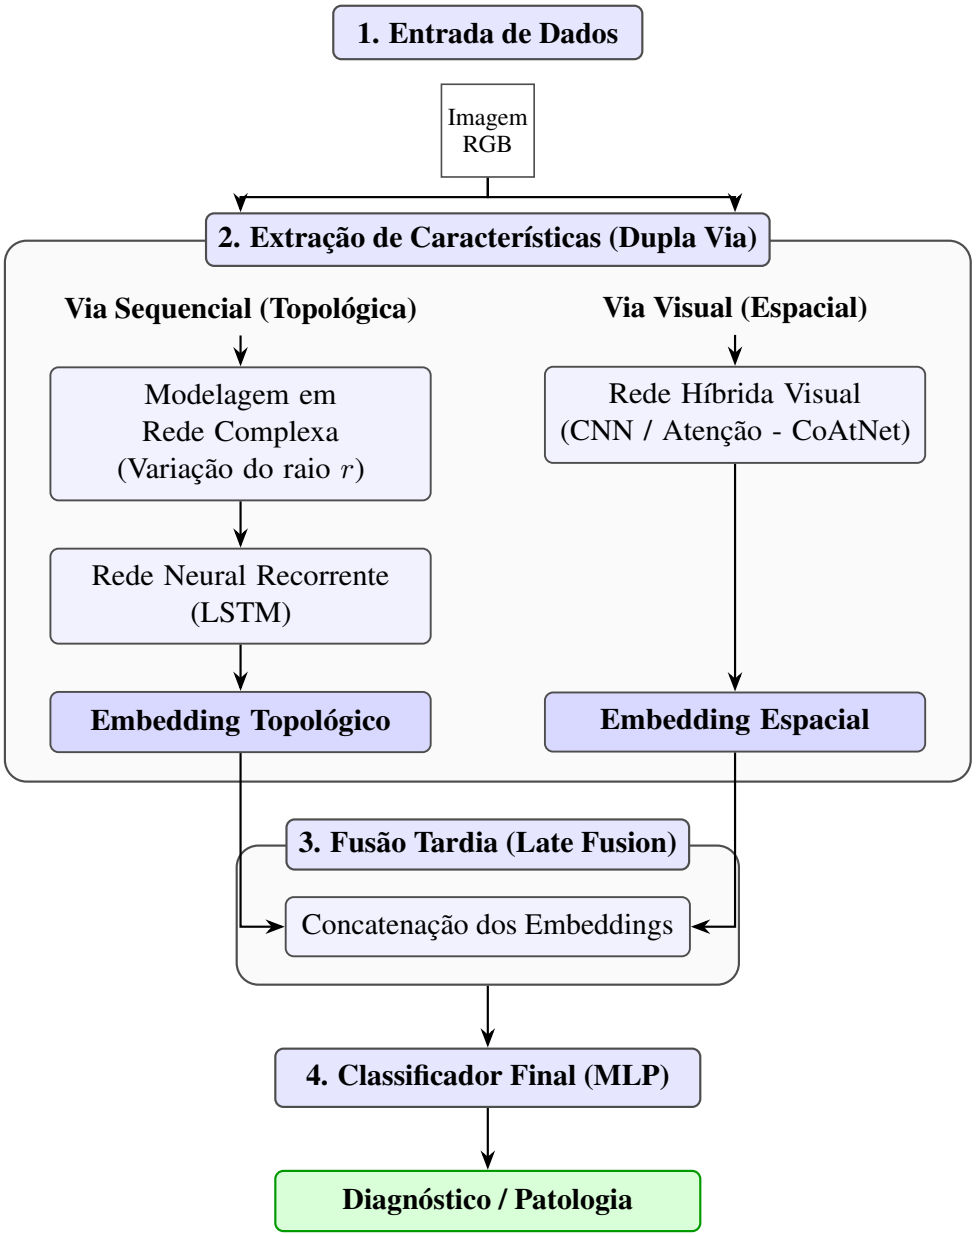


Figura 1 – Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM.

5 RESULTADOS E DISCUSSÃO

6 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006. ISSN 0370-1573.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DAI, Z. et al. Coatnet: Marrying convolution and attention for all data sizes. **Advances in neural information processing systems**, v. 34, p. 3965–3977, 2021.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

EULER, L. Solutio problematis ad geometriam situs pertinentis. **Commentarii academiae scientiarum imperialis Petropolitanae**, v. 8, p. 128–140, 1736.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

JESWANI, U.; PRIYADHARSHINI, S. Exploring facial feature extraction and temporal dynamics for deepfake video detection: A CNN-RNN study on FaceForensics++. In: **2026 International Conference on Innovative Trends in Information Technology (ICITIIT)**. [S.l.: s.n.], 2026.

JUN, K. et al. Feature extraction using an RNN autoencoder for skeleton-based abnormal gait recognition. **IEEE Access**, v. 8, p. 19196–19207, 2020.

KABIR, M. F. et al. Accurate and lightweight oral cancer detection using SE-MobileViT on clinically validated image dataset. **Discover Artificial Intelligence**, v. 5, n. 173, 2025.

KABIR, M. F. et al. TriGWONet: A lightweight multibranch convolutional neural network using gray wolf optimization for accurate oral cancer image classification. **Discover Artificial Intelligence**, v. 6, n. 91, 2026.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PEREZ, L.; WANG, J. The effectiveness of data augmentation in image classification using deep learning. **arXiv preprint arXiv:1712.04621**, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

S, M. N.; DHARAN, S. Multi-modal biometric authentication using attention based RNN feature extraction and walrus-assisted sculptor optimized fusion. In: **2025 IEEE 17th International Conference on Computational Intelligence and Communication Networks (CICN)**. [S.l.: s.n.], 2025. p. 973–979.

SCABINI, L. et al. Complex networks for modeling texture and spectral features of hyperspectral images for environmental analysis. **Computers in Biology and Medicine**, v. 204, p. 111504, 2026.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHARMA, S.; SINGH, Y.; CHOUDHURY, T. Advanced deep learning architectures for enhanced mammography classification: A comparative study of CNNs and ViT. **Discover Artificial Intelligence**, v. 5, n. 187, 2025.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on image data augmentation for deep learning. **Journal of big data**, Springer, v. 6, n. 1, p. 1–48, 2019.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

WANG, C. et al. Research on tissue section negative detection algorithm based on multispectral microscopic imaging. **Journal of Innovative Optical Health Sciences**, v. 19, n. 2, p. 2550035, 2026.

WANG, L.; HE, D.-C. Texture classification using texture spectrum. **Pattern Recognition**, Pergamon Press, v. 23, n. 8, p. 905–910, 1990.

WU, D. Statistical feature extraction and classification of complex data based on deep learning. In: **2024 3rd International Conference on Artificial Intelligence and Autonomous Robot Systems (AIARS)**. [S.l.: s.n.], 2024. p. 755–760.

YE, M. et al. Feature selection and extraction in sequence labeling for arrhythmia detection. In: **2021 International Balkan Conference on Communications and Networking (BalkanCom)**. [S.l.: s.n.], 2021. p. 107–111.

ZAIDKILANI, N.; GARCIA, M. A.; PUIG, D. Dual-stream CoAtNet models for accurate breast ultrasound image segmentation. **Neural Computing and Applications**, v. 36, p. 16427–16443, 2024.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHAO, C. et al. MMS-Net: Multi-level multi-scale feature extraction network for medical image segmentation. **Biomedical Signal Processing and Control**, v. 86, p. 105330, 2023.

ZHI, R.; WAN, M. Dynamic facial expression feature learning based on sparse RNN. In: **2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. [S.l.: s.n.], 2019. p. 1373–1377.

ZOU, X. et al. Improved breast ultrasound tumor classification using dual-input CNN with GAP-guided attention loss. **Mathematical Biosciences and Engineering**, v. 20, n. 8, p. 15244–15264, 2023.