UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr.Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr.Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Entropias de Shannon e amostral em função do raio de conexão (1 a 15) para as bases CR, LA, LG, NHL e UCSB. As linhas tracejadas correspondem a cada base e as linhas contínuas, à média entre as bases. 21

Figura 2 Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM. 28

Figura 3 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 29

Figura 4 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 30

Figura 5 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 30

Figura 6 Imagens de cada gênero dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 30

Figura 7 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 31

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 29

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RGB	*Red, Green, Blue*
ViT	*Vision Transformer*

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 13

2 OBJETIVOS 16

3 FUNDAMENTAÇÃO TEÓRICA 17
3.1 Extração de *Features* 17
3.1.1 Descritores clássicos (*handcrafted*) 17
3.1.2 Extração por aprendizado profundo 18
3.2 Redes Complexas 18
3.2.1 Modelagem da imagem como rede direcionada 19
3.2.2 Medidas topológicas e configurações da rede 19
3.3 Redes Neurais Recorrentes na Extração de *Features* Topológicas 21
3.3.1 Redes recorrentes e *embedding* topológico 22
3.3.2 Redes recorrentes sobre *features* de imagens e escolha da arquitetura . . 23
3.4 Redes Híbridas para Extração de *Features* Visuais 24
3.4.1 Estratégias de integração entre convolução e atenção 24
3.4.2 MobileViT: o extrator adotado 25
3.4.3 Evidências comparativas e *embedding* visual 25
3.5 Fusão por Concatenação de *Embeddings* e MLP 26
3.5.1 Evidências sobre estratégias de fusão em redes de dupla via 26
3.5.2 Concatenação, classificador MLP e ressalvas 27

4 MATERIAIS E MÉTODOS 28
4.1 *Datasets* 29
4.2 *Two-Stream Network* 31
4.2.1 Extração de *features* texturais 31
4.2.2 Extração via MobileViT 32
4.2.3 Fusão Tardia 33
4.2.4 Classificador MLP 33
4.3 Protocolo de treinamento 34
4.3.1 Métricas 34
4.4 Configuração de ambiente 35

5 RESULTADOS E DISCUSSÃO 36

6 CONCLUSÃO 37

REFERÊNCIAS 38

1 INTRODUÇÃO

A histopatologia é responsável pelo diagnóstico precoce de patologias de tecidos agressivas, como cânceres e doenças autoimunes, infecciosas e degenerativas. Os diagnósticos são realizados, em geral, manualmente por patologistas, em um processo que envolve a extração de tecidos biológicos, a coloração por reagentes químicos para realçar o contraste das estruturas celulares e a investigação microscópica por especialistas. Esse processo é custoso e pode ser acelerado por computadorização (Talo, 2019). A falta de padronização entre laboratórios, a necessidade de anotação exaustiva das imagens e as restrições éticas e de privacidade dificultam ainda a construção de grandes bases de imagens para modelos de aprendizado profundo (*Deep Learning*, DL) (Kumar; Mishra, 2026). Para viabilizar a aplicação de DL nesse cenário, técnicas como transferência de aprendizado, aumento de dados e extração de *features* foram adotadas na literatura, e em determinados casos os modelos superaram patologistas na classificação de tecidos (Bejnordi et al., 2017).

O DL foi difundido pela ampla utilização das *Convolutional Neural Networks* (CNNs) em tarefas de visão computacional, como segmentação e classificação de imagens (Kumar; Mishra, 2026). Essas redes são compostas por camadas de convolução e de *pooling*, que reduzem a resolução das imagens e realizam a classificação principalmente a partir de informações locais. As arquiteturas *Vision Transformer* (ViT) empregam mecanismos de auto-atenção para capturar o contexto global das imagens (Hussaini et al., 2026). Os modelos híbridos CNN-ViT unem a localidade das redes convolucionais ao contexto de longa distância dos modelos baseados em atenção e foram aplicados na classificação de imagens médicas com ganhos de desempenho (Hussaini et al., 2026). A dificuldade de convergência do treinamento com poucas amostras permanece mesmo com a evolução das topologias de rede, e em imagens histológicas a extração de características de textura é uma estratégia comum para contornar essa restrição.

Nas imagens histológicas, a disposição de núcleos, citoplasma e matriz extracelular produz padrões de textura que diferenciam tecidos normais e patológicos, e a extração de *features* é, por esse motivo, uma etapa da classificação desses tecidos. Descritores clássicos como GLCM (Haralick; Shanmugam; Dinstein, 1973), LBP (He; Wang, 1989; Wang; He, 1990) e HOG (Dalal; Triggs, 2005) são empregados com classificadores tradicionais e, mais recentemente, foram comparados e combinados com representações aprendidas por redes profundas em imagens médicas (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025; Shorfuzzaman et al., 2026). Esses descritores são calculados sobre vizinhanças de tamanho fixo e não descrevem de forma explícita a organização do tecido em diferentes escalas.

As Redes Complexas (*Complex Networks*, CN) permitem descrever a textura em múltiplas escalas. Na transformação de uma imagem em CN, os pixels são modelados como vértices e as conexões entre eles são definidas por um raio de distância. A variação desse raio produz uma sequência de redes cada vez mais abrangentes, das quais são extraídas medidas topológicas

(Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Zerati et al., 2026). Em raios pequenos, as medidas descrevem a organização local dos pixels e, em raios maiores, descrevem o tecido em escalas mais amplas. Como as redes de raios maiores incluem as conexões das redes de raios menores, a organização em larga escala depende da organização local, e os descritores obtidos formam uma sequência com dependência histórica entre seus elementos.

O processamento dessa sequência exige um modelo que preserve a informação dos raios anteriores. As Redes Neurais Recorrentes (*Recurrent Neural Networks*, RNNs) atendem a esse requisito, pois o estado interno é atualizado a cada elemento processado e acumula a informação dos elementos precedentes (Hochreiter; Schmidhuber, 1997). Cada raio processado contribui, dessa forma, para um estado que resume a evolução da topologia da imagem. As RNNs foram utilizadas como extratoras de *features* em dados sequenciais de diferentes domínios, como marcha, expressões faciais, sinais cardíacos e vídeos (Jun et al., 2020; Zhi; Wan, 2019; Ye et al., 2021; Jeswani; Priyadharshini, 2026). Na área médica, foram aplicadas na detecção de câncer de pulmão e de medula óssea (Mathiyalagi; Ravi, 2026; Priyadarshini, 2026) e em imagens histopatológicas de mama (Shalini; Rathnamala, 2026).

As *features* de textura podem ser combinadas com o vetor gerado ao final de um classificador visual, e a partir desses dois *embeddings* a fusão tardia (*Late Fusion*) pode ser realizada. Nessa estratégia, cada via é processada por um extrator próprio e as representações são unidas após a extração, enquanto a fusão precoce combina as informações antes do processamento (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017). As arquiteturas de dupla via (*Two-Stream Networks*) foram propostas para processar fontes distintas em paralelo (Simonyan; Zisserman, 2014) e aplicadas na classificação de vídeos (Yousaf; Nawaz; Habib, 2024) e no reconhecimento de imagens por vias de forma e de textura (Wang et al., 2023).

Na histopatologia, a fusão tardia foi aplicada para combinar colorações e dados genômicos (Brussee et al., 2025), e a concatenação das características de uma CNN e de um ViT em imagens de mama superou cada rede isolada (Kushwah; Punn; Bhattacharya, 2026). A combinação de descritores clássicos de textura com características profundas também apresentou ganhos em imagens de próstata (Huang et al., 2022) e de carcinoma oral (Li, 2025), e a combinação das probabilidades de uma CNN com as de classificadores treinados sobre descritores clássicos elevou o desempenho em imagens de cólon (Moldovanu et al., 2026). A fusão tardia por concatenação de *embeddings* é adequada ao presente trabalho porque as duas vias possuem naturezas distintas, uma baseada na imagem e outra em uma sequência de descritores, e a concatenação permite que cada uma seja processada por um extrator próprio antes da camada de decisão, responsável por combinar os dois *embeddings*.

Nos trabalhos citados, a combinação de representações de naturezas distintas melhorou a classificação de imagens médicas, e nenhum deles combina a sequência de descritores topológicos gerada por CN, processada por uma RNN, com a representação visual de uma rede híbrida. As duas vias descrevem o tecido de formas distintas, a primeira pela organização dos pixels em diferentes raios de conexão e a segunda pelo conteúdo visual aprendido pela rede. A combinação

é motivada também pela escassez de imagens histopatológicas anotadas, que torna necessário extrair a maior quantidade possível de informação de cada amostra disponível (Kumar; Mishra, 2026).

A partir dessa lacuna, a questão de pesquisa investigada neste trabalho é: a sequência de descritores topológicos multiescala de CN, processada por uma RNN e fundida tardiamente com a representação visual de uma rede híbrida CNN-ViT, melhora a classificação de imagens histopatológicas em relação aos descritores de textura de vizinhança fixa? A hipótese adotada é que a evolução das medidas topológicas ao longo dos raios de conexão, processada sequencialmente por uma RNN bidirecional (BiLSTM), capta padrões de organização do tecido que os descritores de vizinhança fixa não representam, e que esses padrões acrescentam informação à representação visual da rede híbrida.

As contribuições deste trabalho são:

- A modelagem de imagens histopatológicas coloridas como CN, com a variação do raio de conexão entre os pixels gerando uma sequência de descritores topológicos.
- O uso de uma RNN como extratora de *features* dessa sequência, gerando um *embedding* topológico do tecido.
- O desenvolvimento de uma arquitetura de dupla via, na qual o *embedding* topológico e o *embedding* visual extraído pela MobileViT (Mehta; Rastegari, 2022) são combinados por fusão tardia, por meio de concatenação e de uma MLP.
- A avaliação da arquitetura em bases de dados histopatológicas públicas, em comparação com os descritores GLCM, LBP e HOG.

O restante do documento está organizado em quatro capítulos. A fundamentação teórica (Capítulo 2) aborda os conceitos de CN, RNNs, redes híbridas CNN-ViT e fusão tardia, a metodologia (Capítulo 3) descreve as bases de dados, a arquitetura proposta e o protocolo experimental, os resultados são apresentados e discutidos no Capítulo 4, e as conclusões e os trabalhos futuros são apresentados no Capítulo 5.

2 OBJETIVOS

Este trabalho tem como objetivo geral explorar a utilização de imagens histopatológicas artificiais geradas por redes complexas para criar um *embedding* topológico por meio de uma RNN e uni-lo, por fusão tardia (*feature-level fusion*), a um *embedding* espacial oriundo de uma rede híbrida, investigando se essa técnica de análise topológica e espacial conjunta supera métodos consolidados na literatura.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- Modelar as imagens histopatológicas como redes complexas, variando o raio de conexão para gerar uma sequência de transformações que capture a evolução estrutural e multiescala do tecido celular.
- Implementar e treinar uma Rede Neural Recorrente (LSTM/RNN) capaz de processar a sequência temporal de imagens transformadas para extrair o *embedding* topológico profundo.
- Configurar e treinar a via espacial baseada em uma arquitetura híbrida para processar as imagens microscópicas originais, extraindo um *embedding* espacial focado em características visuais e morfológicas de textura.
- Desenvolver um módulo de fusão tardia para concatenar os *embeddings* espacial e topológico, submetendo o vetor unificado a uma rede perceptron de múltiplas camadas (MLP) para a classificação final.
- Avaliar e validar o desempenho do modelo *Two-Stream* proposto em conjuntos de dados histopatológicos, comparando sua precisão, sensibilidade e robustez frente a arquiteturas de linha de base (*baselines*) consolidadas na literatura.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* é uma medida numérica que representa uma propriedade da imagem, como textura, forma, bordas ou cor. A extração de *features* transforma os pixels em uma representação que pode ser utilizada por um classificador (Ramos-Soto et al., 2025). Em imagens médicas, essas medidas descrevem propriedades como a forma, o tamanho, a textura e a intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A representação pode ser definida por regras matemáticas ou aprendida a partir dos dados, e essa distinção é relevante em bases médicas pequenas, nas quais a disponibilidade de imagens rotuladas é limitada por custos de aquisição, privacidade e necessidade de especialistas (Litjens et al., 2017).

3.1.1 Descritores clássicos (*handcrafted*)

Os descritores clássicos (*handcrafted*) são calculados por regras matemáticas definidas previamente, sem ajuste a partir dos dados. Entre os métodos empregados em imagens médicas estão as estatísticas de primeira ordem, a matriz de coocorrência de níveis de cinza (GLCM), os padrões binários locais (LBP), o histograma de gradientes orientados (HOG), os filtros de Gabor e o SIFT (Ramos-Soto et al., 2025; Ahmed et al., 2023). Neste trabalho, GLCM, LBP e HOG são utilizados como métodos de comparação com a abordagem proposta (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025).

Haralick, Shanmugam & Dinstein (1973) propuseram caracterizar a textura de um bloco de imagem por matrizes de dependência de tons de cinza, hoje conhecidas como GLCM. Cada elemento (i, j) da matriz registra quantas vezes um pixel de tom i ocorre como vizinho de um pixel de tom j, dada uma distância d e uma direção angular (0°, 45°, 90° ou 135°). A partir da matriz normalizada, os autores definiram 14 medidas de textura, entre elas o contraste, a correlação, a variância e a entropia, que foram utilizadas como entradas de classificadores em fotomicrografias, fotografias aéreas e imagens de satélite. Como limitações, He & Wang (1989) apontam que a matriz depende da variação regional do fundo de intensidade da imagem e que a escolha do vetor de deslocamento é problemática.

O espectro de textura, proposto por He & Wang (1989) a partir do conceito de unidade de textura, codifica cada um dos oito vizinhos de um pixel central em um de três valores (0, 1 ou 2), conforme sua relação de intensidade com o pixel central, o que resulta em $3^8 = 6561$ unidades de textura possíveis. A distribuição de frequência dessas unidades ao longo da imagem funciona como descritor, e a redução das intensidades a três valores diminui o custo de cálculo e elimina a influência do fundo regional de intensidade e do ruído (Wang; He, 1990). O LBP mantém a ideia

de codificar a relação entre o pixel central e seus vizinhos, com codificação binária e descrição da imagem pelo histograma dos códigos.

O HOG foi proposto por Dalal & Triggs (2005) para detecção de pessoas e descreve a imagem pela distribuição local das direções de gradiente. A janela é dividida em células, e cada célula acumula um histograma das orientações de gradiente ponderadas pela magnitude. Os histogramas são normalizados em blocos sobrepostos para reduzir a sensibilidade ao contraste e à iluminação. A concatenação dos histogramas forma o descritor, que alimentou uma máquina de vetores de suporte (SVM) linear e reduziu as taxas de falsos positivos em relação ao melhor detector baseado em *wavelets* de Haar (Dalal; Triggs, 2005). Apesar de concebido para detecção, o HOG é empregado como descritor de bordas e forma em imagens médicas (Ramos-Soto et al., 2025).

3.1.2 Extração por aprendizado profundo

Os descritores *handcrafted* capturam relações locais entre pixels, em escalas e vizinhanças definidas previamente. As redes neurais convolucionais (CNNs), em contraste, aprendem filtros que vão de bordas e texturas nas primeiras camadas até padrões semânticos nas camadas finais, e são amplamente utilizadas em análise de imagens médicas (Litjens et al., 2017). Em domínios com poucos dados, a transferência de aprendizado (*transfer learning*) permite empregar uma rede pré-treinada em uma base grande, como a ImageNet, como extrator de *features*, e a ativação de uma camada intermediária ou final é utilizada como vetor de características. Em Dehbozorgi, Ryabchykov & Bocklitz (2025), cinco redes pré-treinadas (VGG16, ResNet50, DenseNet121, MobileNetV2 e InceptionV3) em geral superaram os métodos estatísticos e de *radiomics* em sensibilidade e em tempo de extração. Os autores apontam como limitações a necessidade de GPUs, a dependência de grandes bases de dados e a baixa interpretabilidade.

As CNNs aprendem filtros a partir dos exemplos, enquanto os *Vision Transformers* (ViT) representam a imagem como uma sequência de *patches* e utilizam autoatenção para modelar relações entre regiões (Dosovitskiy et al., 2020; Shamshad et al., 2023). Em bases médicas pequenas, o ajuste de modelos com muitos parâmetros pode favorecer o sobreajuste. O MIAFEx (Ramos-Soto et al., 2025), por exemplo, modifica o *token* de classificação de um *Transformer* por meio de pesos aprendíveis e superou extratores clássicos, CNNs e ViTs em conjuntos pequenos, com vantagem reduzida à medida que os dados aumentaram. A variação de tamanho e aparência das estruturas também motiva métodos multiescala, e a MMS-Net (Zhao et al., 2023) combinou informações locais e globais e manteve resultados competitivos com uma fração dos dados de treinamento. Neste trabalho, a abordagem multiescala é aplicada à via topológica, na qual os descritores são calculados para raios de conexão crescentes (Seção 3.2) e a sequência resultante é processada por uma rede recorrente (Seção 3.3).

3.2 REDES COMPLEXAS

A teoria de Redes Complexas (CN, do inglês *Complex Networks*) é uma abstração para modelar sistemas naturais cujos elementos interagem de maneira não trivial (Boccaletti et al., 2006). Essas redes foram empregadas para modelar os pixels de uma imagem e suas relações de vizinhança, e descritores baseados em topologia quantificam propriedades de textura a partir dessa modelagem (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). Neste trabalho, a transformação segue a abordagem de Zerati et al. (2026) e é aplicada a imagens histopatológicas.

3.2.1 Modelagem da imagem como rede direcionada

Cada imagem é representada como uma CN direcionada e ponderada $G = (V, E)$, na qual cada pixel é modelado como um vértice e as conexões entre pixels são estabelecidas dentro de um raio máximo r_{max}. Para um pixel $i = (x_i, y_i)$ em um canal de cor c da imagem I, é definido um vértice $v_i^{(c)} \in V$. Uma aresta direcionada é criada entre os vértices $v_i^{(c)}$ e $v_j^{(c_w)}$, em que c e c_w são os canais de cor do primeiro e do segundo pixel, quando a distância euclidiana quadrática entre os pixels satisfaz a Equação 1:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 < \rho_{ij}^2 \leq r_{max}^2, \tag{1}$$

em que x e y são as coordenadas dos pixels e ρ_{ij} é a distância euclidiana entre eles. A condição $\rho_{ij}^2 > 0$ exclui laços, isto é, a conexão de um pixel consigo mesmo. Cada aresta é associada a um raio discreto $r \in \{1, 2, \ldots, r_{max}\}$, definido como o menor inteiro que satisfaz $(r-1)^2 < \rho_{ij}^2 \leq r^2$, o que permite acumular as medidas da rede progressivamente sobre vizinhanças cada vez maiores.

O peso atribuído a cada aresta é a diferença absoluta de intensidade entre os pixels conectados, conforme a Equação 2:

$$w_{ij} = \left| I(x_i, y_i, c) - I(x_j, y_j, c_w) \right|. \tag{2}$$

A direção de cada aresta é determinada pelas intensidades dos pixels conectados, do pixel de menor intensidade para o de maior intensidade. Quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$, a conexão é classificada como de saída (*out*) a partir de v_i e de entrada (*in*) em v_j. No caso contrário, ela é classificada como de entrada em v_i. Conexões entre pixels de mesma intensidade são contabilizadas em ambas as direções. O grau de saída de um vértice conta seus vizinhos mais claros, e o grau de entrada conta seus vizinhos mais escuros.

3.2.2 Medidas topológicas e configurações da rede

O grau (*degree*) e a força (*force*) são calculados para cada vértice pela acumulação das quantidades correspondentes até o raio r, nas versões de saída e de entrada. O grau quantifica o

número de conexões dentro da vizinhança considerada, como na Equação 3:

$$d_{out}(v_i, r) = \sum_{k=1}^{r} n_{out}(v_i, k), \tag{3}$$

em que $n_{out}(v_i, k)$ é o número de arestas de saída de v_i cujo raio discreto vale k, e o grau de entrada, $d_{in}(v_i, r)$, é calculado de forma análoga a partir de $n_{in}(v_i, k)$. A força incorpora as diferenças de intensidade e a proximidade entre os pixels, o que a torna sensível aos gradientes locais de textura. Para uma rede construída com raio r, cada aresta (v_i, v_j) recebe um peso de força que combina a diferença de intensidade normalizada com a distância normalizada, conforme a Equação 4:

$$\omega_{ij}^{(r)} = \begin{cases} \dfrac{w_{ij}}{2L}, & r = 1, \\ \dfrac{1}{2}\left[\dfrac{w_{ij}}{L} + \dfrac{\rho_{ij}^2 - 1}{r^2 - 1}\right], & r \geq 2, \end{cases} \tag{4}$$

em que $L = 255$ é o nível máximo de intensidade para imagens de 8 bits e w_{ij} é o peso dado pela Equação 2. A força de saída acumulada é dada pela Equação 5:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{5}$$

em que $\mathcal{N}_{out}^{(r)}(v_i)$ é o conjunto de vértices conectados a v_i por arestas de saída com $\rho_{ij}^2 \leq r^2$, e force$_{in}$ é definida de forma análoga sobre as arestas de entrada. O fator $r^2 - 1$ na Equação 4 é o valor máximo de $\rho_{ij}^2 - 1$ dentro de uma vizinhança de raio r, o que mantém o termo de distância no intervalo $[0, 1]$. Para $r = 1$, a única distância quadrática possível é $\rho_{ij}^2 = 1$, de modo que o termo de distância é nulo e o fator $r^2 - 1$ anularia o denominador, e nesse caso o peso é reduzido à componente de intensidade. As medidas resultam em quatro grandezas por vértice: grau de saída, grau de entrada, força de saída e força de entrada.

Para estender as medidas aos três canais de cor das imagens histopatológicas RGB, as formulações anteriores podem ser aplicadas em três configurações de rede (Scabini; Ribas; Bruno, 2020): *within-channel*, com $c = c_w$, *between-channel*, com $c \neq c_w$, e *full*, que inclui simultaneamente conexões intracanal e intercanal. A configuração *full* é adotada neste trabalho para capturar conjuntamente as transições de intensidade e as relações cromáticas entre canais (Zerati et al., 2026). A rede é construída sobre a imagem em inteiros de 8 bits, antes da normalização aplicada à via visual, pois os pesos e as direções das arestas dependem da comparação de intensidades inteiras, inclusive dos empates. O redimensionamento das imagens altera a textura em nível de pixel, e a etapa em que é aplicado é descrita na metodologia.

O raio máximo foi definido por uma heurística baseada na distribuição das medidas topológicas. Raios entre 1 e 15 foram avaliados em todas as bases de dados, em um intervalo definido a

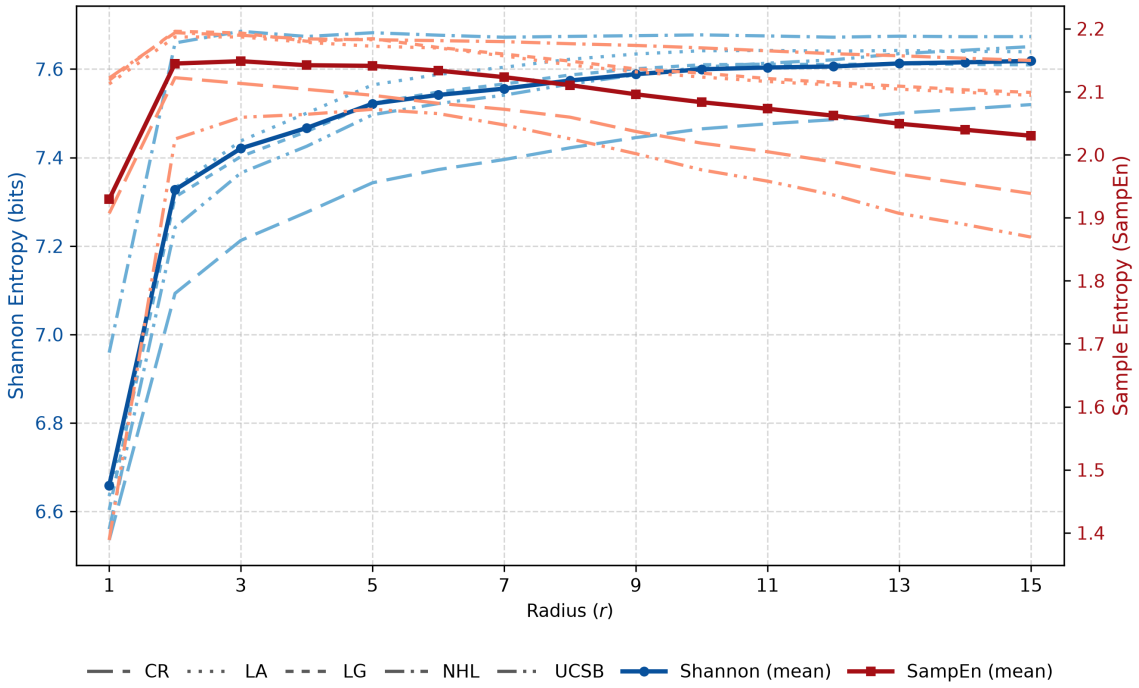


Figura 1 – Entropias de Shannon e amostral em função do raio de conexão (1 a 15) para as bases CR, LA, LG, NHL e UCSB. As linhas tracejadas correspondem a cada base e as linhas contínuas, à média entre as bases.

partir de valores explorados na literatura (Zerati et al., 2026; Scabini et al., 2026). A entropia de Shannon da distribuição dos valores topológicos cresceu até aproximadamente $r = 10$ e atingiu um platô a partir daí, e a entropia amostral teve pico em $r = 10$ e decresceu depois, conforme a Figura Figura 1. Como a entropia da distribuição das medidas não é um critério de classificação, $r_{max} = 10$ constitui uma escolha heurística, apoiada em achados anteriores de que combinações multiescala de raios são úteis (Ribas et al., 2024; Zerati et al., 2026), e a sensibilidade a esse valor é verificada pela comparação de diferentes valores de R na via topológica isolada. À medida que r cresce, as características locais dos menores raios dão lugar a características progressivamente mais globais, e a evolução ao longo dos raios forma a sequência processada pela via recorrente (Seção 3.3).

3.3 REDES NEURAIS RECORRENTES NA EXTRAÇÃO DE *FEATURES* TOPOLÓGICAS

Na arquitetura proposta, a via sequencial, baseada em uma Rede Neural Recorrente (RNN, do inglês *Recurrent Neural Network*), transforma a evolução topológica da imagem, modelada como CN (Seção 3.2), em um *embedding* topológico que é combinado com o *embedding* visual na fusão por concatenação (Seção 3.5). A *Spatio-Spectral Network* depende de um conjunto de raios (Scabini; Ribas; Bruno, 2020), e Ribas et al. (2024) exploraram essa dimensão. As medidas topológicas de cada vértice (grau de saída, força de entrada e força de saída) foram calculadas em vários raios $r = \{1, 2, \ldots, R\}$, e os valores obtidos em $r = 1, \ldots, R - 1$ formaram um

vetor de entrada usado para prever o valor da mesma medida no raio máximo R. Os autores descrevem esse procedimento como uma análise multiescala da evolução topológica dos vértices, e a maior acurácia média nos três conjuntos de textura colorida foi obtida pela combinação de duas representações, com $R = 4$ e $R = 10$, o que indica que as escalas locais e as mais amplas contribuem para a discriminação.

A proposta deste trabalho difere no tratamento da sequência. Em Ribas et al. (2024), a sequência de raios é achatada em um único vetor de entrada de uma rede neural aleatorizada de uma camada oculta, e o descritor da imagem são os pesos da camada de saída, calculados por mínimos quadrados regularizados. O artigo utiliza a sigla RNN para essa rede, que não é recorrente, pois os valores de cada raio entram simultaneamente e a arquitetura não explora a ordem entre eles. Neste trabalho, a sigla RNN designa exclusivamente a rede recorrente. A sequência de raios é tratada como tal, com $R = r_{max} = 10$ passos, em que o passo t corresponde ao raio $r_t = t$. Uma série $x_1, x_2, \ldots, x_R$ é definida, em que $x_t \in \mathbb{R}^d$, com $d = 24$, reúne as medidas topológicas calculadas sobre a rede construída com o raio r_t, e a RNN lê a série passo a passo, do menor raio para o maior. Essa organização reflete a hipótese de que as macroestruturas da imagem dependem da organização das microestruturas, de modo que o descritor do raio r_t deve ser interpretado à luz do que foi observado nos raios anteriores.

As medidas são acumuladas ao longo dos raios e, por isso, crescem de forma monotônica com r, e valores de grau e de força atingem a ordem de centenas em $r = 10$, o que satura as portas da rede recorrente. Cada característica é padronizada, com média e desvio padrão ajustados apenas sobre os dados de treino de cada partição da validação cruzada. A diferença entre raios consecutivos constitui uma representação alternativa da sequência, que remove a monotonicidade das medidas acumuladas.

3.3.1 Redes recorrentes e *embedding* topológico

Uma RNN processa uma sequência um elemento por vez e mantém um estado interno que carrega informação sobre os elementos anteriores (LeCun; Bengio; Hinton, 2015). Na rede recorrente simples de Elman (1990), o estado oculto depende da entrada atual e do estado anterior, e os parâmetros são compartilhados entre os passos, de modo que sua quantidade não depende do comprimento da sequência. O treinamento por retropropagação enfrenta o desaparecimento ou a explosão dos gradientes à medida que o intervalo entre entrada e saída aumenta (Bengio; Simard; Frasconi, 1994), e a LSTM (Hochreiter; Schmidhuber, 1997) mitiga esse problema com uma célula de memória c_t controlada por portas. Na formulação usual, que inclui a porta de

esquecimento (Gers; Schmidhuber; Cummins, 2000), as atualizações são:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{6}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{7}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{8}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{9}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{10}$$

$$h_t = o_t \odot \tanh(c_t), \tag{11}$$

em que σ é a função sigmoide, $\odot$ denota o produto elemento a elemento e f_t, i_t e o_t são as portas de esquecimento, entrada e saída. A GRU (Cho et al., 2014) é uma alternativa com menos portas e menos parâmetros, e Greff et al. (2017) concluíram, em um estudo de larga escala com oito variantes da LSTM, que nenhuma melhorou significativamente a LSTM padrão, o que sustenta seu uso como ponto de partida.

A RNN unidirecional lê a sequência em um único sentido, e a RNN bidirecional (Schuster; Paliwal, 1997) utiliza duas redes independentes, uma lendo a sequência na ordem original e outra na ordem inversa, e combina seus estados:

$$h_t = \left[\overrightarrow{h}_t \,\|\, \overleftarrow{h}_t\right]. \tag{12}$$

Em classificação de fonemas por quadro, as redes bidirecionais superaram as unidirecionais e a LSTM superou as RNNs convencionais (Graves; Schmidhuber, 2005), e os trabalhos mais próximos da proposta que aplicam recorrência a sequências de características utilizam BiLSTM (Yousaf; Nawaz; Habib, 2024; Priyadarshini, 2026; Zeng et al., 2025). Na sequência de raios, a leitura no sentido direto acumula em cada passo a informação das escalas locais nas mais amplas, o que corresponde à hipótese de que a macroestrutura depende da microestrutura. A leitura no sentido inverso fornece a cada raio o acesso ao contexto das escalas mais amplas, e a contribuição dessa segunda direção é verificada por ablação contra a LSTM unidirecional.

A BiLSTM adotada possui uma camada, e a dimensão do estado oculto por direção é descrita na metodologia. Como a imagem inteira recebe um único rótulo, a rede opera no formato *many-to-one*, e o *embedding* topológico é definido como a concatenação dos estados finais de cada direção, $z_{\text{top}} = [\,\overrightarrow{h}_R \,\|\, \overleftarrow{h}_1]$. Esse vetor tem dimensão fixa, o que permite concatená-lo ao *embedding* visual (Seção 3.4). Diferentemente do descritor de Ribas et al. (2024), cujos pesos de saída são obtidos por mínimos quadrados sem retropropagação, os parâmetros da BiLSTM são aprendidos por gradiente a partir do rótulo da classe, em treinamento de ponta a ponta com o classificador da fusão, e o *embedding* é otimizado para a classificação.

3.3.2 Redes recorrentes sobre *features* de imagens e escolha da arquitetura

Embora a recorrência seja associada a sequências temporais, diversos trabalhos a aplicaram a *features* extraídas de imagens médicas, tratando-as como uma sequência ordenada. Shalini & Rathnamala (2026) organizaram *features* de imagens de histopatologia de mama em sequência para que a LSTM capture relações entre seus elementos que uma CNN, centrada em padrões locais, pode não explorar. Mathiyalagi & Ravi (2026) alimentaram uma CNN-LSTM com *features* de textura da GLCM reduzidas por análise de componentes principais, em tomografias de pulmão, e Akanksha et al. (2022) utilizaram *features* SIFT como entrada de uma RNN para classificar leucemia. Em outros casos, a sequência é formada por mapas de uma CNN, como em Zeng et al. (2025), em que uma BiLSTM modelou a relação entre fatias de tomografias de pulmão e sua remoção reduziu a acurácia na ablação. Fora de imagens, Lin et al. (2022) mostraram que diferentes comprimentos de sequência de entrada de uma LSTM contêm informações distintas e afetam a acurácia, o que é análogo à escolha do conjunto de raios, e Kang et al. (2024) integraram, por uma camada totalmente conectada, um ramo de convoluções dilatadas multiescala com BiLSTM e um ramo sobre informação de estrutura molecular, em uma organização de dupla via semelhante à proposta.

Os resultados muito altos reportados nesses trabalhos provêm, em geral, de conjuntos pequenos, de dados tabulares ou de protocolos com validação limitada, e constituem evidência de viabilidade e não de superioridade. Até onde foi possível verificar na literatura consultada, nenhum desses trabalhos constrói a sequência a partir de descritores topológicos de uma rede em raios crescentes, e a contribuição aqui proposta é essa organização, apoiada na formulação de Ribas et al. (2024). A literatura consultada também não traz comparação direta entre arquiteturas para esse tipo de sequência, e a escolha da BiLSTM se apoia nas evidências citadas sobre bidirecionalidade e em argumentos de plausibilidade. A GRU conta apenas com a referência original (Cho et al., 2014), sem evidência comparativa neste contexto, e é mantida como alternativa na ablação. Os *transformers* permitem modelar relações entre elementos da sequência (Khan et al., 2022), mas o treinamento a partir de pesos aleatórios pode exigir mais dados do que os disponíveis neste estudo (Dosovitskiy et al., 2020), e a via sequencial não dispõe de modelo pré-treinado para descritores topológicos, com bases médicas de dezenas a poucas centenas de imagens e conjuntos de raios curtos (valores de R entre 4 e 12 em Ribas et al. (2024)).

Fawaz et al. (2019) observam, em revisão de arquiteturas profundas para classificação de séries temporais, que as redes recorrentes raramente são usadas por serem projetadas para uma saída por instante, sofrerem com gradientes em séries longas e serem difíceis de paralelizar. Os dois primeiros motivos são atenuados neste trabalho, pois a rede opera no formato *many-to-one* e a sequência tem 10 passos, e a mesma revisão trata perceptrons multicamadas e CNNs como alternativas legítimas. A vantagem da recorrência é uma hipótese verificada por ablação da via topológica isolada, que compara a BiLSTM com a LSTM, a GRU, um perceptron multicamadas sobre o vetor achatado dos 240 valores (10×24) e uma CNN unidimensional sobre a sequência.

Se o perceptron multicamadas apresentar desempenho equivalente, esse resultado é reportado e a contribuição da recorrência não é sustentada.

3.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* VISUAIS

Na arquitetura proposta, a via visual extrai, diretamente da imagem RGB, o *embedding* visual que é combinado com o *embedding* topológico na fusão (Seção 3.5). As CNNs extraem padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de longo alcance (Ma et al., 2026). Os *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) abordam esse problema pela autoatenção sobre sequências de *patches* e são estudados em imagens médicas (Shamshad et al., 2023), mas a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). As arquiteturas híbridas combinam a captura de padrões locais das CNNs com a modelagem global dos *transformers*, em geral com blocos convolucionais que extraem informação localizada e mecanismos de atenção que integram o contexto global, o que é relevante em patologia computacional, em que a interpretação depende de detalhes morfológicos finos e de padrões em escala de tecido (Oliveira et al., 2025).

3.4.1 Estratégias de integração entre convolução e atenção

Oliveira et al. (2025) resumem duas taxonomias para a integração de CNNs e *transformers*, atribuídas a Kim et al. e a Khan et al. A primeira separa projetos paralelos, em que CNN e ViT operam de forma independente e têm suas saídas fundidas, de projetos sequenciais, em que as *features* de um módulo alimentam o outro. A segunda distingue a integração em camadas iniciais, em camadas laterais, sequencial, paralela, em bloco, hierárquica, baseada em atenção e por reforço de canais. Os próprios autores propõem uma taxonomia por tarefa, na qual as arquiteturas de classificação consistem em um codificador de *features*, um estágio de adaptação e um classificador final, organização que corresponde, neste trabalho, ao MobileViT como codificador e ao perceptron multicamadas (MLP) como classificador. No modelo proposto, a MobileViT integra convolução e atenção dentro do próprio extrator visual, e a combinação com a via topológica ocorre fora dele, na concatenação dos *embeddings*. Na revisão de escopo de Oliveira et al. (2025) sobre estudos de histopatologia, a maioria dos trabalhos adotou arquiteturas integradas ou sequenciais, e os autores apontam como limitações recorrentes a escassez de validação externa, o uso de bases pequenas e homogêneas, a predominância da validação por *holdout* e o uso restrito de técnicas de explicabilidade. Essas limitações são consideradas na interpretação dos resultados deste trabalho.

3.4.2 MobileViT: o extrator adotado

O extrator visual adotado é a MobileViT, proposta por Mehta & Rastegari (2022) para combinar operações convolucionais e autoatenção em uma arquitetura de baixo custo computacional, adequada a bases com 58 a 528 imagens. Em cada bloco MobileViT, uma convolução $n \times n$ seguida de uma convolução pontual 1×1 produz uma representação local da entrada. Essa representação é organizada em *patches*, processada por um *Transformer* e reorganizada no formato do mapa de características. O resultado é combinado com a representação local e processado por outra convolução, que integra as informações obtidas pelos dois tipos de operação (Ding et al., 2023). Os mapas resultantes incorporam informação local e global sem depender exclusivamente da autoatenção sobre todos os pixels (Mehta; Rastegari, 2022; Ding et al., 2023).

A MobileViT e suas variantes foram aplicadas em diferentes tarefas médicas, como classificação de lesões de pele, microscopia multiespectral de tecido, câncer oral e ultrassom de mama (Ding et al., 2023; Wang et al., 2026; Kabir et al., 2025; Zou et al., 2023). Esses estudos mostram que a arquitetura já foi aplicada a imagens médicas, mas não permitem antecipar seu desempenho nas bases avaliadas neste trabalho.

3.4.3 Evidências comparativas e *embedding* visual

Arquiteturas de ramos paralelos também são empregadas. No CIHM, a camada CiMC combina em paralelo um ramo de modelo de espaço de estados (Mamba), que captura dependências de longo alcance com complexidade linear, e um bloco convolucional, que extrai detalhes locais (Ma et al., 2026), e o GSAC-UFormer integra em paralelo convolução em grupos e autoatenção adaptada por CNN (Garbaz et al., 2025). Estudos comparativos indicam que o desempenho depende da adequação da arquitetura ao domínio e que há um compromisso entre acurácia e custo computacional (Sharma; Singh; Choudhury, 2025). Acurácias próximas de 100% em bases com poucas centenas de imagens (Kabir et al., 2025; Kabir et al., 2026) são tomadas neste trabalho como evidência de viabilidade e não como desempenho esperado, pois a ausência de validação externa limita a generalização dos resultados (Oliveira et al., 2025).

Para obter o *embedding* visual, a MobileViT-S processa a imagem redimensionada para 256×256 pixels, com a normalização da ImageNet, e a agregação global do mapa de características produz um vetor $z_{\text{vis}} \in \mathbb{R}^{640}$. A cabeça de classificação original é removida, e o vetor é utilizado como entrada visual da fusão. Os pesos pré-treinados são ajustados por *fine-tuning* para adaptar a representação à classificação histopatológica.

3.5 FUSÃO POR CONCATENAÇÃO DE *EMBEDDINGS* E MLP

A arquitetura proposta produz dois vetores antes da classificação: o *embedding* topológico z_{top}, gerado pela BiLSTM (Seção 3.3), e o *embedding* visual z_{vis}, extraído pela MobileViT (Seção 3.4). A literatura de aprendizado multimodal distingue estratégias que combinam as

representações antes da classificação daquelas que combinam as decisões de modelos independentes (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017). Na fusão em nível de características, os vetores são unidos antes de um classificador compartilhado. Na fusão em nível de decisão, cada via produz uma saída de classificação e os escores são combinados por regras como soma, produto, máximo ou voto majoritário (Kittler et al., 1998). A arquitetura deste trabalho utiliza a primeira estratégia, em que as características das duas vias são concatenadas e fornecidas a um único MLP.

Como a expressão *fusão tardia* é utilizada na literatura tanto para a concatenação de características (Nawaz et al., 2025) quanto para a combinação de decisões (Yousaf; Nawaz; Habib, 2024), este trabalho adota a denominação fusão por concatenação de *embeddings*. O modelo é treinado de ponta a ponta, de modo que as duas vias são ajustadas em conjunto, e a separação entre elas se limita à extração das representações, que possuem naturezas distintas, antes da camada de decisão.

3.5.1 Evidências sobre estratégias de fusão em redes de dupla via

Os trabalhos que compararam formas de combinar duas vias não apontam uma estratégia superior em todos os cenários. Em uma rede com EfficientNet-B7 e BiLSTM, Yousaf, Nawaz & Habib (2024) compararam fusão precoce, concatenação de características e média de escores, e a fusão precoce apresentou o pior desempenho, enquanto a concatenação e a média de escores obtiveram resultados próximos. Essa arquitetura, com extrator convolucional pré-treinado, recorrência e concatenação seguida de camadas totalmente conectadas, é a mais próxima da proposta, embora as sequências sejam de quadros de vídeo. Nawaz et al. (2025) justificam a concatenação pela limitação de dados, pois métodos como *bilinear pooling* e redes de autoatenção exigem camadas adicionais com muitos parâmetros e podem levar a sobreajuste, e o melhor resultado foi obtido com extratores congelados, embora as faixas de variação entre as partições se sobreponham. Peng et al. (2025) concatenaram estatísticas calculadas do sinal com *features* aprendidas em diagnóstico de falhas com poucas amostras, em uma organização análoga à proposta, pois os descritores topológicos também são calculados e não aprendidos pela rede. Em imagens médicas, Wang et al. (2023) concatenaram *features* de dois fluxos, de forma e de textura, seguidas de seleção por atenção de canal, com ganho sobre a rede de fluxo único. Em imagens de próstata, a concatenação de descritores clássicos de textura com características profundas superou o uso isolado de cada tipo (Huang et al., 2022). Alternativas com interação entre as vias durante a extração, por atenção cruzada ou bidirecional, trouxeram ganhos pequenos sobre a concatenação em segmentação (Sheng; He; Shi, 2026) e foram aplicadas a mapas densos dentro do codificador (Yang et al., 2026; Chen et al., 2025), o que difere da fusão de vetores globais.

3.5.2 Concatenação, classificador MLP e ressalvas

Dados os *embeddings* $z_{\text{top}} \in \mathbb{R}^{d_t}$ e $z_{\text{vis}} \in \mathbb{R}^{d_v}$, a concatenação forma o vetor conjunto

$$z = [\, z_{\text{top}} \,\|\, z_{\text{vis}} \,] \in \mathbb{R}^{d_t + d_v}, \tag{13}$$

que contém, lado a lado, a informação sobre a evolução topológica e sobre o aspecto visual da imagem. Os dois vetores têm origens e escalas diferentes. O estado oculto da LSTM é limitado ao intervalo $(-1, 1)$ pela tangente hiperbólica (Equação 11), e as ativações finais da rede visual não têm essa restrição, de modo que cada vetor passa por uma normalização de camada (*LayerNorm*) antes da concatenação. Como a dimensão do vetor visual ($d_v = 640$) pode superar a do vetor topológico, o vetor de maior dimensão tende a predominar na primeira camada do classificador, o que motiva projetar as duas vias para a mesma dimensão.

O perceptron multicamadas é uma rede *feedforward* em que cada camada aplica uma transformação afim seguida de uma não linearidade, treinada por retropropagação do erro (Rumelhart; Hinton; Williams, 1986), e redes desse tipo, com ao menos uma camada oculta, são aproximadores universais de funções sob condições gerais (Hornik; Stinchcombe; White, 1989). Com uma camada oculta, o classificador é dado por

$$h = \mathrm{ReLU}(W_1 z + b_1)\,, \tag{14}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{15}$$

em que $\hat{y}$ é o vetor de probabilidades sobre as classes e os pesos são ajustados pela minimização da entropia cruzada, $\mathcal{L} = -\sum_c y_c \log \hat{y}_c$. O número de parâmetros da primeira camada é proporcional ao produto de $d_t + d_v$ pela dimensão da camada oculta, o que exige atenção em conjuntos com dezenas a poucas centenas de imagens. A literatura consultada adota cabeças de tamanhos diversos, de uma única camada (Nawaz et al., 2025) a duas camadas totalmente conectadas, a primeira com 1024 unidades (Yousaf; Nawaz; Habib, 2024). O *dropout*, que desativa aleatoriamente unidades durante o treinamento, é uma técnica de regularização contra o sobreajuste (Srivastava et al., 2014), e é aplicado na camada oculta.

Os estudos disponíveis não estabelecem uma estratégia de combinação superior em todos os cenários, e os resultados dependem do domínio e do protocolo experimental. Até onde foi possível verificar na literatura consultada, os trabalhos citados não avaliam a combinação de um vetor recorrente formado por descritores topológicos multiescala com um vetor visual extraído pela MobileViT. A eficácia dessa combinação é verificada experimentalmente por comparações com cada via isolada, com a concatenação do vetor visual a descritores clássicos (GLCM, LBP e HOG) processada pelo mesmo MLP, como em Huang et al. (2022), e com a fusão de escores utilizada por Yousaf, Nawaz & Habib (2024) e Nawaz et al. (2025). O protocolo de validação e as métricas são descritos no capítulo de metodologia.

4 MATERIAIS E MÉTODOS

As imagens utilizadas são oriundas de cinco *datasets* histopatológicos, os quais são descritos na Seção 4.1. Esses conjuntos formam a entrada da etapa de extração de características (Seção 4.2), que alimenta as vias topológica e visual da arquitetura proposta. Após a extração, é realizada uma concatenação dos vetores (Seção 4.2.3), que é utilizada em um classificador MLP (Seção 4.2.4) para a obtenção das métricas de classificação. O fluxo completo está apresentado na Figura Figura 2.

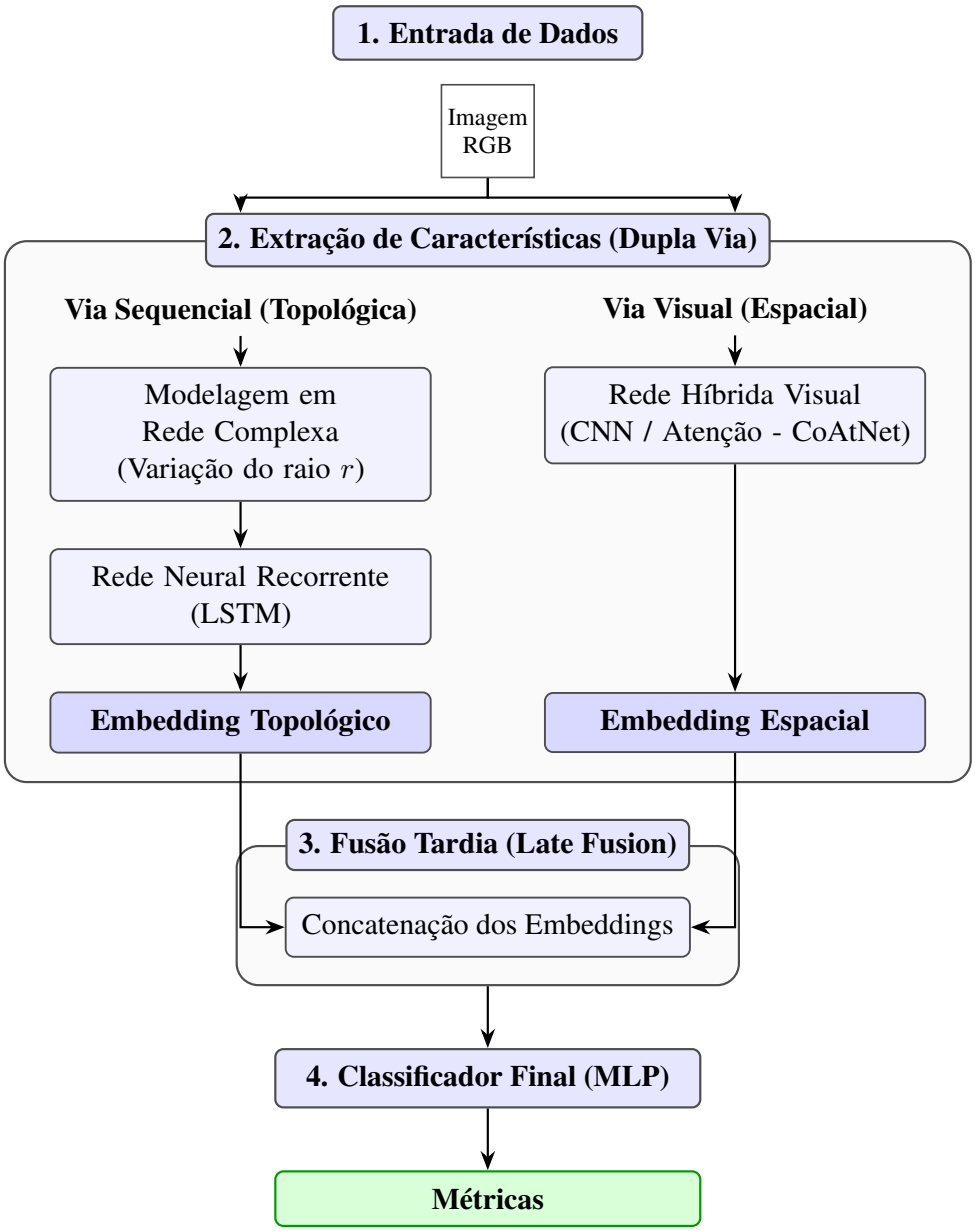


Figura 2 – Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM.

4.1 *DATASETS*

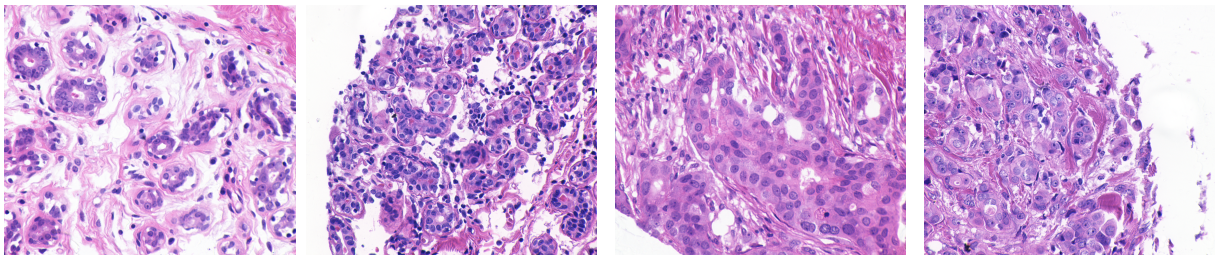
A avaliação foi realizada em *datasets* de imagens histopatológicas com 58 a 528 imagens cada. Os conjuntos abrangem tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, permitindo avaliar a capacidade de generalização do modelo sob diferentes condições de disponibilidade de dados. A Tabela 1 resume as características de cada conjunto.

Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**
UCSB	Mama (benigno / maligno)	58	2	32 / 26
CR	Colorretal (benigno / maligno)	165	2	74 / 91
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151
LG	Gênero (macho / fêmea)	265	2	150 / 115
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122

Todas as imagens originais foram redimensionadas para 256×256 pixels por interpolação de área, com o objetivo de padronizar a entrada da rede. Por fim, as imagens foram normalizadas utilizando as médias por canal padrão da ImageNet, $[0{,}485;\ 0{,}456;\ 0{,}406]$, e os respectivos desvios padrão, $[0{,}229;\ 0{,}224;\ 0{,}225]$, antes de serem fornecidas aos modelos de extração de características.

No contexto considerado, o *dataset* UCSB (Gelasca et al., 2008) é composto por 58 imagens RGB de tecido de câncer de mama (Figura Figura 3), sendo 32 benignas e 26 malignas, e possui o menor número de amostras entre os conjuntos avaliados.

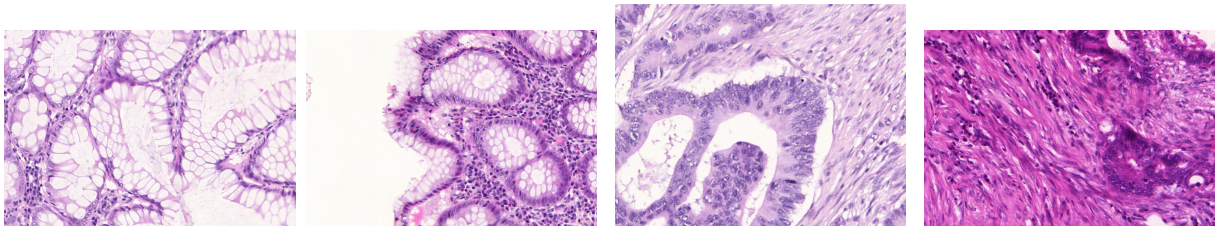


(a) (b) (c) (d)

Figura 3 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.

O *dataset* CR (Sirinukunwattana et al., 2017) contém 165 imagens RGB de tecido colorretal, obtidas a partir de 16 seções histológicas representativas de câncer colorretal nos estágios T3 e T4. O conjunto é levemente desbalanceado, com 74 imagens de tecido benigno e 91 de tecido maligno, e aquisições originais com resoluções de 567×430 a 775×522 pixels (Figura Figura 4).

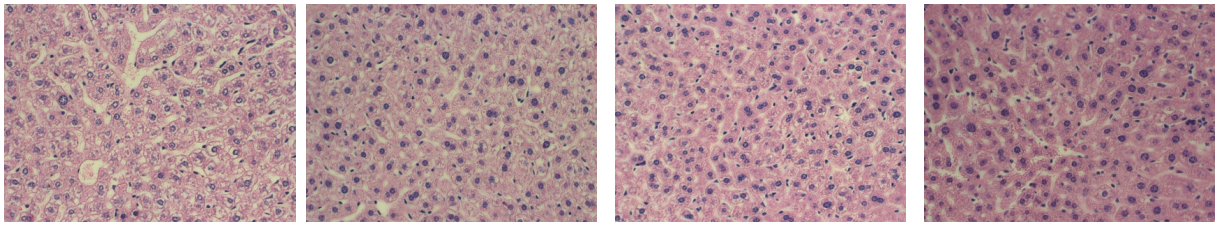
Os *datasets* LA e LG (Shamir et al., 2008) compreendem micrografias RGB de tecido hepático de camundongos. O LA tem como objetivo classificar a idade dos animais fêmeas em quatro grupos: um mês (100 imagens), seis meses (115), 16 meses (162) e 24 meses (151),



(a) (b) (c) (d)

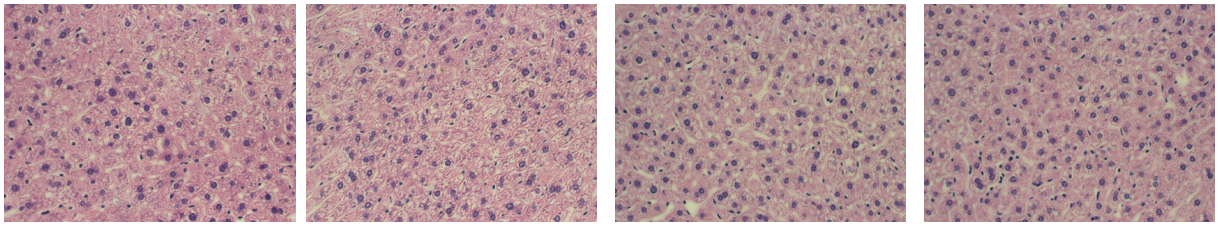
Figura 4 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

totalizando 528 imagens. O LG contém 265 imagens para classificação de gênero, divididas em 150 machos e 115 fêmeas. As Figuras Figura 5 e Figura 6 apresentam amostras dos dois conjuntos.



(a) (b) (c) (d)

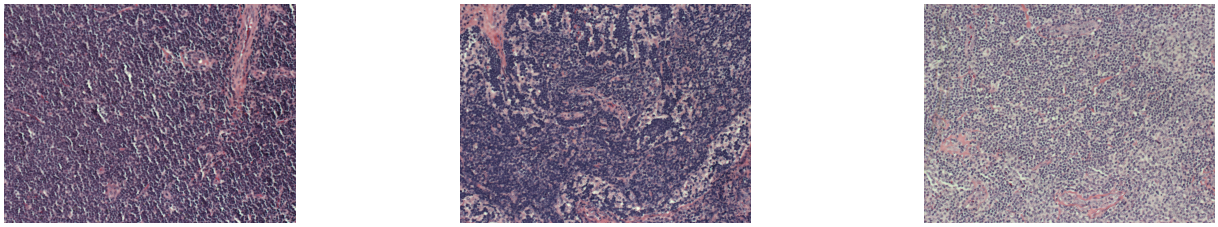
Figura 5 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).



(a) (b) (c) (d)

Figura 6 – Imagens de cada gênero dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.

O *dataset* NHL (Shamir et al., 2008) contém 374 imagens RGB de linfoma não Hodgkin, distribuídas em três classes diagnósticas: leucemia linfocítica crônica (*chronic lymphocytic leukemia*, CLL, 113 imagens), linfoma folicular (*follicular lymphoma*, FL, 139 imagens) e linfoma de células do manto (*mantle cell lymphoma*, MCL, 122 imagens). Diferentemente de aquisições realizadas em um único centro, o NHL reúne espécimes preparados por diferentes histologistas em diversos hospitais e laboratórios de histopatologia, apresentando marcantes variações de coloração e iluminação entre laboratórios (Figura Figura 7). Esse conjunto foi incluído especificamente para avaliar a generalização dos modelos sob substancial variabilidade de domínio e cromática.



(a) (b) (c)

Figura 7 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

4.2 *TWO-STREAM NETWORK*

A arquitetura proposta, ilustrada na Figura Figura 2, consiste em uma rede de dupla via (*Two-Stream Network*) destinada à classificação de imagens histopatológicas. O modelo combina duas representações complementares da imagem: uma representação topológica, construída a partir de medidas de redes complexas e processada por uma rede neural recorrente, e uma representação visual, extraída por uma arquitetura híbrida baseada em convoluções e mecanismos de atenção. As duas vias operam de forma independente durante a extração de características, e suas representações são integradas posteriormente por concatenação, seguida de um perceptron multicamadas (*Multilayer Perceptron* – MLP).

A separação dos fluxos permite explorar diferentes propriedades da imagem. A via topológica descreve as relações entre pixels e suas variações em diferentes escalas espaciais, enquanto a via visual aprende representações diretamente dos padrões presentes na imagem RGB. Essa organização é fundamentada em arquiteturas de dupla via empregadas na literatura para separar domínios de aprendizado conjunto (*joint learning*) (Yousaf; Nawaz; Habib, 2024; Wang et al., 2023). A combinação de descritores calculados explicitamente com características profundas minimiza a dependência de grandes volumes de dados, abordando restrições comuns na classificação de imagens histopatológicas (Huang et al., 2022).

O processamento é dividido em quatro etapas principais: (i) extração de características texturais por meio de redes complexas e codificação temporal por uma rede recorrente; (ii) extração de características visuais pela MobileViT; (iii) concatenação dos vetores resultantes; e (iv) classificação da matriz conjunta pelo MLP. A predição final resulta de uma avaliação simultânea das informações morfológicas e locais.

4.2.1 Extração de *features* texturais

A primeira via representa a textura da imagem por meio de medidas topológicas obtidas de redes complexas. A abordagem transforma cada pixel em um vértice de um grafo, estabelecendo arestas entre pixels vizinhos com base em suas posições e intensidades. A conversão das imagens para redes complexas permite quantificar características topológicas que algoritmos baseados em matrizes de vizinhança convencionais não processam diretamente (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024).

Redes direcionadas e ponderadas são construídas para cada amostra, sendo as conexões delimitadas por um raio máximo $r_{\max}$. O peso da aresta reflete a diferença absoluta de intensidade, e sua direção indica o gradiente local entre os pixels. Considerando o formato RGB, adota-se a configuração *full*, a qual estabelece ligações tanto intra quanto intercanais para analisar conjuntamente as mudanças de textura e cromaticidade (Scabini; Ribas; Bruno, 2020; Zerati et al., 2026).

Quatro grandezas topológicas (grau de saída, grau de entrada, força de saída e força de entrada) são calculadas para cada vértice. O raio máximo estipulado foi $r_{\max} = 10$. A escolha resulta da observação do pico de ganho de informação aferido pelas entropias de Shannon e amostral em avaliações prévias da base de dados, estando alinhada aos achados da literatura sobre análise multiescala em grafos coloridos (Ribas et al., 2024; Zerati et al., 2026).

Para transformar essas matrizes em um vetor representativo de dimensão fixa para cada raio r, a média global e o desvio padrão global das quatro medidas são calculados para cada um dos três canais da imagem. A agregação dessas duas medidas estatísticas produz 24 características estáticas para cada incremento do raio (Ribas et al., 2024). A representação ordenada desse processo compõe a sequência de entrada:

$$X_{\text{top}} = [x_1, x_2, \ldots, x_{10}], \tag{1}$$

em que cada passo da sequência corresponde ao vetor $x_r \in \mathbb{R}^{24}$.

O processamento dessa evolução espacial é executado por uma rede recorrente do tipo *Long Short-Term Memory* Bidirecional (BiLSTM). A leitura bidirecional percorre as representações do micro (raio 1) para o macro (raio 10) e em sentido inverso, uma estratégia adotada na extração de sequências espaço-temporais em modelos de dupla via para maximizar a captura de padrões (Yousaf; Nawaz; Habib, 2024; Hochreiter; Schmidhuber, 1997). A BiLSTM foi instanciada com uma camada oculta de 128 unidades em cada sentido de leitura. A concatenação dos estados ocultos produzidos em ambas as direções forma o *embedding* topológico $z_{\text{top}} \in \mathbb{R}^{256}$, o qual é repassado ao módulo de fusão.

4.2.2 Extração via MobileViT

A via paralela obtém atributos visuais diretamente da matriz RGB utilizando a MobileViT, uma arquitetura híbrida projetada para fundir operações de convolução e mecanismos de atenção global de forma eficiente. O processamento combinado é aplicado na histopatologia para assimilar detalhes microcelulares por meio das convoluções e avaliar o tecido em larga escala pelos blocos de *transformer* (Mehta; Rastegari, 2022; Oliveira et al., 2025).

A versão implementada para a extração de características é a MobileViT-S (Small). A adoção desta variante pauta-se na capacidade de gerar representações discriminativas sem exceder restrições computacionais em bases de dados limitadas (Mehta; Rastegari, 2022). O modelo recebe os dados de entrada na resolução padronizada de 256×256 pixels. Para utilizar

a arquitetura como um extrator puro em *transfer learning*, a camada densa de classificação originalmente concebida no topo da rede foi suprimida.

As ativações produzidas pelo último bloco convolucional são submetidas a uma camada de agrupamento médio global (*Global Average Pooling*). Esta operação condensa a dimensionalidade espacial dos mapas de características em um tensor linear. Sendo I a imagem processada e $f_{\text{vis}}(\cdot)$ o codificador visual, o mapeamento é expresso por:

$$z_{\text{vis}} = f_{\text{vis}}(I), \tag{2}$$

onde $z_{\text{vis}} \in \mathbb{R}^{640}$ representa o *embedding* visual.

A arquitetura visual é inicializada com os pesos da ImageNet, permitindo a reutilização das respostas de filtragem primárias otimizadas durante as etapas de treinamento do modelo proposto. O vetor de 640 dimensões resultante é transmitido em paralelo para a camada de integração.

4.2.3 Fusão Tardia

A fusão tardia (*Late Fusion*) constitui a etapa na qual os *embeddings* derivados da via topológica e da via visual são combinados no mesmo espaço dimensional. A junção dessas representações independentes a nível de *features* evita interferências recíprocas na aprendizagem local dos pesos, procedimento aplicado com eficácia na análise de câncer de próstata com características manuais e profundas (Huang et al., 2022; Baltrušaitis; Ahuja; Morency, 2019).

A combinação simples dos tensores expõe a rede ao problema da divergência de magnitude. Os valores provenientes da rede BiLSTM são matematicamente delimitados no intervalo $[-1, 1]$ em função da tangente hiperbólica de sua célula de memória. Os dados extraídos pela MobileViT passam por ativações não limitadas (*ReLU* ou *Swish*). A discrepância numérica leva os atributos de maior escala a anularem a influência dos atributos menores durante a propagação do erro. Para garantir a paridade na representação conjunta, os vetores z_{top} e z_{vis} são regularizados por uma camada de normalização de ativações (*Layer Normalization*) imediatamente antes da junção (Huang et al., 2022).

A construção do vetor unificado é executada pela concatenação dos tensores normalizados:

$$z_{\text{fuso}} = [z_{\text{top}} \,\|\, z_{\text{vis}}] \in \mathbb{R}^{896}, \tag{3}$$

em que o símbolo $\|$ indica a operação matemática de alinhamento sequencial. O tensor resultante carrega a somatória das representações da BiLSTM ($d_t = 256$) e da MobileViT-S ($d_v = 640$). O vetor completo é alimentado na etapa de decisão não linear do modelo.

4.2.4 Classificador MLP

A discriminação das classes histopatológicas baseada na matriz fundida é executada por um perceptron multicamadas (MLP). O classificador mapeia os 896 atributos recebidos e estabelece

relações estatísticas entre a forma visual do tecido e a distribuição estrutural de seu grafo (Rumelhart; Hinton; Williams, 1986).

A rede foi projetada com uma camada oculta contendo 512 neurônios. A transformação inicial dos dados é modelada pela equação:

$$h = \mathrm{ReLU}\left(W_1 z_{\mathrm{fuso}} + b_1\right), \tag{4}$$

em que a função de ativação linear retificada (*ReLU*) introduz não linearidade e gera a representação profunda h. A arquitetura compacta atua na prevenção do sobreajuste. Como técnica adicional de regularização direcionada aos cenários de dados exíguos encontrados nos conjuntos UCSB e CR, uma camada *Dropout* configurada com retenção de 50% (probabilidade de 0,5) processa as ativações produzidas (Srivastava et al., 2014; Nawaz et al., 2025).

As respostas estabilizadas alimentam a camada terminal do classificador. A camada de saída é instanciada com uma dimensão C, condizente ao número de categorias de cada base de dados (variando entre 2 a 4 neurônios). Os escores brutos são processados conforme a equação:

$$\hat{y} = \mathrm{softmax}\left(W_2 h + b_2\right). \tag{5}$$

A função *softmax* distribui os resultados em um escopo normalizado, gerando o vetor de probabilidade $\hat{y}$ relativo à classificação final da amostra de tecido.

4.3 PROTOCOLO DE TREINAMENTO

A arquitetura proposta é treinada de forma conjunta (*end-to-end*). O fluxo de processamento atualiza simultaneamente os parâmetros da rede MobileViT-S, da rede recorrente e do perceptron multicamadas. A divergência entre as predições e os rótulos verdadeiros é calculada pela função de perda de entropia cruzada. O otimizador AdamW é empregado para a atualização dos pesos, configurado com uma taxa de aprendizado inicial de 1×10^{-4}. A rede visual é submetida a ajuste fino a partir de pesos pré-treinados, enquanto os parâmetros das vias sequencial e de decisão são inicializados aleatoriamente.

A avaliação do modelo adota a validação cruzada estratificada com 10 partições (10-*fold*) (Kohavi et al., 1995). O conjunto de dados é dividido em 10 subconjuntos independentes. Em cada iteração, nove partições são utilizadas para o treinamento da rede e uma partição forma o conjunto de teste isolado. A divisão estratificada preserva a proporção original das classes em todas as partições. O resultado de desempenho do modelo corresponde à média aritmética das métricas obtidas nas 10 iterações.

4.3.1 Métricas

O desempenho da classificação é quantificado pelas métricas de Acurácia, F1-Score e Área Sob a Curva ROC (AUC-ROC). A Acurácia contabiliza a proporção global de predições corretas.

O F1-Score estabelece a média harmônica entre a precisão e a sensibilidade, fornecendo uma avaliação adequada para conjuntos de dados com desbalanceamento de classes, como o *dataset* CR. A métrica AUC-ROC afere a capacidade do classificador em distinguir entre as categorias ao longo de diferentes limiares de decisão. O desempenho da rede de dupla via é comparado diretamente aos resultados obtidos pelas técnicas de extração clássica (GLCM, LBP e HOG) submetidas à mesma arquitetura de classificação e ao mesmo particionamento de dados.

4.4 CONFIGURAÇÃO DE AMBIENTE

Os experimentos foram desenvolvidos na linguagem Python. A implementação da rede neural de dupla via, a extração de características e a otimização dos pesos foram executadas utilizando o *framework* PyTorch. O cálculo das matrizes topológicas e a extração dos descritores clássicos empregaram bibliotecas de processamento de imagens e análise de grafos. O treinamento e a inferência dos modelos foram acelerados por meio de unidades de processamento gráfico (GPUs).

5 RESULTADOS E DISCUSSÃO

6 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

AKANKSHA, M. N. V. et al. Implementation of potential leukemia detection using recurrent neural networks with blood cell counting. In: **2022 First International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)**. [S.l.: s.n.], 2022.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006. ISSN 0370-1573.

BRUSSEE, S. et al. Graph neural networks in histopathology: Emerging trends and future directions. **Medical Image Analysis**, v. 101, p. 103444, 2025.

CHEN, Y. et al. Bidirectional feature fusion via cross-attention transformer for chrysanthemum classification. **Pattern Analysis and Applications**, v. 28, p. 41, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

FAWAZ, H. I. et al. Deep learning for time series classification: a review. **Data Mining and Knowledge Discovery**, v. 33, n. 4, p. 917–963, 2019.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GELASCA, E. D. et al. Evaluation and benchmark for biological image segmentation. In: **2008 15th IEEE International Conference on Image Processing**. [S.l.: s.n.], 2008. p. 1816–1819.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

GREFF, K. et al. LSTM: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989.

HUANG, X. et al. Fusing hand-crafted and deep-learning features in a convolutional neural network model to identify prostate cancer in pathology images. **Frontiers in Oncology**, v. 12, p. 994950, 2022.

HUSSAINI, H. et al. A clinically grounded review of medical image classification: Quantitative insights into cnns, vision transformers, and hybrid cnn-vit models. **Journal of Imaging Informatics in Medicine**, 2026. Disponível em: https://doi.org/10.1007/s10278-026-02249-8.

JESWANI, U.; PRIYADHARSHINI, S. Exploring facial feature extraction and temporal dynamics for deepfake video detection: A CNN-RNN study on FaceForensics++. In: **2026 International Conference on Innovative Trends in Information Technology (ICITIIT)**. [S.l.: s.n.], 2026.

JUN, K. et al. Feature extraction using an RNN autoencoder for skeleton-based abnormal gait recognition. **IEEE Access**, v. 8, p. 19196–19207, 2020.

KABIR, M. F. et al. Accurate and lightweight oral cancer detection using SE-MobileViT on clinically validated image dataset. **Discover Artificial Intelligence**, v. 5, n. 173, 2025.

KABIR, M. F. et al. TriGWONet: A lightweight multibranch convolutional neural network using gray wolf optimization for accurate oral cancer image classification. **Discover Artificial Intelligence**, v. 6, n. 91, 2026.

KANG, Y. et al. MMDB: Multimodal dual-branch model for multi-functional bioactive peptide prediction. **Analytical Biochemistry**, v. 690, p. 115491, 2024.

KHAN, S. et al. Transformers in vision: A survey. **ACM Computing Surveys**, v. 54, n. 10s, p. 1–41, 2022.

KITTLER, J. et al. On combining classifiers. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 20, n. 3, p. 226–239, 1998.

KOHAVI, R. et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: MONTREAL, CANADA. **International joint conference on artificial intelligence**. [S.l.], 1995. v. 14, n. 2, p. 1137–1145.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026. ISSN 0952-1976. Disponível em: https://www.sciencedirect.com/science/article/pii/S0952197626005439.

KUSHWAH, S. S.; PUNN, N. S.; BHATTACHARYA, M. EVC-Net: A hybrid deep learning network for breast cancer classification from histopathological images. **ACM Transactions on Intelligent Systems and Technology**, v. 17, n. 4, p. 87, 2026.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, J. Fusion feature-based hybrid methods for diagnosing oral squamous cell carcinoma in histopathological images. **Frontiers in Oncology**, v. 15, p. 1551876, 2025.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022. ArXiv:2110.02178.

MOLDOVANU, S. et al. Hybrid decision-level fusion of CNN-based deep and handcrafted features for colon cancer classification. **Journal of Imaging**, v. 12, n. 8, p. 368, 2026.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PENG, H. et al. A lightweight triple-stream network with multisensor fusion for enhanced few-shot learning fault diagnosis. **IEEE Transactions on Reliability**, v. 74, n. 3, p. 4062–4075, 2025.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

SCABINI, L. et al. Complex networks for modeling texture and spectral features of hyperspectral images for environmental analysis. **Computers in Biology and Medicine**, v. 204, p. 111504, 2026.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMIR, L. et al. Iicbu 2008: a proposed benchmark suite for biological image analysis. **Medical & biological engineering & computing**, Springer, v. 46, n. 9, p. 943–947, 2008.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHARMA, S.; SINGH, Y.; CHOUDHURY, T. Advanced deep learning architectures for enhanced mammography classification: A comparative study of CNNs and ViT. **Discover Artificial Intelligence**, v. 5, n. 187, 2025.

SHENG, M.; HE, S.; SHI, Z. GTUNet: a GNN and transformer enhanced U-Net for coronary artery segmentation. **Signal, Image and Video Processing**, v. 20, n. 10, p. 532, 2026.

SHORFUZZAMAN, M. et al. Ai-driven tumor characterization and histological subtype classification in lung cancer using ct imaging. **Diagnostics**, v. 16, n. 17, 2026. ISSN 2075-4418. Disponível em: https://www.mdpi.com/2075-4418/16/17/2805.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SIRINUKUNWATTANA, K. et al. Gland segmentation in colon histology images: The glas challenge contest. **Medical Image Analysis**, v. 35, p. 489–502, 2017. ISSN 1361-8415. Disponível em: https://www.sciencedirect.com/science/article/pii/S1361841516301542.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TALO, M. Automated classification of histopathology images using transfer learning. **Artificial Intelligence in Medicine**, v. 101, p. 101743, 2019. ISSN 0933-3657. Disponível em: https://www.sciencedirect.com/science/article/pii/S0933365719307110.

WANG, C. et al. Research on tissue section negative detection algorithm based on multispectral microscopic imaging. **Journal of Innovative Optical Health Sciences**, v. 19, n. 2, p. 2550035, 2026.

WANG, L.; HE, D.-C. Texture classification using texture spectrum. **Pattern Recognition**, Pergamon Press, v. 23, n. 8, p. 905–910, 1990.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YANG, X. et al. DAPR-Net: Symmetric dual-stream pyramid architecture for non-rigid brain MRI registration. **Biomedical Signal Processing and Control**, v. 122, p. 110495, 2026.

YE, M. et al. Feature selection and extraction in sequence labeling for arrhythmia detection. In: **2021 International Balkan Conference on Communications and Networking (BalkanCom)**. [S.l.: s.n.], 2021. p. 107–111.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZENG, H. et al. MSSFN: A multi-scale sequence fusion network for CT-based diagnosis of pulmonary complications. **Neurocomputing**, v. 634, p. 129878, 2025.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHAO, C. et al. MMS-Net: Multi-level multi-scale feature extraction network for medical image segmentation. **Biomedical Signal Processing and Control**, v. 86, p. 105330, 2023.

ZHI, R.; WAN, M. Dynamic facial expression feature learning based on sparse RNN . In: **2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. [S.l.: s.n.], 2019. p. 1373–1377.

ZOU, X. et al. Improved breast ultrasound tumor classification using dual-input CNN with GAP-guided attention loss. **Mathematical Biosciences and Engineering**, v. 20, n. 8, p. 15244–15264, 2023.