UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr.Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr.Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM. 26

Figura 2 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 28

Figura 3 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 28

Figura 4 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 28

Figura 5 Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 29

Figura 6 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 29

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 27

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RGB	*Red, Green, Blue*
ViT	*Vision Transformer*

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 13
1.1 Objetivos 15

2 FUNDAMENTAÇÃO TEÓRICA 17
2.1 Extração de *Features* 17
2.1.1 Descritores clássicos 17
2.1.1.1 Matriz de coocorrência de níveis de cinza 17
2.1.1.2 Padrões binários locais 18
2.1.1.3 Histograma de gradientes orientados 19
2.1.2 Extração por aprendizado profundo 19
2.2 Redes Complexas 20
2.2.1 Modelagem da imagem como rede direcionada 20
2.2.2 Medidas topológicas e configurações da rede 21
2.3 RNN na Extração de *Features* 22
2.3.1 Evolução topológica ao longo dos raios 22
2.3.2 Redes recorrentes e *embedding* de sequência 22
2.4 Redes Híbridas para Extração de *Features* Visuais 23
2.5 Fusão por Concatenação de *Embeddings* e MLP 24

3 MATERIAIS E MÉTODOS 26
3.1 *Datasets* 27
3.2 *Two-Stream Network* 29
3.2.1 Via topológica 30
3.2.2 Via visual 31
3.2.3 Fusão por concatenação de *embeddings* 31
3.2.4 Classificador MLP 32
3.3 Protocolo de treinamento 32
3.3.1 Validação 33
3.3.2 Métricas 33
3.3.3 Limitações do protocolo 33
3.4 Comparações e ablações 34
3.5 Configuração de ambiente 35

4 RESULTADOS E DISCUSSÃO 36

5 CONCLUSÃO 37

REFERÊNCIAS 38

1 INTRODUÇÃO

A histopatologia é responsável pelo diagnóstico precoce de patologias de tecidos agressivas, como cânceres e doenças autoimunes, infecciosas e degenerativas. Os diagnósticos são realizados, em geral, manualmente por patologistas, em um processo que envolve a extração de tecidos biológicos, a coloração por reagentes químicos para realçar o contraste das estruturas celulares e a investigação microscópica por especialistas. Esse processo é custoso e pode ser acelerado por computadorização (Talo, 2019). A falta de padronização entre laboratórios, a necessidade de anotação exaustiva das imagens e as restrições éticas e de privacidade dificultam ainda a construção de grandes bases de imagens para modelos de aprendizado profundo (*Deep Learning*, DL) (Kumar; Mishra, 2026). Para viabilizar a aplicação de DL nesse cenário, técnicas como transferência de aprendizado, aumento de dados e extração de *features* foram adotadas na literatura, e em determinados casos os modelos superaram patologistas na classificação de tecidos (Bejnordi et al., 2017).

O DL foi difundido pela ampla utilização das *Convolutional Neural Networks* (CNNs) em tarefas de visão computacional, como segmentação e classificação de imagens (Kumar; Mishra, 2026). Essas redes são compostas por camadas de convolução e de *pooling*, que reduzem a resolução das imagens e realizam a classificação principalmente a partir de informações locais. As arquiteturas *Vision Transformer* (ViT) empregam mecanismos de auto-atenção para capturar o contexto global das imagens (Hussaini et al., 2026). Os modelos híbridos CNN-ViT unem a localidade das redes convolucionais ao contexto de longa distância dos modelos baseados em atenção e foram aplicados na classificação de imagens médicas com ganhos de desempenho (Hussaini et al., 2026). A dificuldade de convergência do treinamento com poucas amostras permanece mesmo com a evolução das topologias de rede, e em imagens histológicas a extração de características de textura é uma estratégia comum para contornar essa restrição.

Nas imagens histológicas, a disposição de núcleos, citoplasma e matriz extracelular produz padrões de textura que diferenciam tecidos normais e patológicos, e a extração de *features* é, por esse motivo, uma etapa da classificação desses tecidos. Descritores clássicos como GLCM (Haralick; Shanmugam; Dinstein, 1973), LBP (Ojala; Pietikäinen; Harwood, 1996; Ojala; Pietikäinen; Mäenpää, 2002) e HOG (Dalal; Triggs, 2005) são empregados com classificadores tradicionais e, mais recentemente, foram comparados e combinados com representações aprendidas por redes profundas em imagens médicas (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025; Shorfuzzaman et al., 2026). Esses descritores são calculados sobre vizinhanças de tamanho fixo e não descrevem de forma explícita a organização do tecido em diferentes escalas.

As Redes Complexas (*Complex Networks*, CN) permitem descrever a textura em múltiplas escalas. Na transformação de uma imagem em CN, os pixels são modelados como vértices e as conexões entre eles são definidas por um raio de distância. A variação desse raio produz uma sequência de redes cada vez mais abrangentes, das quais são extraídas medidas topológicas

(Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Zerati et al., 2026). Em raios pequenos, as medidas descrevem a organização local dos pixels e, em raios maiores, descrevem o tecido em escalas mais amplas. Como as redes de raios maiores incluem as conexões das redes de raios menores, a organização em larga escala depende da organização local, e os descritores obtidos formam uma sequência com dependência histórica entre seus elementos.

O processamento dessa sequência exige um modelo que preserve a informação dos raios anteriores. As Redes Neurais Recorrentes (*Recurrent Neural Networks*, RNNs) atendem a esse requisito, pois o estado interno é atualizado a cada elemento processado e acumula a informação dos elementos precedentes (Hochreiter; Schmidhuber, 1997). Cada raio processado contribui, dessa forma, para um estado que resume a evolução da topologia da imagem. As RNNs foram utilizadas como extratoras de *features* em dados sequenciais de diferentes domínios, como marcha, expressões faciais, sinais cardíacos e vídeos (Jun et al., 2020; Zhi; Wan, 2019; Ye et al., 2021; Jeswani; Priyadharshini, 2026). Na área médica, foram aplicadas na detecção de câncer de pulmão e de medula óssea (Mathiyalagi; Ravi, 2026; Priyadarshini, 2026) e em imagens histopatológicas de mama (Shalini; Rathnamala, 2026).

As *features* de textura podem ser combinadas com o vetor gerado ao final de um classificador visual. Na literatura de aprendizado multimodal, a combinação de duas fontes de informação pode ocorrer antes da extração, quando as entradas são unidas (fusão precoce), em nível de características, quando os vetores extraídos por cada via são unidos antes de um classificador compartilhado, ou em nível de decisão, quando são combinadas as saídas de classificadores independentes (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017). As arquiteturas de dupla via (*Two-Stream Networks*) foram propostas para processar fontes distintas em paralelo (Simonyan; Zisserman, 2014) e aplicadas na classificação de vídeos (Yousaf; Nawaz; Habib, 2024) e no reconhecimento de imagens por vias de forma e de textura (Wang et al., 2023).

Na histopatologia, a fusão de representações foi aplicada para combinar colorações e dados genômicos (Brussee et al., 2025), e a concatenação das características de uma CNN e de um ViT em imagens de mama superou cada rede isolada (Kushwah; Punn; Bhattacharya, 2026). A combinação de descritores clássicos de textura com características profundas também apresentou ganhos em imagens de próstata (Huang et al., 2022) e de carcinoma oral (Li, 2025), e a combinação das probabilidades de uma CNN com as de classificadores treinados sobre descritores clássicos elevou o desempenho em imagens de cólon (Moldovanu et al., 2026). A fusão em nível de características por concatenação de *embeddings* é adequada ao presente trabalho porque as duas vias possuem naturezas distintas, uma baseada na imagem e outra em uma sequência de descritores, e a concatenação permite que cada uma seja processada por um extrator próprio antes da camada de decisão, responsável por combinar os dois *embeddings*. Este trabalho adota a denominação fusão por concatenação de *embeddings*, e não fusão tardia, porque o segundo termo é empregado na literatura tanto para a combinação de características quanto para a combinação de decisões (Seção 2.5).

Nos trabalhos citados, a combinação de representações de naturezas distintas melhorou a

classificação de imagens médicas, e nenhum deles combina a sequência de descritores topológicos gerada por CN, processada por uma RNN, com a representação visual de uma rede híbrida. As duas vias descrevem o tecido de formas distintas, a primeira pela organização dos pixels em diferentes raios de conexão e a segunda pelo conteúdo visual aprendido pela rede. A combinação é motivada também pela escassez de imagens histopatológicas anotadas, que torna necessário extrair a maior quantidade possível de informação de cada amostra disponível (Kumar; Mishra, 2026).

A partir dessa lacuna, a questão de pesquisa investigada neste trabalho é: a sequência de descritores topológicos multiescala de CN, processada por uma RNN e combinada, por concatenação de *embeddings*, com a representação visual de uma rede híbrida CNN-ViT, melhora a classificação de imagens histopatológicas em relação aos descritores de textura de vizinhança fixa? A hipótese adotada é que a evolução das medidas topológicas ao longo dos raios de conexão, processada sequencialmente por uma RNN bidirecional (BiLSTM), capta padrões de organização do tecido que os descritores de vizinhança fixa não representam, e que esses padrões acrescentam informação à representação visual da rede híbrida.

As contribuições deste trabalho são:

- A modelagem de imagens histopatológicas coloridas como CN, com a variação do raio de conexão entre os pixels gerando uma sequência de descritores topológicos.
- O uso de uma RNN como extratora de *features* dessa sequência, gerando um *embedding* topológico do tecido.
- O desenvolvimento de uma arquitetura de dupla via, na qual o *embedding* topológico e o *embedding* visual extraído pela MobileViT (Mehta; Rastegari, 2022) são combinados por concatenação e classificados por um MLP.
- A avaliação da arquitetura em cinco bases de dados histopatológicas públicas (UCSB, CR, LA, LG e NHL), em comparação com cada via isolada, com os descritores GLCM, LBP e HOG (isolados e concatenados à MobileViT-S) e com a fusão de escores, e a análise por ablações da codificação da sequência topológica.

Os objetivos do trabalho são apresentados na Seção 1.1. O restante do documento está organizado em quatro capítulos. A fundamentação teórica (Capítulo 2) aborda os conceitos de CN, RNNs, redes híbridas CNN-ViT e fusão por concatenação de *embeddings*, a metodologia (Capítulo 3) descreve as bases de dados, a arquitetura proposta e o protocolo experimental, os resultados são apresentados e discutidos no Capítulo 4, e as conclusões e os trabalhos futuros são apresentados no Capítulo 5.

1.1 OBJETIVOS

Este trabalho tem como objetivo geral propor e avaliar uma rede de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas, na qual a evolução de medidas topológicas de redes complexas, calculadas em raios de conexão crescentes e codificada por uma BiLSTM, forma um *embedding* topológico. Esse *embedding* é concatenado ao *embedding* visual extraído por uma rede híbrida (MobileViT-S) e classificado por um MLP, e investiga-se se essa combinação supera cada via isolada e os descritores clássicos de textura (GLCM, LBP e HOG).

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- Modelar as imagens histopatológicas coloridas como redes complexas direcionadas e ponderadas (*Spatio-Spectral Network*), variando o raio de conexão de 1 a 15 para obter uma sequência de vetores de medidas topológicas que descreva a textura do tecido em escalas crescentes.
- Implementar e treinar uma BiLSTM que codifique essa sequência em um *embedding* topológico.
- Configurar a via visual com a MobileViT-S, pré-treinada na ImageNet e ajustada por *fine-tuning*, para extrair das imagens originais um *embedding* visual.
- Desenvolver a fusão por concatenação de *embeddings*, com projeção e normalização de camada dos vetores das duas vias, e submeter o vetor concatenado a um perceptron de múltiplas camadas (MLP) para a classificação final.
- Avaliar o modelo proposto em cinco conjuntos de dados (UCSB, CR, LA, LG e NHL) por validação cruzada estratificada, com acurácia, F1-*score* macro e AUC-ROC, comparando-o com cada via isolada, com os descritores GLCM, LBP e HOG (isolados e concatenados à MobileViT-S) e com a fusão de escores.
- Verificar, por ablações na via topológica, a contribuição da recorrência (BiLSTM, LSTM, GRU, MLP e CNN unidimensional), da representação da sequência (medidas acumuladas ou diferenças entre raios) e do raio máximo de conexão.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* é uma medida numérica que representa uma propriedade da imagem, como textura, forma, bordas ou cor. A extração de *features* transforma os pixels em uma representação que pode ser utilizada por um classificador (Ramos-Soto et al., 2025). Em imagens médicas, essas medidas descrevem propriedades como a forma, o tamanho, a textura e a intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A representação pode ser definida por regras matemáticas ou aprendida a partir dos dados, e essa distinção é relevante em bases médicas pequenas, nas quais a disponibilidade de imagens rotuladas é limitada por custos de aquisição, privacidade e necessidade de especialistas (Litjens et al., 2017).

Em histopatologia, o tecido é fixado, cortado, corado, em geral pela hematoxilina e eosina (H&E), e digitalizado. As diferenças de protocolo de coloração e de iluminação entre laboratórios alteram a cor e o contraste da imagem para um mesmo tipo de tecido, e a textura formada pelo arranjo de núcleos, citoplasma e matriz extracelular é uma das principais fontes de informação para o diagnóstico.

2.1.1 Descritores clássicos

Os descritores clássicos (*handcrafted*) são calculados por regras matemáticas definidas previamente, sem ajuste a partir dos dados. Entre os métodos empregados em imagens médicas estão as estatísticas de primeira ordem, a matriz de coocorrência de níveis de cinza (GLCM), os padrões binários locais (LBP), o histograma de gradientes orientados (HOG), os filtros de Gabor e o SIFT (Ramos-Soto et al., 2025; Ahmed et al., 2023; Dehbozorgi; Ryabchykov; Bocklitz, 2025). As subseções seguintes definem GLCM, LBP e HOG.

2.1.1.1 Matriz de coocorrência de níveis de cinza

A GLCM (Haralick; Shanmugam; Dinstein, 1973) registra a frequência com que pares de pixels de tons i e j ocorrem separados por um deslocamento definido por uma distância d e um ângulo θ (0°, 45°, 90° ou 135°). Para uma imagem I com N_g níveis de cinza, a matriz e sua versão normalizada são

$$P_{d,\theta}(i,j) = \left|\{(\mathbf{p},\mathbf{q}) : I(\mathbf{p}) = i,\ I(\mathbf{q}) = j,\ \mathbf{q} = \mathbf{p} + d\,(\cos\theta, \sin\theta)\}\right|, \qquad p(i,j) = \frac{P_{d,\theta}(i,j)}{\sum_{k,l} P_{d,\theta}(k,l)}. \tag{1}$$

A partir de $p(i,j)$ são calculadas medidas de textura, como o contraste, a energia, a homogeneidade, a entropia e a correlação (Haralick; Shanmugam; Dinstein, 1973):

$$\begin{aligned}
\text{contraste} &= \sum_{i,j} (i-j)^2\, p(i,j), & \text{energia} &= \sum_{i,j} p(i,j)^2, \\
\text{homogeneidade} &= \sum_{i,j} \frac{p(i,j)}{1+|i-j|}, & \text{entropia} &= -\sum_{i,j} p(i,j)\, \log p(i,j), \\
\text{correlação} &= \sum_{i,j} \frac{(i-\mu_i)(j-\mu_j)\, p(i,j)}{\sigma_i\, \sigma_j}, & &
\end{aligned} \tag{2}$$

em que μ_i, μ_j, σ_i e σ_j são as médias e os desvios padrão das distribuições marginais de p. A matriz depende da escolha do vetor de deslocamento e da variação regional do fundo de intensidade da imagem (He; Wang, 1989).

2.1.1.2 Padrões binários locais

O LBP (Ojala; Pietikäinen; Harwood, 1996) descreve a textura pela relação entre cada pixel e sua vizinhança, e tem origem no espectro de textura de He & Wang (1989), que codifica cada vizinho em três valores. No LBP a codificação é binária. Sendo g_c a intensidade do pixel central e g_p, com $p = 0, \ldots, P-1$, a intensidade de cada um de seus P vizinhos, o código do pixel é

$$\mathrm{LBP}_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s\,(g_p - g_c)\, 2^p, \qquad s(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0. \end{cases} \tag{3}$$

Na versão original, $P = 8$ e $R = 1$, os vizinhos são os oito pixels da janela 3×3 e há $2^8 = 256$ códigos possíveis. Ojala, Pietikäinen & Mäenpää (2002) estenderam o operador a múltiplas resoluções: os P vizinhos ficam igualmente espaçados em um círculo de raio R, nas coordenadas

$$(x_p, y_p) = \left(x_c + R\cos\frac{2\pi p}{P},\; y_c - R\sin\frac{2\pi p}{P} \right), \tag{4}$$

e as intensidades g_p nas posições que não coincidem com um pixel são obtidas por interpolação bilinear. A imagem é descrita pelo histograma dos códigos, normalizado pelo número de pixels N:

$$H(k) = \frac{1}{N} \sum_{x,y} \mathbb{1}\left[\mathrm{LBP}_{P,R}(x,y) = k\right], \qquad k = 0, 1, \ldots, 2^P - 1. \tag{5}$$

Os mesmos autores definiram os padrões *uniformes*, que contêm no máximo duas transições entre 0 e 1 no código circular. Com

$$U\left(\mathrm{LBP}_{P,R}\right) = \left|s(g_{P-1} - g_c) - s(g_0 - g_c)\right| + \sum_{p=1}^{P-1} \left|s(g_p - g_c) - s(g_{p-1} - g_c)\right|, \tag{6}$$

o operador invariante à rotação e uniforme é

$$\mathrm{LBP}_{P,R}^{riu2} = \begin{cases} \sum_{p=0}^{P-1} s\left(g_p - g_c\right), & U\left(\mathrm{LBP}_{P,R}\right) \leq 2, \\ P+1, & \text{caso contrário}, \end{cases} \tag{7}$$

cujo histograma tem $P+2$ posições. A combinação de operadores com diferentes pares (P, R) forma o descritor multirresolução.

2.1.1.3 Histograma de gradientes orientados

O HOG (Dalal; Triggs, 2005) descreve a imagem pela distribuição local das direções de gradiente. Os gradientes horizontal e vertical, G_x e G_y, são obtidos por filtros de derivada, e a magnitude e a orientação de cada pixel são

$$m(x,y) = \sqrt{G_x(x,y)^2 + G_y(x,y)^2}, \qquad \phi(x,y) = \arctan \frac{G_y(x,y)}{G_x(x,y)}. \tag{8}$$

A imagem é dividida em células, e cada célula acumula um histograma de B intervalos de orientação em que cada pixel contribui com sua magnitude:

$$h_{\mathrm{cel}}(b) = \sum_{(x,y)\in \mathrm{cel}} m(x,y) \mathbb{1}\left[\phi(x,y) \in \mathrm{intervalo}_b\right], \qquad b = 1, \ldots, B. \tag{9}$$

Os histogramas das células de cada bloco, concatenados em um vetor $\mathbf{v}$, são normalizados para reduzir a sensibilidade ao contraste e à iluminação,

$$\mathbf{v}' = \frac{\mathbf{v}}{\sqrt{\|\mathbf{v}\|_2^2 + \varepsilon^2}}, \tag{10}$$

em que ε é uma constante pequena, e os blocos sobrepostos concatenados formam o descritor. O HOG foi concebido para a detecção de pessoas e é empregado como descritor de bordas e de forma em imagens médicas (Ramos-Soto et al., 2025).

2.1.2 Extração por aprendizado profundo

Os descritores *handcrafted* capturam relações locais entre pixels, em escalas e vizinhanças definidas previamente. As redes neurais convolucionais (CNNs), em contraste, aprendem filtros que vão de bordas e texturas nas primeiras camadas até padrões semânticos nas camadas finais, e são amplamente utilizadas em análise de imagens médicas (Litjens et al., 2017). Os *Vision Transformers* (ViT) representam a imagem como uma sequência de *patches* e utilizam

autoatenção para modelar relações entre regiões (Dosovitskiy et al., 2020; Shamshad et al., 2023).

Em domínios com poucos dados, a transferência de aprendizado (*transfer learning*) permite empregar uma rede pré-treinada em uma base grande, como a ImageNet, como ponto de partida. Na extração de *features*, a ativação de uma camada intermediária ou final é utilizada como vetor de características. No ajuste fino (*fine-tuning*), os pesos pré-treinados servem de inicialização e são atualizados no conjunto-alvo, em geral com taxa de aprendizado menor que a dos módulos inicializados aleatoriamente. Modelos com muitos parâmetros ajustados em poucas imagens estão sujeitos ao sobreajuste, o que torna a regularização e o aumento de dados relevantes. O aumento de dados gera amostras adicionais por transformações que preservam o rótulo, como inversões e rotações.

A variação de tamanho e de aparência das estruturas do tecido motiva descritores multiescala, que descrevem a imagem em vizinhanças de tamanhos crescentes. Na abordagem de redes complexas apresentada a seguir, a escala é controlada pelo raio de conexão.

2.2 REDES COMPLEXAS

A teoria de Redes Complexas (CN, do inglês *Complex Networks*) é uma abstração para modelar sistemas naturais cujos elementos interagem de maneira não trivial (Boccaletti et al., 2006). Essas redes foram empregadas para modelar os pixels de uma imagem e suas relações de vizinhança, e descritores baseados em topologia quantificam propriedades de textura a partir dessa modelagem (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). A *Spatio-Spectral Network* (SSN), proposta por Scabini, Ribas & Bruno (2020) para a análise de textura colorida, é a modelagem adotada e é descrita a seguir.

2.2.1 Modelagem da imagem como rede direcionada

Na SSN (Scabini; Ribas; Bruno, 2020), cada imagem é representada como uma CN direcionada e ponderada $G = (V, E)$, na qual cada pixel é modelado como um vértice e as conexões entre pixels são estabelecidas dentro de um raio máximo r_{max}. Para um pixel $i = (x_i, y_i)$ em um canal de cor c da imagem I, é definido um vértice $v_i^{(c)} \in V$. Uma aresta direcionada é criada entre os vértices $v_i^{(c)}$ e $v_j^{(c_w)}$, em que c e c_w são os canais de cor do primeiro e do segundo pixel, quando a distância euclidiana quadrática entre os pixels satisfaz a Equação 11:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 < \rho_{ij}^2 \leq r_{max}^2, \tag{11}$$

em que x e y são as coordenadas dos pixels e ρ_{ij} é a distância euclidiana entre eles. A condição $\rho_{ij}^2 > 0$ exclui laços, isto é, a conexão de um pixel consigo mesmo. Cada aresta é associada a um raio discreto $r \in \{1, 2, \ldots, r_{max}\}$, definido como o menor inteiro que satisfaz $(r-1)^2 < \rho_{ij}^2 \leq r^2$, o que permite acumular as medidas da rede progressivamente sobre vizinhanças cada vez maiores.

O peso atribuído a cada aresta é a diferença absoluta de intensidade entre os pixels conectados, conforme a Equação 12:

$$w_{ij} = \left| I(x_i, y_i, c) - I(x_j, y_j, c_w) \right|. \tag{12}$$

A direção de cada aresta é determinada pelas intensidades dos pixels conectados, do pixel de menor intensidade para o de maior intensidade (Scabini; Ribas; Bruno, 2020). Quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$, a conexão é classificada como de saída (*out*) a partir de v_i e de entrada (*in*) em v_j. No caso contrário, ela é classificada como de entrada em v_i. Conexões entre pixels de mesma intensidade são contabilizadas em ambas as direções. O grau de saída de um vértice conta, portanto, seus vizinhos mais claros.

2.2.2 Medidas topológicas e configurações da rede

O grau (*degree*) e a força (*force*) são calculados para cada vértice pela acumulação das quantidades correspondentes até o raio r. O grau de saída quantifica o número de conexões de saída dentro da vizinhança considerada, como na Equação 13:

$$d_{out}(v_i, r) = \sum_{k=1}^{r} n_{out}(v_i, k), \tag{13}$$

em que $n_{out}(v_i, k)$ é o número de arestas de saída de v_i cujo raio discreto vale k. A força incorpora as diferenças de intensidade e a proximidade entre os pixels, o que a torna sensível aos gradientes locais de textura. Para uma rede construída com raio r, cada aresta (v_i, v_j) recebe um peso de força que combina a diferença de intensidade normalizada com a distância normalizada, conforme a Equação 14:

$$\omega_{ij}^{(r)} = \begin{cases} \dfrac{w_{ij}}{2L}, & r = 1, \\ \dfrac{1}{2}\left[\dfrac{w_{ij}}{L} + \dfrac{\rho_{ij}^2 - 1}{r^2 - 1}\right], & r \geq 2, \end{cases} \tag{14}$$

em que $L = 255$ é o nível máximo de intensidade para imagens de 8 bits e w_{ij} é o peso dado pela Equação 12. A força de saída acumulada é dada pela Equação 15:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{15}$$

em que $\mathcal{N}_{out}^{(r)}(v_i)$ é o conjunto de vértices conectados a v_i por arestas de saída com $\rho_{ij}^2 \leq r^2$, e force$_{in}$ é definida de forma análoga sobre as arestas de entrada. O fator $r^2 - 1$ na Equação 14 é o valor máximo de $\rho_{ij}^2 - 1$ dentro de uma vizinhança de raio r, o que mantém o termo de distância no intervalo $[0, 1]$. Para $r = 1$, a única distância quadrática possível é $\rho_{ij}^2 = 1$, de modo que o termo de distância é nulo e o fator $r^2 - 1$ anularia o denominador, e nesse caso o peso é reduzido à componente de intensidade. As medidas por vértice utilizadas são o grau de saída, a força de

saída e a força de entrada (Ribas et al., 2024).

Para estender as medidas aos três canais de cor das imagens RGB, as formulações anteriores podem ser aplicadas em três configurações de rede (Scabini; Ribas; Bruno, 2020): *within-channel*, com $c = c_w$, *between-channel*, com $c \neq c_w$, e *full*, que inclui simultaneamente conexões intracanal e intercanal. Como os pesos e as direções das arestas dependem da comparação de intensidades inteiras, inclusive dos empates, a rede é construída sobre a imagem em inteiros de 8 bits, e o redimensionamento altera a textura em nível de pixel.

O raio máximo r_{max} determina a escala espacial descrita pelas medidas. Nos raios menores, elas refletem relações locais entre pixels próximos, e, à medida que r cresce, as vizinhanças acumuladas se tornam progressivamente mais amplas. A evolução das medidas ao longo dos raios compõe uma descrição multiescala da textura, tratada na seção seguinte.

2.3 RNN NA EXTRAÇÃO DE *FEATURES*

Uma rede neural recorrente (RNN, do inglês *Recurrent Neural Network*) processa dados organizados em sequência. Como Ribas et al. (2024) utilizam a sigla RNN para a rede neural aleatorizada (*Randomized Neural Network*), neste texto a sigla RNN designa exclusivamente a rede recorrente, e a rede aleatorizada é abreviada por RaNN.

2.3.1 Evolução topológica ao longo dos raios

A descrição da textura pela evolução das medidas topológicas ao longo dos raios tem origem na SSN, que define um conjunto de raios $\{r_1, \ldots, r_R\}$ para a vizinhança dos vértices e analisa as propriedades topológicas da rede por medidas de vértice simples (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). A partir dessa modelagem, Ribas et al. (2024) descreveram a evolução topológica por uma RaNN, uma rede de alimentação direta com uma camada oculta, cujos pesos são gerados aleatoriamente, e com pesos de saída obtidos por mínimos quadrados com regularização de Tikhonov. As medidas de cada vértice (grau de saída, força de entrada e força de saída) foram calculadas em vários raios $r = \{1, 2, \ldots, R\}$, e os valores obtidos em $r = 1, \ldots, R-1$ formaram um vetor de entrada usado para prever o valor da mesma medida no raio máximo R. Os pesos da camada de saída da RaNN, treinada para cada imagem, constituem o descritor, e os autores descrevem esse procedimento como uma análise multiescala da evolução topológica dos vértices.

Na RaNN, os valores de todos os raios entram simultaneamente em uma rede de alimentação direta, sem recorrência. Uma alternativa é ler os descritores de cada raio como uma sequência $x_1, x_2, \ldots, x_R$, do menor raio para o maior, por uma rede recorrente cujos parâmetros são aprendidos a partir do rótulo da classe, em vez de calculados por imagem.

2.3.2 Redes recorrentes e *embedding* de sequência

Uma RNN processa um elemento por vez de uma sequência e mantém um estado interno que carrega informação sobre os elementos anteriores (LeCun; Bengio; Hinton, 2015). Na rede recorrente simples de Elman (1990), o estado oculto depende da entrada atual e do estado anterior, e os parâmetros são compartilhados entre os passos, de modo que sua quantidade não depende do comprimento da sequência. O treinamento por retropropagação enfrenta o desaparecimento ou a explosão dos gradientes à medida que o intervalo entre entrada e saída aumenta (Bengio; Simard; Frasconi, 1994), e a LSTM (Hochreiter; Schmidhuber, 1997) mitiga esse problema com uma célula de memória c_t controlada por portas. Na formulação usual, que inclui a porta de esquecimento (Gers; Schmidhuber; Cummins, 2000), as atualizações são:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{16}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{17}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{18}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{19}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{20}$$

$$h_t = o_t \odot \tanh(c_t), \tag{21}$$

em que σ é a função sigmoide, $\odot$ denota o produto elemento a elemento e f_t, i_t e o_t são as portas de esquecimento, entrada e saída. A GRU (Cho et al., 2014) é uma alternativa com menos portas e menos parâmetros.

A RNN unidirecional lê a sequência em um único sentido, e a RNN bidirecional (Schuster; Paliwal, 1997) utiliza duas redes independentes, uma lendo a sequência na ordem original e outra na ordem inversa, e combina seus estados:

$$h_t = \left[\overrightarrow{h}_t \,\|\, \overleftarrow{h}_t\right]. \tag{22}$$

Quando a sequência inteira recebe um único rótulo, a rede opera no formato *many-to-one*: em vez da saída de cada passo, utiliza-se um vetor de dimensão fixa que resume a sequência, obtido do estado final de cada direção, $\left[\overrightarrow{h}_T \,\|\, \overleftarrow{h}_1\right]$, com T passos. Esse vetor, denominado *embedding* da sequência, pode ser concatenado a vetores de outras fontes de informação (Seção 2.5). Diferentemente dos pesos de saída da RaNN, obtidos por mínimos quadrados sem retropropagação, os parâmetros de uma LSTM são aprendidos por gradiente, e o *embedding* pode ser otimizado em conjunto com o classificador.

2.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* VISUAIS

As CNNs extraem padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de

longo alcance (Ma et al., 2026). Os ViT (Dosovitskiy et al., 2020) abordam esse problema pela autoatenção sobre sequências de *patches*, mas a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). As arquiteturas híbridas combinam a captura de padrões locais das CNNs com a modelagem global dos *transformers*, em geral com blocos convolucionais que extraem informação localizada e mecanismos de atenção que integram o contexto global, o que é relevante em patologia computacional, em que a interpretação depende de detalhes morfológicos finos e de padrões em escala de tecido (Oliveira et al., 2025).

A MobileViT, proposta por Mehta & Rastegari (2022), combina operações convolucionais e autoatenção em uma arquitetura de baixo custo computacional. Em cada bloco MobileViT, uma convolução $n \times n$ seguida de uma convolução pontual 1×1 produz uma representação local da entrada. Essa representação é organizada em *patches*, processada por um *Transformer* e reorganizada no formato do mapa de características. O resultado é combinado com a representação local e processado por outra convolução, que integra as informações obtidas pelos dois tipos de operação (Ding et al., 2023). Os mapas resultantes incorporam informação local e global sem depender exclusivamente da autoatenção sobre todos os pixels (Mehta; Rastegari, 2022; Ding et al., 2023). Para obter um vetor de características da imagem, a cabeça de classificação é removida e os mapas do último bloco são agregados por um agrupamento médio global (*Global Average Pooling*).

2.5 FUSÃO POR CONCATENAÇÃO DE *EMBEDDINGS* E MLP

A literatura de aprendizado multimodal distingue estratégias que combinam as representações antes da classificação daquelas que combinam as decisões de modelos independentes (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017). Na fusão em nível de características, os vetores são unidos antes de um classificador compartilhado. Na fusão em nível de decisão, cada fonte produz uma saída de classificação e os escores são combinados por regras como soma, produto, máximo ou voto majoritário (Kittler et al., 1998).

A expressão *fusão tardia* é utilizada na literatura tanto para a concatenação de características (Nawaz et al., 2025) quanto para a combinação de decisões (Yousaf; Nawaz; Habib, 2024). Para evitar a ambiguidade, a combinação em nível de características por concatenação é denominada, neste texto, fusão por concatenação de *embeddings*. Quando o modelo é treinado de ponta a ponta, as fontes são ajustadas em conjunto, e a separação entre elas se limita à extração das representações, que possuem naturezas distintas, antes da camada de decisão.

As arquiteturas de dupla via (*two-stream*) processam fontes distintas de informação por ramos independentes e combinam as representações resultantes (Yousaf; Nawaz; Habib, 2024; Wang et al., 2023). A combinação de descritores calculados explicitamente com características profundas foi aplicada em imagens histopatológicas de próstata (Huang et al., 2022).

Dados os *embeddings* $z_{\mathrm{a}} \in \mathbb{R}^{d_a}$ e $z_{\mathrm{b}} \in \mathbb{R}^{d_b}$ de duas vias, a concatenação forma o vetor conjunto

$$z = [\, z_{\mathrm{a}} \,\|\, z_{\mathrm{b}} \,] \in \mathbb{R}^{d_a + d_b}. \tag{23}$$

Os vetores de vias distintas têm origens, escalas e dimensões diferentes. Quando uma via produz valores limitados, como o estado oculto da LSTM, restrito ao intervalo $(-1, 1)$ pela tangente hiperbólica, e a outra produz ativações sem essa restrição, as características de maior magnitude tendem a predominar na primeira camada do classificador. O mesmo ocorre com o vetor de maior dimensão. Duas medidas contornam o problema: projetar os vetores para a mesma dimensão por uma camada linear e normalizá-los por *Layer Normalization* (LN), que, para um vetor $z \in \mathbb{R}^d$, é dada por

$$\mathrm{LN}(z) = \gamma \odot \frac{z - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta, \qquad \mu = \frac{1}{d}\sum_{k=1}^{d} z_k, \qquad \sigma^2 = \frac{1}{d}\sum_{k=1}^{d} (z_k - \mu)^2, \tag{24}$$

em que γ e β são parâmetros aprendidos e ε é uma constante pequena.

O perceptron multicamadas (MLP) é uma rede *feedforward* em que cada camada aplica uma transformação afim seguida de uma não linearidade, treinada por retropropagação do erro (Rumelhart; Hinton; Williams, 1986), e redes desse tipo, com ao menos uma camada oculta, são aproximadores universais de funções sob condições gerais (Hornik; Stinchcombe; White, 1989). Com uma camada oculta, o classificador é dado por

$$h = \mathrm{ReLU}(W_1 z + b_1)\,, \tag{25}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{26}$$

em que $\hat{y}$ é o vetor de probabilidades sobre as classes e os pesos são ajustados pela minimização da entropia cruzada, $\mathcal{L} = -\sum_c y_c \log \hat{y}_c$. O número de parâmetros da primeira camada é proporcional ao produto de $d_a + d_b$ pela dimensão da camada oculta, o que exige atenção em conjuntos com dezenas a poucas centenas de imagens. O *dropout*, que desativa aleatoriamente unidades durante o treinamento, é uma técnica de regularização contra o sobreajuste (Srivastava et al., 2014), aplicável à camada oculta.

3 MATERIAIS E MÉTODOS

As imagens utilizadas provêm de cinco *datasets* histopatológicos, descritos na Seção 3.1. A arquitetura proposta extrai características de cada imagem por duas vias, a topológica e a visual (Seção 3.2). Os *embeddings* resultantes são concatenados (Seção 3.2.3) e classificados por um MLP (Seção 3.2.4), e o desempenho é medido pelo protocolo da Seção 3.3. O fluxo completo está apresentado na Figura Figura 1.

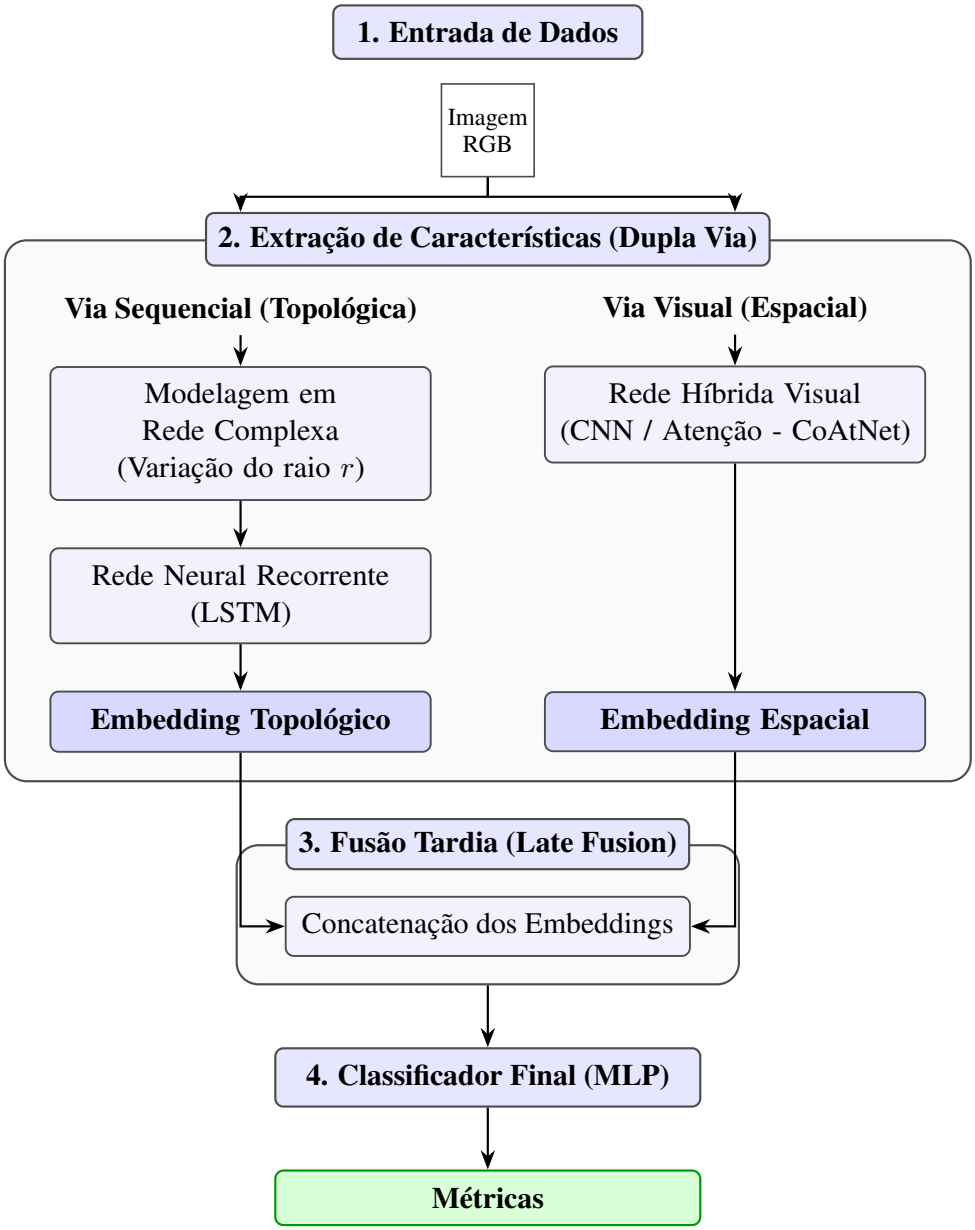


Figura 1 – Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM.

3.1 *DATASETS*

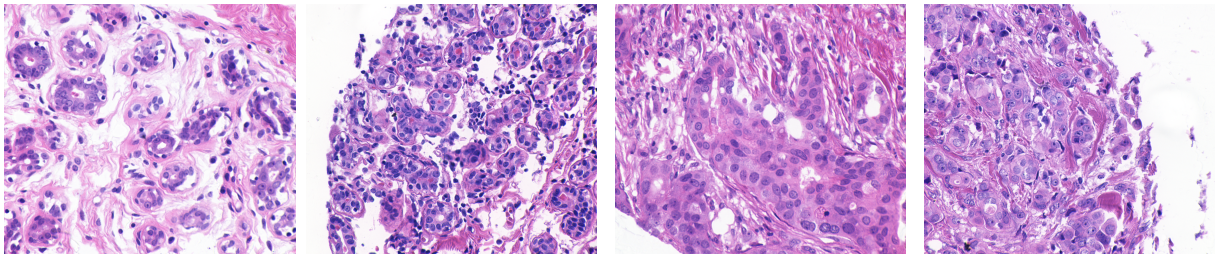
A avaliação foi conduzida em cinco *datasets* de imagens histopatológicas, com 58 a 528 imagens cada. Os conjuntos incluem tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, o que permite observar o comportamento do modelo em cenários com poucos dados. As características de cada conjunto estão resumidas na Tabela 1. Os conjuntos LA e LG não correspondem a tarefas diagnósticas, pois as classes são a idade e o sexo de camundongos. Esses conjuntos foram incluídos como *benchmarks* de textura histológica, nos quais a distinção entre as classes depende do padrão do tecido hepático e não de uma lesão.

Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**	**Resolução original**
UCSB	Mama (benigno / maligno)	58	2	32 / 26	896×768
CR	Colorretal (benigno / maligno)	165	2	74 / 91	775×522 (14 exceções)
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151	417×312
LG	Sexo (macho / fêmea)	265	2	150 / 115	417×312
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122	1388×1040

As imagens foram mantidas em inteiros de 8 bits por canal e alimentaram as duas vias em resoluções distintas. A via topológica utilizou a imagem na resolução original de cada *dataset* (Tabela 1), sem redimensionamento e sem alteração de intensidades, pois as arestas das redes complexas dependem da comparação de intensidades inteiras, incluindo os empates, e a interpolação suavizaria essas diferenças. A via visual utilizou uma versão de 256×256 pixels, escala em que a MobileViT-S foi pré-treinada, o que também uniformiza as dimensões dos lotes. Essa versão foi obtida pelo redimensionamento do lado menor para 256 pixels, por interpolação de área e com a proporção preservada, seguido de um recorte central de 256×256 pixels. Em seguida, a imagem foi convertida para o intervalo $[0, 1]$ e normalizada pela ImageNet, com médias por canal de $0{,}485$, $0{,}456$ e $0{,}406$ e desvios padrão de $0{,}229$, $0{,}224$ e $0{,}225$. Esse procedimento evita a distorção de proporção, mas o recorte central descarta as bordas das imagens que não são quadradas.

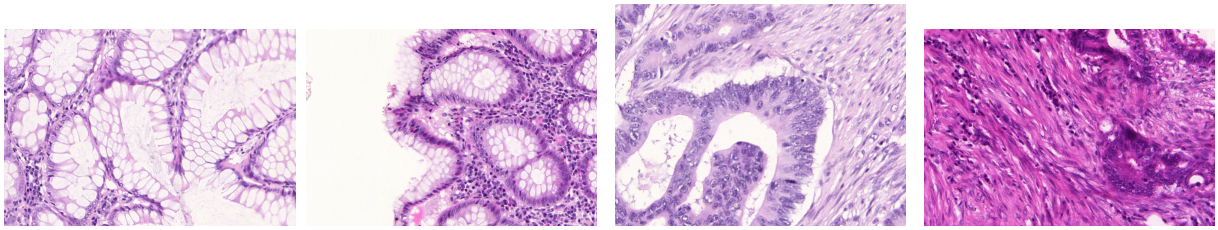
Como consequência, as duas vias descrevem a mesma imagem em escalas e regiões diferentes: a via topológica, a imagem inteira em resolução nativa, e a via visual, o recorte central reduzido. Dentro de cada *dataset* a resolução é praticamente uniforme, de modo que a escala é consistente entre as amostras. Entre *datasets*, porém, um mesmo raio em pixels cobre frações diferentes da cena, e as comparações entre bases devem considerar esse fator. O efeito da resolução sobre a via topológica foi avaliado em uma análise de sensibilidade (Seção 3.4). O *dataset* UCSB (Gelasca et al., 2008) é composto por 58 imagens RGB de tecido de câncer de mama (Figura Figura 2), sendo 32 benignas e 26 malignas, e possui o menor número de amostras entre os conjuntos avaliados.



(a) (b) (c) (d)

Figura 2 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.

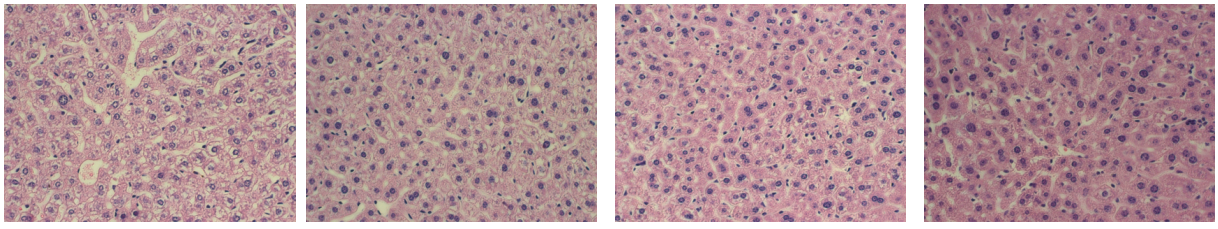
O *dataset* CR (Sirinukunwattana et al., 2017) contém 165 imagens RGB de tecido colorretal, obtidas a partir de 16 seções histológicas representativas de câncer colorretal nos estágios T3 e T4. O conjunto é levemente desbalanceado, com 74 imagens de tecido benigno e 91 de tecido maligno, e a resolução original é de 775×522 pixels em 151 imagens, enquanto 14 imagens (7 por classe) têm resoluções menores, de 567×430 a 589×453 pixels, com proporção diferente das demais (Figura Figura 3).



(a) (b) (c) (d)

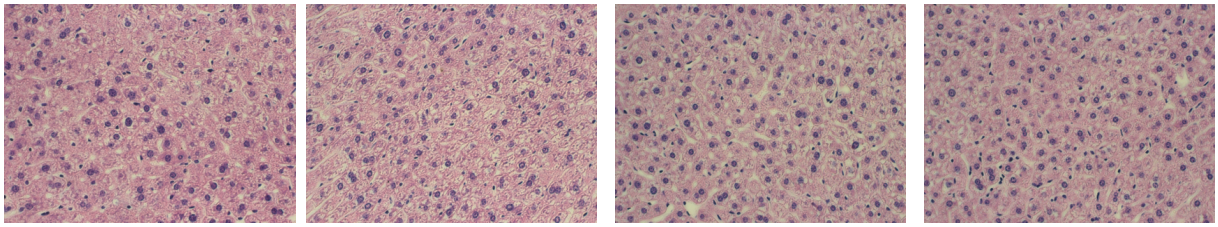
Figura 3 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

Os *datasets* LA e LG (Shamir et al., 2008) compreendem micrografias RGB de tecido hepático de camundongos. O LA tem como objetivo classificar a idade dos animais fêmeas em quatro grupos, com um mês (100 imagens), seis meses (115), 16 meses (162) e 24 meses (151), totalizando 528 imagens. O LG contém 265 imagens para classificação de sexo, divididas em 150 machos e 115 fêmeas. As amostras dos dois conjuntos estão nas Figuras Figura 4 e Figura 5.



(a) (b) (c) (d)

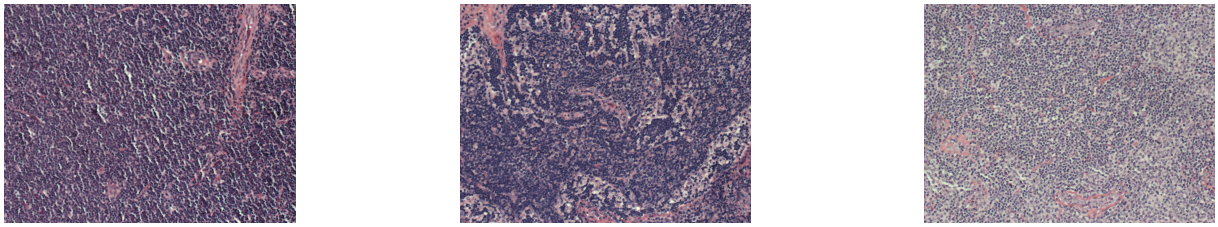
Figura 4 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).



(a) (b) (c) (d)

Figura 5 – Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.

O *dataset* NHL (Shamir et al., 2008) contém 374 imagens RGB de linfoma não Hodgkin, distribuídas em três classes diagnósticas: leucemia linfocítica crônica (*chronic lymphocytic leukemia*, CLL, 113 imagens), linfoma folicular (*follicular lymphoma*, FL, 139 imagens) e linfoma de células do manto (*mantle cell lymphoma*, MCL, 122 imagens). Diferentemente de aquisições realizadas em um único centro, o NHL reúne espécimes preparados por diferentes histologistas em diversos hospitais e laboratórios, com variações marcantes de coloração e iluminação (Figura Figura 6). Essa variabilidade cromática motivou a inclusão do conjunto. Como a validação cruzada foi realizada dentro do próprio conjunto e sem metadados de laboratório, o protocolo não avalia a generalização para laboratórios não vistos.



(a) (b) (c)

Figura 6 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

3.2 *TWO-STREAM NETWORK*

A arquitetura proposta, ilustrada na Figura Figura 1, é uma rede de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas. A via topológica representa a imagem por medidas de redes complexas processadas por uma rede recorrente, e a via visual extrai características diretamente da imagem RGB por uma arquitetura híbrida baseada em convoluções e atenção. As duas vias são independentes durante a extração. Os *embeddings* resultantes são projetados para a mesma dimensão, concatenados e classificados por um perceptron multicamadas (*Multilayer Perceptron*, MLP), e todos os parâmetros são ajustados em conjunto no treinamento (Seção 3.3).

Na arquitetura proposta, a via topológica descreve as relações entre pixels em raios de conexão crescentes, e a via visual aprende representações a partir dos pixels da imagem. O fundamento das arquiteturas de dupla via e da combinação das representações está na Seção 2.5.

O processamento ocorre em quatro etapas. A primeira extrai as características topológicas por redes complexas e as codifica por uma BiLSTM. A segunda extrai as características visuais pela MobileViT-S. A terceira projeta, normaliza e concatena os dois *embeddings*. A quarta classifica o vetor concatenado por um MLP.

3.2.1 Via topológica

A primeira via descreve a textura da imagem por medidas topológicas de redes complexas (Seção 2.2). Cada imagem foi convertida em uma rede direcionada e ponderada, na qual cada pixel é um vértice e as arestas ligam pixels cuja distância é de no máximo $r_{\max}$. O peso de cada aresta é a diferença absoluta de intensidade entre os pixels, e a direção vai do pixel de menor intensidade para o de maior intensidade (Scabini; Ribas; Bruno, 2020; Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). Para as imagens RGB foi adotada a configuração *full*, que estabelece conexões intracanal e intercanais (Scabini; Ribas; Bruno, 2020). A rede foi construída sobre a imagem original de 8 bits, na resolução nativa de cada *dataset*, sem redimensionamento e sem normalização. As medidas por raio são médias e desvios padrão sobre os vértices, de modo que imagens de tamanhos diferentes geram sequências com a mesma dimensão. Por serem determinísticas, as medidas foram calculadas uma única vez por imagem e reutilizadas em todas as partições e sementes.

Para cada vértice foram calculados o grau de saída, a força de saída e a força de entrada, acumulados até cada raio $r \in \{1, 2, \ldots, r_{\max}\}$, conjunto de medidas adotado por Ribas et al. (2024). O grau de entrada não foi utilizado. Em cada raio, a média global e o desvio padrão global das três medidas foram calculados para cada um dos três canais, o que produz 18 características por raio. A imagem é descrita pela sequência

$$X_{\text{top}} = [x_1, x_2, \ldots, x_{15}], \tag{1}$$

em que cada passo $x_r \in \mathbb{R}^{18}$ corresponde ao raio r, e a sequência completa contém 270 valores. As medidas por raio seguem a SSN (Scabini; Ribas; Bruno, 2020), e a sequência é processada por uma rede recorrente, e não pela rede neural aleatorizada (RaNN) de Ribas et al. (2024), cujos pesos de saída formam o descritor.

O raio de conexão variou de 1 a 15, de modo que $r_{\max} = 15$, intervalo analisado na literatura de redes complexas aplicadas à textura (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). A sensibilidade ao valor de $r_{\max}$ foi verificada na via topológica isolada, com $r_{\max} \in \{4, 7, 10, 15\}$ (Seção 3.4). Como o raio é medido em pixels, $r_{\max} = 15$ cobre uma fração maior da imagem nos conjuntos de menor resolução (LA e LG) e menor nos de maior resolução (NHL), o que altera a escala espacial descrita pelas medidas.

As medidas são acumuladas e crescem de forma monotônica com r, e assumem magnitudes elevadas nos raios maiores, o que pode saturar as portas da rede recorrente. Cada uma das 270 coordenadas de X_{top} foi padronizada pela média e pelo desvio padrão do conjunto de

treino de cada partição da validação cruzada, e os mesmos parâmetros foram aplicados às imagens de validação e de teste. Uma representação alternativa, formada pelas diferenças entre raios consecutivos, $\Delta x_r = x_r - x_{r-1}$ com $\Delta x_1 = x_1$, remove a monotonicidade das medidas acumuladas e foi avaliada nas ablações (Seção 3.4).

A sequência padronizada foi processada por uma rede *Long Short-Term Memory* bidirecional (BiLSTM) (Hochreiter; Schmidhuber, 1997; Schuster; Paliwal, 1997), com uma camada e 64 unidades ocultas por direção, o que resulta em cerca de 43 mil parâmetros. Essa dimensão reduzida foi adotada para limitar o risco de sobreajuste nos conjuntos menores, nos quais o treino contém cerca de 47 imagens (UCSB), após a separação do conjunto de validação. A rede opera no formato *many-to-one*, e o *embedding* topológico é a concatenação do estado final da leitura direta, do raio 1 ao 15, com o estado final da leitura inversa:

$$z_{\text{top}} = \left[\overrightarrow{h}_{15} \,\|\, \overleftarrow{h}_{1} \right] \in \mathbb{R}^{128}. \tag{2}$$

A leitura direta acumula, a cada passo, a informação dos raios menores nos raios maiores, o que corresponde à hipótese de que a organização em larga escala depende da organização local. A leitura inversa fornece a cada raio o acesso ao contexto das escalas maiores. A contribuição da segunda direção foi verificada por ablação contra a LSTM unidirecional, com suporte na literatura de redes bidirecionais (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005).

3.2.2 Via visual

A via visual extrai atributos diretamente da imagem RGB por meio da MobileViT, uma arquitetura híbrida que combina convoluções, que capturam detalhes celulares, e blocos *transformer*, que modelam o contexto do tecido em escala maior (Mehta; Rastegari, 2022; Oliveira et al., 2025). A variante MobileViT-S (*Small*) foi adotada por seu custo computacional reduzido (Mehta; Rastegari, 2022), adequado a bases de 58 a 528 imagens. O modelo recebeu a versão de 256×256 pixels da imagem (Seção 3.1), normalizada pela ImageNet, e a camada densa de classificação do topo da rede foi removida.

As ativações do último bloco convolucional foram agregadas por uma camada de agrupamento médio global (*Global Average Pooling*), que reduz cada mapa de características a um valor. Sendo I a imagem processada e $f_{\text{vis}}(\cdot)$ o codificador visual, o mapeamento é dado por

$$z_{\text{vis}} = f_{\text{vis}}(I), \tag{3}$$

em que $z_{\text{vis}} \in \mathbb{R}^{640}$ é o *embedding* visual. A rede foi inicializada com pesos pré-treinados na ImageNet e ajustada por *fine-tuning* junto com o restante do modelo.

3.2.3 Fusão por concatenação de *embeddings*

Os *embeddings* das duas vias foram combinados em nível de características, antes do classificador, na estratégia denominada fusão por concatenação de *embeddings* (Seção 2.5). Como o modelo é treinado de ponta a ponta, as duas vias são ajustadas em conjunto, e a separação entre elas se limita à extração das representações.

Os dois vetores têm escalas e dimensões distintas. Os valores de z_{top} são limitados ao intervalo $(-1, 1)$ pela tangente hiperbólica da célula de memória, enquanto z_{vis} resulta de ativações sem essa limitação, e a diferença de escala pode fazer as características de maior magnitude predominarem na primeira camada do classificador. O vetor visual, com 640 dimensões, também supera o topológico, com 128. Por esse motivo, z_{vis} foi projetado para 128 dimensões por uma camada linear, e cada vetor foi normalizado por *Layer Normalization* (LN) antes da concatenação:

$$\tilde{z}_{\text{vis}} = W_p\, z_{\text{vis}} + b_p, \qquad W_p \in \mathbb{R}^{128\times 640}, \tag{4}$$

$$z_{\text{fus}} = [\text{LN}(z_{\text{top}}) \parallel \text{LN}(\tilde{z}_{\text{vis}})] \in \mathbb{R}^{256}. \tag{5}$$

O símbolo $\parallel$ indica a concatenação dos vetores. O vetor z_{fus} contém 128 dimensões de cada via e é a entrada do classificador.

3.2.4 Classificador MLP

A classificação foi realizada por um MLP (Rumelhart; Hinton; Williams, 1986) com uma camada oculta de 128 neurônios, o que resulta em cerca de 33 mil parâmetros na primeira camada. A camada oculta é dada por

$$h = \text{ReLU}\left(W_1 z_{\text{fus}} + b_1\right), \tag{6}$$

em que a função de ativação linear retificada (*ReLU*) introduz a não linearidade. Sobre h foi aplicada uma camada de *Dropout* com probabilidade de desativação de $0{,}5$ durante o treinamento (Srivastava et al., 2014), como regularização para os conjuntos com poucas imagens, como UCSB e CR. A camada de saída tem C neurônios, com C igual ao número de classes de cada *dataset* (de 2 a 4), e as probabilidades são obtidas por

$$\hat{y} = \text{softmax}\left(W_2 h + b_2\right). \tag{7}$$

3.3 PROTOCOLO DE TREINAMENTO

A arquitetura foi treinada de ponta a ponta (*end-to-end*). Os parâmetros da MobileViT-S, da projeção, da BiLSTM e do MLP foram atualizados em conjunto pela minimização da entropia

cruzada, com o otimizador AdamW. A MobileViT-S, inicializada com pesos pré-treinados, foi ajustada com taxa de aprendizado de 1×10^{-5}, e os módulos inicializados aleatoriamente (BiLSTM, projeção e MLP) utilizaram taxa de 1×10^{-4}. O decaimento de pesos foi de **[XX]**, o tamanho do lote foi de **[XX]**, o agendador da taxa de aprendizado foi **[XX]** e o número máximo de épocas foi de **[XX]**. **[XX: informar se foi aplicado aumento de dados. Se sim, listar as transformações e confirmar que foram aplicadas apenas ao treino.]**

3.3.1 Validação

O desempenho foi estimado por validação cruzada estratificada com 10 partições (10-*fold*) (Kohavi et al., 1995), repetida com três sementes aleatórias distintas, o que resulta em 30 avaliações por *dataset*. Em cada avaliação, uma partição formou o conjunto de teste e as nove restantes formaram o conjunto de treino. A divisão estratificada preservou a proporção original das classes. Todos os métodos comparados utilizaram as mesmas partições.

Do conjunto de treino de cada avaliação, 10% das imagens foram separadas de forma estratificada como conjunto de validação, utilizado para a parada antecipada (*early stopping*) pela perda de validação, com paciência de **[XX]** épocas e restauração dos melhores pesos. A padronização das características topológicas e de todos os descritores clássicos foi ajustada apenas sobre as imagens de treino. O conjunto de teste não participou da escolha de épocas, de hiperparâmetros ou de parâmetros de padronização. O resultado de cada *dataset* corresponde à média e ao desvio padrão das métricas nas 30 avaliações.

3.3.2 Métricas

O desempenho da classificação foi quantificado pela acurácia, pelo F1-*score* macro e pela área sob a curva ROC (AUC-ROC). A acurácia é a proporção global de predições corretas. O F1-*score* macro é a média, entre as classes, da média harmônica da precisão e da sensibilidade de cada classe, e atribui o mesmo peso a todas as classes, o que o torna adequado a conjuntos desbalanceados, como o CR. A AUC-ROC mede a capacidade de distinguir as classes ao longo dos limiares de decisão e, nos conjuntos multiclasse (LA e NHL), foi calculada pela estratégia um-contra-todos (*one-vs-rest*) com média macro. As métricas foram calculadas em cada conjunto de teste e depois agregadas.

3.3.3 Limitações do protocolo

O protocolo apresenta limitações que são consideradas na interpretação dos resultados. No UCSB, cada conjunto de teste contém cerca de 6 imagens e o conjunto de validação, cerca de 5, de modo que as métricas por partição são discretas e o desvio padrão tende a ser elevado. As partições foram formadas por imagem. O CR reúne imagens de 16 seções histológicas, e os conjuntos LA e LG provêm de um número limitado de animais. Como identificadores de lâmina ou de animal não foram utilizados, imagens da mesma origem podem aparecer no treino

e no teste, o que pode superestimar o desempenho. O NHL não foi avaliado com a exclusão de laboratórios inteiros. Por fim, a via visual recebe um recorte central reduzido, que descarta as bordas das imagens não quadradas, e a via topológica recebe a imagem inteira, de modo que as duas vias não observam exatamente a mesma região. O raio de 15 pixels também cobre frações distintas da cena em cada *dataset*, e as 14 imagens do CR com resolução diferente da modal podem ter escala distinta das demais.

3.4 COMPARAÇÕES E ABLAÇÕES

O desempenho da arquitetura proposta foi comparado com os métodos de referência por meio do mesmo protocolo e das mesmas partições (Seção 3.3). As comparações foram organizadas em três grupos.

O primeiro grupo avalia se a combinação das duas vias supera cada via e as alternativas clássicas, e inclui:

- a via visual isolada (MobileViT-S, projeção e MLP),
- a via topológica isolada (BiLSTM e MLP),
- os descritores GLCM, LBP e HOG isolados, classificados pelo mesmo MLP,
- a MobileViT-S concatenada a cada descritor clássico (GLCM, LBP ou HOG) e classificada pelo mesmo MLP, como em Huang et al. (2022), que substitui apenas a via topológica e é a comparação mais direta com a proposta,
- a fusão de escores, calculada como a média das probabilidades das duas vias treinadas isoladamente (Yousaf; Nawaz; Habib, 2024; Nawaz et al., 2025).

Nas comparações com descritores clássicos, cada vetor foi padronizado com estatísticas do treino, projetado para 128 dimensões e normalizado por LN, de forma análoga a z_{top}. Os descritores clássicos foram calculados sobre a imagem na resolução original, a mesma da via topológica, e seus parâmetros foram **[XX]**.

O segundo grupo avalia a via topológica isolada, a fim de verificar se a recorrência contribui para o resultado. Foram comparadas as seguintes estratégias de codificação da sequência X_{top}:

- a BiLSTM e a LSTM unidirecional, que verifica a contribuição da leitura inversa,
- a GRU (Cho et al., 2014),
- um MLP sobre o vetor achatado de 270 valores,
- uma CNN unidimensional sobre a sequência.

Cada estratégia foi avaliada com as medidas acumuladas e com as diferenças entre raios consecutivos, e a melhor delas foi avaliada com $r_{\max} \in \{4, 7, 10, 15\}$. Se o MLP sobre o vetor achatado apresentar desempenho equivalente ao da BiLSTM, esse resultado será reportado e a contribuição da recorrência não será sustentada.

O terceiro grupo avalia a sensibilidade à resolução, escolha de entrada decisiva para a via topológica. A via topológica isolada foi calculada também sobre a imagem redimensionada para 256×256 pixels por interpolação de área, e o desempenho foi comparado ao da resolução original nas mesmas partições. No CR, o resultado principal foi obtido com as 165 imagens, e uma análise adicional restrita às 151 imagens de resolução 775×522 verificou se as 14 imagens de outra resolução afetam a conclusão. O critério dessa análise (manter apenas a resolução modal) foi definido antes da avaliação dos resultados.

3.5 CONFIGURAÇÃO DE AMBIENTE

Os experimentos foram implementados em Python com a biblioteca PyTorch (versão **[XX]**). A MobileViT-S e seus pesos pré-treinados foram obtidos de **[XX: biblioteca ou repositório]**. As redes complexas foram construídas por uma implementação em C++, com custo de **[XX]** segundos por imagem na resolução original de cada *dataset* com $r_{\max} = 15$. Na versão de 256×256 pixels usada na análise de sensibilidade, o custo medido no UCSB foi de 4,83 segundos por imagem (280 segundos para 58 imagens e 15 raios). Os descritores GLCM, LBP e HOG foram calculados com **[XX]**. O treinamento e a inferência foram executados em uma GPU **[XX]**, com tempo médio de **[XX]** por avaliação. As sementes aleatórias foram **[XX]**.

4 RESULTADOS E DISCUSSÃO

5 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006. ISSN 0370-1573.

BRUSSEE, S. et al. Graph neural networks in histopathology: Emerging trends and future directions. **Medical Image Analysis**, v. 101, p. 103444, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GELASCA, E. D. et al. Evaluation and benchmark for biological image segmentation. In: **2008 15th IEEE International Conference on Image Processing**. [S.l.: s.n.], 2008. p. 1816–1819.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989.

HUANG, X. et al. Fusing hand-crafted and deep-learning features in a convolutional neural network model to identify prostate cancer in pathology images. **Frontiers in Oncology**, v. 12, p. 994950, 2022.

HUSSAINI, H. et al. A clinically grounded review of medical image classification: Quantitative insights into cnns, vision transformers, and hybrid cnn-vit models. **Journal of Imaging Informatics in Medicine**, 2026. Disponível em: https://doi.org/10.1007/s10278-026-02249-8.

JESWANI, U.; PRIYADHARSHINI, S. Exploring facial feature extraction and temporal dynamics for deepfake video detection: A CNN-RNN study on FaceForensics++. In: **2026 International Conference on Innovative Trends in Information Technology (ICITIIT)**. [S.l.: s.n.], 2026.

JUN, K. et al. Feature extraction using an RNN autoencoder for skeleton-based abnormal gait recognition. **IEEE Access**, v. 8, p. 19196–19207, 2020.

KITTLER, J. et al. On combining classifiers. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 20, n. 3, p. 226–239, 1998.

KOHAVI, R. et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: **International joint conference on artificial intelligence**. Montreal, Canada: [s.n.], 1995. v. 14, n. 2, p. 1137–1145.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026. ISSN 0952-1976. Disponível em: https://www.sciencedirect.com/science/article/pii/S0952197626005439.

KUSHWAH, S. S.; PUNN, N. S.; BHATTACHARYA, M. EVC-Net: A hybrid deep learning network for breast cancer classification from histopathological images. **ACM Transactions on Intelligent Systems and Technology**, v. 17, n. 4, p. 87, 2026.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, J. Fusion feature-based hybrid methods for diagnosing oral squamous cell carcinoma in histopathological images. **Frontiers in Oncology**, v. 15, p. 1551876, 2025.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022. ArXiv:2110.02178.

MOLDOVANU, S. et al. Hybrid decision-level fusion of CNN-based deep and handcrafted features for colon cancer classification. **Journal of Imaging**, v. 12, n. 8, p. 368, 2026.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OJALA, T.; PIETIKÄINEN, M.; HARWOOD, D. A comparative study of texture measures with classification based on featured distributions. **Pattern Recognition**, v. 29, n. 1, p. 51–59, 1996.

OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 24, n. 7, p. 971–987, 2002.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMIR, L. et al. Iicbu 2008: a proposed benchmark suite for biological image analysis. **Medical & biological engineering & computing**, Springer, v. 46, n. 9, p. 943–947, 2008.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHORFUZZAMAN, M. et al. Ai-driven tumor characterization and histological subtype classification in lung cancer using ct imaging. **Diagnostics**, v. 16, n. 17, 2026. ISSN 2075-4418. Disponível em: https://www.mdpi.com/2075-4418/16/17/2805.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SIRINUKUNWATTANA, K. et al. Gland segmentation in colon histology images: The glas challenge contest. **Medical Image Analysis**, v. 35, p. 489–502, 2017. ISSN 1361-8415. Disponível em: https://www.sciencedirect.com/science/article/pii/S1361841516301542.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TALO, M. Automated classification of histopathology images using transfer learning. **Artificial Intelligence in Medicine**, v. 101, p. 101743, 2019. ISSN 0933-3657. Disponível em: https://www.sciencedirect.com/science/article/pii/S0933365719307110.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YE, M. et al. Feature selection and extraction in sequence labeling for arrhythmia detection. In: **2021 International Balkan Conference on Communications and Networking (BalkanCom)**. [S.l.: s.n.], 2021. p. 107–111.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHI, R.; WAN, M. Dynamic facial expression feature learning based on sparse RNN . In: **2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. [S.l.: s.n.], 2019. p. 1373–1377.