UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr.Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr.Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Entropias de Shannon e amostral em função do raio de conexão (1 a 15) para as bases CR, LA, LG, NHL e UCSB. As linhas tracejadas correspondem a cada base e as linhas contínuas, à média entre as bases. 20

Figura 2 Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM. 29

Figura 3 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 30

Figura 4 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 30

Figura 5 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 31

Figura 6 Imagens de cada gênero dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 31

Figura 7 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 31

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 28

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RGB	*Red, Green, Blue*
ViT	*Vision Transformer*

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 13

2 OBJETIVOS 15

3 FUNDAMENTAÇÃO TEÓRICA 16
3.1 Extração de *Features* 16
3.1.1 Descritores clássicos (*handcrafted*) 16
3.1.2 Extração por aprendizado profundo 17
3.2 Redes Complexas 18
3.2.1 Modelagem da imagem como rede direcionada 18
3.2.2 Medidas topológicas e configurações da rede 18
3.3 RNN na Extração de *Features* Topológicas 20
3.3.1 Redes recorrentes e *embedding* topológico 21
3.3.2 Redes recorrentes sobre *features* de imagens e escolha da arquitetura . . 22
3.4 Redes Híbridas para Extração de *Features* Visuais 23
3.4.1 Estratégias de integração entre convolução e atenção 23
3.4.2 MobileViT: o extrator adotado 24
3.4.3 Evidências comparativas e *embedding* visual 24
3.5 Fusão Tardia e MLP 25
3.5.1 Evidências sobre estratégias de fusão em redes de dupla via 26
3.5.2 Concatenação, classificador MLP e ressalvas 26

4 MATERIAIS E MÉTODOS 28
4.1 *Datasets* 28
4.2 *Two-Stream Network* 31
4.2.1 Extração de *features* texturais 31
4.2.2 Extração via MobileViT 31
4.3 Fusão Tardia 31
4.4 Classificador MLP 31
4.5 Protocolo de treinamento 31
4.5.1 Métricas 31
4.6 Configuração de ambiente 31

5 RESULTADOS E DISCUSSÃO 32

6 CONCLUSÃO 33

REFERÊNCIAS 34

1 INTRODUÇÃO

A histopatologia é responsável pelo diagnóstico precoce de patologias de tecidos agressivas como cânceres e doenças autoimunes, infecciosas e degenerativas. Geralmente esses diagnósticos são feitos manualmente por patologistas e demandam um processo de análise de extração de tecidos biológicos, coloração por meio de reagentes químicos (para realçar o contraste de estruturas celulares) e então a investigação microscópica de especialistas, e todo esse processo é custoso e pode ser acelerado por computadorização (Talo, 2019). Além do processo custoso, a falta de padronização entre laboratórios, a requisição de uma exaustiva anotação de imagens de tecidos, junto de restrições éticas e de privacidade de dados, dificultam a criação de grandes bases de imagens para utilização em modelos de aprendizado profundo (Kumar; Mishra, 2026). Apesar da escassez de imagens, técnicas como transferência de aprendizado, aumento de dados e extração de *features* estão sendo utilizadas na literatura para tornar possível a aplicação de modelos de *deep learning*, e os resultados obtidos mostram que em determinados casos os modelos superaram a precisão no diagnóstico quando comparados a especialistas da área (Bejnordi et al., 2017; Esteva et al., 2017).

As arquiteturas baseadas em aprendizado profundo são aplicadas para mitigar as limitações impostas pela avaliação humana. As Redes Neurais Convolucionais (CNNs) tornaram-se predominantes na automatização da extração de características locais em imagens médicas. A análise de lâminas inteiras exige frequentemente a divisão em pequenas áreas independentes, uma abordagem descontextualizada que viola o comportamento diagnóstico natural do patologista e compromete a perceção global do tecido (Kumar; Mishra, 2026). Para capturar correlações de longa distância, os *Vision Transformers* (ViTs) foram introduzidos na patologia digital (Shamshad et al., 2023). A combinação das capacidades das CNNs e dos ViTs resultou no desenvolvimento de modelos híbridos. Os resultados indicam que a união da extração de características locais com a atenção global proporcionada pelos modelos híbridos produziu um desempenho superior na análise de imagens histopatológicas quando comparado ao uso isolado de redes convolucionais ou transformadores (Oliveira et al., 2025; Dai et al., 2021).

A modelagem topológica oferece uma via alternativa para a extração de *features*. Fundamentada na teoria dos grafos (Euler, 1736), a abstração de redes complexas mapeia a dinâmica de sistemas intrincados (Boccaletti et al., 2006). Ao modelar os pixels de uma imagem como vértices e estabelecer arestas baseadas em distâncias métricas, descritores topológicos são obtidos para auxiliar na classificação de texturas (Backes; Casanova; Bruno, 2013; Zerati et al., 2026). O cálculo do peso dessas arestas a partir de diferenças de intensidade aprimorou a obtenção das características (Ribas et al., 2020; Ribas et al., 2024). A expansão progressiva do raio de conexão entre os nós gera uma sequência ordenada de descritores, caracterizando uma dinâmica na qual as macro-organizações dependem da distribuição dos componentes microscópicos. Para processar essa evolução histórica, as Redes Neurais Recorrentes (RNNs) interpretam a variação do grafo

como passos sequenciais e geram representações discriminatórias focadas na organização do tecido (Hochreiter; Schmidhuber, 1997).

A integração de múltiplas representações de dados eleva a precisão analítica de sistemas de inteligência artificial. Arquiteturas de dupla via (*Two-Stream Networks*) processam diferentes fontes de informação em paralelo para extrair representações distintas (Simonyan; Zisserman, 2014; Yousaf; Nawaz; Habib, 2024). A combinação de características visuais com assinaturas topológicas é executada de maneira eficiente por meio da fusão tardia (*Late Fusion*). A estratégia de fusão tardia atua diretamente nas camadas de decisão dos modelos e permite que as representações independentes sejam combinadas sem interferir na estabilidade do treinamento inicial (Kittler et al., 1998; Wang et al., 2023). Na patologia computacional, a concatenação das características baseadas em conhecimento de domínio com atributos profundos tem provado ser uma solução eficaz para o treinamento de modelos precisos sob condições de escassez de dados (Baltrušaitis; Ahuja; Morency, 2019).

A literatura carece de abordagens que combinem representações visuais extraídas por modelos híbridos com assinaturas topológicas sequenciais em imagens médicas. A aplicação direta de métodos clássicos de extração de textura ignora as relações entre os canais de cor presentes nos exames histopatológicos originais. A motivação deste trabalho reside na hipótese de que a união da representação visual gerada por um modelo híbrido com a evolução topológica de uma rede complexa processada por uma arquitetura recorrente resulta em um classificador de alta acurácia. A justificativa para essa integração pauta-se na necessidade de contornar a escassez de imagens anotadas através do enriquecimento das características extraídas em cada amostra disponível.

As contribuições deste trabalho incluem a adaptação da modelagem de redes complexas para imagens histopatológicas coloridas e o desenvolvimento de uma arquitetura de dupla via baseada em fusão tardia. O modelo proposto processa as características morfológicas por meio de uma rede híbrida baseada em convolução e atenção em paralelo com o processamento da dinâmica topológica do tecido utilizando uma arquitetura recorrente. O sistema desenvolvido foi avaliado em bases de dados histopatológicas públicas. Os resultados demonstram a eficácia da abordagem proposta na classificação de tecidos celulares frente a modelos de referência consolidados.

2 OBJETIVOS

Este trabalho tem como objetivo geral explorar a utilização de imagens histopatológicas artificiais geradas por redes complexas para criar um *embedding* topológico por meio de uma RNN e uni-lo, por fusão tardia (*feature-level fusion*), a um *embedding* espacial oriundo de uma rede híbrida, investigando se essa técnica de análise topológica e espacial conjunta supera métodos consolidados na literatura.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- Modelar as imagens histopatológicas como redes complexas, variando o raio de conexão para gerar uma sequência de transformações que capture a evolução estrutural e multiescala do tecido celular.
- Implementar e treinar uma Rede Neural Recorrente (LSTM/RNN) capaz de processar a sequência temporal de imagens transformadas para extrair o *embedding* topológico profundo.
- Configurar e treinar a via espacial baseada em uma arquitetura híbrida para processar as imagens microscópicas originais, extraindo um *embedding* espacial focado em características visuais e morfológicas de textura.
- Desenvolver um módulo de fusão tardia para concatenar os *embeddings* espacial e topológico, submetendo o vetor unificado a uma rede perceptron de múltiplas camadas (MLP) para a classificação final.
- Avaliar e validar o desempenho do modelo *Two-Stream* proposto em conjuntos de dados histopatológicos, comparando sua precisão, sensibilidade e robustez frente a arquiteturas de linha de base (*baselines*) consolidadas na literatura.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* é uma medida numérica que resume aspectos relevantes da imagem, como bordas, texturas, formas e padrões de cor. A extração de *features* é o processo que mapeia a imagem bruta para uma representação de menor dimensão, utilizável, por exemplo, para melhorar a classificação por modelos de *deep learning* (Ramos-Soto et al., 2025). Em imagens médicas, uma *feature* corresponde a uma característica ou padrão relevante para a tarefa diagnóstica, como forma, tamanho, textura, densidade ou intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A qualidade dessa representação influencia a capacidade de generalização do classificador, principalmente quando há poucos dados, cenário recorrente na área da saúde devido a protocolos de privacidade, custos de aquisição e necessidade de especialistas para a rotulação (Litjens et al., 2017). Nenhum método de extração é superior em todos os casos, e a escolha depende da disponibilidade e da dimensionalidade dos dados, da existência de rótulos e da estratégia de aprendizado (Ahmed et al., 2023).

3.1.1 Descritores clássicos (*handcrafted*)

Os descritores clássicos (*handcrafted*) são calculados por procedimentos matemáticos fixados previamente, sem aprendizado a partir dos dados. Entre os mais utilizados em imagens médicas estão as estatísticas de primeira ordem, a matriz de coocorrência de níveis de cinza (GLCM), os padrões binários locais (LBP), o histograma de gradientes orientados (HOG), os filtros de Gabor e a transformada de características invariantes à escala (SIFT) (Ramos-Soto et al., 2025; Ahmed et al., 2023). Três deles (GLCM, LBP e HOG) são adotados neste trabalho como métodos comparativos da técnica proposta, e aparecem juntos em estudos de classificação de imagens médicas (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025).

Haralick, Shanmugam & Dinstein (1973) propuseram caracterizar a textura de um bloco de imagem por matrizes de dependência de tons de cinza, hoje conhecidas como GLCM. Cada elemento (i, j) da matriz registra quantas vezes um pixel de tom i ocorre como vizinho de um pixel de tom j, dada uma distância d e uma direção angular (0°, 45°, 90° ou 135°). A partir da matriz normalizada, os autores definiram 14 medidas de textura, entre elas o contraste, a correlação, a variância e a entropia, e aplicaram essas características como entradas em classificadores que obtiveram acurácias de teste acima de 82% em fotomicrografias de arenitos, fotografias aéreas e imagens de satélite. Como limitações, He & Wang (1989) apontam que a matriz depende da variação regional do fundo de intensidade da imagem e que a escolha do vetor de deslocamento é problemática.

O espectro de textura, proposto por He & Wang (1989) a partir do conceito de unidade de textura, codifica cada um dos oito vizinhos de um pixel central em um de três valores (0, 1 ou 2), conforme sua relação de intensidade com o pixel central, o que resulta em $3^8 = 6561$ unidades de textura possíveis. A distribuição de frequência dessas unidades ao longo da imagem funciona como descritor, e a redução das intensidades a três valores diminui o custo de cálculo e elimina a influência do fundo regional de intensidade e do ruído (Wang; He, 1990). Em quatro texturas naturais do álbum de Brodatz, o espectro alcançou acurácia média de 97,5% com um classificador de distância mínima (Wang; He, 1990). Os LBP seguem a mesma ideia de codificar a relação entre o pixel central e seus vizinhos, com uma codificação binária mais compacta e a descrição da imagem pelo histograma dos códigos.

O HOG foi proposto por Dalal & Triggs (2005) para detecção de pessoas e descreve a imagem pela distribuição local das direções de gradiente. A janela é dividida em células, em cada uma é acumulado um histograma das orientações de gradiente ponderadas pela magnitude, e as respostas são normalizadas quanto ao contraste em blocos sobrepostos para ganhar invariância a iluminação. A concatenação dos histogramas forma o descritor, que alimentou uma máquina de vetores de suporte (SVM) linear e reduziu as taxas de falsos positivos em mais de uma ordem de magnitude em relação ao melhor detector baseado em *wavelets* de Haar (Dalal; Triggs, 2005). Apesar de concebido para detecção, o HOG é empregado como descritor de bordas e forma em imagens médicas (Ramos-Soto et al., 2025).

3.1.2 Extração por aprendizado profundo

Os descritores *handcrafted* capturam relações locais entre pixels, em escalas e vizinhanças definidas previamente. As redes neurais convolucionais (CNNs), em contraste, aprendem filtros que vão de bordas e texturas nas primeiras camadas até padrões semânticos nas camadas finais, e se tornaram uma abordagem consolidada em análise de imagens médicas (Litjens et al., 2017). Em domínios com poucos dados, a transferência de aprendizado (*transfer learning*) permite empregar uma rede pré-treinada em uma base grande, como a ImageNet, como extrator de *features*, e a ativação de uma camada intermediária ou final é utilizada como vetor de características. Em Dehbozorgi, Ryabchykov & Bocklitz (2025), cinco redes pré-treinadas (VGG16, ResNet50, DenseNet121, MobileNetV2 e InceptionV3) em geral superaram os métodos estatísticos e de *radiomics* em sensibilidade e em tempo de extração, e a DenseNet121 alcançou 98,6% na base de tomografia de coerência óptica, contra 91% do *radiomics*. Os autores apontam como limitações a necessidade de GPUs, a dependência de grandes bases de dados e a baixa interpretabilidade.

A necessidade de capturar dependências de longo alcance motivou o uso de *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) e de arquiteturas híbridas que combinam convolução e atenção, como a CoAtNet (Dai et al., 2021), discutidas em revisões sobre *transformers* em imagens médicas (Shamshad et al., 2023). CNNs e ViTs tendem ao sobreajuste quando treinados em bases pequenas ou com alta variância intraclasse, e o MIAFEx (Ramos-Soto et al., 2025)

refina o *token* de classificação de um *Transformer* por pesos aprendíveis para atenuar esse problema. Em bases médicas pequenas, o MIAFEx superou extratores clássicos, CNNs e ViTs, e os autores reportam que essa vantagem diminui à medida que o conjunto de dados cresce. Como lesões e estruturas de interesse variam em tamanho e aparência, também é recorrente a análise em várias escalas, como na MMS-Net (Zhao et al., 2023), que combinou contexto multiescala local e global e manteve resultados competitivos com apenas 20% dos dados de treino. A análise da imagem em vários níveis de vizinhança é análoga à variação progressiva do raio de conexão nas redes complexas (Seção 3.2). *Features* aprendidas sobre dados ordenados por redes recorrentes e features topológicas extraídas de redes complexas são tratadas nas Seções 3.3 e 3.2,

3.2 REDES COMPLEXAS

A teoria de Redes Complexas (CN, do inglês *Complex Networks*) é uma abstração para modelar sistemas naturais cujos elementos interagem de maneira não trivial (Boccaletti et al., 2006). Essas redes foram empregadas para modelar os pixels de uma imagem e suas relações de vizinhança, o que permite que descritores baseados em topologia quantifiquem propriedades de textura de forma discriminativa (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). Neste trabalho, a abordagem segue a transformação por redes complexas empregada em Zerati et al. (2026) e é aplicada a imagens histopatológicas.

3.2.1 Modelagem da imagem como rede direcionada

Cada imagem é representada como uma rede complexa direcionada e ponderada $G = (V, E)$, na qual cada pixel é modelado como um vértice e as conexões entre pixels são estabelecidas dentro de um raio máximo r_{max}. Para um pixel $i = (x_i, y_i)$ em um canal de cor c da imagem I, é definido um vértice $v_i^{(c)} \in V$. Uma aresta direcionada é criada entre os vértices $v_i^{(c)}$ e $v_j^{(c_w)}$ quando a distância euclidiana quadrática entre os pixels satisfaz a Equação 1:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 < \rho_{ij}^2 \leq r_{max}^2, \tag{1}$$

em que x e y são as coordenadas dos pixels e ρ_{ij} é a distância euclidiana entre eles. A condição $\rho_{ij}^2 > 0$ exclui laços, isto é, a conexão de um pixel consigo mesmo. Cada aresta é associada a um raio discreto $r \in \{1, 2, \ldots, r_{max}\}$, definido como o menor inteiro que satisfaz $(r-1)^2 < \rho_{ij}^2 \leq r^2$, o que permite acumular as medidas da rede progressivamente sobre vizinhanças cada vez maiores.

O peso atribuído a cada aresta é a diferença absoluta de intensidade entre os pixels conectados, conforme a Equação 2:

$$w_{ij} = \left| I(x_i, y_i, c) - I(x_j, y_j, c_w) \right|. \tag{2}$$

O direcionamento de cada aresta é determinado pelas intensidades relativas dos pixels incidentes e vai do pixel de menor intensidade para o de maior intensidade. Quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$, a conexão é classificada como de saída (*out*) a partir de v_i e de entrada (*in*) em v_j.

No caso contrário, ela é classificada como de entrada em v_i. Conexões entre pixels de mesma intensidade são contabilizadas em ambas as direções. O grau de saída de um vértice conta seus vizinhos mais claros, e o grau de entrada conta seus vizinhos mais escuros.

3.2.2 Medidas topológicas e configurações da rede

O grau (*degree*) e a força (*force*) são calculados para cada vértice pela acumulação das quantidades correspondentes até o raio r, nas versões de saída e de entrada. O grau quantifica o número de conexões dentro da vizinhança considerada, como na Equação 3:

$$d_{out}(v_i, r) = \sum_{k=1}^{r} n_{out}(v_i, k), \tag{3}$$

em que $n_{out}(v_i, k)$ é o número de arestas de saída de v_i cujo raio discreto vale k, e o grau de entrada, $d_{in}(v_i, r)$, é calculado de forma análoga a partir de $n_{in}(v_i, k)$. A força incorpora as diferenças de intensidade e a proximidade entre os pixels, o que a torna sensível aos gradientes locais de textura. Para uma rede construída com raio r, cada aresta (v_i, v_j) recebe um peso de força que combina a diferença de intensidade normalizada com a distância normalizada, conforme a Equação 4:

$$\omega_{ij}^{(r)} = \begin{cases} \dfrac{w_{ij}}{2L}, & r = 1, \\ \dfrac{1}{2}\left[\dfrac{w_{ij}}{L} + \dfrac{\rho_{ij}^2 - 1}{r^2 - 1}\right], & r \geq 2, \end{cases} \tag{4}$$

em que $L = 255$ é o nível máximo de intensidade para imagens de 8 bits e w_{ij} é o peso dado pela Equação 2. A força de saída acumulada é dada pela Equação 5:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{5}$$

em que $\mathcal{N}_{out}^{(r)}(v_i)$ é o conjunto de vértices conectados a v_i por arestas de saída com $\rho_{ij}^2 \leq r^2$, e force$_{in}$ é definida de forma análoga sobre as arestas de entrada. O fator $r^2 - 1$ na Equação 4 é o valor máximo de $\rho_{ij}^2 - 1$ dentro de uma vizinhança de raio r, o que mantém o termo de distância no intervalo $[0, 1]$. Para $r = 1$, a única distância quadrática possível é $\rho_{ij}^2 = 1$, de modo que o termo de distância é nulo e o fator $r^2 - 1$ anularia o denominador, e nesse caso o peso é reduzido à componente de intensidade. As medidas resultam em quatro grandezas por vértice: grau de saída, grau de entrada, força de saída e força de entrada.

Para estender as medidas aos três canais de cor das imagens histopatológicas RGB, as formulações anteriores podem ser aplicadas em três configurações de rede (Scabini; Ribas; Bruno, 2020): *within-channel*, com $c = c_w$, *between-channel*, com $c \neq c_w$, e *full*, que inclui simultaneamente conexões intracanal e intercanal. A configuração *full* é adotada neste trabalho

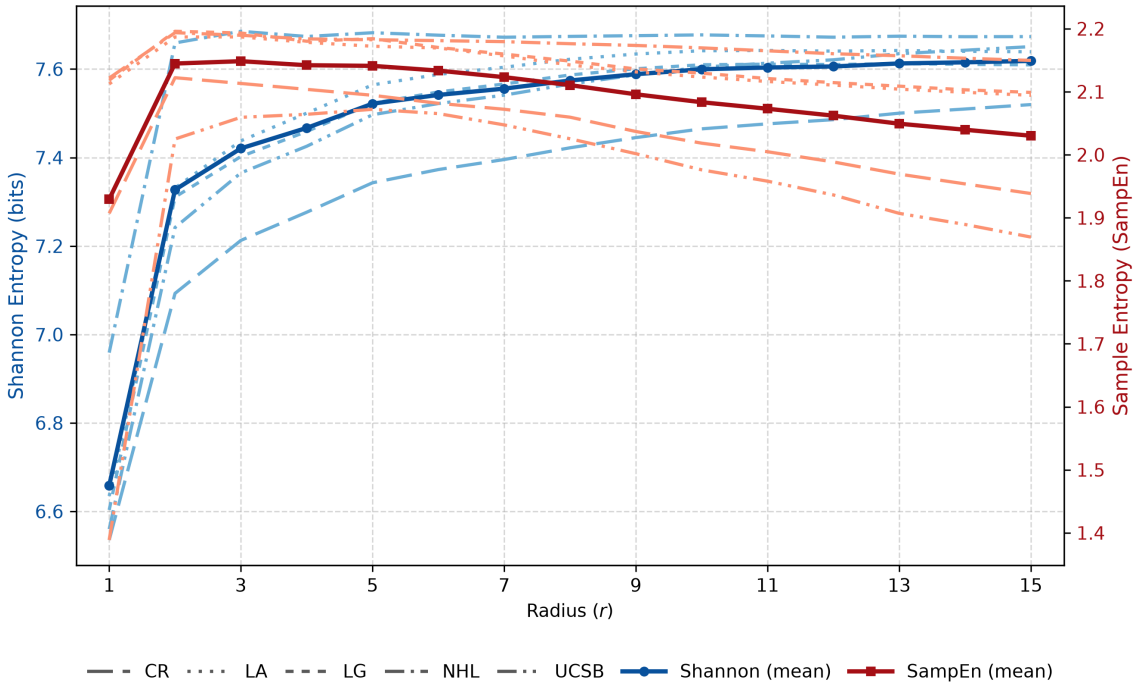


Figura 1 – Entropias de Shannon e amostral em função do raio de conexão (1 a 15) para as bases CR, LA, LG, NHL e UCSB. As linhas tracejadas correspondem a cada base e as linhas contínuas, à média entre as bases.

para capturar conjuntamente as transições de intensidade e as relações cromáticas entre canais (Zerati et al., 2026). O raio máximo r_{max} foi selecionado pela avaliação de raios de 1 a 15 em todas as bases de dados, esse intervalo foi selecionado considerando valores explorados na literatura (Zerati et al., 2026; Scabini et al., 2026). A entropia de Shannon, utilizada para quantificar as mudanças na distribuição dos valores topológicos, cresceu até aproximadamente $r = 10$ e atingiu um platô a partir daí, e a entropia amostral teve pico em $r = 10$ e decresceu depois, conforme mostra a Figura Figura 1. Esses resultados, somados a achados anteriores de que combinações multiescala de raios são úteis (Ribas et al., 2024; Zerati et al., 2026), justificam a adoção de $r_{max} = 10$. À medida que r cresce, as características locais dos menores raios dão lugar a características progressivamente mais globais, e essa evolução ao longo dos raios forma a sequência processada pela via recorrente (Seção 3.3).

3.3 RNN NA EXTRAÇÃO DE *FEATURES* TOPOLÓGICAS

Na arquitetura proposta, a via sequencial transforma a evolução topológica da imagem, modelada como rede complexa (Seção 3.2), em um *embedding* topológico que é combinado com o *embedding* visual no estágio de fusão tardia (Seção 3.5). A *Spatio-Spectral Network* depende de um conjunto de raios (Scabini; Ribas; Bruno, 2020), e Ribas et al. (2024) exploraram essa dimensão: as medidas topológicas de cada vértice (grau de saída, força de entrada e força de saída) foram calculadas em vários raios $r = \{1, 2, \ldots, R\}$, e os valores obtidos em

$r = 1, \ldots, R-1$ formaram um vetor de entrada usado para prever o valor da mesma medida no raio máximo R. Os autores descrevem esse procedimento como uma análise multiescala da evolução topológica dos vértices, e a maior acurácia média nos três conjuntos de textura colorida foi obtida pela combinação de duas representações, com $R = 4$ e $R = 10$, o que indica que tanto a escala local quanto as escalas mais amplas contribuem para a discriminação.

A proposta deste trabalho difere no tratamento da sequência, onde em Ribas et al. (2024), a sequência de raios é achatada em um único vetor de entrada de uma rede neural aleatorizada de uma camada oculta, e o descritor da imagem são os pesos da camada de saída, calculados por mínimos quadrados regularizados. O artigo utiliza a sigla RNN para essa rede, mas ela não é recorrente, pois os valores de cada raio entram simultaneamente e a arquitetura não explora a ordem entre eles. Neste trabalho, a sequência é tratada como tal: uma série de passos $x_1, x_2, \ldots, x_R$ é definida, em que $x_t \in \mathbb{R}^d$ reúne as medidas topológicas calculadas sobre o grafo construído com o raio r_t, e uma rede recorrente a lê passo a passo, do menor raio para o maior. Essa organização reflete a hipótese de que as macroestruturas da imagem dependem da organização das microestruturas, de modo que o descritor do raio r_t deve ser interpretado à luz do que foi observado nos raios anteriores.

3.3.1 Redes recorrentes e *embedding* topológico

Uma rede neural recorrente processa uma sequência um elemento por vez e mantém um estado interno que carrega informação sobre os elementos anteriores (LeCun; Bengio; Hinton, 2015). Na rede recorrente simples de Elman (1990), o estado oculto depende da entrada atual e do estado anterior, com parâmetros compartilhados por todos os passos, e o número de parâmetros não depende do comprimento da sequência. O treinamento por retropropagação enfrenta o desaparecimento ou a explosão dos gradientes à medida que o intervalo entre entrada e saída aumenta (Bengio; Simard; Frasconi, 1994), e a LSTM (Hochreiter; Schmidhuber, 1997) mitiga esse problema com uma célula de memória c_t controlada por portas. Na formulação usual, que inclui a porta de esquecimento (Gers; Schmidhuber; Cummins, 2000), as atualizações são:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{6}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{7}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{8}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{9}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{10}$$

$$h_t = o_t \odot \tanh(c_t), \tag{11}$$

em que σ é a função sigmoide, $\odot$ denota o produto elemento a elemento e f_t, i_t e o_t são as portas de esquecimento, entrada e saída. A GRU (Cho et al., 2014) é uma alternativa com menos portas e menos parâmetros, e Greff et al. (2017) concluíram, em cerca de 5.400 execuções de

treinamento sobre oito variantes da LSTM, que nenhuma melhorou significativamente a LSTM padrão, o que sustenta seu uso como ponto de partida.

Uma RNN unidirecional lê a sequência em um único sentido, e a RNN bidirecional (Schuster; Paliwal, 1997) utiliza duas redes independentes, uma lendo a sequência na ordem original e outra na ordem inversa, e combina seus estados:

$$h_t = \left[\overrightarrow{h}_t \,\|\, \overleftarrow{h}_t \right]. \tag{12}$$

Em classificação de fonemas por quadro, as redes bidirecionais superaram as unidirecionais e a LSTM superou as RNNs convencionais (Graves; Schmidhuber, 2005). No presente caso, a sequência de raios está integralmente disponível na inferência, e não há restrição de causalidade que impeça a leitura nos dois sentidos. Como a imagem inteira recebe um único rótulo, a rede opera no formato *many-to-one*, e o *embedding* topológico z_{top} é definido como o estado final: $z_{\text{top}} = h_R$ em uma rede unidirecional e, em uma rede bidirecional, $z_{\text{top}} = [\overrightarrow{h}_R \,\|\, \overleftarrow{h}_1]$. Esse vetor tem dimensão fixa, o que permite concatená-lo ao *embedding* visual (Seção 3.4) e entregá-lo ao classificador da fusão tardia. Diferentemente do descritor de Ribas et al. (2024), cujos pesos de saída são obtidos por mínimos quadrados sem retropropagação, os parâmetros da rede recorrente são aprendidos por gradiente a partir do rótulo da classe, e o *embedding* é otimizado para a classificação.

3.3.2 Redes recorrentes sobre *features* de imagens e escolha da arquitetura

Embora a recorrência seja associada a sequências temporais, diversos trabalhos a aplicaram a *features* extraídas de imagens médicas, tratando-as como uma sequência ordenada. Shalini & Rathnamala (2026) organizaram *features* de imagens de histopatologia de mama em sequência para que a LSTM capture relações entre seus elementos que uma CNN, centrada em padrões locais, pode não explorar, e reportaram acurácia de 99,31% na base BreakHis. Mathiyalagi & Ravi (2026) alimentaram uma CNN-LSTM com *features* de textura da GLCM reduzidas por análise de componentes principais, em tomografias de pulmão, com acurácia de 98,45% e sem validação externa, e Akanksha et al. (2022) utilizaram *features* SIFT como entrada de uma RNN para classificar leucemia. Em outros casos, a sequência é formada por mapas de uma CNN, como em Zeng et al. (2025), em que uma BiLSTM modelou a relação entre fatias de tomografias de pulmão e sua remoção reduziu a acurácia em 12,42% na ablação. Fora de imagens, Lin et al. (2022) mostraram que diferentes comprimentos de sequência de entrada de uma LSTM contêm informações distintas e afetam a acurácia, o que é análogo à escolha do conjunto de raios r, e Kang et al. (2024) integraram, por uma camada totalmente conectada, um ramo de convoluções dilatadas multiescala com BiLSTM e um ramo sobre informação de estrutura molecular, uma organização de dupla via semelhante à do modelo aqui proposto.

A maior parte dos resultados acima de 98% provém de conjuntos pequenos, de dados tabulares ou de protocolos com validação limitada, e constitui evidência de viabilidade e não de

superioridade. Nenhum desses trabalhos constrói a sequência a partir de descritores topológicos de um grafo em raios crescentes, e a contribuição aqui proposta é essa organização, apoiada na formulação de Ribas et al. (2024). Quanto à escolha da rede recorrente, a literatura consultada não traz comparação direta entre arquiteturas para sequências de descritores topológicos, e os argumentos são de plausibilidade. Um perceptron multicamadas sobre o vetor achatado dos R passos trata todas as posições como entradas independentes, enquanto a rede recorrente acumula em seu estado o que foi visto nos raios anteriores. Os *transformers* requerem poucas premissas de projeto sobre a estrutura dos dados (Khan et al., 2022) e dependem de grandes volumes de dados ou de pré-treinamento (Dosovitskiy et al., 2020), e a via sequencial não dispõe de modelo pré-treinado para descritores topológicos, com bases médicas de dezenas a poucas centenas de imagens e conjuntos de raios curtos (valores de R entre 4 e 12 em Ribas et al. (2024)). Fawaz et al. (2019) observam, em revisão de arquiteturas profundas para classificação de séries temporais, que as redes recorrentes raramente são usadas por serem projetadas para uma saída por instante, sofrerem com gradientes em séries longas e serem difíceis de paralelizar. Os dois primeiros motivos são atenuados neste trabalho, pois a rede opera no formato *many-to-one* e a sequência é curta, e a mesma revisão trata perceptrons multicamadas e CNNs como alternativas legítimas. A vantagem da recorrência permanece uma hipótese a ser verificada experimentalmente, por exemplo contra um perceptron multicamadas sobre o vetor achatado e uma CNN unidimensional sobre a sequência.

3.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* VISUAIS

Na arquitetura proposta, a via visual extrai, diretamente da imagem RGB, o *embedding* visual que é combinado com o *embedding* topológico no estágio de fusão (Seção 3.5). As CNNs extraem com eficiência padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de longo alcance (Ma et al., 2026). Os *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) abordam esse problema pela autoatenção sobre sequências de *patches*, e são estudados em imagens médicas (Shamshad et al., 2023), mas a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). As arquiteturas híbridas combinam a captura de padrões locais das CNNs com a modelagem global dos *transformers*, em geral com blocos convolucionais que extraem informação localizada e mecanismos de atenção que integram o contexto global, o que é relevante em patologia computacional, em que a interpretação depende de detalhes morfológicos finos e de padrões em escala de tecido (Oliveira et al., 2025).

3.4.1 Estratégias de integração entre convolução e atenção

A literatura descreve diversas formas de integrar CNNs e *transformers*, e Oliveira et al. (2025) resumem duas taxonomias existentes, atribuídas a Kim et al. e a Khan et al. A taxonomia de Kim et al. separa projetos paralelos, em que CNN e ViT operam de forma independente e têm suas saídas fundidas, por exemplo por atenção cruzada, de projetos sequenciais, em que as *features* de um módulo alimentam o outro. A de Khan et al. é mais granular e distingue a integração em camadas iniciais, em camadas laterais, sequencial, paralela, em bloco, hierárquica, baseada em atenção e por reforço de canais. Os próprios autores propõem uma taxonomia por tarefa, na qual as arquiteturas de classificação consistem em um codificador de *features*, um estágio de adaptação e um classificador final, organização que corresponde, neste trabalho, ao MobileViT como codificador e ao perceptron multicamadas (MLP) da fusão tardia como classificador. A rede proposta é um projeto paralelo, pois as vias visual e topológica operam de forma independente e são combinadas apenas na fusão tardia. Na revisão de escopo de Oliveira et al. (2025), que analisou 39 estudos de histopatologia, a maioria dos trabalhos adotou arquiteturas integradas ou sequenciais, e os autores apontam limitações recorrentes: poucos estudos realizaram validação externa, muitos utilizaram bases pequenas e homogêneas, a maioria empregou validação por *holdout* em vez de validação cruzada e apenas 35,9% utilizaram técnicas de explicabilidade. O delineamento experimental deste trabalho considera essas observações e prevê validação cruzada estratificada e comparação com modelos de via única.

3.4.2 MobileViT: o extrator adotado

A CoAtNet (Dai et al., 2021) empilha convoluções eficientes nos estágios iniciais, que operam sobre mapas de alta resolução, e blocos de autoatenção nos estágios finais, sobre mapas de baixa resolução (Zaidkilani; Garcia; Puig, 2024), e ilustra o princípio de combinar convolução e atenção em sequência. O extrator adotado neste trabalho é o MobileViT, proposto por Mehta & Rastegari (2022) como uma rede híbrida leve. No bloco MobileViT, uma convolução $n \times n$ seguida de uma convolução pontual 1×1 gera uma representação local do tensor de entrada, essa representação é dividida em *patches* não sobrepostos, sobre os quais um *Transformer* codifica as relações entre *patches*, e o resultado é reorganizado, concatenado com a entrada e processado por uma nova convolução $n \times n$, que funde as informações local e global (Ding et al., 2023). O bloco combina convolução e autoatenção em um mesmo módulo, característica que Oliveira et al. (2025) atribuem aos projetos integrados.

A adoção do MobileViT tem três justificativas. A primeira é que o vetor final carrega informação local e global em um único módulo (Ding et al., 2023). A segunda é o baixo custo computacional, pois o HI-MViT, derivado do MobileViT, é descrito como leve e implantável em dispositivos móveis (Ding et al., 2023), e o MobileViT tem eficiência superior à de *transformers* puros (Wang et al., 2026), perfil adequado às bases pequenas previstas neste trabalho (de 68 a 528 imagens). A terceira é o desempenho em imagens médicas de diferentes modalidades: o HI-

MViT alcançou acurácia de 0,932 e F1 de 0,931 na base ISIC-2018 e superou em 3,4% a acurácia da ConvNeXt (Ding et al., 2023), e, em microscopia multiespectral de tecido, o MobileViT obteve a maior acurácia (91,70%) entre cinco arquiteturas, incluindo Swin-Transformer e ResNet (Wang et al., 2026). Outras variações exploram o mesmo princípio, como o LightSE-MobileViT, que insere um bloco *Squeeze-and-Excitation* para classificar câncer oral (Kabir et al., 2025), e a combinação de ResNet e MobileViT em um modelo de dupla entrada para ultrassom de mama (Zou et al., 2023).

3.4.3 Evidências comparativas e *embedding* visual

Arquiteturas de ramos paralelos também são empregadas. No CIHM, a camada CiMC combina em paralelo um ramo de modelo de espaço de estados (Mamba), que captura dependências de longo alcance com complexidade linear, e um bloco convolucional, que extrai detalhes locais (Ma et al., 2026), e o GSAC-UFormer integra em paralelo convolução em grupos e autoatenção adaptada por CNN (Garbaz et al., 2025). Estudos comparativos indicam que o desempenho depende da adequação da arquitetura ao domínio e que há um compromisso entre acurácia e custo computacional, como em quinze arquiteturas avaliadas em quatro bases de mamografia (Sharma; Singh; Choudhury, 2025). Acurácias próximas de 100% em bases com poucas centenas de imagens (Kabir et al., 2025; Kabir et al., 2026) são tomadas neste trabalho como evidência da viabilidade de cada desenho e não como desempenho esperado, pois a ausência de validação externa limita a generalização dos resultados (Oliveira et al., 2025).

No modelo proposto, o codificador híbrido produz, após uma etapa de *pooling* global ou do uso de um *token* de classificação, um vetor de dimensão fixa que resume a imagem (Ding et al., 2023; Ramos-Soto et al., 2025), e esse vetor é o *embedding* visual. A via visual utiliza o MobileViT como extrator, inicializado com pesos pré-treinados e ajustado por *fine-tuning*. A cabeça de classificação própria da rede é descartada, e o vetor imediatamente anterior a ela é entregue à etapa de fusão tardia, na qual é concatenado ao *embedding* topológico gerado pela RNN. O *embedding* visual captura padrões locais (via convolução) e globais (via atenção) da imagem, e o topológico captura a organização entre pixels e canais de cor ao longo de diferentes raios.

3.5 FUSÃO TARDIA E MLP

Na arquitetura proposta, a imagem é descrita por duas vias independentes: a via sequencial produz o *embedding* topológico z_{top} (Seção 3.3) e a via visual produz o *embedding* visual z_{vis} (Seção 3.4). A combinação de informações provenientes de fontes ou representações distintas é tratada pela literatura de aprendizado multimodal (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017), que descreve três abordagens de fusão independentes do modelo (Baltrušaitis; Ahuja; Morency, 2019). Na fusão precoce, de nível de *features*, as representações são combinadas, em geral por concatenação, antes de uma única etapa de aprendizado, o que

permite aprender interações entre as *features* de baixo nível de cada fonte. Na fusão tardia, de nível de decisão, cada fonte é processada por seu próprio modelo e apenas as saídas são combinadas, por média, votação, ponderação ou um modelo aprendido, o que permite usar o preditor mais adequado a cada fonte, mas ignora a interação entre elas em nível baixo. A fusão híbrida combina as duas abordagens. A combinação de decisões de classificadores distintos tem uma formulação clássica, com regras como soma, produto, máximo e voto majoritário (Kittler et al., 1998).

O termo *fusão tardia* é empregado com mais de um sentido nos trabalhos de redes de dupla via. As redes de dois fluxos para reconhecimento de ações (Simonyan; Zisserman, 2014) combinam as saídas de redes separadas apenas ao final. Yousaf, Nawaz & Habib (2024) usam fusão tardia no sentido de decisão, com média dos escores de classificação dos dois fluxos, e chamam de fusão em nível de *feature* a concatenação das representações antes do classificador. Nawaz et al. (2025), por outro lado, chamam de *late feature fusion* a concatenação dos vetores extraídos por duas redes independentes, seguida de um classificador. Neste trabalho, a fusão tardia segue o segundo sentido: cada via é processada de forma independente até produzir um vetor de dimensão fixa, os vetores são concatenados e um classificador treinável decide a classe. Ela difere da fusão precoce porque as vias não compartilham camadas de extração, e da fusão de decisões porque o classificador recebe as *features* das duas vias e não apenas os seus escores. A natureza das vias favorece essa escolha, pois a imagem entra na via visual como matriz de pixels e na via sequencial como série de medidas calculadas sobre grafos, e a fusão em nível de entrada é pouco natural.

3.5.1 Evidências sobre estratégias de fusão em redes de dupla via

Os trabalhos que compararam formas de combinar duas vias não apontam uma estratégia universalmente superior. Yousaf, Nawaz & Habib (2024) compararam fusão precoce, em nível de *feature* e de escores em uma rede de dois fluxos com EfficientNet-B7 e BiLSTM, e a fusão precoce teve o pior desempenho, com as duas demais próximas (F1 de 0,9316 na concatenação e de 0,9227 na média de escores). Essa arquitetura, com extrator convolucional pré-treinado, recorrência e concatenação seguida de camadas totalmente conectadas, é a mais próxima da proposta, embora as sequências sejam de quadros de vídeo. Nawaz et al. (2025) justificam a concatenação pela limitação de dados, pois métodos como *bilinear pooling* e redes de autoatenção exigem camadas adicionais com muitos parâmetros e podem levar a sobreajuste, e o melhor resultado (acurácia de 0,852 em 153 pacientes) foi obtido com extratores congelados, embora as faixas de variação entre as partições se sobreponham. Peng et al. (2025) concatenaram estatísticas calculadas do sinal com *features* aprendidas em diagnóstico de falhas com poucas amostras, uma estrutura análoga à proposta aqui, pois os descritores topológicos também são calculados e não aprendidos pela rede. Em imagens médicas, Wang et al. (2023) concatenaram *features* de dois fluxos (forma e textura) seguidas de seleção por atenção de canal e obtiveram acurácia de 0,967 em 17.397 imagens dermatoscópicas, com ganho sobre a rede de fluxo único. Alternativas com

interação entre as vias durante a extração, por atenção cruzada ou bidirecional, trouxeram ganhos pequenos sobre a concatenação em segmentação (0,5 ponto percentual de Dice em Sheng, He & Shi (2026)) e foram aplicadas a mapas densos dentro do codificador (Yang et al., 2026; Chen et al., 2025), o que difere da fusão de vetores globais.

3.5.2 Concatenação, classificador MLP e ressalvas

Dados os *embeddings* $z_{\text{top}} \in \mathbb{R}^{d_t}$ e $z_{\text{vis}} \in \mathbb{R}^{d_v}$, a fusão tardia forma o vetor conjunto

$$z = [\, z_{\text{top}} \,\|\, z_{\text{vis}} \,] \in \mathbb{R}^{d_t + d_v}, \tag{13}$$

que contém, lado a lado, a informação sobre a evolução topológica e sobre o aspecto visual da imagem. Os dois vetores têm origens e escalas diferentes: o estado oculto de uma LSTM é limitado ao intervalo $(-1, 1)$ pela tangente hiperbólica (Equação 11), e as ativações finais da rede visual não têm essa restrição, o que pode exigir normalizar cada vetor antes da concatenação.

O perceptron multicamadas é uma rede *feedforward* em que cada camada aplica uma transformação afim seguida de uma não linearidade, treinada por retropropagação do erro (Rumelhart; Hinton; Williams, 1986), e redes desse tipo, com ao menos uma camada oculta, são aproximadores universais de funções sob condições gerais (Hornik; Stinchcombe; White, 1989). Com uma camada oculta, o classificador é dado por

$$h = \mathrm{ReLU}(W_1 z + b_1)\,, \tag{14}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{15}$$

em que $\hat{y}$ é o vetor de probabilidades sobre as classes e os pesos são ajustados pela minimização da entropia cruzada, $\mathcal{L} = -\sum_c y_c \log \hat{y}_c$. O número de parâmetros do classificador cresce com a soma das dimensões dos *embeddings*, o que pesa em conjuntos com dezenas a poucas centenas de imagens, e a literatura consultada adota cabeças de tamanhos diversos, de uma única camada (Nawaz et al., 2025) a duas camadas totalmente conectadas, a primeira com 1024 unidades (Yousaf; Nawaz; Habib, 2024). O *dropout*, que desativa aleatoriamente unidades durante o treinamento, é uma técnica de regularização contra o sobreajuste (Srivastava et al., 2014). A hipótese de partida deste trabalho é uma cabeça pequena, com uma camada oculta e *dropout*, mantida simples pelo mesmo motivo apresentado por Nawaz et al. (2025): com poucos dados, camadas adicionais aumentam o risco de sobreajuste sem garantia de ganho.

Três ressalvas acompanham o uso da concatenação seguida de MLP. A primeira é que a literatura não aponta uma estratégia de fusão universalmente superior, e os ganhos de cada estratégia são pequenos frente à variação entre partições. A segunda é que a maior parte dos trabalhos combina vias de natureza comparável, e nenhum combina um *embedding* gerado por rede recorrente sobre descritores topológicos com um *embedding* visual. A terceira é que os resultados vêm de domínios diversos e raramente de imagens médicas com poucos exemplos, de

modo que a evidência é de viabilidade e não de superioridade garantida. A eficácia da fusão tardia por concatenação é tratada como hipótese a ser verificada experimentalmente, com comparação com as vias isoladas, como em Chen et al. (2025) e Wang et al. (2023), e com a média de escores como alternativa de decisão, como em Yousaf, Nawaz & Habib (2024) e Nawaz et al. (2025). A avaliação utiliza validação cruzada estratificada (Kohavi et al., 1995) e as métricas acurácia, F1 e AUC-ROC, relatadas por média e dispersão entre partições.

4 MATERIAIS E MÉTODOS

As imagens utilizadas são oriundas de cinco *datasets* histopatológicos, os quais são descritos na Seção 4.1. Esses conjuntos formam a entrada da etapa de extração de características (Seção 4.2), onde primeiramente gera-se as imagens artificiais, oriundas da CNIT, baseadas nas imagens originais, as quais respectivamente são utilizadas na via de extração de features texturais e na via da MobileViT. Após a etapa de extração de características é realizada uma concatenação dos vetores (Seção 4.3), que é utilizada em um classificador MLP (Seção 4.4) e então obtêm-se as métricas de classificação.

4.1 *DATASETS*

A avaliação foi realizada em *datasets* de imagens histopatológicas com 58 a 528 imagens cada. Os conjuntos abrangem tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, o que permitiu avaliar as técnicas de aumento de dados sob diferentes condições de disponibilidade de dados. A Tabela 1 resume as características de cada conjunto.

Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**
UCSB	Mama (benigno / maligno)	58	2	32 / 26
CR	Colorretal (benigno / maligno)	165	2	74 / 91
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151
LG	Gênero (macho / fêmea)	265	2	150 / 115
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122

Todas as imagens originais foram redimensionadas para 256×256 pixels por interpolação de área antes de qualquer técnica de aumento de dados, de modo que tanto as transformações complexas quanto o treinamento da WGAN-GP operassem sobre imagens de mesma dimensão. As transformações complexas (CNIT) operaram diretamente sobre as intensidades RGB discretas de 8 bits, $I \in [0, 255]$, preservando os valores fotométricos originais exigidos por sua formulação de métricas com $L = 255$. As imagens transformadas resultantes foram, em seguida, mapeadas para a faixa padrão de 8 bits, $[0, 255]$. Para a WGAN-GP, as imagens reais foram escaladas para $[-1, 1]$ durante o treinamento generativo. As imagens geradas foram então convertidas para a faixa $[0, 255]$ e redimensionadas de 256×256 para 224×224 pixels por interpolação de área. Por fim, as imagens produzidas por ambas as técnicas foram normalizadas com as médias por canal padrão do ImageNet, $[0{,}485;\ 0{,}456;\ 0{,}406]$, e os respectivos desvios padrão, $[0{,}229;\ 0{,}224;\ 0{,}225]$, antes de serem fornecidas aos modelos de classificação.

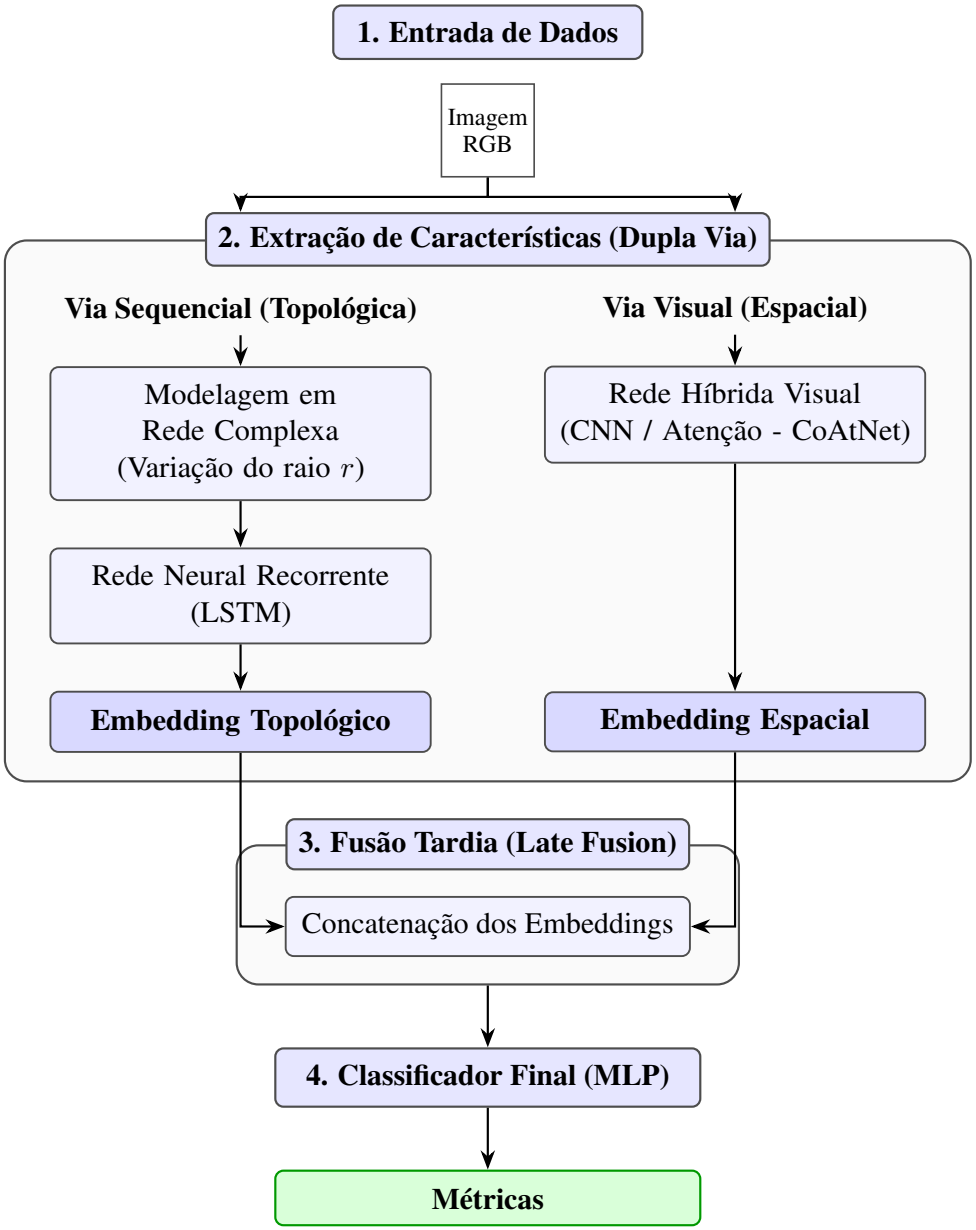
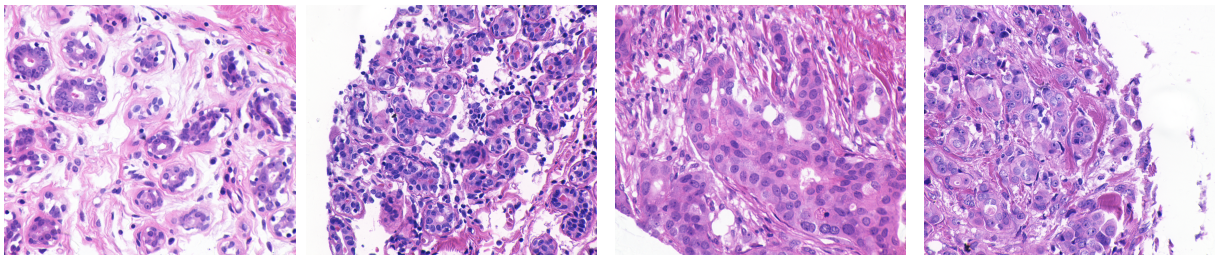


Figura 2 – Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM.

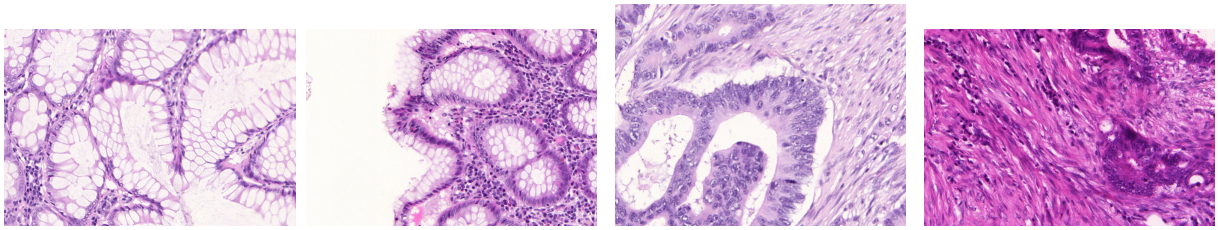
No contexto considerado, o *dataset* UCSB (**??**) é composto por 58 imagens RGB de tecido de câncer de mama (Figura Figura 3), sendo 32 benignas e 26 malignas, e possui o menor número de amostras entre os conjuntos avaliados.



(a) (b) (c) (d)

Figura 3 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.

O *dataset* CR (**??**) contém 165 imagens RGB de tecido colorretal, obtidas a partir de 16 seções histológicas representativas de câncer colorretal nos estágios T3 e T4. O conjunto é levemente desbalanceado, com 74 imagens de tecido benigno e 91 de tecido maligno, e aquisições originais com resoluções de 567×430 a 775×522 pixels (Figura Figura 4).

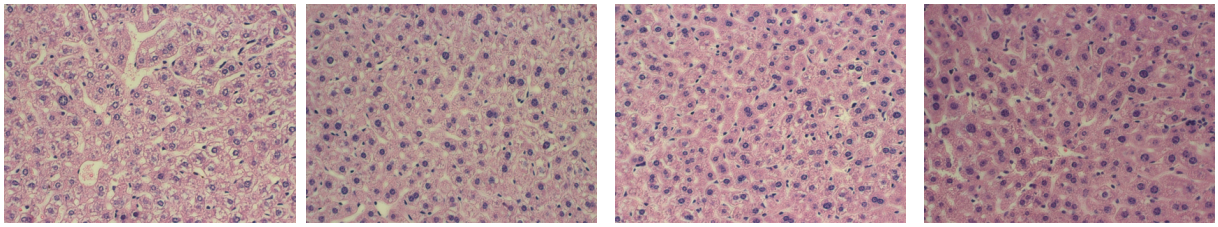


(a) (b) (c) (d)

Figura 4 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

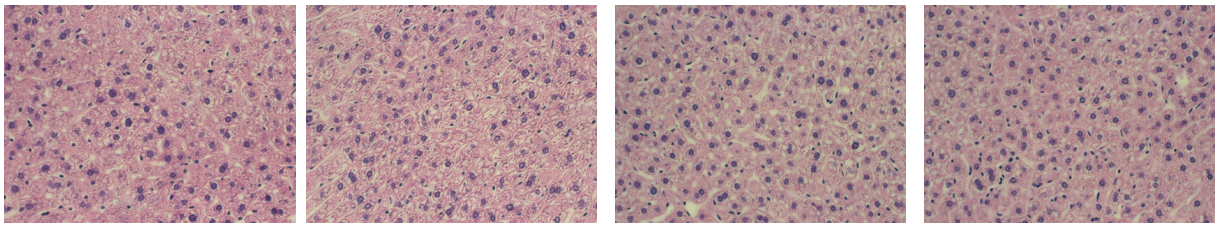
Os *datasets* LA e LG (**??**) compreendem micrografias RGB de tecido hepático de camundongos. O LA tem como objetivo classificar a idade dos animais fêmeas em quatro grupos: um mês (100 imagens), seis meses (115), 16 meses (162) e 24 meses (151), totalizando 528 imagens. O LG contém 265 imagens para classificação de gênero, divididas em 150 machos e 115 fêmeas. As Figuras Figura 5 e Figura 6 apresentam amostras dos dois conjuntos.

O *dataset* NHL (**??**) contém 374 imagens RGB de linfoma não Hodgkin, distribuídas em três classes diagnósticas: leucemia linfocítica crônica (*chronic lymphocytic leukemia*, CLL, 113 imagens), linfoma folicular (*follicular lymphoma*, FL, 139 imagens) e linfoma de células do manto (*mantle cell lymphoma*, MCL, 122 imagens). Diferentemente de aquisições realizadas em um único centro, o NHL reúne espécimes preparados por diferentes histologistas em diversos hospitais e laboratórios de histopatologia, apresentando marcantes variações de coloração e iluminação entre laboratórios (Figura Figura 7). Esse conjunto foi incluído especificamente para avaliar a robustez dos modelos e das técnicas de aumento de dados sob substancial variabilidade de domínio e cromática.



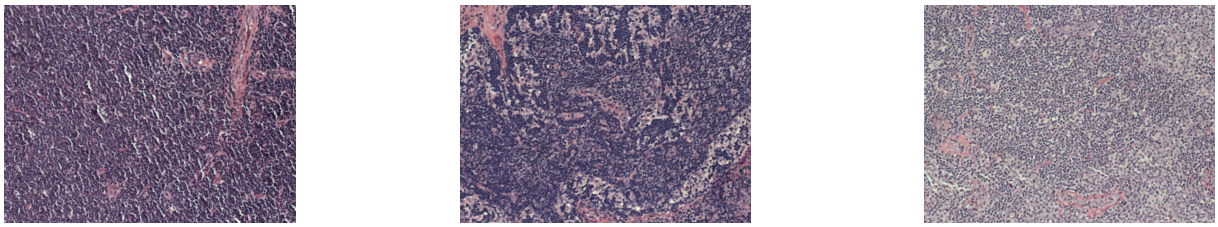
(a) (b) (c) (d)

Figura 5 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).



(a) (b) (c) (d)

Figura 6 – Imagens de cada gênero dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.



(a) (b) (c)

Figura 7 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

4.2 *TWO-STREAM NETWORK*

4.2.1 Extração de *features* texturais

4.2.2 Extração via MobileViT

4.3 FUSÃO TARDIA

4.4 CLASSIFICADOR MLP

4.5 PROTOCOLO DE TREINAMENTO

4.5.1 Métricas

4.6 CONFIGURAÇÃO DE AMBIENTE

5 RESULTADOS E DISCUSSÃO

6 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

AKANKSHA, M. N. V. et al. Implementation of potential leukemia detection using recurrent neural networks with blood cell counting. In: **2022 First International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)**. [S.l.: s.n.], 2022.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006. ISSN 0370-1573.

CHEN, Y. et al. Bidirectional feature fusion via cross-attention transformer for chrysanthemum classification. **Pattern Analysis and Applications**, v. 28, p. 41, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DAI, Z. et al. Coatnet: Marrying convolution and attention for all data sizes. **Advances in neural information processing systems**, v. 34, p. 3965–3977, 2021.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. **Nature**, Nature Publishing Group, v. 542, n. 7639, p. 115–118, 2017.

EULER, L. Solutio problematis ad geometriam situs pertinentis. **Commentarii academiae scientiarum imperialis Petropolitanae**, v. 8, p. 128–140, 1736.

FAWAZ, H. I. et al. Deep learning for time series classification: a review. **Data Mining and Knowledge Discovery**, v. 33, n. 4, p. 917–963, 2019.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

GREFF, K. et al. LSTM: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989.

KABIR, M. F. et al. Accurate and lightweight oral cancer detection using SE-MobileViT on clinically validated image dataset. **Discover Artificial Intelligence**, v. 5, n. 173, 2025.

KABIR, M. F. et al. TriGWONet: A lightweight multibranch convolutional neural network using gray wolf optimization for accurate oral cancer image classification. **Discover Artificial Intelligence**, v. 6, n. 91, 2026.

KANG, Y. et al. MMDB: Multimodal dual-branch model for multi-functional bioactive peptide prediction. **Analytical Biochemistry**, v. 690, p. 115491, 2024.

KHAN, S. et al. Transformers in vision: A survey. **ACM Computing Surveys**, v. 54, n. 10s, p. 1–41, 2022.

KITTLER, J. et al. On combining classifiers. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 20, n. 3, p. 226–239, 1998.

KOHAVI, R. et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: MONTREAL, CANADA. **International joint conference on artificial intelligence**. [S.l.], 1995. v. 14, n. 2, p. 1137–1145.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026. ISSN 0952-1976. Disponível em: https://www.sciencedirect.com/science/article/pii/S0952197626005439.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022. ArXiv:2110.02178.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PENG, H. et al. A lightweight triple-stream network with multisensor fusion for enhanced few-shot learning fault diagnosis. **IEEE Transactions on Reliability**, v. 74, n. 3, p. 4062–4075, 2025.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

SCABINI, L. et al. Complex networks for modeling texture and spectral features of hyperspectral images for environmental analysis. **Computers in Biology and Medicine**, v. 204, p. 111504, 2026.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHARMA, S.; SINGH, Y.; CHOUDHURY, T. Advanced deep learning architectures for enhanced mammography classification: A comparative study of CNNs and ViT. **Discover Artificial Intelligence**, v. 5, n. 187, 2025.

SHENG, M.; HE, S.; SHI, Z. GTUNet: a GNN and transformer enhanced U-Net for coronary artery segmentation. **Signal, Image and Video Processing**, v. 20, n. 10, p. 532, 2026.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TALO, M. Automated classification of histopathology images using transfer learning. **Artificial Intelligence in Medicine**, v. 101, p. 101743, 2019. ISSN 0933-3657. Disponível em: https://www.sciencedirect.com/science/article/pii/S0933365719307110.

WANG, C. et al. Research on tissue section negative detection algorithm based on multispectral microscopic imaging. **Journal of Innovative Optical Health Sciences**, v. 19, n. 2, p. 2550035, 2026.

WANG, L.; HE, D.-C. Texture classification using texture spectrum. **Pattern Recognition**, Pergamon Press, v. 23, n. 8, p. 905–910, 1990.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YANG, X. et al. DAPR-Net: Symmetric dual-stream pyramid architecture for non-rigid brain MRI registration. **Biomedical Signal Processing and Control**, v. 122, p. 110495, 2026.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZAIDKILANI, N.; GARCIA, M. A.; PUIG, D. Dual-stream CoAtNet models for accurate breast ultrasound image segmentation. **Neural Computing and Applications**, v. 36, p. 16427–16443, 2024.

ZENG, H. et al. MSSFN: A multi-scale sequence fusion network for CT-based diagnosis of pulmonary complications. **Neurocomputing**, v. 634, p. 129878, 2025.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHAO, C. et al. MMS-Net: Multi-level multi-scale feature extraction network for medical image segmentation. **Biomedical Signal Processing and Control**, v. 86, p. 105330, 2023.

ZOU, X. et al. Improved breast ultrasound tumor classification using dual-input CNN with GAP-guided attention loss. **Mathematical Biosciences and Engineering**, v. 20, n. 8, p. 15244–15264, 2023.