UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr.Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr.Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM. 40

LISTA DE TABELAS

Tabela 1 – Síntese dos trabalhos sobre extração de *features* discutidos nesta seção. . . . 22
Tabela 2 – Síntese dos trabalhos sobre redes recorrentes aplicadas a *features* discutidos nesta seção. 28
Tabela 3 – Síntese dos trabalhos sobre redes híbridas discutidos nesta seção. 34
Tabela 4 – Síntese dos trabalhos sobre fusão de duas vias discutidos nesta seção. 37

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RGB	*Red, Green, Blue*
ViT	*Vision Transformer*

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 14

2 OBJETIVOS 15

3 FUNDAMENTAÇÃO TEÓRICA 16

3.1 Extração de *Features* 16

3.1.1 Descritores clássicos (*handcrafted*) 16

3.1.1.1 Matriz de coocorrência de níveis de cinza (GLCM) 17

3.1.1.2 Espectro de textura e padrões binários locais (LBP) 17

3.1.1.3 Histograma de gradientes orientados (HOG) 18

3.1.1.3.1 Papel como métodos comparativos. 18

3.1.2 Extração por aprendizado profundo 19

3.1.3 Extração de *features* sequenciais com redes recorrentes 20

3.1.4 *Features* topológicas a partir de redes complexas 21

3.1.5 Síntese 21

3.2 Redes Complexas 23

3.3 RNN na Extração de *Features* Topológicas 24

3.3.1 A sequência estrutural gerada pela expansão do raio 24

3.3.2 Redes neurais recorrentes 25

3.3.3 Do estado oculto ao *embedding* topológico 26

3.3.4 Redes recorrentes sobre *features* de imagens na literatura 27

3.3.5 Por que uma rede recorrente e não uma alternativa 28

3.4 Redes Híbridas para Extração de *Features* Espaciais 29

3.4.1 Contexto local e contexto global 29

3.4.2 Estratégias de integração entre convolução e atenção 30

3.4.3 CoAtNet 30

3.4.4 MobileViT: o extrator adotado 31

3.4.4.0.1 Justificativa da escolha. 31

3.4.4.0.2 Variações em imagens médicas. 32

3.4.5 Ramos paralelos e arquiteturas multirramo 32

3.4.6 Evidências comparativas e cautelas 32

3.4.7 Embedding espacial e uso no modelo proposto 33

3.5 Fusão Tardia e MLP 33

3.5.1 Níveis de fusão em modelos de múltiplas vias 33

3.5.2 Evidências sobre estratégias de fusão em redes de dupla via 35

3.5.2.0.1 Comparação direta entre níveis de fusão. 35

3.5.2.0.2 Concatenação com poucos dados. *35*
3.5.2.0.3 Via de descritores manuais mais via aprendida. *36*
3.5.2.0.4 Concatenação seguida de seleção de features em imagens médicas. *36*
3.5.2.0.5 Fusão com interação entre as vias. *36*
3.5.3 Concatenação de *embeddings* e classificador MLP **37**
3.5.4 Ressalvas e comparação com alternativas **38**

4 METODOLOGIA **40**

5 RESULTADOS E DISCUSSÃO **41**

6 CONCLUSÃO **42**

REFERÊNCIAS **43**

1 INTRODUÇÃO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional ao permitir a extração de características semânticas complexas com alta precisão. Contudo, no domínio da saúde, a aplicação dessas técnicas frequentemente esbarra na escassez de imagens médicas anotadas, decorrente de rigorosos protocolos de privacidade, altos custos e da necessidade de especialistas para rotulação (Litjens et al., 2017). Para mitigar essa limitação, o aumento de dados (*Data Augmentation*) consolidou-se como uma etapa essencial. Ao expandir o espaço amostral, essas técnicas atuam como fortes regularizadores, reduzindo o sobreajuste (*overfitting*) e viabilizando o treinamento de modelos complexos em domínios restritos (Perez; Wang, 2017; Shorten; Khoshgoftaar, 2019).

Além das abordagens convencionais de transformação de imagem, a modelagem topológica oferece uma via promissora para o enriquecimento estrutural dos dados. Fundamentada na teoria dos grafos (Euler, 1736), a abstração de Redes Complexas mapeia a dinâmica de sistemas intrincados (Boccaletti et al., 2006). Trabalhos pioneiros (Backes; Casanova; Bruno, 2013) demonstraram que, ao modelar os pixels de uma textura como vértices e estabelecer arestas baseadas em um raio de distância euclidiana r, obtêm-se descritores topológicos robustos. A literatura evoluiu para incorporar o peso dessas arestas a partir de diferenças de intensidade (**??**). Contudo, diferentemente das abordagens clássicas de análise de textura – que comumente operam sobre imagens em escala de cinza, o presente projeto inova ao estender essa modelagem topológica para imagens RGB originais, capturando a complexa relação estrutural entre os canais de cor presentes em exames médicos.

A expansão progressiva do raio r gera uma sequência ordenada de descritores, caracterizando uma dinâmica análoga a uma série temporal na qual as macroestruturas dependem da organização das microestruturas. Para capturar essa evolução espacial histórica, as Redes Neurais Recorrentes (RNNs) (Hochreiter; Schmidhuber, 1997; Cho et al., 2014) emergem como a solução ideal, interpretando a variação do grafo como passos sequenciais e gerando representações altamente discriminatórias.

Para integrar essas dinâmicas topológicas com os atributos semânticos explícitos da imagem, arquiteturas híbridas de dupla via (*Two-Stream Networks*) consolidaram-se como uma estratégia de alto impacto (Simonyan; Zisserman, 2014). A proposta deste trabalho é processar, em paralelo, as assinaturas estruturais (via RNN) e as características espaciais visuais da imagem (através de arquiteturas baseadas em convolução e atenção, inspiradas em modelos como a CoAtNet (Dai et al., 2021)). A união dessas vias por meio de fusão tardia (*Late Fusion*) e concatenação de *embeddings* visa estabelecer um classificador coeso e de precisão superior para cenários de dados limitados.

2 OBJETIVOS

3 FUNDAMENTAÇÃO TEÓRICA

3.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* (característica) é uma medida numérica que resume algum aspecto relevante do dado. No caso de imagens, esses aspectos incluem bordas, texturas, formas e padrões de cor, e a extração de *features* é o processo que mapeia a imagem bruta para uma representação de menor dimensão, sobre a qual o classificador opera (Ramos-Soto et al., 2025). Em imagens médicas, uma *feature* corresponde a uma característica ou padrão relevante para a tarefa diagnóstica, como forma, tamanho, textura, densidade ou intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A qualidade dessa representação influencia diretamente a capacidade de generalização do classificador, especialmente quando há poucos dados disponíveis (Ramos-Soto et al., 2025), cenário recorrente na área da saúde em razão de protocolos de privacidade, custos de aquisição e da necessidade de especialistas para a rotulação (Litjens et al., 2017).

Não existe um método de extração universalmente superior. Segundo Ahmed et al. (2023), a escolha depende de fatores como a disponibilidade e a dimensionalidade dos dados, a existência de rótulos e o paradigma de aprendizado (supervisionado ou não supervisionado). Nas subseções seguintes, os métodos são organizados em três famílias: (i) descritores clássicos, projetados manualmente; (ii) representações aprendidas por redes profundas sobre a imagem; e (iii) representações aprendidas sobre dados sequenciais por redes recorrentes, com destaque para as *features* de natureza topológica que motivam este trabalho.

3.1.1 Descritores clássicos (*handcrafted*)

Os descritores clássicos são calculados por procedimentos matemáticos fixados previamente, sem aprendizado a partir dos dados. Entre os mais utilizados em imagens médicas estão: estatísticas de primeira ordem (como média e desvio padrão da intensidade); a matriz de coocorrência de níveis de cinza (GLCM) e as *features* de Haralick (Haralick; Shanmugam; Dinstein, 1973), que descrevem a relação espacial entre pares de pixels; os padrões binários locais (LBP) e seu antecessor, o espectro de textura (He; Wang, 1989; Wang; He, 1990); o histograma de gradientes orientados (HOG) (Dalal; Triggs, 2005); os filtros de Gabor; e a transformada de características invariantes à escala (SIFT) (Ramos-Soto et al., 2025; Ahmed et al., 2023). Um conjunto frequentemente adotado em estudos de *radiomics* é o do pacote *pyradiomics*, que agrega estatísticas de primeira ordem e matrizes de textura (GLCM, GLSZM, GLRLM, NGTDM e GLDM), totalizando 93 *features* por imagem em Dehbozorgi, Ryabchykov & Bocklitz (2025). Quando o vetor resultante é grande, é comum aplicar seleção ou redução de dimensionalidade, por exemplo com análise de componentes principais (PCA) (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ahmed et al., 2023).

Três desses descritores (GLCM, LBP e HOG) são adotados neste trabalho como métodos comparativos da técnica proposta. Eles são amplos em uso na análise de imagens médicas: em Dehbozorgi, Ryabchykov & Bocklitz (2025), por exemplo, o conjunto de *features* estatísticas é composto por média, desvio padrão, LBP, GLCM e HOG, e Ramos-Soto et al. (2025) também os incluem entre os extratores clássicos de referência. Cada um é descrito a seguir.

3.1.1.1 Matriz de coocorrência de níveis de cinza (GLCM)

Haralick, Shanmugam & Dinstein (1973) propuseram caracterizar a textura de um bloco de imagem a partir de matrizes de dependência espacial de tons de cinza, hoje conhecidas como matrizes de coocorrência (GLCM). Cada elemento (i, j) da matriz registra quantas vezes um pixel de tom i ocorre como vizinho de um pixel de tom j, dada uma distância d e uma direção angular (0°, 45°, 90° ou 135°); normalizada, a matriz representa a distribuição de probabilidade conjunta desses pares. A partir de cada matriz, os autores definem 14 medidas de textura, entre elas o momento angular de segunda ordem, o contraste, a correlação, a variância, o momento da diferença inversa e a entropia, que refletem aspectos como homogeneidade, dependências lineares de tons de cinza, contraste, número e natureza das bordas e complexidade da imagem. O custo de cálculo de cada medida é proporcional ao número de células de resolução do bloco, razão pela qual foram chamadas de rapidamente computáveis. O método foi avaliado em fotomicrografias de arenitos (cinco classes), fotografias aéreas (oito categorias de uso do solo) e imagens de satélite (sete categorias), com acurácias de teste de 89%, 82% e 83%, respectivamente (Haralick; Shanmugam; Dinstein, 1973). Como limitações, He & Wang (1989) apontam que a matriz depende não só das relações espaciais entre tons de cinza, mas também da variação regional do fundo de intensidade da imagem, e que a escolha do vetor de deslocamento é problemática.

3.1.1.2 Espectro de textura e padrões binários locais (LBP)

O espectro de textura (*texture spectrum*) foi proposto por He & Wang (1989) a partir do conceito de unidade de textura (*texture unit*). Em uma vizinhança 3×3, cada um dos oito vizinhos do pixel central é codificado em um de três valores (0, 1 ou 2), de acordo com sua relação de intensidade com o pixel central, o que resulta em $3^8 = 6561$ unidades de textura possíveis. A distribuição de frequência dessas unidades ao longo da imagem, o espectro de textura, funciona como descritor, e imagens de texturas distintas apresentam espectros distintos (He; Wang, 1989). Segundo Wang & He (1990), a redução das intensidades a apenas três valores diminui o custo de cálculo e elimina a influência do fundo regional de intensidade e do ruído. Em Wang & He (1990), o espectro foi usado para classificar quatro texturas naturais do álbum de Brodatz com um classificador de distância mínima, baseado na soma das diferenças absolutas entre espectros, e obteve acurácia média de 97,5%. Os padrões binários locais (LBP) seguem a mesma ideia de codificar a relação entre o pixel central e seus vizinhos e de descrever a imagem

pelo histograma dos códigos obtidos, com uma codificação binária mais compacta que a do espectro de textura.

3.1.1.3 Histograma de gradientes orientados (HOG)

O HOG foi proposto por Dalal & Triggs (2005) para detecção de pessoas, e descreve a imagem pela distribuição local das direções de gradiente. A janela é dividida em pequenas regiões espaciais (células), e em cada célula acumula-se um histograma das orientações de gradiente ponderadas pela magnitude. Para ganhar invariância a iluminação e sombreamento, as respostas são normalizadas quanto ao contraste em blocos maiores e sobrepostos, e a concatenação dos histogramas normalizados forma o descritor, que alimenta um classificador (no trabalho original, uma máquina de vetores de suporte (SVM) linear). A configuração padrão dos autores usa filtro de gradiente $[-1, 0, 1]$ sem suavização, nove *bins* de orientação entre 0° e 180°, blocos de 16×16 pixels formados por quatro células de 8×8 pixels, normalização L2-Hys e passo de 8 pixels entre blocos, em uma janela de 64×128 pixels. O descritor reduziu as taxas de falsos positivos em mais de uma ordem de magnitude em relação ao melhor detector baseado em *wavelets* de Haar e levou a separação quase perfeita no conjunto MIT de pedestres (Dalal; Triggs, 2005). Embora tenha sido concebido para um problema de detecção, o HOG é amplamente empregado como descritor de bordas e forma em imagens médicas (Ramos-Soto et al., 2025).

3.1.1.3.1 Papel como métodos comparativos.

GLCM, LBP e HOG descrevem a imagem a partir de relações locais entre pixels (pares de tons de cinza, códigos de vizinhança e orientações de gradiente), em escalas e vizinhanças definidas previamente e, em geral, sobre imagens em níveis de cinza. A técnica proposta neste trabalho, em contraste, modela a imagem RGB como um grafo e analisa a evolução de suas medidas topológicas à medida que o raio de conexão aumenta, de modo que a comparação com esses três descritores permite avaliar o ganho de uma representação topológica sequencial sobre as abordagens clássicas de textura e forma.

Esses métodos têm vantagens de interpretabilidade e baixo custo de treinamento, mas apresentam limitações importantes. De acordo com Ramos-Soto et al. (2025), eles capturam padrões locais simples (bordas e gradientes), mas têm dificuldade em representar características de alto nível, não modelam o contexto global da imagem, são sensíveis a ruído e artefatos e escalam mal para dados de alta dimensão. Em um estudo comparativo com imagens de histologia (H&E), raio-X de tórax e tomografia de coerência óptica (OCT) da retina, Dehbozorgi, Ryabchykov & Bocklitz (2025) observaram que as *features* estatísticas e de *radiomics* foram as mais lentas de extrair e as de menor desempenho: na base de H&E, a extração estatística levou cerca de uma hora e atingiu 90,8% de sensibilidade média, enquanto a ResNet50 reduziu o tempo em quatro vezes e elevou a sensibilidade a 96,9%. Resultado semelhante aparece fora do domínio de imagens: em detecção de arritmia por eletrocardiograma (ECG), Ye et al.

(2021) compararam descritores manuais (intervalos RR, FFT, *wavelets*, estatísticas de ordem superior e funções de Hermite) com a alimentação do sinal bruto em classificadores profundos, e concluíram que o sinal bruto superou as *features* manuais em todos os classificadores avaliados, embora os classificadores profundos tenham apresentado maior tempo de inferência.

3.1.2 Extração por aprendizado profundo

Redes neurais convolucionais (CNNs) aprendem, de forma hierárquica e a partir dos próprios dados, filtros que vão de bordas e texturas nas primeiras camadas a padrões semânticos nas camadas finais, o que as tornou a abordagem dominante em análise de imagens médicas (Litjens et al., 2017). Uma estratégia amplamente usada em domínios com poucos dados é a transferência de aprendizado (*transfer learning*), na qual uma rede pré-treinada em uma base grande, como a ImageNet, é empregada como extrator de *features*: a imagem é propagada pela rede e a ativação de uma camada intermediária ou final é usada como vetor de características. Em Dehbozorgi, Ryabchykov & Bocklitz (2025), cinco redes pré-treinadas (VGG16, ResNet50, DenseNet121, MobileNetV2 e InceptionV3) produziram entre 512 e 2048 *features* por imagem, com tempos de extração de aproximadamente 10 minutos (MobileNetV2, a mais rápida) a 15 minutos (DenseNet121), e em geral superaram os métodos estatísticos e de *radiomics* em sensibilidade nas três modalidades; na base de OCT, por exemplo, a DenseNet121 alcançou 98,6%, contra 91% do *radiomics*. Os autores destacam, porém, limitações do uso de redes profundas: necessidade de GPUs, dependência de grandes bases de dados e baixa interpretabilidade.

A necessidade de capturar dependências de longo alcance motivou o uso de *Vision Transformers* (ViT) (Dosovitskiy et al., 2020) e de arquiteturas híbridas que combinam convolução e atenção, como a CoAtNet (Dai et al., 2021), discutidas em revisões sobre *transformers* em imagens médicas (Shamshad et al., 2023). Tanto CNNs quanto ViTs, contudo, tendem ao sobreajuste quando treinados em bases pequenas ou com alta variância intraclasse (Ramos-Soto et al., 2025). Para atenuar esse problema, Ramos-Soto et al. (2025) propuseram o MIAFEx, que utiliza o *token* de classificação ([CLS]) de um *Transformer* encoder como representação global da imagem e o refina por meio de pesos aprendíveis (multiplicação elemento a elemento sobre o vetor de dimensão 768), permitindo amplificar ou atenuar dimensões conforme sua relevância. As *features* resultantes podem alimentar classificadores tradicionais. Em bases médicas pequenas, o MIAFEx superou extratores clássicos, CNNs e ViTs; em contrapartida, os autores reportam que essa vantagem diminui à medida que o conjunto de dados cresce. Como exemplo, na base de biópsias histológicas com classificador SVM, o MIAFEx obteve 81,25% de acurácia, contra no máximo 56,25% dos descritores clássicos avaliados.

Outro aspecto relevante é a escala. Lesões e estruturas de interesse variam em tamanho e aparência, e extratores de escala única tendem a ter dificuldade em representá-las. No contexto de segmentação, a MMS-Net (Zhao et al., 2023) combina módulos de conexão de salto (*skip connection modules*), que extraem contexto multiescala local, com uma rede piramidal de *features* (FPN), que agrega informação multiescala global, e manteve resultados competitivos

mesmo com apenas 50% e 20% dos dados de treino. Essa ideia de analisar a imagem em vários níveis de vizinhança é análoga à variação progressiva do raio de conexão nos modelos de redes complexas discutidos adiante.

3.1.3 Extração de *features* sequenciais com redes recorrentes

Redes neurais recorrentes (RNNs) são projetadas para dados ordenados: a cada passo, o estado oculto combina a entrada atual com a memória dos passos anteriores. Variantes com portas, como a memória de longo e curto prazo (*Long Short-Term Memory*, LSTM) (Hochreiter; Schmidhuber, 1997) e a unidade recorrente com portas (*Gated Recurrent Unit*, GRU) (Cho et al., 2014), mitigam o problema do desaparecimento do gradiente e permitem modelar dependências mais longas (Jun et al., 2020). Para fins de extração de *features*, o estado oculto final (ou a saída de um codificador recorrente) funciona como um *embedding* que resume a sequência inteira em um vetor de dimensão fixa, que pode então ser usado por um classificador.

Essa estratégia tem sido explorada em diferentes domínios. Jun et al. (2020) utilizaram autoencoders recorrentes (LSTM AE e GRU AE) para extrair automaticamente *features* de sequências de esqueletos em reconhecimento de marcha anormal. O autoencoder é treinado para reconstruir a entrada, o que tende a reduzir informação irrelevante e redundante no código latente. As *features* extraídas foram mais discriminativas e robustas que os dados originais e que *features* manuais; o LSTM AE superou o GRU AE; e os modelos híbridos (autoencoder seguido de modelo discriminativo) atingiram maior acurácia com menos épocas de treinamento e menos parâmetros que o modelo único alimentado com os dados originais. Os autores também observaram que o treinamento em duas etapas foi mais eficaz que o treinamento ponta a ponta com o mesmo fluxo de dados. Em expressões faciais dinâmicas, Zhi & Wan (2019) propuseram uma LSTM com restrição de esparsidade (SLSTM), baseada no algoritmo ISTA, que aprende códigos esparsos de forma automática, zera pesos de *features* pouco úteis e reduz a complexidade computacional em relação à LSTM convencional, com avaliação em detecção de dor (BioVid) e microexpressões (CASME II e SMIC).

Quando a entrada são imagens, é comum combinar uma CNN, que extrai *features* espaciais por quadro, com uma RNN, que agrega a informação ao longo da sequência. Jeswani & Priyadharshini (2026) compararam três arquiteturas CNN–RNN para detecção de *deepfakes* em vídeo e obtiveram o melhor resultado com ResNeXt50 e LSTM (acurácia de 0,80, F1 de 0,75 e área sob a curva ROC (AUC-ROC) de 0,80), embora em um conjunto de teste de apenas dez vídeos, limitação reconhecida pelos autores. Wu (2024) propuseram um modelo composto por CNN, RNN e mecanismo de atenção para dados complexos (imagens, textos e áudio) e reportaram desempenho superior ao de uma rede neural densa convencional nas curvas de treino e validação. Já S & Dharan (2025) empregaram uma RNN com atenção sobre os mapas de características de uma MobileNetV2 pré-treinada para gerar vetores de 512 dimensões para cada modalidade biométrica (face, impressão digital e íris), posteriormente combinados por um algoritmo de fusão e classificados por SVM, com acurácia de 99,50%. Esse último caso ilustra o

princípio de gerar um *embedding* por via de processamento e integrá-lo em um estágio posterior, tema da Seção 3.5.

Em todos os trabalhos acima, a dimensão sequencial é o tempo (quadros de vídeo, amostras de ECG, posturas de esqueleto). Neste trabalho, a sequência é construída de outra forma: a expansão progressiva do raio de conexão de um grafo gera uma série ordenada de descritores topológicos, de modo que a RNN passa a modelar a evolução estrutural da imagem em vez de uma evolução temporal.

3.1.4 *Features* topológicas a partir de redes complexas

Uma terceira família de métodos extrai *features* da organização estrutural da imagem, modelando-a como uma rede complexa (Boccaletti et al., 2006). Em análise de textura, Backes, Casanova & Bruno (2013) representaram os pixels como vértices e conectaram aqueles cuja distância euclidiana é menor que um raio r, obtendo descritores a partir de medidas de vértice como o grau; Ribas et al. (2020) estenderam a abordagem para redes ponderadas e a combinaram com redes neurais aleatorizadas. A formulação detalhada de grafos e medidas topológicas é apresentada na Seção 3.2.

O trabalho que inspirou esta proposta (Ribas et al., 2024) leva essa ideia para imagens coloridas por meio da *Spatio-Spectral Network* (SSN), proposta originalmente por Scabini, Ribas & Bruno (2020), um grafo direcionado em que as conexões dentro de cada canal de cor (rede W) representam as características espaciais e as conexões entre canais (rede B) representam padrões espectrais. A partir de um conjunto de raios, calculam-se medidas de vértice (grau de saída, força de entrada e força de saída) e, com elas, treina-se uma rede neural aleatorizada (*Randomized Neural Network*), cuja camada oculta tem pesos sorteados e cuja camada de saída é resolvida por mínimos quadrados, para prever a dinâmica de evolução da rede. Os pesos aprendidos na camada de saída são então adotados como descritor da imagem. O método combina, portanto, uma modelagem manual (a SSN) com um aprendizado de representação (a rede neural), e superou diversas técnicas da literatura, inclusive CNNs profundas, em quatro bases de textura colorida. Os próprios autores apontam como limitação a interpretação física das representações aprendidas (Ribas et al., 2024).

3.1.5 Síntese

O Quadro 1 resume os trabalhos discutidos. Dois pontos orientam as escolhas metodológicas desta proposta. Primeiro, as evidências indicam que *features* aprendidas superam descritores manuais em desempenho e em tempo de extração (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ye et al., 2021), mas que modelos profundos treinados com poucos dados tendem ao sobreajuste (Ramos-Soto et al., 2025), o que justifica o uso de modelos pré-treinados, de arquiteturas com atenção e de regularização em bases médicas pequenas. Segundo, descritores topológicos oferecem uma representação estrutural complementar à aparência visual (Ribas et al., 2024), e

redes recorrentes são adequadas para resumir sequências desses descritores em um *embedding* (Jun et al., 2020). Assim, este trabalho extrai dois *embeddings* em paralelo: um *embedding* topológico, gerado por uma RNN sobre a sequência de descritores do grafo RGB em diferentes raios, e um *embedding* espacial, gerado por um modelo visual híbrido de convolução e atenção. A integração desses vetores é tratada na Seção 3.5.

Tabela 1 – Síntese dos trabalhos sobre extração de *features* discutidos nesta seção.

Trabalho	**Domínio**	**Extração de *features***	**Resultado reportado**
Haralick, Shanmugam & Dinstein (1973)	Fotomicrografias, fotos aéreas e imagens de satélite	GLCM e 14 medidas de textura	Acurácia de teste de 89%, 82% e 83% nas três bases
Wang & He (1990)	Texturas naturais (Brodatz)	Espectro de textura (3×3, 6561 unidades)	Acurácia média de 97,5% em quatro texturas, com distância mínima
Dalal & Triggs (2005)	Detecção de pessoas	HOG (células e blocos normalizados) e SVM linear	Redução de falsos positivos em mais de uma ordem de magnitude frente a descritores com *wavelets*
Dehbozorgi, Ryabchykov & Bocklitz (2025)	H&E, raio-X, OCT	Estatísticas, *radiomics* e CNNs pré-treinadas	*Features* profundas com maior sensibilidade e menor latência (OCT: 98,6% com DenseNet121 *vs.* 91% com *radiomics*)
Ramos-Soto et al. (2025)	Imagens médicas (bases pequenas)	ViT com refinamento do *token* [CLS]	Superou extratores clássicos, CNNs e ViTs em bases pequenas; vantagem diminui com mais dados
Zhao et al. (2023)	Segmentação médica	Multiescala (SCM e FPN)	Resultados competitivos com 50% e 20% dos dados de treino
Ahmed et al. (2023)	Mamografia e RM	Revisão (GLCM, Haralick, Gabor, LBP, PCA, LVQ)	Escolha do método depende dos dados e da tarefa
Ye et al. (2021)	ECG	*Features* manuais *vs.* sinal bruto	Sinal bruto em CNN foi o melhor, com maior tempo de inferência
Jun et al. (2020)	Marcha (esqueleto)	Autoencoder LSTM/GRU	*Features* do autoencoder superaram os dados originais; LSTM AE superou GRU AE
Zhi & Wan (2019)	Expressões faciais (vídeo)	LSTM esparsa (SLSTM)	Seleção automática de *features* e menor complexidade
Jeswani & Priyadharshini (2026)	*Deepfake* (vídeo)	CNN e GRU/LSTM	ResNeXt50 + LSTM: acurácia de 0,80 e F1 de 0,75 (10 vídeos de teste)
Wu (2024)	Dados complexos (imagem, texto, áudio)	CNN, RNN e atenção	Superior a uma DNN convencional (curvas de acurácia)
S & Dharan (2025)	Biometria multimodal	MobileNetV2 e RNN com atenção	Acurácia de 99,50% após fusão e SVM
Ribas et al. (2024)	Textura colorida	SSN e rede neural aleatorizada	Superou diversos métodos, inclusive CNNs profundas, em quatro bases

3.2 REDES COMPLEXAS

A teoria de Redes Complexas (CN - *Complex Networks*) atua como uma abstração para modelar sistemas naturais onde os elementos interagem de maneira não trivial. Em visão

computacional, essas redes têm sido empregadas para modelar os pixels de uma imagem e suas adjacências, possibilitando que descritores baseados em topologia quantifiquem propriedades de textura de forma discriminativa (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). Neste trabalho, a abordagem é aplicada a imagens histopatológicas.

Para processar a imagem, a estrutura regular de *grid* de seus pixels é mapeada em um grafo direcionado ponderado $G = (V, E)$, no qual cada pixel na imagem original está associado a um vértice $v \in V$, e a relação entre um par de pixels define a formação de uma aresta e seu respectivo peso, $e \in E$ (Zerati et al., 2026). A formulação original de CNs direcionadas para imagens (Backes; Casanova; Bruno, 2013; Ribas et al., 2020) propõe mapear as conexões restritas a um raio circular de distância r, criando uma vizinhança na qual apenas os pixels dentro do raio r ao redor de um dado pixel se conectarão a ele, como descrito a seguir:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 < \rho_{ij}^2 \leq r^2. \tag{1}$$

Em que x e y representam as coordenadas do pixel correspondente ao nó v na imagem, e ρ descreve a distância euclidiana. Assim como o raio de conexão, a relação entre a intensidade do pixel formará o direcionamento do grafo, onde para $I(x_i, y_i) \geq I(x_j, y_j)$, a conexão torna-se direcionada do nó v_i de saída (*out*) para o nó v_j (Zerati et al., 2026; Ribas et al., 2024).

$$w_{ij} = \left| I(x_i, y_i) - I(x_j, y_j) \right|. \tag{2}$$

A extração de características da rede envolve computar medidas topológicas em diferentes raios. Neste estudo, foram empregados o grau (*degree*) (Backes; Casanova; Bruno, 2013) e a força (*force*) (Zerati et al., 2026) como medidas topológicas. Cada uma foi calculada nas versões de entrada e de saída, resultando em grau de entrada, grau de saída, força de entrada e força de saída. O grau quantifica as incidências no vértice v_i, contabilizando a quantidade de conexões direcionadas cujas intensidades sejam superiores ou inferiores à do vértice analisado.

Por outro lado, a medida força (Zerati et al., 2026) quantifica essas ligações de forma mais discriminativa, considerando as distâncias e intensidades de cada nó dentro do raio r. Cada medida pode ser computada da seguinte forma, levando em consideração também o peso de força que combina a diferença de intensidade normalizada com a distância espacial normalizada na Equação 3:

$$\omega_{ij}^{(r)} = \begin{cases} \dfrac{w_{ij}}{2L}, & r = 1, \\ \dfrac{1}{2}\left[\dfrac{w_{ij}}{L} + \dfrac{\rho_{ij}^2 - 1}{r^2 - 1}\right], & r \geq 2, \end{cases} \tag{3}$$

Sendo $L = 255$ o nível de intensidade máximo da imagem, e força de saída quantificada

acumulada do raio 1 ao raio r em:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{4}$$

Em que $\mathcal{N}_{out}^{(r)}(v_i)$ representa os nós v_j para os quais v_i possui aresta de saída, e $\mathcal{N}_{in}^{(r)}(v_i)$, os nós que possuem aresta de entrada em v_i. A force$_{in}$ é calculada de forma análoga, com $\mathcal{N}_{in}^{(r)}$.

Essas propriedades formam uma estrutura matemática análoga a matrizes densas ou imagens discretas (Ribas et al., 2024; Zerati et al., 2026). Dessa forma, com a quantificação das medidas topológicas sob variados raios de limitação, a representação da rede complexa descreverá o crescimento espacial topológico ao longo dos raios (variações da distância circular r) (Scabini et al., 2026; Ribas et al., 2024). À medida que r aumenta, as características estritamente locais, observadas nos menores raios, dão lugar a características progressivamente mais globais.

Além disso, para estender as matrizes das medidas topológicas aos três canais de cor das imagens histopatológicas *RGB*, a estrutura das formulações pode ser utilizada nas configurações *Between-channel*, *Within-channel* e *Full* (Scabini; Ribas; Bruno, 2020). Neste trabalho, considera-se a configuração *Full*, que unifica simultaneamente os processos intracanal e intercanal sob as mesmas métricas (Zerati et al., 2026).

3.3 RNN NA EXTRAÇÃO DE *FEATURES* TOPOLÓGICAS

Na arquitetura proposta, a via sequencial é responsável por transformar a evolução topológica da imagem, modelada como rede complexa (Seção 3.2), em um *embedding* topológico que será combinado com o *embedding* espacial no estágio de fusão tardia (Seção 3.5). Esta seção apresenta, primeiro, como a variação do raio de conexão gera uma sequência ordenada de descritores; em seguida, os fundamentos das redes neurais recorrentes que processam essa sequência; depois, como o estado da rede é convertido em *embedding*; e, por fim, a evidência da literatura sobre o uso de redes recorrentes em *features* extraídas de imagens, bem como os argumentos e as ressalvas para preferi-las a alternativas não recorrentes.

3.3.1 A sequência estrutural gerada pela expansão do raio

Na modelagem de texturas por redes complexas, os pixels são representados como vértices e as arestas são criadas entre pares de pixels cuja distância euclidiana é menor ou igual a um raio r (Backes; Casanova; Bruno, 2013). O raio é, portanto, o único parâmetro que define a vizinhança de cada vértice: raios pequenos descrevem relações locais entre pixels próximos e, à medida que r cresce, regiões mais distantes passam a ser consideradas na topologia da rede. A *Spatio-Spectral Network* (SSN) estende essa modelagem para imagens coloridas e também depende de um conjunto de raios (Scabini; Ribas; Bruno, 2020).

O trabalho que inspirou esta proposta (Ribas et al., 2024) explora justamente essa dimensão. Para cada vértice, as medidas topológicas (grau de saída, força de entrada e força de saída; o grau de entrada é omitido por ser uma transformação linear do grau de saída) são calculadas em vários raios $r = \{1, 2, \ldots, R\}$, e os valores obtidos em $r = 1, \ldots, R-1$ formam um vetor de entrada usado para prever o valor da mesma medida no raio máximo R. Os autores descrevem esse procedimento como uma análise da evolução topológica dos vértices à medida que a vizinhança aumenta, isto é, uma análise multiescala. Nos três conjuntos de textura colorida usados para definir os parâmetros, a maior acurácia média foi obtida combinando duas representações, com $R = 4$ e $R = 10$ raios, o que indica que tanto a escala local quanto as escalas mais amplas contribuem para a discriminação.

Há, porém, uma diferença importante entre aquele trabalho e a proposta deste TCC. Em Ribas et al. (2024), a sequência de raios é *achatada* em um único vetor de entrada de uma rede neural aleatorizada de uma camada oculta, e o descritor da imagem são os pesos da camada de saída, calculados por mínimos quadrados regularizados. Embora o artigo utilize a sigla RNN para essa rede, ela não é recorrente: os valores de cada raio entram simultaneamente, sem que a ordem entre eles seja explorada pela arquitetura. Os próprios autores indicam como direções futuras o emprego de redes mais profundas e de arquiteturas neurais alternativas (Ribas et al., 2024). Neste trabalho, a sequência é tratada como tal: em vez de um vetor único, define-se uma série de passos $x_1, x_2, \ldots, x_R$, em que $x_t \in \mathbb{R}^d$ reúne as medidas topológicas calculadas sobre o grafo construído com o raio r_t, e uma rede recorrente a lê passo a passo, do raio menor para o maior.

Essa organização reflete a hipótese de que as macroestruturas da imagem dependem da organização das microestruturas: o descritor do raio r_t deve ser interpretado à luz do que já foi observado nos raios anteriores, o que é precisamente a função do estado oculto de uma rede recorrente.

3.3.2 Redes neurais recorrentes

Uma rede neural recorrente processa uma sequência um elemento por vez, mantendo um estado interno que carrega informação sobre os elementos anteriores (LeCun; Bengio; Hinton, 2015). Na rede recorrente simples de Elman (1990), o estado oculto h_t depende da entrada atual x_t e do estado anterior h_{t-1}; em sua forma usual atualmente, com tangente hiperbólica,

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)\,, \tag{5}$$

em que W_x, W_h e b são parâmetros aprendidos e compartilhados por todos os passos da sequência. Esse compartilhamento faz com que o número de parâmetros não dependa do comprimento da sequência.

O treinamento por retropropagação ao longo da sequência enfrenta uma dificuldade conhecida: à medida que o intervalo entre a entrada e a saída aumenta, os gradientes tendem

a desaparecer (ou a explodir), o que dificulta o aprendizado de dependências de longo prazo (Bengio; Simard; Frasconi, 1994). A LSTM (Hochreiter; Schmidhuber, 1997) mitiga esse problema com uma célula de memória c_t controlada por portas. Na formulação usual, que inclui a porta de esquecimento (Gers; Schmidhuber; Cummins, 2000), tem-se:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{6}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{7}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{8}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{9}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{10}$$

$$h_t = o_t \odot \tanh(c_t), \tag{11}$$

em que σ é a função sigmoide, $\odot$ denota o produto elemento a elemento e f_t, i_t e o_t são as portas de esquecimento, entrada e saída. A GRU (Cho et al., 2014) é uma alternativa com menos portas e, portanto, menos parâmetros. Em um estudo com cerca de 5.400 execuções de treinamento sobre oito variantes da LSTM em reconhecimento de fala, reconhecimento de escrita e modelagem musical, Greff et al. (2017) concluíram que nenhuma variante melhorou significativamente a LSTM padrão e que a porta de esquecimento e a função de ativação da saída foram os componentes mais críticos. Esse resultado sustenta o uso da LSTM padrão como ponto de partida, sem a necessidade de variantes mais elaboradas.

Uma RNN unidirecional lê a sequência em um único sentido, de modo que o estado em t só conhece o passado. A RNN bidirecional (Schuster; Paliwal, 1997) utiliza duas redes independentes, uma lendo a sequência na ordem original e outra na ordem inversa, e combina seus estados:

$$h_t = \left[\overrightarrow{h}_t\,;\,\overleftarrow{h}_t\right]. \tag{12}$$

Em um problema de classificação de fonemas por quadro, Graves & Schmidhuber (2005) observaram que a LSTM superou as RNNs convencionais e que as redes bidirecionais superaram as unidirecionais. No presente caso, a sequência de raios está integralmente disponível no momento da inferência, de modo que não há restrição de causalidade que impeça a leitura nos dois sentidos.

3.3.3 Do estado oculto ao *embedding* topológico

Como a imagem inteira recebe um único rótulo, a rede recorrente opera no formato *many-to-one*: a sequência $x_1, \ldots, x_R$ é lida por completo e o estado final resume a evolução estrutural observada em todos os raios. O *embedding* topológico z_{top} é definido como esse estado final: $z_{\text{top}} = h_R$ em uma rede unidirecional ou, em uma rede bidirecional, a concatenação do último estado da leitura direta com o último estado da leitura inversa, $z_{\text{top}} = [\overrightarrow{h}_R\,;\,\overleftarrow{h}_1]$. Em ambos os casos, z_{top} é um vetor de dimensão fixa, independentemente da imagem, o que permite

concatená-lo ao *embedding* espacial produzido pelo MobileViT (Seção 3.4) e entregá-lo ao classificador da fusão tardia (Seção 3.5).

Diferentemente do descritor de Ribas et al. (2024), cujos pesos de saída são obtidos por um ajuste de mínimos quadrados sem retropropagação, os parâmetros da rede recorrente são aprendidos por gradiente a partir do rótulo da classe, de modo que o *embedding* é otimizado para a tarefa de classificação.

3.3.4 Redes recorrentes sobre *features* de imagens na literatura

Embora a recorrência seja associada a sequências temporais, diversos trabalhos a aplicam a *features* extraídas de imagens médicas, tratando-as como uma sequência ordenada. Shalini & Rathnamala (2026) justificam explicitamente esse procedimento: as *features* extraídas da imagem são organizadas em sequência para que a LSTM capture relações entre seus elementos que uma CNN, centrada em padrões espaciais locais, pode não explorar. Os autores propõem uma LSTM empilhada com mecanismo de autoatenção sobre *features* selecionadas por otimização, aplicada a imagens de histopatologia de mama (BreakHis), e reportam acurácia de 99,31%. Mathiyalagi & Ravi (2026) alimentam uma rede híbrida CNN–LSTM, com uma camada LSTM bidirecional de 128 unidades, com *features* de textura obtidas pela GLCM e reduzidas por análise de componentes principais, em tomografias de pulmão, com acurácia de 98,45%; os autores reconhecem, no entanto, que o desempenho em bases externas ainda precisa ser avaliado. Esse trabalho é particularmente próximo do presente, pois combina um descritor clássico de textura com uma rede recorrente. Akanksha et al. (2022) utilizam *features* SIFT como entrada de uma RNN para classificar leucemia em imagens de esfregaço sanguíneo, mas a descrição da arquitetura é escassa.

Em outros casos, a sequência não é de *features* isoladas, mas de mapas produzidos por uma CNN. Zeng et al. (2025) combinam uma CNN pré-treinada, um módulo de convolução multiescala e uma BiLSTM que modela a relação entre as fatias de tomografias de pulmão, em um conjunto pequeno de exames; a remoção da BiLSTM reduziu a acurácia em 12,42% no estudo de ablação, e o modelo completo atingiu acurácia de 82,54%. Nesse caso, a sequência é formada pelas fatias do exame, não pelo tempo. Há ainda trabalhos que, embora fora do domínio de imagens, apresentam arquiteturas e argumentos análogos aos desta proposta. Lin et al. (2022) estudam o comprimento da sequência de entrada de uma LSTM como hiperparâmetro e mostram que diferentes escalas de sequência contêm informações distintas e afetam a acurácia da predição da vida útil restante de motores de turbina; a ideia de que a escala da sequência merece investigação própria é análoga à escolha do conjunto de raios r. Kang et al. (2024) propõem, para predição de peptídeos bioativos, um modelo de dois ramos, um com convoluções dilatadas multiescala seguidas de BiLSTM e outro com convoluções sobre informação estrutural, cujas saídas são integradas por uma camada totalmente conectada, estrutura de dupla via semelhante à do modelo aqui proposto. Priyadarshini (2026) combinam uma CNN unidimensional e uma BiLSTM sobre dados estruturados de câncer ósseo e de anomalias da medula, com acurácias

de 98,55% e 96,04%, e Xu, Wei & Zeng (2025) integram CNN, autoatenção e BiLSTM para previsão de carga elétrica.

O Quadro 2 resume esses trabalhos. Três ressalvas devem acompanhar a leitura. Primeiro, a maior parte dos resultados acima de 98% provém de conjuntos pequenos, de dados tabulares ou de protocolos com validação limitada, e deve ser lida como evidência de viabilidade, não de superioridade. Segundo, nenhum desses trabalhos constrói a sequência a partir de descritores topológicos de um grafo em raios crescentes; a contribuição aqui proposta é essa organização, apoiada na formulação de Ribas et al. (2024). Terceiro, vários estudos misturam a recorrência com outros componentes (otimização por metaheurísticas, atenção, CNN), o que dificulta isolar a contribuição da rede recorrente.

Tabela 2 – Síntese dos trabalhos sobre redes recorrentes aplicadas a *features* discutidos nesta seção.

Trabalho	**Entrada da rede recorrente e arquitetura**	**Domínio**	**Resultado e ressalva**
Shalini & Rathnamala (2026)	*Features* selecionadas por otimização, organizadas em sequência; LSTM empilhada com autoatenção	Histopatologia de mama (BreakHis)	Acurácia de 99,31%
Mathiyalagi & Ravi (2026)	GLCM e PCA; CNN–LSTM com BiLSTM de 128 unidades	Tomografia de pulmão	Acurácia de 98,45%; sem validação externa
Akanksha et al. (2022)	*Features* SIFT; RNN	Esfregaço sanguíneo (leucemia)	Descrição metodológica escassa
Zeng et al. (2025)	Mapas de uma CNN por fatia; BiLSTM entre fatias	Tomografia de pulmão	Acurácia de 82,54%; ablação: $-12{,}42\%$ sem a BiLSTM
Lin et al. (2022)	Janelas deslizantes de diferentes comprimentos; LSTM de duas camadas	Vida útil de motores (C-MAPSS)	O comprimento da sequência afeta a acurácia; domínio distinto
Kang et al. (2024)	Convolução dilatada multiescala e BiLSTM, em ramo paralelo	Peptídeos bioativos	Melhor que o estado da arte em precisão e acurácia; domínio distinto
Priyadarshini (2026)	CNN 1D e BiLSTM sobre dados estruturados	Câncer ósseo e medula (dados tabulares)	Acurácia de 98,55% e 96,04%
Xu, Wei & Zeng (2025)	CNN, autoatenção e BiLSTM de duas camadas	Carga elétrica	Redução de 12% no erro percentual absoluto médio (MAPE); domínio distinto

3.3.5 Por que uma rede recorrente e não uma alternativa

A escolha da rede recorrente para a via sequencial se apoia em dois argumentos e uma ressalva, discutidos a seguir de forma cautelosa, pois a literatura consultada não traz uma comparação direta entre arquiteturas para sequências de descritores topológicos.

O primeiro é o viés indutivo da ordem. Um perceptron multicamadas aplicado ao vetor achatado dos R passos, como ocorre na rede aleatorizada de Ribas et al. (2024), trata todas as posições como entradas independentes, e o tamanho da primeira camada cresce linearmente com R. A rede recorrente processa cada passo com os mesmos parâmetros, e o seu estado

acumula o que foi visto nos raios anteriores, o que corresponde à hipótese de dependência entre microestruturas e macroestruturas descrita na Seção 3.3.1.

O segundo é a compatibilidade com conjuntos pequenos. Os *transformers* requerem poucos vieses indutivos em seu projeto (Khan et al., 2022), o que, em geral, os torna mais dependentes de grandes volumes de dados ou de pré-treinamento (Dosovitskiy et al., 2020). A via sequencial, ao contrário da visual, não dispõe de um modelo pré-treinado aplicável a descritores topológicos, e as bases médicas consideradas neste trabalho têm de dezenas a poucas centenas de imagens. Além disso, o conjunto de raios usado por Ribas et al. (2024) é curto (valores de R entre 4 e 12), o que deixa pouco espaço para que a autoatenção modele relações de longo alcance. Trata-se, contudo, de um argumento de plausibilidade, e não de uma evidência direta.

A ressalva vem da própria literatura de classificação de séries temporais. Fawaz et al. (2019), ao revisarem as arquiteturas profundas para essa tarefa, observam que as redes recorrentes são raramente usadas em classificação por três motivos: foram projetadas sobretudo para produzir uma saída por instante de tempo, sofrem com o desaparecimento de gradientes em séries longas e são difíceis de treinar e de paralelizar. Dois desses motivos são atenuados no presente caso: a rede opera em formato *many-to-one*, com uma única saída por imagem, e a sequência é curta, de modo que o problema descrito por Bengio, Simard & Frasconi (1994) é menos severo do que nas aplicações originais das LSTMs, e as portas se justificam aqui mais pelo controle de quanta informação dos raios anteriores é retida do que pela retenção de dependências muito longas. O terceiro motivo não é relevante em sequências de poucos passos. Ainda assim, a mesma revisão compara perceptrons multicamadas e redes convolucionais como alternativas legítimas, de modo que a vantagem da recorrência é uma hipótese a ser verificada experimentalmente, por exemplo contra um perceptron multicamadas sobre o vetor achatado e uma CNN unidimensional sobre a sequência.

3.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* ESPACIAIS

Na arquitetura proposta, a via visual é responsável por extrair, diretamente da imagem RGB, o *embedding* espacial que será combinado com o *embedding* topológico no estágio de fusão (Seção 3.5). Esta seção apresenta os fundamentos das redes híbridas, que combinam convolução e mecanismos de atenção, e discute como elas têm sido empregadas na análise de imagens médicas. O extrator adotado neste trabalho é o MobileViT, uma rede híbrida leve; por isso, a seção apresenta primeiro os fundamentos gerais e a CoAtNet, como referência de arquitetura híbrida, e em seguida detalha o MobileViT e a justificativa de sua escolha.

3.4.1 Contexto local e contexto global

As redes convolucionais (CNNs) são eficientes na extração de padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de longo alcance (Ma et al., 2026). Os *Vision Transformers*

(ViT) (Dosovitskiy et al., 2020) atacam esse problema por meio da autoatenção sobre sequências de *patches*, que permite modelar relações entre regiões distantes da imagem, e vêm sendo amplamente estudados em imagens médicas (Shamshad et al., 2023). Em contrapartida, a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). Além disso, como discutido na Seção 3.1, tanto CNNs quanto ViTs tendem ao sobreajuste em bases pequenas (Ramos-Soto et al., 2025).

As arquiteturas híbridas buscam combinar o viés indutivo local das CNNs com a capacidade de modelagem global dos *transformers*: em geral, blocos convolucionais extraem informação localizada e mecanismos de atenção integram o contexto global (Oliveira et al., 2025). Essa combinação é particularmente relevante em patologia computacional, em que a interpretação depende tanto de detalhes morfológicos finos quanto de padrões em escala de tecido (Oliveira et al., 2025).

3.4.2 Estratégias de integração entre convolução e atenção

A literatura descreve diversas formas de integrar CNNs e *transformers*. Oliveira et al. (2025) resumem duas taxonomias existentes: uma que distingue projetos paralelos, em que CNN e ViT operam de forma independente e têm suas saídas fundidas (por exemplo, por atenção cruzada), de projetos sequenciais, em que as *features* de um módulo alimentam o outro; e outra, mais granular, que inclui integração em camadas iniciais, laterais, em bloco, hierárquica, baseada em atenção e por reforço de canais. Os próprios autores propõem uma taxonomia por tarefa. Para classificação, as arquiteturas são compostas por um codificador de *features* (convolucional ou baseado em autoatenção), um estágio de adaptação que refina as *features* extraídas e um classificador final; para segmentação, por codificador, gargalo, decodificador e conexões de salto; e para detecção, por *backbone*, *neck* e *head*.

Na revisão de escopo de Oliveira et al. (2025), que analisou 39 estudos de histopatologia, a maioria dos trabalhos adota arquiteturas integradas ou sequenciais, e estratégias como aprendizado guiado cruzado e fusão por múltiplos caminhos são pouco exploradas. Os autores concluem que os modelos híbridos frequentemente superam abordagens convencionais, mas apontam limitações recorrentes: poucos estudos realizam validação externa, muitos usam bases pequenas e homogêneas, o aumento de dados é aplicado e relatado de forma inconsistente, a maioria emprega validação por *holdout* em vez de validação cruzada, apenas 35,9% utilizam técnicas de explicabilidade (em geral Grad-CAM) e a reprodutibilidade é prejudicada pela escassez de código público. Essas observações são consideradas no delineamento experimental deste trabalho, que prevê validação cruzada estratificada e comparação com modelos de via única.

3.4.3 CoAtNet

A CoAtNet (Dai et al., 2021) é uma arquitetura que empilha camadas convolucionais e de autoatenção. Conforme descrito por Zaidkilani, Garcia & Puig (2024), a rede possui cinco estágios: o primeiro é uma haste convolucional (duas convoluções 3×3 com normalização em lote e ativação GELU); o segundo e o terceiro empregam blocos MBConv, do tipo *inverted bottleneck* da MobileNetV2 (convolução 1×1 de expansão, convolução *depthwise* 3×3 e convolução 1×1 de projeção, com ramo residual); e os dois últimos aplicam blocos *Transformer*, formados por autoatenção com posição relativa seguida de uma camada *feed-forward*. Assim, as camadas iniciais, que operam sobre mapas de alta resolução, usam convoluções eficientes para extrair *features* locais, enquanto as camadas finais usam atenção sobre mapas de baixa resolução para extrair *features* globais (Zaidkilani; Garcia; Puig, 2024). A CoAtNet ilustra, assim, o princípio de empilhar convolução nas camadas iniciais e atenção nas finais, e é discutida aqui como referência de rede híbrida; o extrator adotado neste trabalho, entretanto, é o MobileViT (Seção 3.4.4).

Como ilustração de uma extensão dessa arquitetura, Zaidkilani, Garcia & Puig (2024) substituem as camadas de atenção dos estágios finais por um fluxo duplo, em que blocos de convolução e de autoatenção atuam em paralelo e têm suas saídas integradas, de modo que as camadas finais também considerem a informação local dos mapas de baixa resolução. Na segmentação de imagens de ultrassom de mama, a melhor variante atingiu coeficiente Dice de 78,84% na base UDIAT, contra 73,83% da CoAtNet original, e de 77,91% na BUSI, valores que os autores reconhecem como ainda distantes do ideal.

3.4.4 MobileViT: o extrator adotado

O extrator de *features* espaciais adotado neste trabalho é o MobileViT, proposto por Mehta & Rastegari (2022) como uma rede híbrida leve que combina convolução e *transformers*, e que tem sido amplamente usado em imagens médicas. No bloco MobileViT, conforme descrito por Ding et al. (2023), uma convolução $n \times n$ seguida de uma convolução pontual 1×1 gera uma representação local do tensor de entrada; essa representação é dividida em *patches* não sobrepostos, sobre os quais um *Transformer* codifica as relações entre *patches*; o resultado é reorganizado na forma espacial original, concatenado com a entrada e processado por uma nova convolução $n \times n$, que funde as informações local e global. O HI-MViT, proposto para classificação de lesões de pele, combina convolução comum, blocos Improved-MV2 (expansão 1×1, convolução *depthwise* separável e projeção 1×1, com conexão residual), blocos MobileViT, *pooling* global e camadas totalmente conectadas, e alcançou acurácia de 0,932 e F1 de 0,931 na base ISIC-2018 (Ding et al., 2023).

3.4.4.0.1 Justificativa da escolha.

A adoção do MobileViT como extrator se apoia em três pontos. Primeiro, o bloco MobileViT já reúne extração local (convoluções) e modelagem global (*transformer*) em um único módulo (Ding et al., 2023), de modo que o vetor final carrega os dois tipos de informação. Segundo, trata-se de uma rede de baixo custo computacional: o HI-MViT, derivado do MobileViT, é descrito como leve e implantável em dispositivos móveis (Ding et al., 2023), e o MobileViT tem eficiência computacional superior à de *transformers* puros (Wang et al., 2026). Esse perfil é adequado às bases pequenas previstas neste trabalho (de 68 a 528 imagens) e ao treinamento em nuvem; espera-se que um número menor de parâmetros facilite o ajuste fino nesse cenário, hipótese que deve ser verificada experimentalmente. Terceiro, há evidências de bom desempenho em imagens médicas de diferentes modalidades: o HI-MViT superou em 3,4% a acurácia da ConvNeXt, a CNN mais competitiva do estudo, na base ISIC-2018 (Ding et al., 2023), e, em microscopia multiespectral, o MobileViT obteve a maior acurácia entre cinco arquiteturas, incluindo Swin-Transformer e ResNet (Wang et al., 2026).

3.4.4.0.2 Variações em imagens médicas.

Outros trabalhos exploram o mesmo princípio com modificações. O LightSE-MobileViT (Kabir et al., 2025) insere um bloco *Squeeze-and-Excitation* após a terceira camada convolucional de um *backbone* leve, seguido de um codificador MobileViT, para classificar câncer oral, e relata acurácia de 98,39% em um conjunto expandido por aumento de dados de 131 para 981 imagens; os autores reconhecem o tamanho e a diversidade limitados da base. Zou et al. (2023) combinam ResNet e MobileViT em um modelo de dupla entrada (imagem de ultrassom original e imagem de atenção), com módulo de fusão e função de perda guiada por *global average pooling* (GAP), e relatam desempenho superior a alguns métodos do estado da arte nas bases BUSI e BUSC. Em imagens de microscopia multiespectral de tecido (520, 600 e 630 nm), Wang et al. (2026) compararam DenseNet, EfficientNet, Swin-Transformer, ResNet e MobileViT e obtiveram a maior acurácia com o MobileViT (91,70%, contra 89,80% da ResNet e 88,00% da Swin-Transformer). Os autores o escolheram como base para otimização por combinar a extração local da CNN com a modelagem global do *Transformer* e por ter eficiência computacional superior à de *transformers* puros, e o ajustaram com perda focal ponderada por classe para lidar com o desbalanceamento da base.

3.4.5 Ramos paralelos e arquiteturas multirramo

Uma terceira estratégia consiste em processar a imagem por ramos paralelos, cada um responsável por um tipo de informação, e integrá-los em seguida. No CIHM, proposto para segmentação, a camada CiMC combina em paralelo um ramo de modelo de espaço de estados (Mamba), que captura dependências de longo alcance com complexidade linear, e um bloco

convolucional com convolução em forma de T, que extrai detalhes locais; os autores reportam desempenho superior ao da U-Net e ao da U-Mamba com 40 e 345 vezes menos parâmetros, respectivamente (Ma et al., 2026). O GSAC-UFormer, também de segmentação, integra em paralelo convolução em grupos e autoatenção adaptada por CNN em seu bloco principal, e usa um módulo de atenção contextual guiada para refinar as relações espaciais e de canal, com coeficientes Dice de 91,6%, 94,61% e 82,24% nas bases MICCAI 2017 (lesão vermelha), PH2 e CVC-ClinicalDB (Garbaz et al., 2025). Já o TriGWONet (Kabir et al., 2026), voltado à classificação de câncer oral, é uma rede convolucional com três ramos paralelos (camadas *SeparableConv2D*, normalização em lote, ReLU e *global max pooling*, seguidas de camadas densas), inspirada em princípios de *transformers* e com hiperparâmetros otimizados por *Gray Wolf Optimization*; os autores relatam acurácia de 99,64% em uma base de 240 imagens e reconhecem que ela é modesta em tamanho.

3.4.6 Evidências comparativas e cautelas

Estudos comparativos ajudam a situar esses modelos. Sharma, Singh & Choudhury (2025) avaliaram 15 arquiteturas de classificação de mamografias (como ResNet50, EfficientNetB0 e ViT, além de modelos específicos para mamografia) em quatro bases públicas (CBIS-DDSM, INbreast, MIAS e VinDr-Mammo), com protocolos padronizados. Os modelos específicos para mamografia, em especial o ViT-Mammo (AUC de 0,961) e o FCCS-Net, superaram as arquiteturas de propósito geral, ao passo que modelos leves como EfficientNetB0 e DenseNet121 foram menos precisos, porém mais eficientes. Esses resultados indicam que o desempenho depende da adequação da arquitetura ao domínio e que há um compromisso entre acurácia e custo computacional.

Alguns cuidados devem ser tomados ao interpretar a literatura. Dois dos trabalhos citados reportam acurácias próximas de 100% em bases com poucas centenas de imagens (Kabir et al., 2025; Kabir et al., 2026), e Oliveira et al. (2025) alertam que a ausência de validação externa e de bases de referência comparáveis limita a generalização dos resultados. Por isso, neste trabalho esses valores são tomados como evidência da viabilidade de cada desenho arquitetural, e não como referência de desempenho esperado.

3.4.7 Embedding espacial e uso no modelo proposto

Em tarefas de classificação, o codificador híbrido produz, após uma etapa de *pooling* global ou do uso de um *token* de classificação, um vetor de dimensão fixa que resume a imagem e é então encaminhado ao classificador (Ding et al., 2023; Ramos-Soto et al., 2025). Esse vetor é o *embedding* espacial. No modelo proposto, a via visual utiliza o MobileViT como extrator, inicializado com pesos pré-treinados e ajustado por *fine-tuning*. A cabeça de classificação própria da rede é descartada para que o vetor imediatamente anterior a ela seja entregue à etapa de fusão tardia, onde é concatenado ao *embedding* topológico gerado pela RNN (Seção 3.5). Dessa forma,

o *embedding* espacial captura padrões locais (via convolução) e globais (via atenção) da imagem, e o topológico captura a organização estrutural entre pixels e canais de cor ao longo de diferentes raios.

Tabela 3 – Síntese dos trabalhos sobre redes híbridas discutidos nesta seção.

Trabalho	**Tarefa e domínio**	**Estratégia híbrida**	**Resultado reportado**
Oliveira et al. (2025)	Revisão (histopatologia)	Taxonomia por tarefa; projetos sequenciais, paralelos e integrados	39 estudos; híbridos frequentemente superam abordagens convencionais, com lacunas de validação e explicabilidade
Zaidkilani, Garcia & Puig (2024)	Segmentação (ultrassom de mama)	CoAtNet com fluxo duplo de convolução e atenção	Dice de 78,84% (UDIAT) e 77,91% (BUSI)
Ding et al. (2023)	Classificação (lesões de pele)	Improved-MV2 e blocos MobileViT	Acurácia de 0,932 e F1 de 0,931 (ISIC-2018)
Kabir et al. (2025)	Classificação (câncer oral)	Bloco SE e codificador MobileViT	Acurácia de 98,39% (981 imagens após aumento de dados)
Zou et al. (2023)	Classificação (ultrassom de mama)	ResNet e MobileViT com dupla entrada e perda guiada por GAP	Superior a alguns métodos do estado da arte (BUSI e BUSC)
Wang et al. (2026)	Classificação (microscopia multiespectral)	MobileViT otimizada com perda focal ponderada	MobileViT com a maior acurácia entre cinco arquiteturas (91,70%)
Ma et al. (2026)	Segmentação (múltiplas modalidades)	Ramos paralelos Mamba e CNN	40 e 345 vezes menos parâmetros que U-Net e U-Mamba
Garbaz et al. (2025)	Segmentação (endoscopia e dermatoscopia)	Convolução em grupos e autoatenção em paralelo	Dice de 91,6%, 94,61% e 82,24%
Kabir et al. (2026)	Classificação (câncer oral)	CNN com três ramos paralelos e otimização por GWO	Acurácia de 99,64% (240 imagens)
Sharma, Singh & Choudhury (2025)	Classificação (mamografia)	Comparação de 15 modelos (CNNs, ViT e modelos específicos)	Modelos específicos superaram os de propósito geral (ViT-Mammo, AUC de 0,961)

3.5 FUSÃO TARDIA E MLP

Na arquitetura proposta, a imagem é descrita por duas vias independentes: a via sequencial produz o *embedding* topológico z_{top}, a partir da evolução da rede complexa ao longo dos raios (Seção 3.3), e a via visual produz o *embedding* espacial z_{esp}, a partir da imagem RGB (Seção 3.4). Esta seção descreve como esses dois vetores são combinados. Apresenta, primeiro, os níveis em que a informação de múltiplas vias pode ser fundida e o sentido em que o termo *fusão tardia* é empregado neste trabalho; em seguida, a evidência da literatura sobre estratégias de fusão em redes de dupla via; depois, a concatenação de *embeddings* e o perceptron multicamadas (MLP) que a classifica; e, por fim, as ressalvas e o plano de comparação com alternativas.

3.5.1 Níveis de fusão em modelos de múltiplas vias

A combinação de informações provenientes de fontes ou representações distintas é tratada pela literatura de aprendizado multimodal (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram;

Taylor, 2017). Baltrušaitis, Ahuja & Morency (2019) descrevem três abordagens de fusão independentes do modelo. Na fusão precoce, de nível de *features*, as representações são combinadas, em geral por concatenação, antes de uma única etapa de aprendizado; ela permite aprender interações entre as *features* de baixo nível de cada fonte e treina um único modelo para todas elas. Na fusão tardia, de nível de decisão, cada fonte é processada por seu próprio modelo e apenas as saídas são combinadas, por média, votação, ponderação ou um modelo aprendido; isso permite usar o preditor mais adequado a cada fonte, mas ignora a interação entre elas em nível baixo. A fusão híbrida combina as duas. A combinação de decisões de classificadores distintos tem uma formulação clássica, com regras como soma, produto, máximo e voto majoritário (Kittler et al., 1998). Em sistemas multissensoriais, essa mesma divisão em níveis de dado, de *feature* e de decisão é usada para organizar a literatura (Peng et al., 2025).

O termo *fusão tardia* é empregado com mais de um sentido nos trabalhos de redes de dupla via, e a diferença importa para este capítulo. As redes de dois fluxos para reconhecimento de ações (Simonyan; Zisserman, 2014) processam o fluxo espacial e o temporal em redes separadas e combinam as saídas apenas ao final. Yousaf, Nawaz & Habib (2024) usam fusão tardia no sentido de decisão, com média (ou média ponderada) dos escores de classificação dos dois fluxos, e chamam de fusão em nível de *feature*, ou intermediária, a concatenação das representações antes do classificador. Nawaz et al. (2025), por outro lado, chamam de *late feature fusion* a concatenação dos vetores extraídos por duas redes independentes, seguida de um classificador, e a distinguem tanto da fusão no nível da entrada quanto da média de escores. Neste trabalho, a fusão tardia é entendida como no segundo sentido: cada via é processada de forma independente até produzir um vetor de dimensão fixa, os vetores são concatenados e um classificador treinável decide a classe. Ela se distingue da fusão precoce porque as vias não compartilham camadas de extração, e da fusão de decisões porque o classificador recebe as *features* das duas vias, e não apenas os seus escores.

Essa escolha é coerente com a natureza das duas vias. A imagem entra na via visual como matriz de pixels e na via sequencial como uma série de medidas calculadas sobre grafos; as duas representações não têm o mesmo formato, de modo que uma fusão em nível de entrada não é natural, e cada via pode ser projetada, inicializada e ajustada com a arquitetura mais adequada ao seu tipo de dado.

3.5.2 Evidências sobre estratégias de fusão em redes de dupla via

Os trabalhos a seguir comparam ou empregam diferentes formas de combinar duas vias. O Quadro 4 os resume.

3.5.2.0.1 Comparação direta entre níveis de fusão.

Yousaf, Nawaz & Habib (2024) propõem uma rede de dois fluxos para classificar vídeos em seis categorias: um fluxo recebe quadros RGB e o outro, quadros de fluxo óptico; cada um passa

por uma EfficientNet-B7 pré-treinada seguida de uma BiLSTM, e o classificador é composto por duas camadas totalmente conectadas, a primeira com 1024 unidades e ativação ReLU, e a segunda com saída *softmax*. Os autores comparam fusão precoce (empilhamento dos quadros na entrada), em nível de *feature* (concatenação antes do classificador) e tardia (média dos escores). Com a BiLSTM, a acurácia de validação foi de 93,02%, 96,54% e 96,76%, e o F1 foi de 0,8914, 0,9316 e 0,9227, respectivamente. A fusão precoce foi, portanto, a de pior desempenho, e as duas demais ficaram próximas, com o melhor F1 na concatenação e a melhor acurácia na média de escores. Essa arquitetura, com extrator convolucional pré-treinado, recorrência sobre sequências e concatenação seguida de camadas totalmente conectadas, é a mais próxima da estrutura aqui proposta, embora as sequências sejam de quadros de vídeo.

3.5.2.0.2 Concatenação com poucos dados.

Nawaz et al. (2025) detectam desconforto respiratório agudo em vídeos de pacientes pediátricos a partir das modalidades de cor e de profundidade, em 153 pacientes, com validação cruzada em cinco partições. Os autores justificam a escolha de uma fusão simples pela limitação de dados: métodos como *bilinear pooling* e redes de autoatenção exigem camadas totalmente conectadas adicionais com muitos parâmetros, o que pode levar a sobreajuste. Eles concatenam os vetores de 4096 posições extraídos pelas duas redes e treinam uma rede de uma única camada sobre o vetor concatenado. Em acurácia média, a fusão por concatenação de canais na entrada obteve 0,765, abaixo da modalidade de cor isolada (0,822); a concatenação de *features* e a média de escores obtiveram 0,830 cada; e a concatenação com os extratores congelados, 0,852 (F1 de 0,858). A ressalva é que as faixas de variação entre as partições se sobrepõem (por exemplo, de 0,783 a 0,870 para a cor isolada e de 0,804 a 0,913 para a melhor fusão), de modo que o ganho é modesto frente à variabilidade, e que o conjunto é desbalanceado em favor de crianças pequenas.

3.5.2.0.3 Via de descritores manuais mais via aprendida.

Peng et al. (2025) propõem, para diagnóstico de falhas em rolamentos com poucas amostras de treinamento (1, 5 ou 10 por classe), uma rede com três fluxos: um nos domínios do tempo, um na frequência e um estatístico. Neste último, 18 estatísticas do sinal de cada sensor são calculadas e concatenadas com as *features* de tempo e frequência, já fundidas por atenção de canal, e o vetor resultante é entregue a uma camada totalmente conectada. A estrutura, em que uma via de descritores calculados e uma via aprendida são concatenadas antes de um classificador, em regime de poucos dados, é análoga à proposta aqui, pois os descritores topológicos também são calculados e não aprendidos pela rede. O desempenho médio foi de 80,13% com uma amostra por classe e de 98,13% com cinco, em um dos conjuntos. Como os autores também introduzem estratégias específicas para poucos dados e uma arquitetura leve, o resultado não permite isolar o efeito da fusão.

3.5.2.0.4 Concatenação seguida de seleção de features em imagens médicas.

Wang et al. (2023) propõem, para reconhecimento de melanoma, uma rede de dois fluxos, um enviesado para forma e outro para textura, cujas *features* são concatenadas e passam por um módulo de atenção de canal que seleciona as mais relevantes e reduz a redundância introduzida pela concatenação, antes de um classificador totalmente conectado. Com uma função de perda assimétrica para o desbalanceamento entre amostras benignas e malignas, em 17.397 imagens dermatoscópicas (ISIC-2019), a acurácia foi de 0,967 e o F1, de 0,939. No estudo de ablação com ResNet-50, a rede de dois fluxos sem aprendizado conjunto obteve acurácia de 0,960 e F1 de 0,924, frente a 0,950 e 0,907 da rede de fluxo único, e a adição do módulo de seleção elevou a acurácia de 0,959 para 0,967 e o F1 de 0,924 para 0,939. Esse trabalho é relevante por duas razões: mostra que duas vias complementares superam uma via única em imagens médicas e que a simples concatenação pode carregar redundância.

3.5.2.0.5 Fusão com interação entre as vias.

Uma alternativa à concatenação é permitir que as vias troquem informação durante a extração. Chen et al. (2025) usam dois ramos Swin *Transformer* para as imagens de frente e de verso de crisântemos, com módulos de atenção cruzada entre os estágios, e concatenam os vetores finais (1536 posições) antes de uma camada totalmente conectada com 512 unidades, normalização em lote e *dropout*. O uso apenas da imagem de frente rendeu acurácia de 85,14%, apenas a de verso, 88,66%, e ambas, 93,95%, o que evidencia a complementaridade das duas vistas. Sheng, He & Shi (2026) e Yang et al. (2026) fazem algo semelhante para segmentação e registro de imagens médicas tridimensionais, com módulos de atenção bidirecional ou de alinhamento entre ramos convolucional e de atenção. No estudo de ablação de Sheng, He & Shi (2026) para segmentação das artérias coronárias, a fusão por adição resultou em Dice de 85,07%, a concatenação em 85,24% e o módulo de atenção bidirecional em 85,74%, um ganho de 0,5 ponto percentual sobre a concatenação. Yang et al. (2026) argumentam que a concatenação ou soma direta de *features* de ramos com formas de representação distintas pode introduzir redundância e enfraquecer a complementaridade. Esses trabalhos de segmentação e registro, porém, fundem mapas espaciais densos dentro do codificador, o que difere da fusão de vetores globais, e a informação que as duas vias da presente proposta compartilham é de natureza distinta.

3.5.3 Concatenação de *embeddings* e classificador MLP

Dados os *embeddings* $z_{\text{top}} \in \mathbb{R}^{d_t}$ e $z_{\text{esp}} \in \mathbb{R}^{d_e}$, a fusão tardia forma o vetor conjunto

$$z = [\, z_{\text{top}} \,;\, z_{\text{esp}} \,] \in \mathbb{R}^{d_t + d_e}, \tag{13}$$

que contém, lado a lado, a informação sobre a evolução topológica e sobre o aspecto visual da imagem. Os dois vetores têm origens e escalas diferentes: o estado oculto de uma LSTM

Tabela 4 – Síntese dos trabalhos sobre fusão de duas vias discutidos nesta seção.

Trabalho	**Vias**	**Fusão**	**Resultado e ressalva**
Yousaf, Nawaz & Habib (2024)	RGB e fluxo óptico; EfficientNet-B7 e BiLSTM	Precoce, de *feature* (concatenação) e de escores (média)	F1 de 0,8914, 0,9316 e 0,9227; vídeo, não imagem estática
Nawaz et al. (2025)	Cor e profundidade; CNN de vídeo	Concatenação de *features* e camada única; média de escores; concatenação de canais na entrada	Melhor com extratores congelados (acurácia de 0,852); 153 pacientes; faixas entre partições se sobrepõem
Peng et al. (2025)	Tempo, frequência e estatística; vibração	Atenção de canal (tempo–frequência) e concatenação com estatísticas	98,13% com 5 amostras por classe; efeito da fusão não isolado
Wang et al. (2023)	Forma e textura; dermatoscopia e patologia	Concatenação e atenção de canal	Acurácia de 0,967 (ISIC-2019); dois fluxos superam fluxo único
Chen et al. (2025)	Imagens de frente e de verso; Swin	Atenção cruzada e concatenação	Acurácia de 93,95% contra 85,14% e 88,66% de uma só vista; domínio distinto
Sheng, He & Shi (2026)	CNN 3D e Swin; artérias coronárias	Atenção bidirecional	Dice 85,74% contra 85,24% da concatenação; segmentação
Yang et al. (2026)	CNN e atenção local; ressonância cerebral	Módulo de alinhamento entre ramos	Registro de imagens; fusão densa dentro do codificador

é limitado ao intervalo $(-1, 1)$ pela tangente hiperbólica (Equação 11), enquanto as ativações finais da rede visual não têm essa restrição. Por isso, pode ser necessário normalizar cada vetor antes da concatenação, para que a via de maior magnitude não domine o classificador.

O perceptron multicamadas é uma rede *feedforward* em que cada camada aplica uma transformação afim seguida de uma não linearidade, treinada por retropropagação do erro (Rumelhart; Hinton; Williams, 1986). Redes desse tipo, com ao menos uma camada oculta, são aproximadores universais de funções, sob condições gerais (Hornik; Stinchcombe; White, 1989). Com uma camada oculta, o classificador é

$$h = \mathrm{ReLU}(W_1 z + b_1)\,, \tag{14}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{15}$$

em que $\hat{y}$ é o vetor de probabilidades sobre as classes, e os pesos são ajustados pela minimização da entropia cruzada, $\mathcal{L} = -\sum_c y_c \log \hat{y}_c$. Como a primeira camada tem $(d_t + d_e)$ pesos por unidade oculta, o número de parâmetros do classificador cresce com a soma das dimensões dos *embeddings*, o que pesa em conjuntos com dezenas a poucas centenas de imagens. A literatura consultada adota cabeças de tamanhos diversos: uma única camada sobre o vetor concatenado (Nawaz et al., 2025), uma camada de 512 unidades com normalização em lote e *dropout* (Chen et al., 2025), ou duas camadas totalmente conectadas, a primeira com 1024 unidades (Yousaf; Nawaz; Habib, 2024). O *dropout*, que desativa aleatoriamente unidades durante o treinamento, é uma técnica de regularização contra o sobreajuste (Srivastava et al., 2014). Para o presente trabalho, a hipótese de partida é uma cabeça pequena, com uma camada oculta e *dropout*, mantida

simples pelo mesmo motivo apresentado por Nawaz et al. (2025): com poucos dados, camadas adicionais aumentam o risco de sobreajuste sem garantia de ganho.

Há ainda duas decisões de treinamento. A primeira é se os extratores são ajustados em conjunto com o classificador ou treinados separadamente e congelados. Nawaz et al. (2025) obtiveram o melhor resultado ao treinar cada via de forma independente, remover sua camada de classificação e treinar apenas a camada final sobre os vetores concatenados, em comparação com o treinamento de ponta a ponta; o resultado, porém, vem de um único conjunto pequeno, e a proposta aqui prevê ajuste fino do extrator visual (Seção 3.4.7). A segunda é o desbalanceamento entre classes, comum em dados médicos, que Wang et al. (2023) tratam com uma função de perda assimétrica; a alternativa mais simples é ponderar a entropia cruzada pelas frequências das classes.

3.5.4 Ressalvas e comparação com alternativas

Três ressalvas acompanham o uso da concatenação seguida de MLP. Primeiro, a literatura não aponta uma estratégia de fusão universalmente superior: em Yousaf, Nawaz & Habib (2024), a fusão em nível de *feature* e a de escores ficaram próximas; em Nawaz et al. (2025), os ganhos de cada estratégia são pequenos frente à variação entre partições; e em Sheng, He & Shi (2026), um módulo de atenção bidirecional melhorou o Dice em 0,5 ponto percentual frente à concatenação. Segundo, a maior parte dos trabalhos acima combina vias de natureza comparável (duas redes sobre imagens ou sinais), e nenhum fusiona um *embedding* gerado por rede recorrente sobre descritores topológicos com um *embedding* visual. Terceiro, os resultados são de domínios diversos e raramente de imagens médicas com poucos exemplos, de modo que a evidência é de viabilidade, não de superioridade garantida.

Por isso, a eficácia da fusão tardia por concatenação é tratada como hipótese a ser verificada experimentalmente. O plano é compará-la com as vias isoladas, a via topológica sozinha e a visual sozinha, como em Chen et al. (2025) e Wang et al. (2023), e com a média de escores como alternativa de decisão, como em Yousaf, Nawaz & Habib (2024) e Nawaz et al. (2025). A avaliação usa validação cruzada estratificada (Kohavi et al., 1995) e as métricas acurácia, F1 e AUC-ROC, relatadas por média e dispersão entre partições, a fim de que os ganhos possam ser comparados com a variabilidade do protocolo, e não apenas entre si.

4 METODOLOGIA

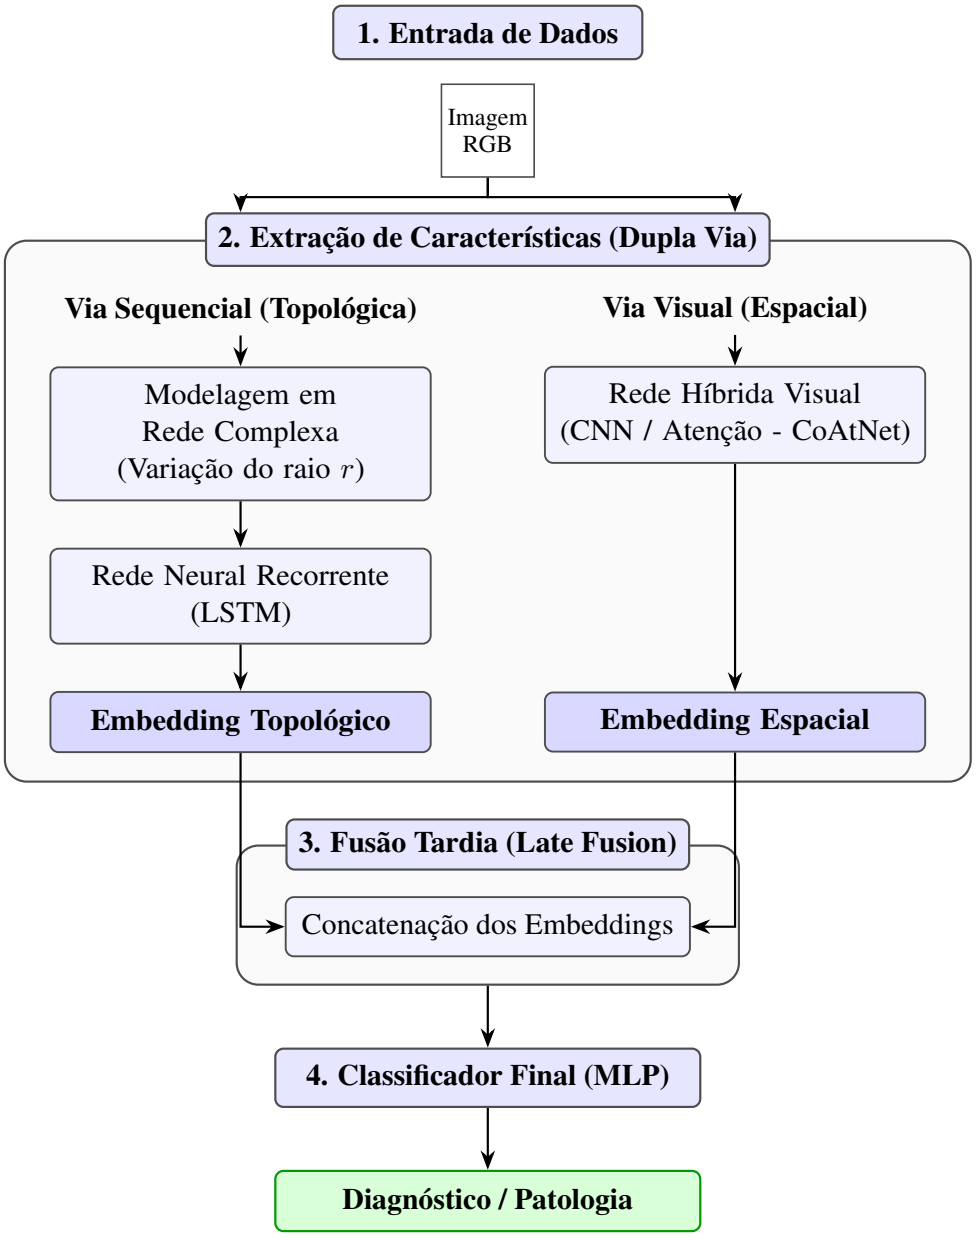


Figura 1 – Arquitetura proposta do modelo híbrido *Two-Stream* para classificação de imagens médicas, integrando extração visual por CNN e extração de características topológicas em grafos via LSTM.

5 RESULTADOS E DISCUSSÃO

6 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

AKANKSHA, M. N. V. et al. Implementation of potential leukemia detection using recurrent neural networks with blood cell counting. In: **2022 First International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)**. [S.l.: s.n.], 2022.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006. ISSN 0370-1573.

CHEN, Y. et al. Bidirectional feature fusion via cross-attention transformer for chrysanthemum classification. **Pattern Analysis and Applications**, v. 28, p. 41, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DAI, Z. et al. Coatnet: Marrying convolution and attention for all data sizes. **Advances in neural information processing systems**, v. 34, p. 3965–3977, 2021.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

EULER, L. Solutio problematis ad geometriam situs pertinentis. **Commentarii academiae scientiarum imperialis Petropolitanae**, v. 8, p. 128–140, 1736.

FAWAZ, H. I. et al. Deep learning for time series classification: a review. **Data Mining and Knowledge Discovery**, v. 33, n. 4, p. 917–963, 2019.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

GREFF, K. et al. LSTM: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989.

JESWANI, U.; PRIYADHARSHINI, S. Exploring facial feature extraction and temporal dynamics for deepfake video detection: A CNN-RNN study on FaceForensics++. In: **2026 International Conference on Innovative Trends in Information Technology (ICITIIT)**. [S.l.: s.n.], 2026.

JUN, K. et al. Feature extraction using an RNN autoencoder for skeleton-based abnormal gait recognition. **IEEE Access**, v. 8, p. 19196–19207, 2020.

KABIR, M. F. et al. Accurate and lightweight oral cancer detection using SE-MobileViT on clinically validated image dataset. **Discover Artificial Intelligence**, v. 5, n. 173, 2025.

KABIR, M. F. et al. TriGWONet: A lightweight multibranch convolutional neural network using gray wolf optimization for accurate oral cancer image classification. **Discover Artificial Intelligence**, v. 6, n. 91, 2026.

KANG, Y. et al. MMDB: Multimodal dual-branch model for multi-functional bioactive peptide prediction. **Analytical Biochemistry**, v. 690, p. 115491, 2024.

KHAN, S. et al. Transformers in vision: A survey. **ACM Computing Surveys**, v. 54, n. 10s, p. 1–41, 2022.

KITTLER, J. et al. On combining classifiers. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 20, n. 3, p. 226–239, 1998.

KOHAVI, R. et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: MONTREAL, CANADA. **International joint conference on artificial intelligence**. [S.l.], 1995. v. 14, n. 2, p. 1137–1145.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022. ArXiv:2110.02178.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PENG, H. et al. A lightweight triple-stream network with multisensor fusion for enhanced few-shot learning fault diagnosis. **IEEE Transactions on Reliability**, v. 74, n. 3, p. 4062–4075, 2025.

PEREZ, L.; WANG, J. The effectiveness of data augmentation in image classification using deep learning. **arXiv preprint arXiv:1712.04621**, 2017.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

S, M. N.; DHARAN, S. Multi-modal biometric authentication using attention based RNN feature extraction and walrus-assisted sculptor optimized fusion. In: **2025 IEEE 17th International Conference on Computational Intelligence and Communication Networks (CICN)**. [S.l.: s.n.], 2025. p. 973–979.

SCABINI, L. et al. Complex networks for modeling texture and spectral features of hyperspectral images for environmental analysis. **Computers in Biology and Medicine**, v. 204, p. 111504, 2026.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHARMA, S.; SINGH, Y.; CHOUDHURY, T. Advanced deep learning architectures for enhanced mammography classification: A comparative study of CNNs and ViT. **Discover Artificial Intelligence**, v. 5, n. 187, 2025.

SHENG, M.; HE, S.; SHI, Z. GTUNet: a GNN and transformer enhanced U-Net for coronary artery segmentation. **Signal, Image and Video Processing**, v. 20, n. 10, p. 532, 2026.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on image data augmentation for deep learning. **Journal of big data**, Springer, v. 6, n. 1, p. 1–48, 2019.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

WANG, C. et al. Research on tissue section negative detection algorithm based on multispectral microscopic imaging. **Journal of Innovative Optical Health Sciences**, v. 19, n. 2, p. 2550035, 2026.

WANG, L.; HE, D.-C. Texture classification using texture spectrum. **Pattern Recognition**, Pergamon Press, v. 23, n. 8, p. 905–910, 1990.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

WU, D. Statistical feature extraction and classification of complex data based on deep learning. In: **2024 3rd International Conference on Artificial Intelligence and Autonomous Robot Systems (AIARS)**. [S.l.: s.n.], 2024. p. 755–760.

XU, J.; WEI, Y.; ZENG, P. VMD-based iterative Boruta feature extraction and CNNA-BiLSTM for short-term load forecasting. **Electric Power Systems Research**, v. 238, p. 111172, 2025.

YANG, X. et al. DAPR-Net: Symmetric dual-stream pyramid architecture for non-rigid brain MRI registration. **Biomedical Signal Processing and Control**, v. 122, p. 110495, 2026.

YE, M. et al. Feature selection and extraction in sequence labeling for arrhythmia detection. In: **2021 International Balkan Conference on Communications and Networking (BalkanCom)**. [S.l.: s.n.], 2021. p. 107–111.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZAIDKILANI, N.; GARCIA, M. A.; PUIG, D. Dual-stream CoAtNet models for accurate breast ultrasound image segmentation. **Neural Computing and Applications**, v. 36, p. 16427–16443, 2024.

ZENG, H. et al. MSSFN: A multi-scale sequence fusion network for CT-based diagnosis of pulmonary complications. **Neurocomputing**, v. 634, p. 129878, 2025.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHAO, C. et al. MMS-Net: Multi-level multi-scale feature extraction network for medical image segmentation. **Biomedical Signal Processing and Control**, v. 86, p. 105330, 2023.

ZHI, R.; WAN, M. Dynamic facial expression feature learning based on sparse RNN. In: **2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. [S.l.: s.n.], 2019. p. 1373–1377.

ZOU, X. et al. Improved breast ultrasound tumor classification using dual-input CNN with GAP-guided attention loss. **Mathematical Biosciences and Engineering**, v. 20, n. 8, p. 15244–15264, 2023.