UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr. Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: dd/mm/yyyy

BANCA EXAMINADORA

_____

Prof. Dr. Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Arquitetura proposta de dupla via. A via topológica converte a imagem em redes complexas de raios crescentes, e a sequência de medidas é codificada por uma BiLSTM. A via visual extrai o *embedding* da imagem redimensionada com a MobileViT-S. Os *embeddings* normalizados são concatenados e classificados por um MLP, e todos os parâmetros são ajustados em conjunto. 29

Figura 2 Protocolo experimental. As ablações utilizam apenas os 80% de desenvolvimento, em validação cruzada aninhada, e o conjunto de teste de 20% permanece isolado até a avaliação final do modelo de dupla via. 30

Figura 3 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 31

Figura 4 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 31

Figura 5 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 31

Figura 6 Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 32

Figura 7 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 32

Figura 8 Separação dos dados e estimativa do desempenho. Um conjunto de teste (*holdout*) de 20% é separado antes de qualquer treinamento. Os 80% restantes (desenvolvimento) são avaliados por validação cruzada aninhada, com 15 partições externas (5 partições repetidas três vezes) e, em cada uma, uma validação cruzada interna de 3 partições para a escolha da configuração e do número de épocas. O mesmo procedimento, aplicado ao desenvolvimento inteiro, gera o modelo avaliado uma única vez no *holdout*. 39

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 28
Tabela 2 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica. 44
Tabela 3 – F1 macro (média $\pm$ desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados. 45
Tabela 4 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo nos cinco conjuntos de dados. 46
Tabela 5 – F1 macro (média $\pm$ desvio padrão entre as 5 partições de validação) da via visual isolada, com *fine-tuning* e aumento de dados rotacional, na melhor combinação de hiperparâmetros de cada *backbone*. Em negrito, o maior valor médio de cada *dataset*. 47
Tabela 6 – Três melhores configurações da via visual, por ranking médio do F1 macro entre os *datasets*. 47

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
ViT	*Vision Transformer*
CNN-ViT	*Convolutional Neural Network with Vision Transformer*
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RaNN	*Randomized Neural Network* (Rede Neural Aleatorizada)
RGB	*Red, Green, Blue*
CN	*Complex Network* (Redes Complexas)
DL	*Deep Learning* (Aprendizado Profundo)
BiLSTM	*Bidirectional Long Short-Term Memory* (Memória de Curto e Longo Prazo Bidirecional)
GLCM	*Gray-Level Co-occurrence Matrix* (Matriz de Coocorrência de Níveis de Cinza)
HOG	*Histogram of Oriented Gradients* (Histograma de Gradientes Orientados)
LBP	*Local Binary Patterns* (Padrões Binários Locais)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
LSTM	*Long Short-Term Memory* (Memória de Curto e Longo Prazo)
GRU	*Gated Recurrent Unit* (Unidade Recorrente com Portas)
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve* (Área sob a Curva ROC)
H&E	*Hematoxylin and Eosin* (Hematoxilina e Eosina)
LN	*Layer Normalization* (Normalização de Camada)
SIFT	*Scale-Invariant Feature Transform* (Transformada de Características Invariante à Escala)
SSN	*Spatio-Spectral Network* (Rede Espaço-Espectral)
ReLU	*Rectified Linear Unit* (Unidade Linear Retificada)

SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
RBF	*Radial Basis Function* (Função de Base Radial)
kNN	*k-Nearest Neighbors* (k Vizinhos Mais Próximos)
CNN1D	*One-Dimensional Convolutional Neural Network* (Rede Neural Convolucional Unidimensional)
CPU	*Central Processing Unit* (Unidade Central de Processamento)
GPU	*Graphics Processing Unit* (Unidade de Processamento Gráfico)
UCSB	*University of California, Santa Barbara*
CR	*Colorectal* (Colorretal)
LA	*Liver Aging* (Envelhecimento Hepático)
LG	*Liver Gender* (Sexo Hepático)
NHL	*Non-Hodgkin Lymphoma* (Linfoma Não Hodgkin)
CLL	*Chronic Lymphocytic Leukemia* (Leucemia Linfocítica Crônica)
FL	*Follicular Lymphoma* (Linfoma Folicular)
MCL	*Mantle Cell Lymphoma* (Linfoma de Células do Manto)

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 15

2 OBJETIVOS 18

3 FUNDAMENTAÇÃO TEÓRICA 19
3.1 Extração de *Features* 19
3.1.1 Matriz de coocorrência de níveis de cinza 19
3.1.2 Padrões binários locais 20
3.1.3 Histograma de gradientes orientados 21
3.1.4 Extração por aprendizado profundo 21
3.2 Redes Complexas 22
3.2.1 Modelagem da imagem como rede direcionada 22
3.2.2 Medidas topológicas e configurações da rede 23
3.3 RNN na Extração de *Features* 24
3.3.1 Evolução topológica ao longo dos raios 24
3.3.2 Redes recorrentes e *embedding* de sequência 24
3.4 Redes Híbridas para Extração de *Features* Visuais 25
3.5 Fusão por Concatenação de *Embeddings* e MLP 26

4 MATERIAIS E MÉTODOS 28
4.1 *Datasets* 28
4.2 *Two-Stream Network* 32
4.2.1 Via topológica 32
4.2.1.1 Codificador BiLSTM 34
4.2.1.2 Codificador MLP 35
4.2.2 Via visual 35
4.2.3 Fusão por concatenação de *embeddings* 36
4.2.4 Classificador MLP 36
4.3 Protocolo de treinamento 37
4.3.1 Validação 38
4.3.2 Métricas 40
4.3.3 Limitações do protocolo 40
4.4 Comparações com os métodos de referência 41
4.5 Configuração de ambiente 41

5 ABLAÇÃO 43

5.1 Ablação da Via Topológica 43
5.2 Seleção da via visual 45
5.2.1 Desempenho dos *backbones* **45**
5.2.2 Ajuste de hiperparâmetros e custo **45**
5.2.3 Configurações selecionadas **45**
5.3 Síntese e encaminhamento para a fusão 45

6 RESULTADOS E DISCUSSÃO 48

7 CONCLUSÃO 49

REFERÊNCIAS 50

1 INTRODUÇÃO

A histopatologia é responsável pelo diagnóstico precoce de patologias de tecidos agressivas, como cânceres e doenças autoimunes, infecciosas e degenerativas. Os diagnósticos são realizados, em geral, manualmente por patologistas, em um processo que envolve a extração de tecidos biológicos, a coloração por reagentes químicos para realçar o contraste das estruturas celulares e a investigação microscópica por especialistas. Esse processo é custoso e pode ser acelerado por computadorização (Talo, 2019). A falta de padronização entre laboratórios, a necessidade de anotação exaustiva das imagens e as restrições éticas e de privacidade dificultam ainda a construção de grandes bases de imagens para modelos de DL (Kumar; Mishra, 2026). Para viabilizar a aplicação de DL nesse cenário, técnicas como transferência de aprendizado, aumento de dados e extração de *features* foram adotadas na literatura, e em determinados casos os modelos superaram patologistas na classificação de tecidos (Bejnordi et al., 2017).

O DL foi difundido pela ampla utilização das CNNs em tarefas de visão computacional, como segmentação e classificação de imagens (Kumar; Mishra, 2026). Essas redes são compostas por camadas de convolução e de *pooling*, que reduzem a resolução das imagens e realizam a classificação principalmente a partir de informações locais. As arquiteturas ViT empregam mecanismos de auto-atenção para capturar o contexto global das imagens (Hussaini et al., 2026). Os modelos híbridos CNN-ViT unem a localidade das redes convolucionais ao contexto de longa distância dos modelos baseados em atenção e foram aplicados na classificação de imagens médicas com ganhos de desempenho (Hussaini et al., 2026). A dificuldade de convergência do treinamento com poucas amostras permanece mesmo com a evolução das topologias de rede, e em imagens histológicas a extração de características de textura é uma estratégia comum para contornar essa restrição.

Nas imagens histológicas, a disposição de núcleos, citoplasma e matriz extracelular produz padrões de textura que diferenciam tecidos normais e patológicos, e a extração de *features* é, por esse motivo, uma etapa da classificação desses tecidos. Descritores clássicos como GLCM (Haralick; Shanmugam; Dinstein, 1973), LBP (Ojala; Pietikäinen; Harwood, 1996; Ojala; Pietikäinen; Mäenpää, 2002) e HOG (Dalal; Triggs, 2005) são empregados com classificadores tradicionais e, mais recentemente, foram comparados e combinados com representações aprendidas por redes profundas em imagens médicas (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025; Shorfuzzaman et al., 2026). Esses descritores são calculados sobre vizinhanças de tamanho fixo e não descrevem de forma explícita a organização do tecido em diferentes escalas.

As CN permitem descrever a textura em múltiplas escalas. Na transformação de uma imagem em CN, os pixels são modelados como vértices e conectados segundo um raio de distância, e a variação desse raio gera uma sequência de redes cada vez mais abrangentes, das quais são extraídas medidas topológicas que descrevem o tecido da organização local à estrutura em larga escala (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Zerati et al., 2026). Como as redes de

raios maiores incluem as conexões das de raios menores, essas medidas formam uma sequência com dependência histórica entre seus elementos. As RNNs são adequadas a esse tipo de dado, pois o estado interno é atualizado a cada elemento processado e acumula a informação dos anteriores (Hochreiter; Schmidhuber, 1997), de modo que o estado final resume a evolução da topologia da imagem. Essa propriedade favoreceu o uso das RNNs como extratoras de *features* em dados sequenciais de diferentes domínios (Jun et al., 2020; Zhi; Wan, 2019; Ye et al., 2021; Jeswani; Priyadharshini, 2026) e em tarefas médicas, como a detecção de câncer de pulmão e de medula óssea e a classificação de imagens histopatológicas de mama (Mathiyalagi; Ravi, 2026; Priyadarshini, 2026; Shalini; Rathnamala, 2026).

A combinação de representações de naturezas distintas apresentou ganhos na histopatologia, como na fusão de colorações e dados genômicos (Brussee et al., 2025), de CNN e ViT em imagens de mama (Kushwah; Punn; Bhattacharya, 2026) e de descritores clássicos de textura com características profundas em imagens de próstata e de carcinoma oral (Huang et al., 2022; Li, 2025). Neste trabalho, adota-se uma arquitetura de dupla via (*Two-Stream Network*) (Simonyan; Zisserman, 2014; Yousaf; Nawaz; Habib, 2024; Wang et al., 2023), na qual a imagem e a sequência de descritores topológicos são processadas em paralelo por extratores próprios, e os *embeddings* resultantes são unidos por concatenação, em nível de características (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017), e classificados por um MLP. Essa estratégia é denominada fusão por concatenação de *embeddings*, e não fusão tardia, termo que a literatura emprega também para a combinação de decisões (Seção 3.5).

Entre os trabalhos citados, nenhum combina a sequência de descritores topológicos gerada por CN, processada por uma RNN, com a representação visual de uma rede híbrida. As duas vias descrevem o tecido de formas distintas, a primeira pela organização dos pixels em diferentes raios de conexão e a segunda pelo conteúdo visual aprendido pela rede. A combinação é motivada também pela escassez de imagens histopatológicas anotadas, que torna necessário extrair a maior quantidade possível de informação de cada amostra disponível (Kumar; Mishra, 2026).

A questão de pesquisa investigada neste trabalho é: a sequência de descritores topológicos multiescala de CN, processada por uma RNN e combinada, por concatenação de *embeddings*, com a representação visual de uma rede híbrida CNN-ViT, melhora a classificação de imagens histopatológicas em relação aos descritores de textura de vizinhança fixa? A hipótese adotada é que a evolução das medidas topológicas ao longo dos raios de conexão, processada sequencialmente por uma RNN bidirecional do tipo BiLSTM, capta padrões de organização do tecido que os descritores de vizinhança fixa não representam, e que esses padrões acrescentam informação à representação visual da rede híbrida.

As contribuições deste trabalho são:

- A modelagem de imagens histopatológicas coloridas como CN, com a variação do raio de conexão entre os pixels gerando uma sequência de descritores topológicos.

- O uso de uma RNN como extratora de *features* dessa sequência, gerando um *embedding* topológico do tecido.
- O desenvolvimento de uma arquitetura de dupla via, na qual o *embedding* topológico e o *embedding* visual extraído pela MobileViT (Mehta; Rastegari, 2022) são combinados por concatenação e classificados por um MLP.
- A avaliação da arquitetura em cinco bases de dados histopatológicas públicas (UCSB, CR, LA, LG e NHL), em comparação com cada via isolada, com os descritores GLCM, LBP e HOG (isolados e concatenados à MobileViT-S) e com a fusão de escores, e a análise por ablações da codificação da sequência topológica.

2 OBJETIVOS

Este trabalho tem como objetivo geral propor e avaliar uma rede de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas, na qual a evolução de medidas topológicas de redes complexas, calculadas em raios de conexão crescentes e codificada por uma BiLSTM ou por um MLP, forma um *embedding* topológico. Esse *embedding* é concatenado ao *embedding* visual extraído por uma rede híbrida (MobileViT-S) e classificado por um MLP, e investiga-se se essa combinação supera cada via isolada e os descritores clássicos de textura (GLCM, LBP e HOG).

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- Modelar as imagens histopatológicas coloridas como redes complexas direcionadas e ponderadas (SSN), variando o raio de conexão de 1 a 15 para obter uma sequência de vetores de medidas topológicas que descreva a textura do tecido em escalas crescentes.
- Implementar e treinar a BiLSTM e o MLP como codificadores dessa sequência em um *embedding* topológico, com medidas acumuladas ou diferenças entre raios consecutivos.
- Configurar a via visual com a MobileViT-S, pré-treinada na ImageNet e ajustada por *fine-tuning*, para extrair das imagens originais um *embedding* visual.
- Desenvolver a fusão por concatenação de *embeddings*, com projeção e normalização de camada dos vetores das duas vias, e submeter o vetor concatenado a um MLP para a classificação final.
- Avaliar o modelo proposto em cinco conjuntos de dados (UCSB, CR, LA, LG e NHL) por validação cruzada estratificada, com acurácia, F1-*score* macro e AUC-ROC, comparando-o com cada via isolada, com os descritores GLCM, LBP e HOG (isolados e concatenados à MobileViT-S) e com a fusão de escores.
- Verificar, por ablações na via topológica, a contribuição da recorrência (BiLSTM, LSTM, GRU, MLP e CNN unidimensional), da representação da sequência (medidas acumuladas ou diferenças entre raios) e do raio máximo de conexão.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 EXTRAÇÃO DE *FEATURES*

Em reconhecimento de padrões, uma *feature* é uma medida numérica que representa uma propriedade da imagem, como textura, forma, bordas ou cor. A extração de *features* transforma os pixels em uma representação que pode ser utilizada por um classificador (Ramos-Soto et al., 2025). Em imagens médicas, essas medidas descrevem propriedades como a forma, o tamanho, a textura e a intensidade das estruturas observadas (Dehbozorgi; Ryabchykov; Bocklitz, 2025). A representação pode ser definida por regras matemáticas ou aprendida a partir dos dados, e essa distinção é relevante em bases médicas pequenas, nas quais a disponibilidade de imagens rotuladas é limitada por custos de aquisição, privacidade e necessidade de especialistas (Litjens et al., 2017).

Em histopatologia, o tecido é fixado, cortado, corado, em geral pela H&E, e digitalizado. As diferenças de protocolo de coloração e de iluminação entre laboratórios alteram a cor e o contraste da imagem para um mesmo tipo de tecido, e a textura formada pelo arranjo de núcleos, citoplasma e matriz extracelular é uma das principais fontes de informação para o diagnóstico.

Os descritores clássicos (*handcrafted*) são calculados por regras matemáticas definidas previamente, sem ajuste a partir dos dados. Entre os métodos empregados em imagens médicas estão as estatísticas de primeira ordem, a GLCM, o LBP, o HOG, os filtros de Gabor e o SIFT (Ramos-Soto et al., 2025; Ahmed et al., 2023; Dehbozorgi; Ryabchykov; Bocklitz, 2025). As subseções seguintes definem GLCM, LBP e HOG.

3.1.1 Matriz de coocorrência de níveis de cinza

A GLCM (Haralick; Shanmugam; Dinstein, 1973) registra a frequência com que pares de pixels de tons i e j ocorrem separados por um deslocamento definido por uma distância d e um ângulo θ (0°, 45°, 90° ou 135°). Para uma imagem I com N_g níveis de cinza, a matriz e sua versão normalizada são

$$\begin{aligned} P_{d,\theta}(i,j) &= \left|\{(\mathbf{p},\mathbf{q}) : I(\mathbf{p}) = i,\ I(\mathbf{q}) = j,\ \mathbf{q} = \mathbf{p} + d\,(\cos\theta, \sin\theta)\}\right|, \\ p(i,j) &= \frac{P_{d,\theta}(i,j)}{\sum_{k,l} P_{d,\theta}(k,l)}. \end{aligned} \tag{1}$$

A partir de $p(i,j)$ são calculadas medidas de textura, como o contraste, a energia, a homogeneidade, a entropia e a correlação (Haralick; Shanmugam; Dinstein, 1973):

$$\begin{aligned}
\text{contraste} &= \sum_{i,j} (i-j)^2\, p(i,j), & \text{energia} &= \sum_{i,j} p(i,j)^2, \\
\text{homogeneidade} &= \sum_{i,j} \frac{p(i,j)}{1+|i-j|}, & \text{entropia} &= -\sum_{i,j} p(i,j)\, \log p(i,j), \\
\text{correlação} &= \sum_{i,j} \frac{(i-\mu_i)(j-\mu_j)\, p(i,j)}{\sigma_i\, \sigma_j}, & &
\end{aligned} \tag{2}$$

em que μ_i, μ_j, σ_i e σ_j são as médias e os desvios padrão das distribuições marginais de p. A matriz depende da escolha do vetor de deslocamento e da variação regional do fundo de intensidade da imagem (He; Wang, 1989).

3.1.2 Padrões binários locais

O LBP (Ojala; Pietikäinen; Harwood, 1996) descreve a textura pela relação entre cada pixel e sua vizinhança, e tem origem no espectro de textura de He & Wang (1989), que codifica cada vizinho em três valores. No LBP a codificação é binária. Sendo g_c a intensidade do pixel central e g_p, com $p = 0, \ldots, P-1$, a intensidade de cada um de seus P vizinhos, o código do pixel é

$$\mathrm{LBP}_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s\,(g_p - g_c)\, 2^p, \qquad s(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0. \end{cases} \tag{3}$$

Na versão original, $P = 8$ e $R = 1$, os vizinhos são os oito pixels da janela 3×3 e há $2^8 = 256$ códigos possíveis. Ojala, Pietikäinen & Mäenpää (2002) estenderam o operador a múltiplas resoluções: os P vizinhos ficam igualmente espaçados em um círculo de raio R, nas coordenadas

$$(x_p, y_p) = \left(x_c + R\cos\frac{2\pi p}{P},\; y_c - R\sin\frac{2\pi p}{P} \right), \tag{4}$$

e as intensidades g_p nas posições que não coincidem com um pixel são obtidas por interpolação bilinear. A imagem é descrita pelo histograma dos códigos, normalizado pelo número de pixels N:

$$H(k) = \frac{1}{N} \sum_{x,y} \mathbb{1}\left[\mathrm{LBP}_{P,R}(x,y) = k\right], \qquad k = 0, 1, \ldots, 2^P - 1. \tag{5}$$

Os mesmos autores definiram os padrões *uniformes*, que contêm no máximo duas transições entre 0 e 1 no código circular. Com

$$U\left(\mathrm{LBP}_{P,R}\right) = \left|s(g_{P-1} - g_c) - s(g_0 - g_c)\right| + \sum_{p=1}^{P-1} \left|s(g_p - g_c) - s(g_{p-1} - g_c)\right|, \tag{6}$$

o operador invariante à rotação e uniforme é

$$\mathrm{LBP}_{P,R}^{riu2} = \begin{cases} \sum_{p=0}^{P-1} s\left(g_p - g_c\right), & U\left(\mathrm{LBP}_{P,R}\right) \leq 2, \\ P+1, & \text{caso contrário}, \end{cases} \tag{7}$$

cujo histograma tem $P+2$ posições. A combinação de operadores com diferentes pares (P, R) forma o descritor multirresolução.

3.1.3 Histograma de gradientes orientados

O HOG (Dalal; Triggs, 2005) descreve a imagem pela distribuição local das direções de gradiente. Os gradientes horizontal e vertical, G_x e G_y, são obtidos por filtros de derivada, e a magnitude e a orientação de cada pixel são

$$m(x,y) = \sqrt{G_x(x,y)^2 + G_y(x,y)^2}, \qquad \phi(x,y) = \arctan \frac{G_y(x,y)}{G_x(x,y)}. \tag{8}$$

A imagem é dividida em células, e cada célula acumula um histograma de B intervalos de orientação em que cada pixel contribui com sua magnitude:

$$h_{\mathrm{cel}}(b) = \sum_{(x,y)\in \mathrm{cel}} m(x,y) \mathbb{1}\left[\phi(x,y) \in \mathrm{intervalo}_b\right], \qquad b = 1, \ldots, B. \tag{9}$$

Os histogramas das células de cada bloco, concatenados em um vetor $\mathbf{v}$, são normalizados para reduzir a sensibilidade ao contraste e à iluminação,

$$\mathbf{v}' = \frac{\mathbf{v}}{\sqrt{\|\mathbf{v}\|_2^2 + \varepsilon^2}}, \tag{10}$$

em que ε é uma constante pequena, e os blocos sobrepostos concatenados formam o descritor. O HOG foi concebido para a detecção de pessoas e é empregado como descritor de bordas e de forma em imagens médicas (Ramos-Soto et al., 2025).

3.1.4 Extração por aprendizado profundo

Os descritores *handcrafted* capturam relações locais entre pixels, em escalas e vizinhanças definidas previamente. As CNNs, em contraste, aprendem filtros que vão de bordas e texturas nas primeiras camadas até padrões semânticos nas camadas finais, e são amplamente utilizadas em análise de imagens médicas (Litjens et al., 2017). Os ViT representam a imagem como uma sequência de *patches* e utilizam autoatenção para modelar relações entre regiões (Dosovitskiy et al., 2020; Shamshad et al., 2023).

Em domínios com poucos dados, a transferência de aprendizado (*transfer learning*) permite empregar uma rede pré-treinada em uma base grande, como a ImageNet, como ponto de partida. Na extração de *features*, a ativação de uma camada intermediária ou final é utilizada como vetor de características. No ajuste fino (*fine-tuning*), os pesos pré-treinados servem de inicialização e

são atualizados no conjunto-alvo, em geral com taxa de aprendizado menor que a dos módulos inicializados aleatoriamente. Modelos com muitos parâmetros ajustados em poucas imagens estão sujeitos ao sobreajuste, o que torna a regularização e o aumento de dados relevantes. O aumento de dados gera amostras adicionais por transformações que preservam o rótulo, como inversões e rotações.

A variação de tamanho e de aparência das estruturas do tecido motiva descritores multiescala, que descrevem a imagem em vizinhanças de tamanhos crescentes. Na abordagem de redes complexas apresentada a seguir, a escala é controlada pelo raio de conexão.

3.2 REDES COMPLEXAS

A teoria de CN é uma abstração para modelar sistemas naturais cujos elementos interagem de maneira não trivial (Boccaletti et al., 2006). Essas redes foram empregadas para modelar os pixels de uma imagem e suas relações de vizinhança, e descritores baseados em topologia quantificam propriedades de textura a partir dessa modelagem (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). A SSN, proposta por Scabini, Ribas & Bruno (2020) para a análise de textura colorida, é a modelagem adotada e é descrita a seguir.

3.2.1 Modelagem da imagem como rede direcionada

Na SSN (Scabini; Ribas; Bruno, 2020), cada imagem é representada como uma CN direcionada e ponderada $G = (V, E)$, na qual cada pixel é modelado como um vértice e as conexões entre pixels são estabelecidas dentro de um raio máximo r_{max}. Para um pixel $i = (x_i, y_i)$ em um canal de cor c da imagem I, é definido um vértice $v_i^{(c)} \in V$. Uma aresta direcionada é criada entre os vértices $v_i^{(c)}$ e $v_j^{(c_w)}$, em que c e c_w são os canais de cor do primeiro e do segundo pixel, quando a distância euclidiana quadrática entre os pixels satisfaz a Equação 11:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 \leq \rho_{ij}^2 \leq r_{max}^2, \tag{11}$$

em que x e y são as coordenadas dos pixels e ρ_{ij} é a distância euclidiana entre eles. A condição $\rho_{ij}^2 = 0$ conecta os vértices dos diferentes canais de cor de um mesmo pixel, o que só ocorre quando $c \neq c_w$ (Ribas et al., 2024). Não há laços, pois um vértice nunca se conecta a si mesmo. Cada aresta é associada a um raio discreto $r \in \{1, 2, \ldots, r_{max}\}$, definido como o menor inteiro $r \geq 1$ que satisfaz $\rho_{ij}^2 \leq r^2$, de modo que as arestas com $\rho_{ij} = 0$ pertencem ao raio 1. Isso permite acumular as medidas da rede progressivamente sobre vizinhanças cada vez maiores.

A diferença absoluta de intensidade entre os pixels conectados, dada pela Equação 12, determina a direção da aresta e compõe o seu peso (Seção 3.2.2):

$$w_{ij} = \left| I(x_i, y_i, c) - I(x_j, y_j, c_w) \right|. \tag{12}$$

A direção de cada aresta é determinada pelas intensidades dos pixels conectados, do pixel de menor intensidade para o de maior intensidade (Scabini; Ribas; Bruno, 2020). Quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$, a conexão é classificada como de saída (*out*) a partir de v_i e de entrada (*in*) em v_j. No caso contrário, ela é classificada como de entrada em v_i. Conexões entre pixels de mesma intensidade são contabilizadas em ambas as direções. O grau de saída de um vértice conta, portanto, seus vizinhos mais claros.

3.2.2 Medidas topológicas e configurações da rede

O grau (*degree*) e a força (*force*) são calculados para cada vértice pela acumulação das quantidades correspondentes até o raio r. O grau de saída quantifica o número de conexões de saída dentro da vizinhança considerada, como na Equação 13:

$$d_{out}(v_i, r) = \sum_{k=1}^{r} n_{out}(v_i, k), \tag{13}$$

em que $n_{out}(v_i, k)$ é o número de arestas de saída de v_i cujo raio discreto vale k. A força incorpora as diferenças de intensidade e a distância entre os pixels, o que a torna sensível aos gradientes locais de textura. Para uma rede construída com raio r, cada aresta (v_i, v_j) recebe o peso proposto por Ribas et al. (2024), que equilibra a diferença de intensidade e a distância euclidiana entre os pixels, conforme a Equação 14:

$$\omega_{ij}^{(r)} = \frac{(w_{ij} + 1)\,(\rho_{ij} + 1) - 1}{(L + 1)(r + 1) - 1}, \tag{14}$$

em que $L = 255$ é o nível máximo de intensidade para imagens de 8 bits, w_{ij} é a diferença de intensidade dada pela Equação 12 e ρ_{ij} é a distância euclidiana entre os pixels. A força de saída acumulada é dada pela Equação 15:

$$\text{force}_{out}(v_i, r) = \sum_{v_j \in \mathcal{N}_{out}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{15}$$

em que $\mathcal{N}_{out}^{(r)}(v_i)$ é o conjunto de vértices conectados a v_i por arestas de saída com $\rho_{ij}^2 \leq r^2$, e force$_{in}$ é definida de forma análoga sobre as arestas de entrada. O denominador da Equação 14 é o maior valor possível do numerador em uma vizinhança de raio r, obtido com diferença de intensidade L e distância r, de modo que $\omega_{ij}^{(r)} \in [0, 1]$, com o valor nulo nas arestas de distância nula entre pixels de mesma intensidade. As medidas por vértice utilizadas são o grau de saída, a força de saída e a força de entrada (Ribas et al., 2024).

Para estender as medidas aos três canais de cor das imagens RGB, as formulações anteriores podem ser aplicadas em três configurações de rede (Scabini; Ribas; Bruno, 2020): *within-channel*, com $c = c_w$, *between-channel*, com $c \neq c_w$, e *full*, que inclui simultaneamente conexões intracanal e intercanal. Como os pesos e as direções das arestas dependem da comparação de

intensidades inteiras, inclusive dos empates, a rede é construída sobre a imagem em inteiros de 8 bits, e o redimensionamento altera a textura em nível de pixel.

O raio máximo r_{max} determina a escala espacial descrita pelas medidas. Nos raios menores, elas refletem relações locais entre pixels próximos, e, à medida que r cresce, as vizinhanças acumuladas se tornam progressivamente mais amplas. A evolução das medidas ao longo dos raios compõe uma descrição multiescala da textura, tratada na seção seguinte.

3.3 RNN NA EXTRAÇÃO DE *FEATURES*

As RNNs processam dados organizados em sequência, atualizando um estado interno a cada elemento lido, de modo que a informação dos elementos anteriores é preservada ao longo do processamento. Essa propriedade permite utilizá-las como extratoras de *features*: o estado obtido ao final da sequência resume seu conteúdo em um vetor de dimensão fixa, que pode ser empregado por um classificador. Nesta seção é apresentada a descrição da textura pela evolução das medidas topológicas ao longo dos raios, e os fundamentos das RNNs utilizadas para codificar essa evolução.

3.3.1 Evolução topológica ao longo dos raios

A descrição da textura pela evolução das medidas topológicas ao longo dos raios tem origem na SSN, que define um conjunto de raios $\{r_1, \ldots, r_R\}$ para a vizinhança dos vértices e analisa as propriedades topológicas da rede por medidas de vértice simples (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). A partir dessa modelagem, Ribas et al. (2024) descreveram a evolução topológica por uma RaNN, uma rede de alimentação direta com uma camada oculta, cujos pesos são gerados aleatoriamente, e com pesos de saída obtidos por mínimos quadrados com regularização de Tikhonov. As medidas de cada vértice (grau de saída, força de entrada e força de saída) foram calculadas em vários raios $r = \{1, 2, \ldots, R\}$, e os valores obtidos em $r = 1, \ldots, R-1$ formaram um vetor de entrada usado para prever o valor da mesma medida no raio máximo R. Os pesos da camada de saída da RaNN, treinada para cada imagem, constituem o descritor, e os autores descrevem esse procedimento como uma análise multiescala da evolução topológica dos vértices.

Na RaNN, os valores de todos os raios entram simultaneamente em uma rede de alimentação direta, sem recorrência. Uma alternativa é ler os descritores de cada raio como uma sequência $x_1, x_2, \ldots, x_R$, do menor raio para o maior, por uma rede recorrente cujos parâmetros são aprendidos a partir do rótulo da classe, em vez de calculados por imagem.

3.3.2 Redes recorrentes e *embedding* de sequência

Uma RNN processa um elemento por vez de uma sequência e mantém um estado interno que carrega informação sobre os elementos anteriores (LeCun; Bengio; Hinton, 2015). Na rede recorrente simples de Elman (1990), o estado oculto depende da entrada atual e do estado anterior,

e os parâmetros são compartilhados entre os passos, de modo que sua quantidade não depende do comprimento da sequência. O treinamento por retropropagação enfrenta o desaparecimento ou a explosão dos gradientes à medida que o intervalo entre entrada e saída aumenta (Bengio; Simard; Frasconi, 1994), e a LSTM (Hochreiter; Schmidhuber, 1997) mitiga esse problema com uma célula de memória c_t controlada por portas. Na formulação usual, que inclui a porta de esquecimento (Gers; Schmidhuber; Cummins, 2000), as atualizações são:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{16}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{17}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{18}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{19}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{20}$$

$$h_t = o_t \odot \tanh(c_t), \tag{21}$$

em que σ é a função sigmoide, $\odot$ denota o produto elemento a elemento e f_t, i_t e o_t são as portas de esquecimento, entrada e saída. A GRU (Cho et al., 2014) é uma alternativa com menos portas e menos parâmetros.

A RNN unidirecional lê a sequência em um único sentido, e a RNN bidirecional (Schuster; Paliwal, 1997) utiliza duas redes independentes, uma lendo a sequência na ordem original e outra na ordem inversa, e combina seus estados:

$$h_t = \left[\overrightarrow{h}_t \,\|\, \overleftarrow{h}_t\right]. \tag{22}$$

Quando a sequência inteira recebe um único rótulo, a rede opera no formato *many-to-one*: em vez da saída de cada passo, utiliza-se um vetor de dimensão fixa que resume a sequência, obtido do estado final de cada direção, $\left[\overrightarrow{h}_T \,\|\, \overleftarrow{h}_1\right]$, com T passos. Esse vetor, denominado *embedding* da sequência, pode ser concatenado a vetores de outras fontes de informação (Seção 3.5). Diferentemente dos pesos de saída da RaNN, obtidos por mínimos quadrados sem retropropagação, os parâmetros de uma LSTM são aprendidos por gradiente, e o *embedding* pode ser otimizado em conjunto com o classificador.

3.4 REDES HÍBRIDAS PARA EXTRAÇÃO DE *FEATURES* VISUAIS

As CNNs extraem padrões locais, como bordas, texturas e pequenas estruturas, mas o campo receptivo restrito das convoluções dificulta a captura de contexto global e de dependências de longo alcance (Ma et al., 2026). Os ViT (Dosovitskiy et al., 2020) abordam esse problema pela autoatenção sobre sequências de *patches*, mas a autoatenção tem custo computacional quadrático em relação ao tamanho da imagem (Ma et al., 2026), e os *transformers* tradicionais têm dificuldade em representar o contexto local (Garbaz et al., 2025). As arquiteturas híbridas

combinam a captura de padrões locais das CNNs com a modelagem global dos *transformers*, em geral com blocos convolucionais que extraem informação localizada e mecanismos de atenção que integram o contexto global, o que é relevante em patologia computacional, em que a interpretação depende de detalhes morfológicos finos e de padrões em escala de tecido (Oliveira et al., 2025).

A MobileViT, proposta por Mehta & Rastegari (2022), combina operações convolucionais e autoatenção em uma arquitetura de baixo custo computacional. Em cada bloco MobileViT, uma convolução $n \times n$ seguida de uma convolução pontual 1×1 produz uma representação local da entrada. Essa representação é organizada em *patches*, processada por um *Transformer* e reorganizada no formato do mapa de características. O resultado é combinado com a representação local e processado por outra convolução, que integra as informações obtidas pelos dois tipos de operação (Ding et al., 2023). Os mapas resultantes incorporam informação local e global sem depender exclusivamente da autoatenção sobre todos os pixels (Mehta; Rastegari, 2022; Ding et al., 2023). Para obter um vetor de características da imagem, a cabeça de classificação é removida e os mapas do último bloco são agregados por um agrupamento médio global (*Global Average Pooling*).

3.5 FUSÃO POR CONCATENAÇÃO DE *EMBEDDINGS* E MLP

A literatura de aprendizado multimodal distingue estratégias que combinam as representações antes da classificação daquelas que combinam as decisões de modelos independentes (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017). Na fusão em nível de características, os vetores são unidos antes de um classificador compartilhado. Na fusão em nível de decisão, cada fonte produz uma saída de classificação e os escores são combinados por regras como soma, produto, máximo ou voto majoritário (Kittler et al., 1998).

A expressão *fusão tardia* é utilizada na literatura tanto para a concatenação de características (Nawaz et al., 2025) quanto para a combinação de decisões (Yousaf; Nawaz; Habib, 2024). Para evitar a ambiguidade, a combinação em nível de características por concatenação é denominada, neste texto, fusão por concatenação de *embeddings*. Quando o modelo é treinado de ponta a ponta, as fontes são ajustadas em conjunto, e a separação entre elas se limita à extração das representações, que possuem naturezas distintas, antes da camada de decisão.

As arquiteturas de dupla via (*two-stream*) processam fontes distintas de informação por ramos independentes e combinam as representações resultantes (Yousaf; Nawaz; Habib, 2024; Wang et al., 2023). A combinação de descritores calculados explicitamente com características profundas foi aplicada em imagens histopatológicas de próstata (Huang et al., 2022).

Dados os *embeddings* $z_{\mathrm{a}} \in \mathbb{R}^{d_a}$ e $z_{\mathrm{b}} \in \mathbb{R}^{d_b}$ de duas vias, a concatenação forma o vetor conjunto

$$z = [\, z_{\mathrm{a}} \,\|\, z_{\mathrm{b}} \,] \in \mathbb{R}^{d_a + d_b}. \tag{23}$$

Os vetores de vias distintas têm origens, escalas e dimensões diferentes. Quando uma via produz

valores limitados, como o estado oculto da LSTM, restrito ao intervalo $(-1, 1)$ pela tangente hiperbólica, e a outra produz ativações sem essa restrição, as características de maior magnitude tendem a predominar na primeira camada do classificador. O mesmo ocorre com o vetor de maior dimensão. Duas medidas contornam o problema: projetar os vetores para a mesma dimensão por uma camada linear e normalizá-los por LN, que, para um vetor $z \in \mathbb{R}^d$, é dada por

$$\mathrm{LN}(z) = \gamma \odot \frac{z - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta, \qquad \mu = \frac{1}{d}\sum_{k=1}^{d} z_k, \qquad \sigma^2 = \frac{1}{d}\sum_{k=1}^{d}(z_k - \mu)^2, \tag{24}$$

em que γ e β são parâmetros aprendidos e ε é uma constante pequena.

O MLP é uma rede *feedforward* em que cada camada aplica uma transformação afim seguida de uma não linearidade, treinada por retropropagação do erro (Rumelhart; Hinton; Williams, 1986), e redes desse tipo, com ao menos uma camada oculta, são aproximadores universais de funções sob condições gerais (Hornik; Stinchcombe; White, 1989). Com uma camada oculta, o classificador é dado por

$$h = \mathrm{ReLU}(W_1 z + b_1)\,, \tag{25}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{26}$$

em que $\hat{y}$ é o vetor de probabilidades sobre as classes e os pesos são ajustados pela minimização da entropia cruzada, $\mathcal{L} = -\sum_c y_c \log \hat{y}_c$. O número de parâmetros da primeira camada é proporcional ao produto de $d_a + d_b$ pela dimensão da camada oculta, o que exige atenção em conjuntos com dezenas a poucas centenas de imagens. O *dropout*, que desativa aleatoriamente unidades durante o treinamento, é uma técnica de regularização contra o sobreajuste (Srivastava et al., 2014), aplicável à camada oculta.

4 MATERIAIS E MÉTODOS

As imagens utilizadas provêm de cinco *datasets* histopatológicos, descritos na Seção 4.1. A arquitetura proposta extrai características de cada imagem por duas vias, a topológica e a visual (Seção 4.2). Os *embeddings* resultantes são concatenados (Seção 4.2.3) e classificados por um MLP (Seção 4.2.4), e o desempenho é medido pelo protocolo da Seção 4.3. O fluxo completo está apresentado na Figura Figura 1.

4.1 *DATASETS*

A avaliação foi conduzida em cinco *datasets* de imagens histopatológicas, com 58 a 528 imagens cada. Os conjuntos incluem tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, o que permite observar o comportamento do modelo em cenários com poucos dados. As características de cada conjunto estão resumidas na Tabela 1. Os conjuntos LA e LG não correspondem a tarefas diagnósticas, pois as classes são a idade e o sexo de camundongos. Esses conjuntos foram incluídos como *benchmarks* de textura histológica, nos quais a distinção entre as classes depende do padrão do tecido hepático e não de uma lesão.

Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**	**Resolução original**
UCSB	Mama (benigno / maligno)	58	2	32 / 26	896×768
CR	Colorretal (benigno / maligno)	165	2	74 / 91	775×522 (14 exceções)
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151	417×312
LG	Sexo (macho / fêmea)	265	2	150 / 115	417×312
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122	1388×1040

As imagens foram mantidas em inteiros de 8 bits por canal e alimentaram as duas vias em resoluções distintas. A via topológica utilizou a imagem na resolução original de cada *dataset* (Tabela 1), sem redimensionamento e sem alteração de intensidades, pois as arestas das redes complexas dependem da comparação de intensidades inteiras, incluindo os empates, e a interpolação suavizaria essas diferenças. A via visual utilizou uma versão de 256×256 pixels, escala em que os modelos utilizados foram pré-treinados, o que também uniformiza as dimensões dos lotes. Essa versão foi obtida pelo redimensionamento do lado menor para 256 pixels, por interpolação de área e com a proporção preservada, seguido de um recorte central de 256×256 pixels. As imagens de 256×256 pixels foram calculadas uma única vez, mantidas como inteiros de 8 bits e armazenadas em cache, com a ordem dos arquivos conferida contra a da via topológica. A conversão para o intervalo $[0, 1]$ e a normalização foram aplicadas a cada lote, com a média e o desvio padrão do pré-processamento de cada *backbone* pré-treinado (Seção 4.2.2): a média de $(0{,}485;\ 0{,}456;\ 0{,}406)$ e o desvio padrão de $(0{,}229;\ 0{,}224;\ 0{,}225)$ da ImageNet para

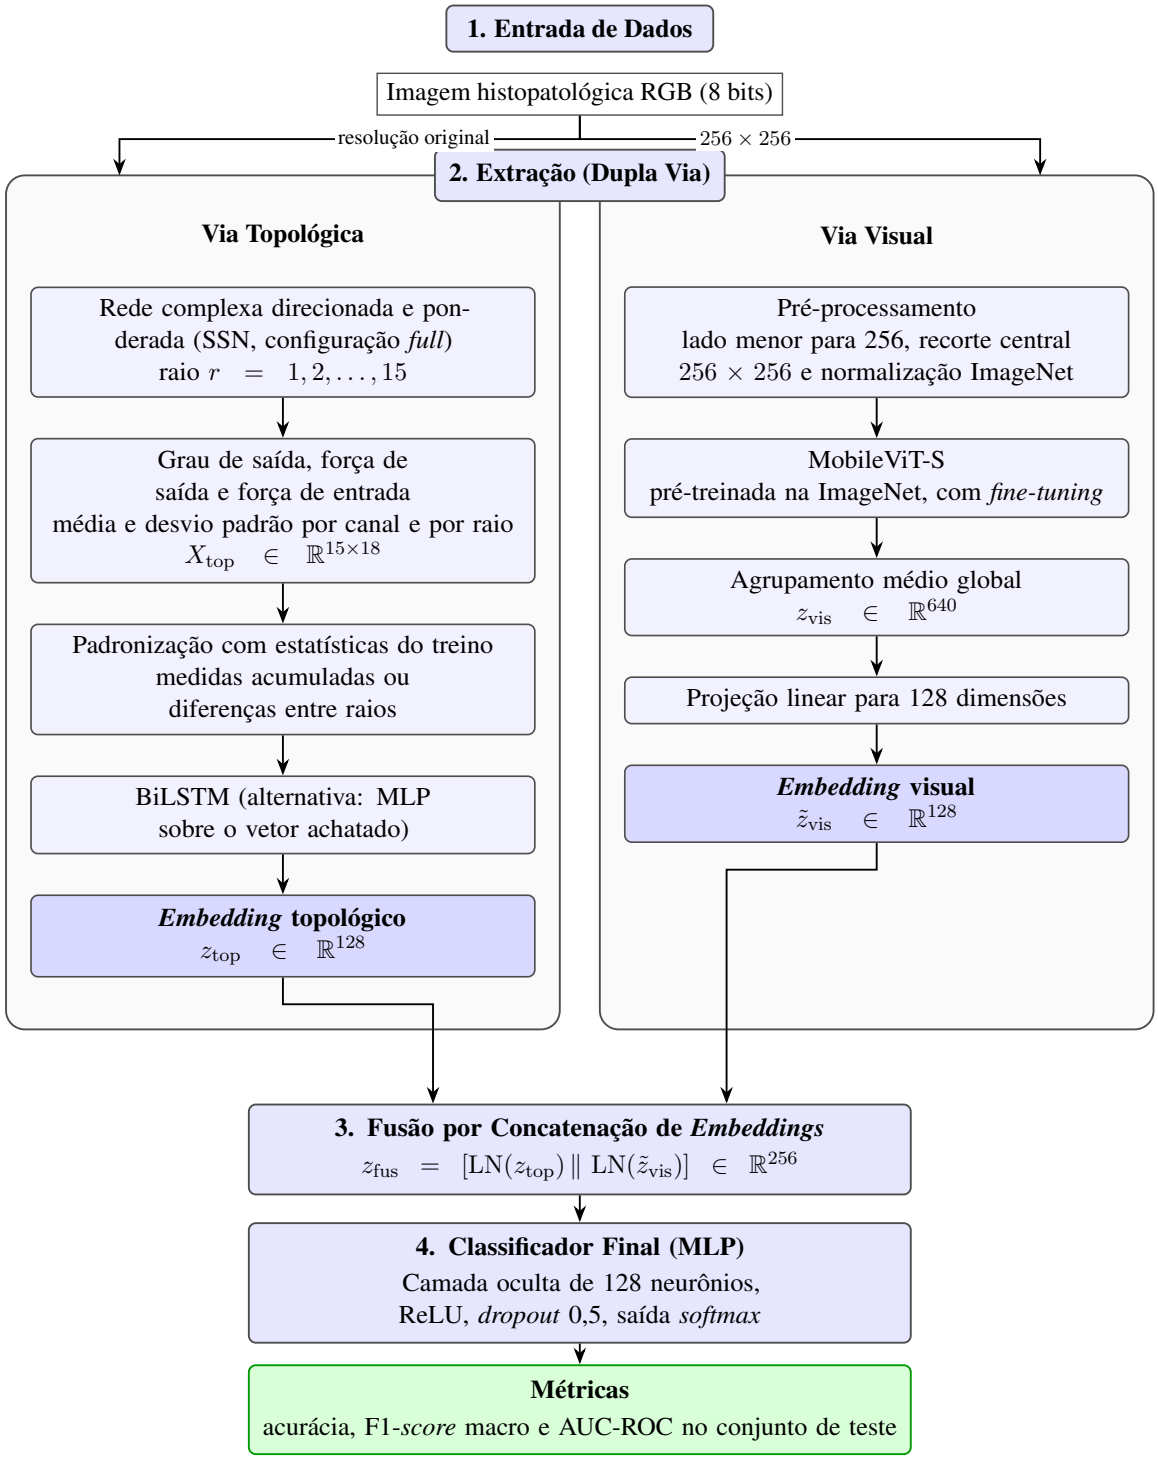


Figura 1 – Arquitetura proposta de dupla via. A via topológica converte a imagem em redes complexas de raios crescentes, e a sequência de medidas é codificada por uma BiLSTM. A via visual extrai o *embedding* da imagem redimensionada com a MobileViT-S. Os *embeddings* normalizados são concatenados e classificados por um MLP, e todos os parâmetros são ajustados em conjunto.

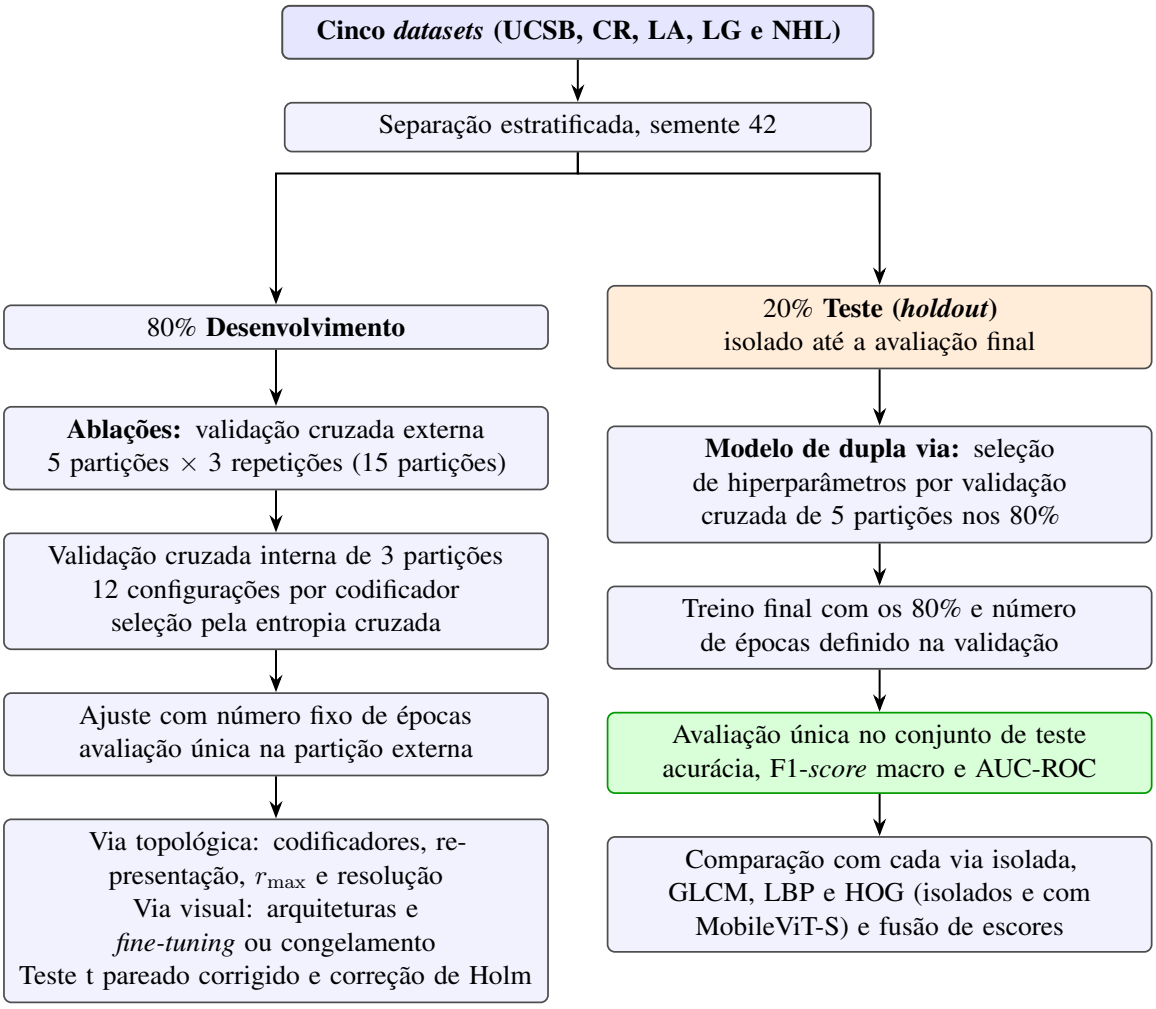
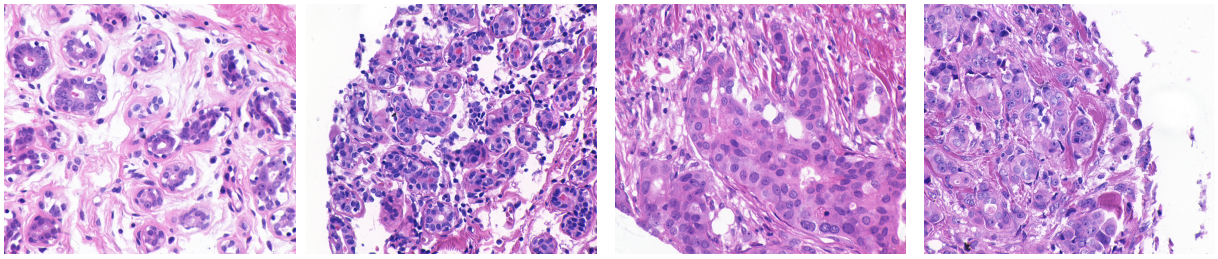


Figura 2 – Protocolo experimental. As ablações utilizam apenas os 80% de desenvolvimento, em validação cruzada aninhada, e o conjunto de teste de 20% permanece isolado até a avaliação final do modelo de dupla via.

a EfficientNet-B0 e a DeiT-Tiny, e média nula e desvio unitário para a MobileViT-S, cujos pesos foram pré-treinados sem normalização por canal. Esse procedimento evita a distorção de proporção, mas o recorte central descarta as bordas das imagens que não são quadradas.

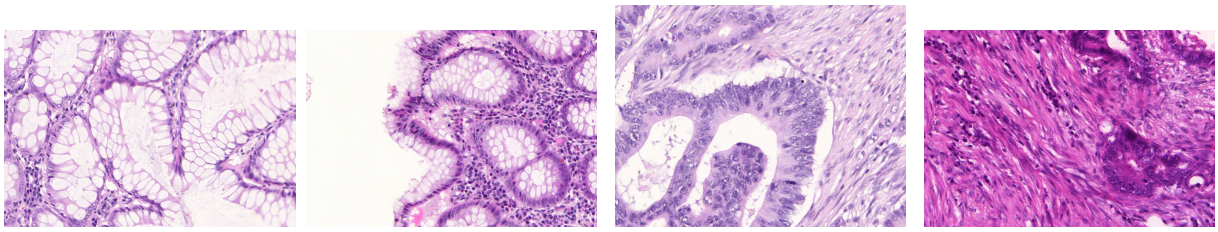
O *dataset* UCSB (Gelasca et al., 2008) é composto por 58 imagens RGB de tecido de câncer de mama (Figura Figura 3), sendo 32 benignas e 26 malignas, e possui o menor número de amostras entre os conjuntos avaliados. O *dataset* CR (Sirinukunwattana et al., 2017) contém 165 imagens RGB de tecido colorretal, obtidas a partir de 16 seções histológicas representativas de câncer colorretal nos estágios T3 e T4. O conjunto é levemente desbalanceado, com 74 imagens de tecido benigno e 91 de tecido maligno, e a resolução original é de 775×522 pixels em 151 imagens, enquanto 14 imagens (7 por classe) têm resoluções menores, de 567×430 a 589×453 pixels, com proporção diferente das demais (Figura Figura 4).

Os *datasets* LA e LG (Shamir et al., 2008) compreendem micrografias RGB de tecido hepático de camundongos. O LA tem como objetivo classificar a idade dos animais fêmeas em quatro grupos, com um mês (100 imagens), seis meses (115), 16 meses (162) e 24 meses (151),



(a) (b) (c) (d)

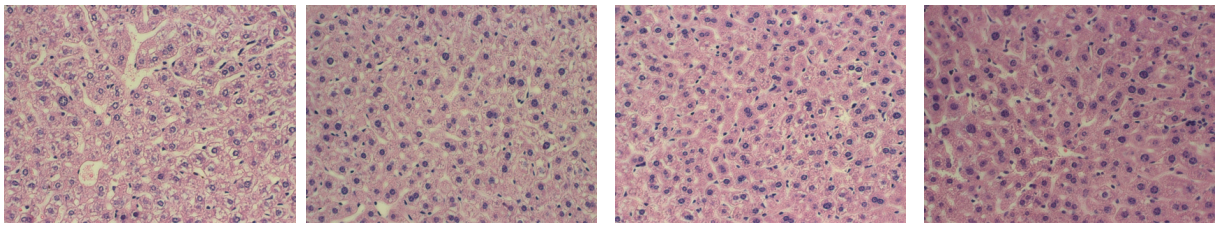
Figura 3 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.



(a) (b) (c) (d)

Figura 4 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

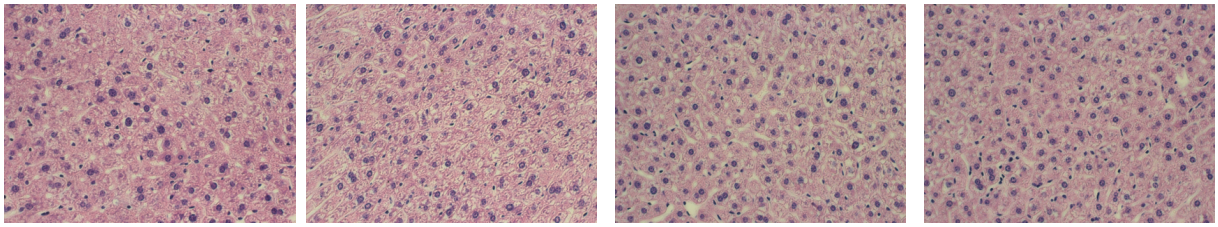
totalizando 528 imagens. O LG contém 265 imagens para classificação de sexo, divididas em 150 machos e 115 fêmeas. As amostras dos dois conjuntos estão nas Figuras Figura 5 e Figura 6.



(a) (b) (c) (d)

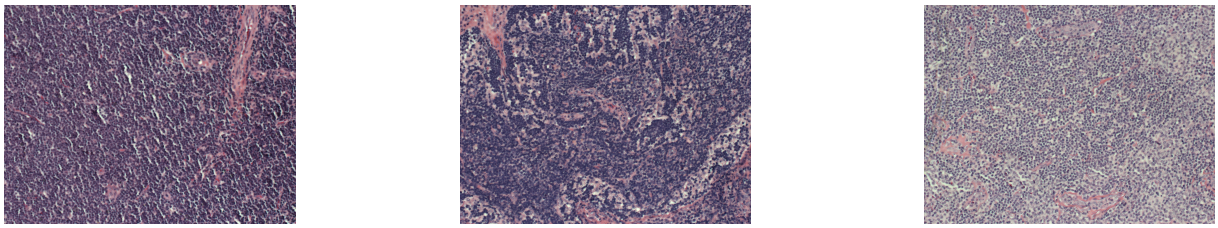
Figura 5 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).

O *dataset* NHL (Shamir et al., 2008) contém 374 imagens RGB de linfoma não Hodgkin, distribuídas em três classes diagnósticas: CLL (113 imagens), FL (139 imagens) e MCL (122 imagens). Diferentemente de aquisições realizadas em um único centro, o NHL reúne espécimes preparados por diferentes histologistas em diversos hospitais e laboratórios, com variações marcantes de coloração e iluminação (Figura Figura 7). Essa variabilidade cromática motivou a inclusão do conjunto. Como as partições de validação cruzada e de teste foram obtidas dentro do próprio conjunto e sem metadados de laboratório, o protocolo não avalia a generalização para laboratórios não vistos.



(a) (b) (c) (d)

Figura 6 – Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.



(a) (b) (c)

Figura 7 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

4.2 *TWO-STREAM NETWORK*

A arquitetura proposta, ilustrada na Figura 1, é uma rede de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas. A via topológica representa a imagem por medidas de redes complexas processadas por uma BiLSTM ou por um MLP, e a via visual extrai características diretamente da imagem RGB por uma arquitetura híbrida baseada em convoluções e atenção. As duas vias são independentes durante a extração. Os *embeddings* resultantes são projetados para a mesma dimensão, concatenados e classificados por um MLP, e todos os parâmetros são ajustados em conjunto no treinamento (Seção 4.3).

Na arquitetura proposta, a via topológica descreve as relações entre pixels em raios de conexão crescentes, e a via visual aprende representações a partir dos pixels da imagem. O fundamento das arquiteturas de dupla via e da combinação das representações está na Seção 3.5.

O processamento ocorre em quatro etapas. A primeira extrai as características topológicas por redes complexas e as codifica por uma BiLSTM ou por um MLP. A segunda extrai as características visuais pela MobileViT-S. A terceira projeta, normaliza e concatena os dois *embeddings*. A quarta classifica o vetor concatenado por um MLP.

4.2.1 Via topológica

A primeira via descreve a textura da imagem por medidas topológicas de redes complexas (Seção 3.2). Cada imagem foi convertida em uma rede direcionada e ponderada, na qual cada pixel é um vértice e as arestas ligam pixels cuja distância é de no máximo $r_{\max}$. O peso de cada aresta combina a diferença absoluta de intensidade e a distância euclidiana entre os pixels (Seção 3.2.2), e a direção vai do pixel de menor intensidade para o de maior intensidade (Scabini;

Ribas; Bruno, 2020; Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). As imagens foram modeladas em redes do tipo *full*, que permite a criação tanto entre pixels de mesmo canal de cor quanto entre pixels de diferentes canais de cores (Scabini; Ribas; Bruno, 2020). As conexões intercanais incluem as arestas de distância nula entre os canais de um mesmo pixel, que pertencem ao raio 1 (Ribas et al., 2024). A rede foi construída sobre a imagem original de 8 bits, na resolução nativa de cada *dataset*, sem redimensionamento e sem normalização. As medidas por raio são médias e desvios padrão sobre os vértices, de modo que imagens de tamanhos diferentes geram sequências com a mesma dimensão. Por serem determinísticas, as medidas foram calculadas uma única vez por imagem e reutilizadas em todas as partições.

Para cada vértice foram calculados o grau de saída, a força de saída e a força de entrada, acumulados até cada raio $r \in \{1, 2, \ldots, r_{\max}\}$, e o grau de entrada não foi utilizado por ser uma combinação linear do grau de saída Ribas et al. (2024). Em cada raio, a média global e o desvio padrão global das três medidas foram calculados para cada um dos três canais, o que produz 18 características por raio. A imagem é descrita pela sequência

$$X_{\text{top}} = [x_1, x_2, \ldots, x_{15}], \tag{1}$$

em que cada passo $x_r \in \mathbb{R}^{18}$ corresponde ao raio r, e a sequência completa contém 270 valores. As medidas por raio seguem a SSN (Scabini; Ribas; Bruno, 2020). A sequência é processada por um codificador, a BiLSTM ou o MLP (descritos adiante), cujo vetor de saída forma o descritor topológico $z_{\text{top}} \in \mathbb{R}^{128}$.

O raio de conexão variou de 1 a 15, de modo que $r_{\max} = 15$, intervalo analisado na literatura de redes complexas aplicadas à textura (Zerati et al., 2026). A sensibilidade ao valor de $r_{\max}$ foi verificada na via topológica isolada, com $r_{\max} \in \{4, 7, 10, 15\}$ (Seção **??**). Como o raio é medido em pixels, $r_{\max} = 15$ cobre uma fração maior da imagem nos conjuntos de menor resolução (LA e LG) e menor nos de maior resolução (NHL), o que altera a escala espacial descrita pelas medidas.

As medidas são acumuladas e crescem de forma monotônica com r, e assumem magnitudes elevadas nos raios maiores, o que pode saturar as portas da BiLSTM e dominar a primeira camada do MLP. Cada uma das 270 coordenadas de X_{top} foi padronizada pela média e pelo desvio padrão do conjunto de treino de cada rodada da validação cruzada e do treinamento final, e os mesmos parâmetros foram aplicados às imagens de validação e de teste. Uma representação alternativa, formada pelas diferenças entre raios consecutivos, $\Delta x_r = x_r - x_{r-1}$ com $\Delta x_1 = x_1$, remove a monotonicidade das medidas acumuladas. Na ablação da via topológica isolada (Seção 5.1), as duas representações não diferiram significativamente em nenhuma das 45 combinações de codificador e *dataset*. Por esse motivo, ambas foram mantidas no modelo de dupla via, e a padronização descrita acima é aplicada à representação utilizada em cada configuração.

Na ablação, o MLP sobre o vetor achatado obteve o melhor ranking médio entre os *datasets* (3,40 com diferenças e 3,60 com medidas acumuladas), e a BiLSTM foi a melhor entre as redes

recorrentes (6,40 e 6,80). A diferença de F1 macro entre os dois não foi significativa em nenhum *dataset*, e a equivalência dentro de $\pm 0{,}02$ foi demonstrada apenas no LA. A ablação, portanto, não sustentou a contribuição da recorrência, mas também não permitiu afirmar a superioridade do MLP. Com base nesse resultado, os dois foram mantidos como codificadores da via topológica no modelo de dupla via: a BiLSTM, por ser o codificador proposto e o melhor entre os recorrentes, e o MLP, por ter obtido o melhor desempenho médio. Cada codificador foi avaliado com as duas representações da sequência (medidas acumuladas e diferenças), o que resulta em quatro variantes da via topológica. As variantes compartilham a via visual, a fusão (Seção 4.2.3) e o classificador (Seção 4.2.4) e diferem apenas no codificador e na representação, o que permite verificar, nas mesmas partições, se a diferença entre recorrência e MLP se mantém quando a via topológica é combinada à via visual (Seção 4.4).

4.2.1.1 Codificador BiLSTM

A sequência padronizada foi processada por uma BiLSTM (Hochreiter; Schmidhuber, 1997; Schuster; Paliwal, 1997). Na configuração padrão, a rede possui uma camada e 64 unidades ocultas por direção, o que resulta em um *embedding* de 128 dimensões e cerca de 43 mil parâmetros na camada recorrente. Essa dimensão reduzida foi adotada para limitar o risco de sobreajuste nos conjuntos menores, nos quais o treino contém cerca de 37 imagens (UCSB). Nas ablações, a dimensão do *embedding*, o número de camadas, o *dropout*, a taxa de aprendizado, o decaimento de pesos e o tamanho do lote foram ajustados por uma busca de hiperparâmetros com o mesmo orçamento de todos os codificadores comparados (Seção 5.1), e as configurações selecionadas tiveram mediana de 60 034 parâmetros, contada a cabeça de classificação. No modelo de dupla via, foi mantida a configuração padrão, com uma camada e *embedding* de 128 dimensões, igual ao da projeção da via visual (Seção 4.2.3), e a arquitetura do codificador não foi variada na busca de hiperparâmetros. Essa escolha se apoia na ablação, em que a busca selecionou uma camada em 74% das partições e o *embedding* de 128 dimensões, e em que o ajuste de hiperparâmetros produziu ganho de F1 macro de no máximo 0,022 em módulo fora do UCSB e da SVM e reduziu o F1 no UCSB, o que é compatível com seleção ruidosa em treinos de poucas imagens (Seção 2). A rede opera no formato *many-to-one*, e o *embedding* topológico é a concatenação do estado final da leitura direta, do raio 1 ao 15, com o estado final da leitura inversa:

$$z_{\text{top}} = \left[\overrightarrow{h}_{15} \,\|\, \overleftarrow{h}_{1} \right] \in \mathbb{R}^{128}. \tag{2}$$

A leitura direta acumula, a cada passo, a informação dos raios menores nos raios maiores, o que corresponde à hipótese de que a organização em larga escala depende da organização local. A leitura inversa fornece a cada raio o acesso ao contexto das escalas maiores. A contribuição da segunda direção foi verificada por ablação contra a LSTM unidirecional, com suporte na literatura de redes bidirecionais (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005).

4.2.1.2 Codificador MLP

No segundo codificador, os 15 vetores de X_{top} são concatenados em um único vetor de 270 valores, $\text{vec}(X_{\text{top}}) \in \mathbb{R}^{270}$, processado por um MLP (Rumelhart; Hinton; Williams, 1986). Na configuração padrão, o codificador possui uma camada linear de 128 neurônios seguida da função ReLU, o que resulta em um *embedding* de 128 dimensões e 34 688 parâmetros na camada linear:

$$z_{\text{top}} = \text{ReLU}\left(W_t\ \text{vec}(X_{\text{top}}) + b_t\right) \in \mathbb{R}^{128}, \qquad W_t \in \mathbb{R}^{128\times 270}. \tag{3}$$

Diferentemente da BiLSTM, o MLP não compartilha pesos entre os raios nem impõe uma ordem de leitura, pois cada uma das 270 coordenadas tem pesos próprios, e a relação entre raios consecutivos precisa ser aprendida a partir dos dados. Nas ablações, as configurações selecionadas para o MLP tiveram mediana de 30 210 parâmetros, contada a cabeça de classificação, contra 60 034 da BiLSTM. No modelo de dupla via foi mantida a configuração padrão, com uma camada oculta e *embedding* de 128 dimensões, que é a mais simples do espaço de busca. A ablação não demonstrou vantagem de maior profundidade, pois o ajuste de hiperparâmetros, que variava entre 1 e 2 camadas ocultas, trouxe ganho pequeno fora do UCSB e da SVM, e o uso da mesma configuração padrão nos dois codificadores mantém a comparação entre eles equilibrada. Como a saída da ReLU não tem limite superior, ao contrário da saída da BiLSTM, a LN aplicada antes da concatenação (Seção 4.2.3) uniformiza a escala dos dois codificadores.

4.2.2 Via visual

A via visual extrai atributos diretamente da imagem RGB por meio da MobileViT, uma arquitetura híbrida que combina convoluções, que capturam detalhes celulares, e blocos *transformer*, que modelam o contexto do tecido em escala maior (Mehta; Rastegari, 2022; Oliveira et al., 2025). A variante MobileViT-S foi adotada por seu custo computacional reduzido (Mehta; Rastegari, 2022), adequado a bases de 58 a 528 imagens. A escolha foi submetida a uma ablação com outras duas arquiteturas de porte semelhante, a EfficientNet-B0 (convolucional) e a DeiT-Tiny (*transformer*), e com o *backbone* congelado e ajustado (Seções **??** e **??**). O modelo recebeu a versão de 256×256 pixels da imagem (Seção 4.1), normalizada pelos parâmetros do pré-treinamento da MobileViT-S (média nula e desvio unitário), e a camada densa de classificação do topo da rede foi removida. Os pesos foram obtidos da biblioteca *timm* (`mobilevit_s.cvnets_in1k`).

As ativações do último bloco convolucional foram agregadas por uma camada de agrupamento médio global (*Global Average Pooling*), que reduz cada mapa de características a um valor. Sendo I a imagem processada e $f_{\text{vis}}(\cdot)$ o codificador visual, o mapeamento é dado por

$$z_{\text{vis}} = f_{\text{vis}}(I), \tag{4}$$

em que $z_{\text{vis}} \in \mathbb{R}^{640}$ é o *embedding* visual. A rede foi inicializada com pesos pré-treinados

na ImageNet e ajustada por *fine-tuning* junto com o restante do modelo. No modelo de dupla via, a via visual recebeu aumento de dados por inversões e rotações de 90 graus (Seção 4.3), configuração tomada como referência na ablação da via visual isolada (Seção 5.2). Nessa ablação, o aumento obteve F1 macro médio maior em quatro dos cinco *datasets*, mas nenhuma diferença foi significativa e a média diminuiu no LG, de modo que a escolha se apoia na referência da ablação e no benefício aparente nos conjuntos menores, e não em um ganho demonstrado.

4.2.3 Fusão por concatenação de *embeddings*

Os *embeddings* das duas vias foram combinados em nível de características, antes do classificador, na estratégia denominada fusão por concatenação de *embeddings* (Seção 3.5). Como o modelo é treinado de ponta a ponta, as duas vias são ajustadas em conjunto, e a separação entre elas se limita à extração das representações.

Os dois vetores têm escalas e dimensões distintas. Os valores de z_{top} da BiLSTM são limitados ao intervalo $(-1, 1)$ pela tangente hiperbólica da célula de memória, e os do MLP são não negativos e sem limite superior, por saírem de uma ReLU. Já z_{vis} resulta de ativações sem limitação, e a diferença de escala pode fazer as características de maior magnitude predominarem na primeira camada do classificador. O vetor visual, com 640 dimensões, também supera o topológico, com 128. Por esse motivo, z_{vis} foi projetado para 128 dimensões por uma camada linear, e cada vetor foi normalizado por LN antes da concatenação:

$$\tilde{z}_{\text{vis}} = W_p\, z_{\text{vis}} + b_p, \qquad W_p \in \mathbb{R}^{128\times 640}, \tag{5}$$

$$z_{\text{fus}} = [\mathrm{LN}(z_{\text{top}}) \,\|\, \mathrm{LN}(\tilde{z}_{\text{vis}})] \in \mathbb{R}^{256}. \tag{6}$$

O símbolo $\|$ indica a concatenação dos vetores, e z_{top} é o *embedding* da BiLSTM (Equação 2) ou do MLP (Equação 3), conforme a variante da via topológica, de modo que a fusão é idêntica nos dois casos. O vetor z_{fus} contém 128 dimensões de cada via e é a entrada do classificador.

4.2.4 Classificador MLP

A classificação foi realizada por um MLP (Rumelhart; Hinton; Williams, 1986), distinto do MLP usado como codificador topológico (Seção 4.2.1.2), com uma camada oculta de 128 neurônios, o que resulta em cerca de 33 mil parâmetros na primeira camada. A camada oculta é dada por

$$h = \mathrm{ReLU}\left(W_1 z_{\text{fus}} + b_1\right), \tag{7}$$

em que a ReLU introduz a não linearidade. Sobre h foi aplicada uma camada de *Dropout* com probabilidade de desativação de $0{,}5$ durante o treinamento (Srivastava et al., 2014), como regularização para os conjuntos com poucas imagens, como UCSB e CR. A camada de saída tem

C neurônios, com C igual ao número de classes de cada *dataset* (de 2 a 4), e as probabilidades são obtidas por

$$\hat{y} = \mathrm{softmax}\left(W_2 h + b_2\right). \tag{8}$$

4.3 PROTOCOLO DE TREINAMENTO

A arquitetura foi treinada de ponta a ponta (*end-to-end*). Os parâmetros da MobileViT-S, da projeção, do codificador topológico (BiLSTM ou MLP) e do MLP classificador foram atualizados em conjunto pela minimização da entropia cruzada, com o otimizador AdamW, a norma do gradiente limitada a 1 e sem agendador da taxa de aprendizado, como nas ablações (Seção 5.2). Os parâmetros foram divididos em três grupos, com taxas de aprendizado próprias: o *backbone* MobileViT-S, inicializado com pesos pré-treinados (lr_{bb}), o codificador topológico, inicializado aleatoriamente, com taxa de 10^{-3}, valor padrão da ablação da via topológica (Seção 5.1), e a projeção e o classificador (lr_{hd}). A taxa do *backbone* foi escolhida em $\{10^{-4}, 3 \times 10^{-4}\}$ e a da projeção e do classificador em $\{10^{-4}, 10^{-3}\}$, o que resulta em quatro configurações. O espaço da taxa do *backbone* substitui o valor de 10^{-5} da configuração padrão da ablação visual, que não foi selecionado em nenhuma partição da MobileViT-S, enquanto 3×10^{-4} foi o mais selecionado (Seção 5.2.2). Como o valor mais selecionado era o limite do espaço da ablação, o valor de 10^{-3} foi verificado em um piloto (**[PILOTO: informar se 10^{-3} é estável e se entra no espaço de busca]**). Os demais hiperparâmetros foram fixados nos valores da ablação: decaimento de pesos de 10^{-4}, *dropout* de $0{,}5$ e lote de 8 imagens quando o treino tem menos de 100 imagens e de 16 nos demais casos, descartando lotes de menos de duas imagens (exigência da normalização de lote). O número máximo de épocas foi de **[PILOTO: 50]** e a paciência da parada antecipada, de **[PILOTO: 10]** épocas, valores maiores que os da ablação visual (30 e 5) porque o codificador topológico, treinado a partir de pesos aleatórios, pode convergir mais devagar que o *backbone* pré-treinado.

A via visual recebeu aumento de dados por inversão horizontal, com probabilidade 0,5, e rotação de 0, 90, 180 ou 270 graus, aplicado por imagem e somente ao treino, a mesma configuração tomada como referência na ablação da via visual (Seção **??**). A via topológica não é transformada, pois suas sequências foram calculadas uma única vez sobre a imagem original. Esse procedimento é coerente porque as medidas topológicas globais, médias e desvios padrão sobre todos os vértices, não mudam por inversões e rotações de 90 graus, já que essas transformações preservam as distâncias entre pixels e as intensidades. Essa invariância foi verificada por um teste que compara as 270 características da imagem original com as de suas versões transformadas (**[XX: resultado do teste]**).

4.3.1 Validação

O desempenho foi estimado em duas etapas, as duas sobre a mesma divisão estratificada das ablações (semente 42). Antes de qualquer treinamento, 20% das imagens de cada *dataset*, com as respectivas sequências topológicas, foram separadas como conjunto de teste (*holdout*) e mantidas isoladas até a avaliação final. As 80% restantes, o conjunto de desenvolvimento, foram utilizadas na estimativa principal do desempenho, por validação cruzada aninhada com as mesmas 15 partições externas das ablações (validação cruzada estratificada com 5 partições, repetida três vezes), o que permite comparar o modelo de dupla via com as vias isoladas partição a partição (Seção 5.1). O alinhamento foi verificado em cada comparação pelo identificador da partição de teste (*hash* dos índices). O esquema completo das separações dos dados, da seleção de configuração e da avaliação está na Figura Figura 8.

Em cada partição externa, o treino foi dividido por uma validação cruzada interna estratificada com 3 partições, usada na escolha entre as quatro configurações de taxa de aprendizado e na definição do número de épocas. Em cada partição interna, a arquitetura completa (MobileViT-S, codificador topológico, projeção e classificador) foi treinada de ponta a ponta com os pesos reinicializados, a MobileViT-S a partir dos pesos da ImageNet, com parada antecipada pela perda de validação e restauração dos melhores pesos. A configuração foi escolhida pela menor entropia cruzada média nas partições internas, e o número de épocas do treino final foi igual à média das épocas ótimas internas, com mínimo de 3. O modelo foi então treinado novamente com todo o treino da partição externa durante esse número fixo de épocas, sem uso de validação, e avaliado uma única vez na partição externa. A padronização das 270 coordenadas topológicas e de todos os descritores clássicos foi ajustada apenas sobre o treino de cada ajuste, e todos os métodos comparados utilizaram as mesmas partições. O desempenho de cada método é o F1 macro médio e o desvio padrão entre as 15 partições externas, comparado pelo teste t pareado corrigido (Seção **??**).

Como análise confirmatória, o procedimento de seleção foi repetido sobre o conjunto de desenvolvimento inteiro, o modelo final foi treinado com as 80% das imagens e avaliado uma única vez no *holdout*, que não participou da escolha de épocas, de hiperparâmetros ou de parâmetros de padronização. As probabilidades preditas para cada imagem de teste, nas partições externas e no *holdout*, foram salvas para a análise da complementaridade dos erros entre as vias.

Entre as quatro variantes da via topológica (Seção 4.2.1), a primária, definida antes da execução e usada na comparação principal entre o modelo de dupla via e a via visual isolada, foi o MLP com a representação por diferenças, que obteve o melhor ranking médio na ablação topológica. As demais três variantes são análises secundárias, e os valores de p são ajustados por Holm entre os cinco *datasets*.

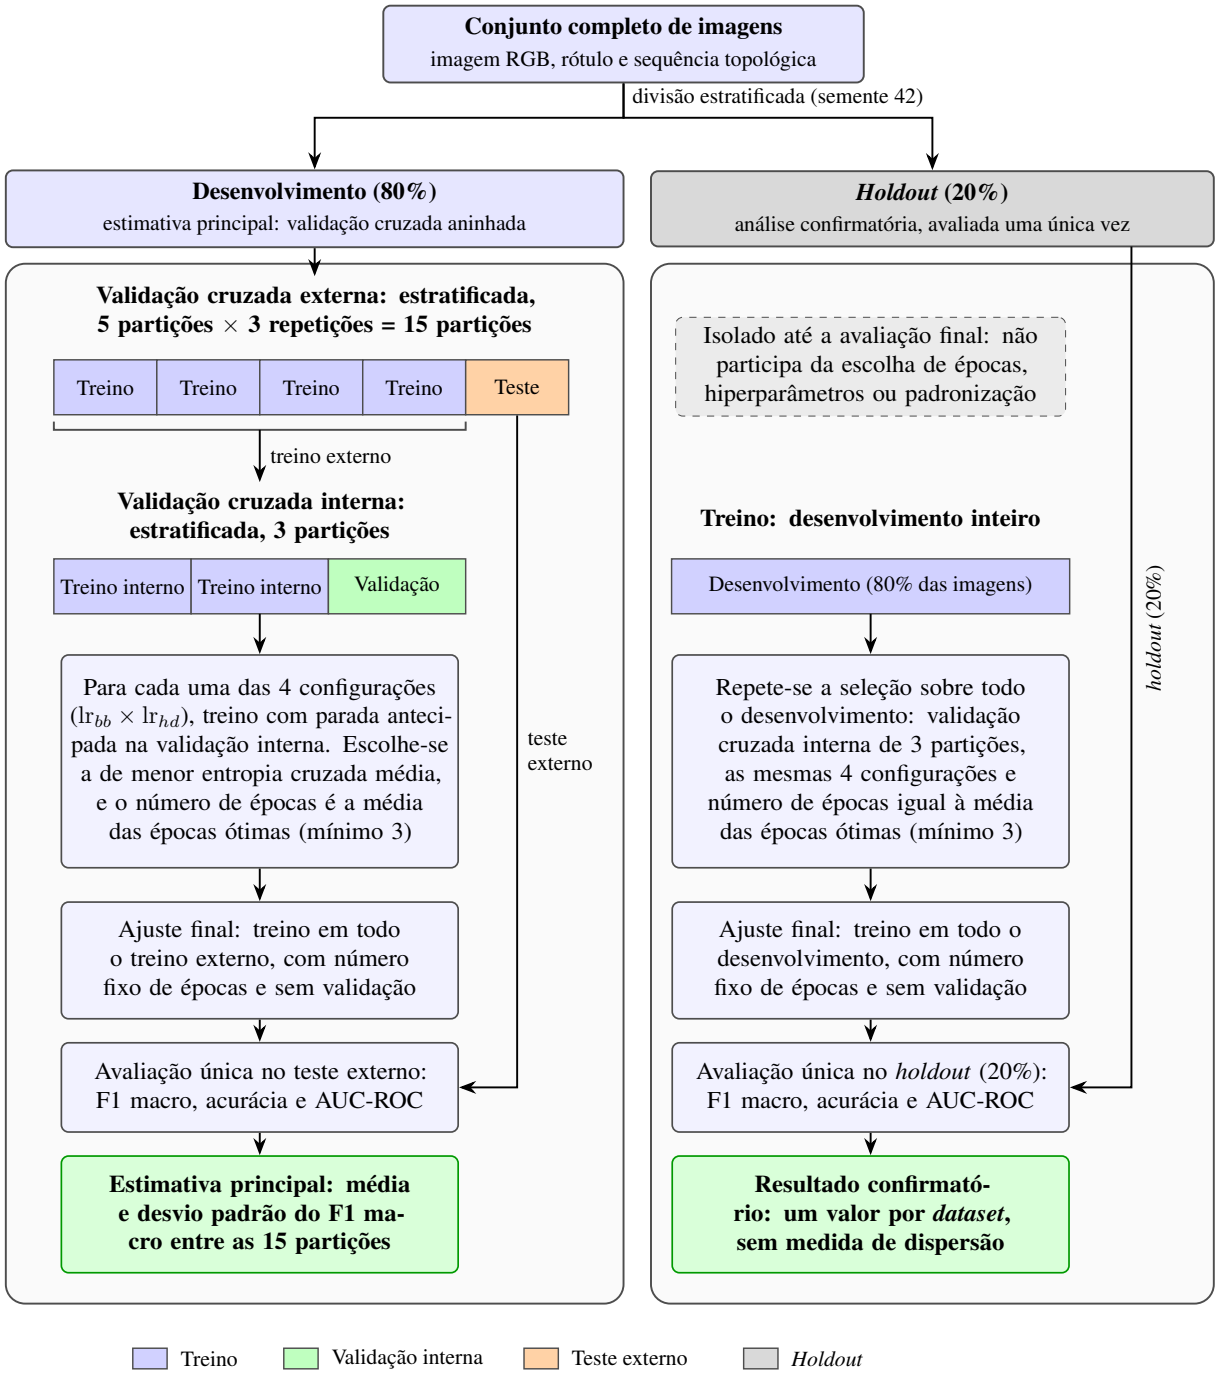


Figura 8 – Separação dos dados e estimativa do desempenho. Um conjunto de teste (*holdout*) de 20% é separado antes de qualquer treinamento. Os 80% restantes (desenvolvimento) são avaliados por validação cruzada aninhada, com 15 partições externas (5 partições repetidas três vezes) e, em cada uma, uma validação cruzada interna de 3 partições para a escolha da configuração e do número de épocas. O mesmo procedimento, aplicado ao desenvolvimento inteiro, gera o modelo avaliado uma única vez no *holdout*.

4.3.2 Métricas

O desempenho da classificação foi quantificado pela acurácia, pelo F1-*score* macro e pela AUC-ROC. A acurácia é a proporção global de predições corretas. O F1-*score* macro é a média, entre as classes, da média harmônica da precisão e da sensibilidade de cada classe, e atribui o mesmo peso a todas as classes, o que o torna adequado a conjuntos desbalanceados, como o CR. A AUC-ROC mede a capacidade de distinguir as classes ao longo dos limiares de decisão e, nos conjuntos multiclasse (LA e NHL), foi calculada pela estratégia um-contra-todos (*one-vs-rest*) com média macro. As métricas foram calculadas em cada partição externa, para a estimativa principal, e no conjunto de teste (*holdout*) pelo modelo final, para a análise confirmatória.

4.3.3 Limitações do protocolo

O protocolo apresenta limitações que são consideradas na interpretação dos resultados. No UCSB, o *holdout* contém cerca de 12 imagens e cada partição externa, 9 ou 10, de modo que as métricas são discretas e sensíveis à classificação de poucas imagens, e como o modelo final é avaliado uma única vez no *holdout*, esse resultado não traz uma medida de dispersão, motivo pelo qual a estimativa principal usa as 15 partições externas. As partições foram formadas por imagem. O CR reúne imagens de 16 seções histológicas, e os conjuntos LA e LG provêm de um número limitado de animais. Como identificadores de lâmina ou de animal não foram utilizados, imagens da mesma origem podem aparecer no treino e no teste, o que pode superestimar o desempenho. O NHL não foi avaliado com a exclusão de laboratórios inteiros. Por fim, a via visual recebe um recorte central reduzido, que descarta as bordas das imagens não quadradas, e a via topológica recebe a imagem inteira, de modo que as duas vias não observam exatamente a mesma região. O raio de 15 pixels também cobre frações distintas da cena em cada *dataset*, e as 14 imagens do CR com resolução diferente da modal podem ter escala distinta das demais. Nas ablações da via topológica, as 15 partições externas por tarefa não são independentes e, no UCSB, cada partição de teste contém 9 ou 10 imagens, o que torna o F1 macro de cada partição discreto e os intervalos de confiança largos. A margem de equivalência de $\pm 0{,}02$ é uma escolha do trabalho. A seleção interna de hiperparâmetros utiliza cerca de 24 imagens de treino por partição no UCSB e é sujeita a ruído. O ranking entre *datasets* é descritivo, e as análises de $r_{\max}$ e de resolução abrangem apenas a BiLSTM e o MLP na representação por diferenças. Na ablação da via visual, o efeito do aumento de dados foi avaliado somente na MobileViT-S, e a EfficientNet-B0 e a DeiT-Tiny foram ajustadas apenas com aumento. O espaço de busca da taxa de aprendizado do *backbone* tem como limite superior 3×10^{-4}, valor mais selecionado na MobileViT-S e na EfficientNet-B0, de modo que o ótimo pode estar fora do espaço (Seção 5.2.2). Como na via topológica, a seleção interna usa cerca de 24 imagens de treino por partição no UCSB e é sujeita a ruído, e o tempo e as configurações selecionadas dependem do tamanho de cada *dataset*.

4.4 COMPARAÇÕES COM OS MÉTODOS DE REFERÊNCIA

O desempenho da arquitetura proposta foi comparado com os métodos de referência por meio do mesmo protocolo e das mesmas partições (Seção 4.3). O grupo de comparações principal avalia se a combinação das duas vias supera cada via e as alternativas clássicas. O modelo de dupla via foi avaliado nas quatro variantes da via topológica (BiLSTM ou MLP, com medidas acumuladas ou diferenças; Seção 4.2.1), e as variantes foram comparadas entre si, para verificar se a diferença entre os codificadores e entre as representações se mantém quando a via topológica é combinada à via visual. Cada variante foi comparada com os métodos a seguir:

- a via visual isolada (MobileViT-S, projeção e MLP),
- a via topológica isolada, com a BiLSTM ou o MLP como codificador, seguido do classificador,
- os descritores GLCM, LBP e HOG isolados, classificados pelo mesmo MLP,
- a MobileViT-S concatenada a cada descritor clássico (GLCM, LBP ou HOG) e classificada pelo mesmo MLP, como em Huang et al. (2022), que substitui apenas a via topológica e é a comparação mais direta com a proposta,
- a fusão de escores, calculada como a média das probabilidades das duas vias treinadas isoladamente, com o codificador topológico da variante correspondente (Yousaf; Nawaz; Habib, 2024; Nawaz et al., 2025),
- um controle de capacidade, o mesmo modelo de dupla via com o descritor topológico permutado entre as imagens do treino e, separadamente, entre as do teste, o que mantém a largura da cabeça de classificação e destrói a informação topológica de cada imagem, para verificar se o ganho sobre a via visual decorre dessa informação e não apenas do aumento de capacidade.

Nas comparações com descritores clássicos, cada vetor foi padronizado com estatísticas do treino, projetado para 128 dimensões e normalizado por LN, de forma análoga a z_{top}. Os descritores clássicos foram calculados sobre a imagem na resolução original, a mesma da via topológica, e seus parâmetros foram **[XX]**.

Os demais grupos de comparação, relativos às ablações da via topológica isolada, da resolução da imagem e da via visual isolada, estão descritos no Capítulo 5.

4.5 CONFIGURAÇÃO DE AMBIENTE

Os experimentos foram implementados em Python com a biblioteca PyTorch (versão **[XX]**). A MobileViT-S, a EfficientNet-B0 e a DeiT-Tiny e seus pesos pré-treinados foram obtidos da biblioteca *timm* (versão **[XX]**), e as imagens de 256×256 pixels foram preparadas com a

biblioteca OpenCV. As redes complexas foram construídas por uma implementação em C++ com paralelismo OpenMP em 16 *threads*, com $r_{\max} = 15$. Na resolução original, o custo médio por imagem foi de 2,45 s no UCSB, 1,46 s no CR, 0,47 s no LA, 0,47 s no LG e 5,44 s no NHL. Na versão de 256×256 pixels usada na análise de sensibilidade, o custo foi de 0,23 a 0,26 s por imagem em todos os *datasets*. As ablações da via topológica foram executadas em CPU, com 16 tarefas em paralelo e uma *thread* por tarefa, e a semente aleatória das partições foi 42. As bibliotecas utilizadas foram PyTorch (versão **[XX]**) e scikit-learn (versão **[XX]**), em um processador **[XX]**. Os descritores GLCM, LBP e HOG foram calculados com **[XX]**. O treinamento e a inferência foram executados em uma GPU **[XX]**, com tempo médio de **[XX]** por avaliação. As ablações da via visual foram executadas em GPU, com duas tarefas simultâneas por GPU e escalonamento dinâmico da fila de tarefas, e as tarefas concluídas eram retomadas a partir da última partição externa em caso de interrupção. **[XX: informar se a precisão mista (bfloat16) foi utilizada; ela é opcional e vem desligada por padrão no *script*.]** A semente aleatória das partições foi 42, a mesma das ablações.

5 ABLAÇÃO

Neste capítulo são detalhados os experimentos de ablação conduzidos para determinar as arquiteturas e os hiperparâmetros da via topológica e da via visual antes da composição do modelo de dupla via. As duas vias foram avaliadas de forma isolada sobre as mesmas partições de dados, com o propósito de selecionar as melhores configurações sem utilizar o conjunto de teste final reservado.

5.1 ABLAÇÃO DA VIA TOPOLÓGICA

A via topológica recebe a sequência de características calculada a partir de redes complexas sobre 15 raios de conexão, denotada por $X_{\text{top}} \in \mathbb{R}^{15\times 18}$, em que cada passo contém 18 medidas descritoras. Para verificar a capacidade de aprendizado sobre essa sequência e avaliar a contribuição da dependência de ordem entre as escalas, foram selecionados cinco modelos de redes neurais recorrentes e um modelo não recorrente como *baseline*:

- a LSTM padrão (Hochreiter; Schmidhuber, 1997; Gers; Schmidhuber; Cummins, 2000), modelo com portas de esquecimento, entrada e saída, empregado como referência no processamento de sequências multiescala (Lin et al., 2022) e diagnósticos médicos (Mathiyalagi; Ravi, 2026),
- a BiLSTM (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005), que processa os raios nos sentidos direto e inverso para integrar informação de micro e macrotextura, com precedentes na detecção de alterações celulares neoplásicas (Priyadarshini, 2026) e em modelos de dupla via (Yousaf; Nawaz; Habib, 2024),
- a GRU (Cho et al., 2014), que unifica as portas e dispensa o estado de célula separado, resultando em menor custo paramétrico para conter o risco de sobreajuste em conjuntos com volume reduzido de imagens,
- a BiGRU (Schuster; Paliwal, 1997; Cho et al., 2014), que combina o fluxo de informação bidirecional entre as escalas à redução paramétrica da unidade GRU,
- a SAC-LSTM (*Self-Attention Coupled LSTM*) (Shalini; Rathnamala, 2026), modelo desenvolvido para classificação histopatológica de câncer de mama, que adiciona uma camada de autoatenção aos estados da LSTM para ponderar dinamicamente os raios de conexão mais discriminativos,
- o MLP (*Multi-Layer Perceptron*) (Huang et al., 2022), rede de alimentação direta que processa as 270 características de forma estática sobre o vetor achatado, avaliada como

linha de base de controle para verificar se a modelagem sequencial traz ganho efetivo frente a uma projeção densa sem recorrência.

Todos os seis codificadores produzem um vetor de características com a mesma dimensão oculta, conectado à mesma cabeça de classificação, formada por normalização por camadas, camada linear de 128 neurônios com ativação ReLU, camada de *dropout* e camada linear de saída com projeção para o número de classes de cada tarefa.

O protocolo experimental foi executado exclusivamente sobre a partição de desenvolvimento de cada conjunto de dados. Inicialmente, as imagens de cada conjunto foram divididas de forma estratificada, com semente 42, na proporção de 80% para desenvolvimento e 20% para teste final, permanecendo a partição de teste totalmente reservada e sem qualquer participação no processo de ablação. Sobre os 80% de desenvolvimento, foi aplicada uma validação cruzada estratificada em cinco partições ($k = 5$). Para cada modelo e para cada combinação de hiperparâmetros, o treinamento foi conduzido em cinco rodadas independentes, nas quais quatro partições foram destinadas ao ajuste dos pesos e uma partição foi utilizada para a validação, alternando a partição de validação a cada rodada. Em cada rodada, as 18 medidas descritoras foram padronizadas por escore padrão calculado exclusivamente sobre as partições de treino, prevenindo vazamento de dados para a validação. As dimensões amostrais das partições e a grade de hiperparâmetros explorada para cada conjunto de dados estão sintetizadas na Tabela 2.

Tabela 2 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica.

Dataset	**Desenv. (80%)**	**Treino / Val. (rodada)**	**Lote (B)**	**Taxa de aprendizado (η)**	**Decaimento (λ)**	***Dropout* (p)**	**Dim. oculta (h)**
UCSB	46	36 a 37 / 9 a 10	$\{4, 8, 16\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}\}$	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{32, 64, 128\}$
CR	132	105 a 106 / 26 a 27	$\{16, 32, 64\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}\}$	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{32, 64, 128\}$
LG	212	169 a 170 / 42 a 43	$\{16, 32, 64\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}\}$	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{32, 64, 128\}$
NHL	299	239 a 240 / 59 a 60	$\{16, 32, 64\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}\}$	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{32, 64, 128\}$
LA	422	337 a 338 / 84 a 85	$\{16, 32, 64\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}\}$	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{32, 64, 128\}$

O processo de treinamento foi conduzido com a função de perda de entropia cruzada, otimizador AdamW e norma de gradiente limitada ao valor 1,0 para conter oscilações numéricas. Em decorrência do tamanho reduzido das representações e dos volumes de dados, o treinamento foi delimitado ao teto de 50 épocas, com parada antecipada regulada por uma tolerância de 10 épocas consecutivas sem decrescimento da perda na partição de validação, restaurando os melhores pesos ao término de cada rodada.

O desempenho de cada combinação foi computado pela média aritmética do F1 macro obtido nas cinco partições de validação, selecionando a combinação responsável pela maior pontuação média como a configuração de referência de cada arquitetura em cada conjunto de dados. Os desempenhos obtidos pelas configurações selecionadas de cada codificador, acompanhados do respectivo desvio padrão, estão registrados na Tabela 3, enquanto as combinações de hiperparâmetros responsáveis por esses resultados estão discriminadas na Tabela 4.

As combinações ótimas de hiperparâmetros responsáveis pelos maiores índices de F1 macro em cada conjunto de dados estão discriminadas na Tabela 4.

Tabela 3 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados.

Codificador	UCSB	CR	LA	LG	NHL
LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

5.2 SELEÇÃO DA VIA VISUAL

A seleção da via visual seguiu o protocolo da Seção **??**, com as mesmas 5 partições de validação da via topológica, seis *backbones* e 12 combinações de hiperparâmetros por *backbone*. Resultam 30 combinações de *dataset* e *backbone*. **[a preencher]** (confirmar que todas foram concluídas).

5.2.1 Desempenho dos *backbones*

O F1 macro médio de cada *backbone*, na melhor combinação de hiperparâmetros, está na Tabela 5. **[a preencher]** (descrever o ranking médio, o desempenho por família de arquitetura nas classes híbrida, convolucional e *transformer*, e a variabilidade no UCSB).

5.2.2 Ajuste de hiperparâmetros e custo

[a preencher] (reportar os valores de hiperparâmetros mais selecionados, em especial a taxa de aprendizado do *backbone*, e se o limite superior do espaço de busca foi o escolhido com frequência, além de relatar a contagem de parâmetros e o tempo mediano de treino por *backbone*).

5.2.3 Configurações selecionadas

As três configurações da via visual que seguem para a fusão estão na Tabela 6.

5.3 SÍNTESE E ENCAMINHAMENTO PARA A FUSÃO

Foram selecionadas três configurações da via topológica (Tabela 4) e três da via visual (Tabela 6), que compõem os modelos de dupla via. Todos os modelos finais são treinados com os 80% de desenvolvimento e avaliados uma única vez nos 20% de teste, reservados em todas as etapas deste capítulo. A comparação entre a via visual isolada, a via topológica isolada e a dupla via, que responde ao objetivo central do trabalho, está na Seção 4.4. **[a preencher]** (comentar,

Tabela 4 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo nos cinco conjuntos de dados.

Dataset	Modelo	Taxa de aprend.	*Weight Decay*	*Dropout*	Dim. oculta	Lote
UCSB	LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	BiLSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	GRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	BiGRU	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	SAC-LSTM	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	MLP	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

de forma descritiva, em quais *datasets* cada via teve vantagem na validação interna, reservando a análise da integração combinada para o capítulo de fusão).

Tabela 5 – F1 macro (média $\pm$ desvio padrão entre as 5 partições de validação) da via visual isolada, com *fine-tuning* e aumento de dados rotacional, na melhor combinação de hiperparâmetros de cada *backbone*. Em negrito, o maior valor médio de cada *dataset*.

Família	***Backbone***	**UCSB**	**CR**	**LA**	**LG**	**NHL**
Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Híbrida	CoAtNet	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Transformer	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Transformer	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

Tabela 6 – Três melhores configurações da via visual, por ranking médio do F1 macro entre os *datasets*.

Posição	***Backbone***	lr_{bb}	lr_{hd}	***Dropout***	**Lote**	**Ranking médio**
1	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
2	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
3	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

6 RESULTADOS E DISCUSSÃO

7 CONCLUSÃO

REFERÊNCIAS

AHMED, M. M. et al. Review on medical image segmentation and feature extraction approaches. **Journal of Independent Studies and Research Computing**, v. 21, n. 2, p. 5–15, 2023.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006.

BRUSSEE, S. et al. Graph neural networks in histopathology: Emerging trends and future directions. **Medical Image Analysis**, v. 101, p. 103444, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GELASCA, E. D. et al. Evaluation and benchmark for biological image segmentation. In: **2008 15th IEEE International Conference on Image Processing**. [S.l.: s.n.], 2008. p. 1816–1819.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. In: **12th Canadian Symposium on Remote Sensing, Geoscience and Remote Sensing Symposium (IGARSS'89)**. [S.l.: s.n.], 1989. v. 5, p. 2769–2772.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989.

HUANG, X. et al. Fusing hand-crafted and deep-learning features in a convolutional neural network model to identify prostate cancer in pathology images. **Frontiers in Oncology**, v. 12, p. 994950, 2022.

HUSSAINI, H. et al. A clinically grounded review of medical image classification: Quantitative insights into cnns, vision transformers, and hybrid cnn-vit models. **Journal of Imaging Informatics in Medicine**, 2026.

JESWANI, U.; PRIYADHARSHINI, S. Exploring facial feature extraction and temporal dynamics for deepfake video detection: A CNN-RNN study on FaceForensics++. In: **2026 International Conference on Innovative Trends in Information Technology (ICITIIT)**. [S.l.: s.n.], 2026.

JUN, K. et al. Feature extraction using an RNN autoencoder for skeleton-based abnormal gait recognition. **IEEE Access**, v. 8, p. 19196–19207, 2020.

KITTLER, J. et al. On combining classifiers. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026.

KUSHWAH, S. S.; PUNN, N. S.; BHATTACHARYA, M. EVC-Net: A hybrid deep learning network for breast cancer classification from histopathological images. **ACM Transactions on Intelligent Systems and Technology**, v. 17, n. 4, p. 87, 2026.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, J. Fusion feature-based hybrid methods for diagnosing oral squamous cell carcinoma in histopathological images. **Frontiers in Oncology**, v. 15, p. 1551876, 2025.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OJALA, T.; PIETIKÄINEN, M.; HARWOOD, D. A comparative study of texture measures with classification based on featured distributions. **Pattern Recognition**, v. 29, n. 1, p. 51–59, 1996.

OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 24, n. 7, p. 971–987, 2002.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMIR, L. et al. Iicbu 2008: a proposed benchmark suite for biological image analysis. **Medical & biological engineering & computing**, v. 46, n. 9, p. 943–947, 2008.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHORFUZZAMAN, M. et al. Ai-driven tumor characterization and histological subtype classification in lung cancer using ct imaging. **Diagnostics**, v. 16, n. 17, 2026.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SIRINUKUNWATTANA, K. et al. Gland segmentation in colon histology images: The glas challenge contest. **Medical Image Analysis**, v. 35, p. 489–502, 2017.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TALO, M. Automated classification of histopathology images using transfer learning. **Artificial Intelligence in Medicine**, v. 101, p. 101743, 2019.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YE, M. et al. Feature selection and extraction in sequence labeling for arrhythmia detection. In: **2021 International Balkan Conference on Communications and Networking (BalkanCom)**. [S.l.: s.n.], 2021. p. 107–111.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

ZHI, R.; WAN, M. Dynamic facial expression feature learning based on sparse RNN . In: **2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. [S.l.: s.n.], 2019. p. 1373–1377.