UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Histopatológicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Histopatológicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr. Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS HISTOPATOLÓGICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: 03/12/2026

BANCA EXAMINADORA

_____

Prof. Dr. Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Dedico meus primeiros agradecimentos aos meus pais, Joneslei Aparecido Leite Brum e Marcia Aparecida Martins Brum. Vocês sempre me incentivaram a focar nos estudos e foram a base que tornou a escrita deste trabalho possível. Serei eternamente grato por todo o esforço e amor com que me criaram, espero um dia poder retribuir por tudo.

À minha amada, Júlia Carreno Garcia Leal, que esteve ao meu lado nas conquistas e nos desafios mais intensos desta jornada. Obrigado por manter o amor e a parceria firmes, mesmo à distância na maior parte do tempo, e por me apoiar nos dias difíceis. Seu carinho foi fundamental para que eu chegasse até aqui.

Gostaria de agradecer também aos grandes amigos que a graduação me presenteou. Primeiro, aos meus parceiros de pensão e apartamento, Allan de Carvalho de Almeida, João Carlos Gonçalves Nobre e Felipe do Amparo Lauria, que deixaram o dia a dia mais leve e foram uma verdadeira família para mim. Estendo esse agradecimento aos meus queridos colegas, os "lipaizinhos"Felipe Gomes da Silva, Luís Henrique Salomão Lobato e Matheus Thomé da Silva. Mais do que parceiros de descontração, vocês foram companhias valiosas no grupo de pesquisa e o apoio de vocês nos estudos e no desenvolvimento das pesquisas foi essencial.

Por fim, agradeço ao meu orientador, Prof. Dr. Leandro Alves Neves. Além da amizade e da notável qualidade futebolística, obrigado por acreditar na minha capacidade e por me incentivar a ir cada vez mais longe na ciência.

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

A classificação computacional de imagens histopatológicas sob restrição amostral enfrenta diversos desafios, e para mitigar tais limitações, este trabalho propõe e avalia uma arquitetura de aprendizado profundo de dupla via que integra uma dinâmica topológica multiescalar a representações visuais. Na via topológica, as imagens são modeladas como redes complexas espaço-espectrais direcionadas e ponderadas, originando sequências multiescala de 270 atributos nodais descritores processadas por codificadores sequenciais recorrentes e por um MLP estático (*baseline*). Paralelamente, a via visual extrai atributos visuais por meio de modelos CNN, ViT e CNN-ViT pré-treinados na base ImageNet-1k. As representações resultantes são equalizadas em 128 dimensões por projeção linear, normalizadas por camadas de forma independente, concatenadas em um vetor unificado de 256 atributos e classificadas por uma cabeça MLP ajustada de ponta a ponta. A avaliação contemplou cinco bases histopatológicas divididas em 80% para desenvolvimento em validação cruzada estratificada de cinco partições e 20% para teste independente avaliado sob cinco sementes pré-fixadas (42 a 46). No conjunto multiclasse desafiador NHL, a rede de dupla via atingiu F1 macro de $0{,}938 \pm 0{,}026$ e acurácia de $0{,}939 \pm 0{,}026$, superando a via visual isolada ($0{,}922 \pm 0{,}037$) e a via topológica ($0{,}865 \pm 0{,}025$), reduzindo a dispersão entre sementes em 30%. No conjunto LA, o modelo integrado alcançou F1 macro de $0{,}998 \pm 0{,}004$, cortando a dispersão pela metade, enquanto nas tarefas binárias de alto contraste (CR e LG) sustentou separação perfeita ($1{,}000 \pm 0{,}000$). A via topológica adiciona menos de 1% aos parâmetros globais sem onerar a memória gráfica. Os resultados confirmam que a topologia de redes complexas atua como regularizador eficaz, aumentando a acurácia diagnóstica sob escassez de dados.

Palavras-chave: Redes Complexas. Redes Neurais Recorrentes. Visão Computacional. Imagens Histopatológicas. Fusão Tardia. Aprendizado Profundo.

ABSTRACT

Computational classification of histopathological images in low-data regimes suffers with several challenges and this study proposes and evaluates a two-stream deep learning architecture integrating multiscale topological dynamics with deep visual representations. In the topological stream, histology images are modeled as spatio-spectral directed and weighted complex networks, generating an ordered multiscale sequence of 270 nodal features processed by recurrent neural encoders and a static MLP control baseline. Simultaneously, the visual stream extracts semantic features using ImageNet-1k pre-trained models across CNN, ViT and CNN-ViT architectures. The resulting representations are projected to 128 dimensions, normalized via layer normalization, concatenated into a 256-dimensional joint embedding, and classified by an MLP head trained end-to-end. The approach was evaluated on five histopathological benchmarks, split into 80% development with 5-fold stratified cross-validation for hyperparameter ablation and 20% independent test evaluated over five random seeds. In the challenging multiclass NHL task, the two-stream network achieved a macro F1-score of 0.938 ± 0.026 and an accuracy of 0.939 ± 0.026, outperforming both the isolated visual stream (0.922 ± 0.037) and topological stream (0.865 ± 0.025) while reducing inter-seed variance by 30%. In the LA dataset, the model reached a macro F1-score of 0.998 ± 0.004, halving the visual dispersion, while sustaining perfect separation (1.000 ± 0.000) in high-contrast binary tasks (CR and LG). The topological stream introduces less than 1% parametric overhead without requiring dedicated GPU memory. These findings demonstrate that complex network topology acts as an effective regularizer, improving diagnostic reliability under data constraints.

Keywords: Complex Networks. Recurrent Neural Networks. Computer Vision. Histopathological Images. Late Fusion. Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Topologias de conectividade em redes espaço-espectrais: rede *full* à esquerda, rede *within* ao centro e rede *between* à direita, extraídas de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). 23

Figura 2 Fluxo conceitual de modelagem de imagens em redes espaço-espectrais, cálculo de medidas nodais e composição de descritores por sumarização estatística, adaptado de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). 23

Figura 3 Pipeline geral da abordagem proposta: os *datasets* histopatológicos alimentam duas vias paralelas. Na via topológica, a imagem original é modelada como um grafo complexo (SSN), gerando a sequência de características X_{top}, que é processada por um codificador recorrente (RNN) para originar o *embedding* topológico z_{top}. Na via visual, a imagem passa por pré-processamento (redimensionamento para 256×256 e aumento de dados por rotação) antes de ser processada pelo *backbone* visual para gerar o *embedding* visual $\tilde{z}_{\text{vis}}$. Ambos os *embeddings* são equalizados, concatenados e classificados por um MLP, gerando as predições finais para extração das métricas. 32

Figura 4 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 33

Figura 5 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 34

Figura 6 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 34

Figura 7 Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 34

Figura 8 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 35

Figura 9 Protocolo de ablação para o treinamento dos modelos: partição estratificada em 80% para desenvolvimento e 20% para teste final (reservado), validação cruzada com cinco partições sobre os 80%, avaliação de X combinações de hiperparâmetros e seleção da combinação de maior desempenho médio. 36

Figura 10 Ablação das vias isoladas. (a) Via topológica: a sequência de características da SSN é processada por seis codificadores (cinco recorrentes e um MLP como *baseline*), cada um testado de forma independente. (b) Via visual: as imagens, após aumento de dados, são processadas por seis modelos (convolucionais, *transformers* e híbridos), também testados individualmente. Cada via possui sua própria cabeça MLP, da qual são extraídas as métricas. 37

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 31
Tabela 2 – Espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica. 39
Tabela 3 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via visual. 40
Tabela 4 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados. 44
Tabela 5 – Configurações ótimas de hiperparâmetros e desempenhos dos codificadores selecionados na via topológica por conjunto de dados. 45
Tabela 6 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via visual isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados. 45
Tabela 7 – Configurações ótimas de hiperparâmetros e desempenhos dos modelos selecionados na via visual por conjunto de dados. 46
Tabela 8 – Configurações ótimas selecionadas nas ablações para a composição da rede de dupla via em cada conjunto de dados. 47
Tabela 9 – F1 macro (média ± desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% dos dados) para os codificadores da via topológica. 47
Tabela 10 – F1 macro (média ± desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% dos dados) para as arquiteturas da via visual. . . . 48
Tabela 11 – Comparação de desempenho (média ± desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% das amostras) entre as vias isoladas e a arquitetura unificada de dupla via. 49
Tabela 12 – Contagem de parâmetros treináveis por componente da arquitetura de dupla via. 52
Tabela 13 – Desempenho detalhado por validação cruzada (5 partições) e configurações ótimas da via topológica. 59
Tabela 14 – Desempenho detalhado por validação cruzada (5 partições) e configurações ótimas da via visual. 60
Tabela 15 – Resultados detalhados por semente e médias consolidadas no teste independente (20% dos dados). 61

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network*
ViT	*Vision Transformer*
CNN-ViT	*Convolutional Neural Network with Vision Transformer*
RNN	*Recurrent Neural Network*
RaNN	*Randomized Neural Network*
RGB	*Red, Green, Blue*
CN	*Complex Network*
DL	*Deep Learning*
BiLSTM	*Bidirectional Long Short-Term Memory*
BiGRU	*Bidirectional Gated Recurrent Unit*
GLCM	*Gray-Level Co-occurrence Matrix*
HOG	*Histogram of Oriented Gradients*
LBP	*Local Binary Patterns*
MLP	*Multilayer Perceptron*
LSTM	*Long Short-Term Memory*
GRU	*Gated Recurrent Unit*
SAC-LSTM	*Self-Attention Coupled Long Short-Term Memory*
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*
H&E	*Hematoxylin and Eosin*
LN	*Layer Normalization*
SIFT	*Scale-Invariant Feature Transform*
SSN	*Spatio-Spectral Network*
ReLU	*Rectified Linear Unit*
SVM	*Support Vector Machine*

RBF	*Radial Basis Function*
kNN	*k-Nearest Neighbors*
CNN1D	*One-Dimensional Convolutional Neural Network*
CPU	*Central Processing Unit*
GPU	*Graphics Processing Unit*
UCSB	*University of California, Santa Barbara*
CR	*Colorectal*
LA	*Liver Aging*
LG	*Liver Gender*
NHL	*Non-Hodgkin Lymphoma*
CLL	*Chronic Lymphocytic Leukemia*
FL	*Follicular Lymphoma*
MCL	*Mantle Cell Lymphoma*
UCP	Unidade Central de Processamento

LISTA DE SÍMBOLOS

G	Grafo ou rede complexa espaço-espectral ($G = (V, E)$)
V	Conjunto de vértices da rede complexa
E	Conjunto de arestas direcionadas da rede complexa
v_i	Vértice associado ao pixel nas coordenadas (x_i, y_i) no canal de cor c
(x_i, y_i)	Coordenadas espaciais do pixel na grade bidimensional da imagem
c, c_w	Canais ou camadas de cor da imagem no espaço RGB
ρ_{ij}	Distância euclidiana espacial entre os pixels dos vértices v_i e v_j
ρ_{ij}^2	Distância euclidiana quadrática entre os vértices v_i e v_j
r	Raio de conexão espacial da rede complexa
$r_{\max}$	Raio máximo de conexão estabelecido para a rede complexa ($r_{\max} = 15$)
$I(x_i, y_i, c)$	Intensidade luminosa do pixel nas coordenadas (x_i, y_i) no canal c
w_{ij}	Diferença absoluta de intensidade luminosa entre os vértices v_i e v_j
ω_{ij}	Peso normalizado atribuído à aresta direcionada entre v_i e v_j no raio r
L	Nível máximo de intensidade em imagens de 8 bits por canal ($L = 255$)
$\mathcal{N}$	Topologia de rede espaço-espectral completa (*full*)
$\mathcal{N}_w$	Topologia de rede espaço-espectral intra-canal (*within*)
$\mathcal{N}_b$	Topologia de rede espaço-espectral inter-canais (*between*)
d_{out}	Grau de saída acumulado de um vértice até o raio de conexão r
n_{out}	Quantidade de arestas direcionadas de saída formadas em um raio discreto
$\text{force}_{\text{out}}$	Força de saída acumulada de um vértice até o raio de conexão r
force_{in}	Força de entrada acumulada de um vértice até o raio de conexão r
$\mathcal{N}_{\text{out}}$	Conjunto de vértices vizinhos de saída até o raio de conexão r
$\mathcal{N}_{\text{in}}$	Conjunto de vértices vizinhos de entrada até o raio de conexão r
x_r	Vetor de atributos topológicos extraídos no raio de conexão r ($x_r \in \mathbb{R}^{18}$)

X_{top}	Sequência ordenada de descritores topológicos multiescala ($X_{\text{top}} \in \mathbb{R}^{15\times 18}$)
t	Passo temporal ou índice de escala na sequência de atributos
x_t	Vetor de atributos de entrada no passo temporal t
h_t	Estado oculto da unidade recorrente no passo temporal t
c_t	Estado da célula de memória da LSTM no passo temporal t
$\tilde{c}_t$	Estado candidato da célula de memória da LSTM no passo temporal t
f_t	Vetor de ativação da porta de esquecimento da LSTM no passo temporal t
i_t	Vetor de ativação da porta de entrada da LSTM no passo temporal t
o_t	Vetor de ativação da porta de saída da LSTM no passo temporal t
W	Matriz de pesos associada às entradas da rede neural
U	Matriz de pesos recorrentes associada aos estados ocultos anteriores
b	Vetor de viés (*bias*) da camada neural
$\sigma(\cdot)$	Função de ativação sigmoide logística
$\tanh(\cdot)$	Função de ativação tangente hiperbólica
$\odot$	Operador de produto de Hadamard (multiplicação elemento a elemento)
r_t	Vetor de ativação da porta de reinicialização da GRU no passo temporal t
z_t	Vetor de ativação da porta de atualização da GRU no passo temporal t
$\tilde{h}_t$	Estado oculto candidato da GRU no passo temporal t
$\overrightarrow{h}_r$	Estado oculto da camada recorrente no sentido direto no passo r
$\overleftarrow{h}_r$	Estado oculto da camada recorrente no sentido reverso no passo r
$\|$	Operador de concatenação vetorial
h_{rec}	Vetor latente concatenado dos estados finais do codificador recorrente
h	Dimensão oculta (*hidden size*) das camadas recorrentes e do MLP topológico
z_{top}	Vetor de características (*embedding*) da via topológica ($z_{\text{top}} \in \mathbb{R}^{128}$)
T	Comprimento total da sequência de escalas da via topológica ($T = 15$)
α_t	Coeficiente de autoatenção atribuído ao passo temporal t na SAC-LSTM

u_t	Vetor latente intermediário do estado oculto na atenção da SAC-LSTM
u_s	Vetor de contexto ajustável do mecanismo de autoatenção na SAC-LSTM
W_a, b_a	Matriz de projeção e vetor de viés da camada de atenção na SAC-LSTM
$\mathrm{vec}(\cdot)$	Operador de vetorização (achatamento de matriz em vetor unidimensional)
h_{mlp}	Vetor latente gerado pelo codificador MLP estático da via topológica
W_t, b_t	Matriz de pesos e vetor de viés da camada linear do MLP topológico
I	Imagem histopatológica de entrada em matriz digital de pixels
$f_{\mathrm{vis}}(\cdot)$	Função de mapeamento do extrator de atributos da via visual
z_{vis}	Vetor de características (*embedding*) extraído pela via visual ($z_{\mathrm{vis}} \in \mathbb{R}^D$)
D	Dimensionalidade do vetor de saída do modelo visual pré-treinado
A	Tensor tridimensional de ativações da última camada convolucional ($A \in \mathbb{R}^{C' \times H' \times W'}$)
C'	Contagem de canais do mapa tridimensional de ativações ($C' = D$)
H', W'	Dimensões de altura e largura espaciais do mapa de ativações
$z_{\mathrm{vis},c'}$	Componente do vetor visual no canal c' gerada por agrupamento médio global
$\tilde{z}_{\mathrm{vis}}$	Vetor visual projetado linearmente para equalização dimensional ($\tilde{z}_{\mathrm{vis}} \in \mathbb{R}^{128}$)
W_p, b_p	Matriz de pesos e vetor de viés da projeção linear da via visual
$\mathrm{LN}(\cdot)$	Operador de normalização por camada (*Layer Normalization*)
μ	Média das ativações calculada ao longo dos elementos do vetor na normalização por camada
σ^2	Variância das ativações calculada ao longo dos elementos do vetor na normalização por camada
ε	Constante infinitesimal de estabilidade numérica na normalização por camada
d	Dimensionalidade dos vetores equalizados na normalização por camada ($d = 128$)

z_{fus}	Vetor de características unificado fundido ($z_{\text{fus}} \in \mathbb{R}^{256}$)
h_{cls}	Vetor de ativações da camada oculta do classificador MLP final
W_1, b_1	Matriz de pesos e vetor de viés da camada oculta do classificador MLP
W_2, b_2	Matriz de pesos e vetor de viés da camada de saída do classificador MLP
C	Quantidade de classes diagnósticas da tarefa de classificação
$\hat{y}$	Vetor de probabilidades de classe preditas gerado pela função *softmax*
p	Probabilidade de desativação aleatória na camada de *Dropout* ($p = 0{,}5$)
η_{bb}	Taxa de aprendizado (*learning rate*) atribuída ao modelo visual (*backbone*)
η_{top}	Taxa de aprendizado atribuída ao codificador da via topológica
η_{hd}	Taxa de aprendizado da cabeça classificadora MLP e projeção (*head*)
B	Tamanho do lote de treinamento (*batch size*)
λ	Coeficiente de decaimento de pesos (*weight decay*, $\lambda = 10^{-4}$)
k	Número de partições na validação cruzada estratificada ($k = 5$); raio discreto na soma de arestas

SUMÁRIO

1 INTRODUÇÃO 18
1.1 Motivação e Justificativa 19
1.2 Objetivos 20

2 FUNDAMENTAÇÃO TEÓRICA 21
2.1 Imagens Histopatológicas 21
2.2 Redes Espaço-Espectrais 22
2.3 Redes Neurais Recorrentes e Codificação de Sequências 24
2.4 Modelos Profundos de Visão Computacional 26
2.5 Fusão em Nível de Características, Otimização e Métricas de Avaliação . 28

3 MATERIAIS E MÉTODOS 31
3.1 *Datasets* 31
3.2 Protocolo experimental 35
3.2.1 Métricas de avaliação 36
3.3 Modelagem e exploração das vias isoladas 37
3.3.1 Via topológica 37
3.3.2 Via visual 39
3.4 Arquitetura unificada de dupla via 39
3.4.1 Fusão por concatenação de *embeddings* 40
3.4.2 Classificador MLP 40
3.4.3 Treinamento de ponta a ponta e herança de hiperparâmetros 41
3.4.4 Avaliação confirmatória no teste independente 41
3.5 Configuração de ambiente 42

4 RESULTADOS E DISCUSSÃO 43
4.1 Ablação e seleção de configurações 43
4.1.1 Ablação da via topológica 43
4.1.2 Ablação da via visual 45
4.1.3 Configurações selecionadas para a composição da dupla via 46
4.2 Desempenho das Vias Isoladas no Conjunto de Teste Independente 47
4.3 Comparação entre as Vias Isoladas e a Rede de Dupla Via 48
4.4 Análise Diagnóstica por Subtipo Patológico e Comportamento por Classe 50
4.5 Análise da Eficiência Paramétrica e Custo Computacional 52

5 CONCLUSÃO 53

REFERÊNCIAS 55

APÊNDICE A – RESULTADOS COMPLETOS DA VALIDAÇÃO CRUZADA DA VIA TOPOLÓGICA 59

APÊNDICE B – RESULTADOS COMPLETOS DA VALIDAÇÃO CRUZADA DA VIA VISUAL 60

APÊNDICE C – DESEMPENHO POR SEMENTE NA PARTIÇÃO DE TESTE INDEPENDENTE 61

1 INTRODUÇÃO

A histopatologia atua no diagnóstico precoce de alterações teciduais associadas a neoplasias e a enfermidades inflamatórias e infecciosas. O procedimento analítico convencional é conduzido por patologistas por meio de microscopia óptica, após a extração da amostra biológica, fixação em lâmina e aplicação de reagentes químicos de contraste, tradicionalmente a coloração H&E (Srinidhi; Ciga; Martel, 2021). Esse fluxo de trabalho demanda tempo extensivo de profissionais especializados e está sujeito a variações intraobservador e interobservador decorrentes de diferenças nos protocolos de preparação e digitalização entre laboratórios (Kumar; Mishra, 2026). A adoção de sistemas de patologia computacional baseados em modelos de aprendizado profundo foi proposta como uma alternativa para auxiliar a análise patológica e padronizar o processo de triagem diagnóstica (Litjens et al., 2017; Bejnordi et al., 2017). Contudo, o desenvolvimento desses modelos enfrenta o obstáculo da disponibilidade restrita de imagens histopatológicas devidamente anotadas por especialistas, dificultando a formação de bases volumosas em decorrência de restrições éticas e da complexidade da rotulação clínica (Kumar; Mishra, 2026; Hussaini et al., 2026).

Na análise computacional de tecidos biológicos, duas abordagens metodológicas são historicamente estabelecidas. A primeira é baseada na extração manual de atributos teciduais calculados a partir de formulações matemáticas pré-definidas, abrangendo descritores clássicos de textura como a matriz de coocorrência de níveis de cinza (GLCM) (Haralick; Shanmugam; Dinstein, 1973), os padrões binários locais (LBP) (Ojala; Pietikäinen; Mäenpää, 2002) e o histograma de gradientes orientados (HOG) (Dalal; Triggs, 2005). A segunda abordagem adota modelos profundos de visão computacional, nos quais representações densas são aprendidas diretamente da matriz de pixels, com destaque para redes neurais convolucionais (CNN) (He et al., 2016), transformadores visuais (ViT) (Dosovitskiy et al., 2020) e arquiteturas híbridas CNN-ViT (Mehta; Rastegari, 2022; Dai et al., 2021), frequentemente inicializadas com pesos pré-treinados e associadas a técnicas de aumento de dados para mitigar o sobreajuste em pequenas bases (Talo, 2019; Shorten; Khoshgoftaar, 2019).

Embora ambas as abordagens forneçam descrições úteis, os extratores clássicos de textura e os modelos profundos operam sobre janelas ou vizinhanças de observação fixas. Como consequência, essas representações não descrevem a transição gradual e ordenada das relações teciduais que ocorre quando a escala de análise é progressivamente expandida do nível celular microscópico para arranjos teciduais amplos (Backes; Casanova; Bruno, 2013; Scabini; Ribas; Bruno, 2020). A modelagem por redes complexas contorna essa restrição ao representar a imagem histopatológica como um grafo ponderado e direcionado no qual os vértices são interligados sob raios de conexão crescentes, gerando uma sequência ordenada de propriedades topológicas ao longo de múltiplas escalas (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). Dada a dependência de ordem inerente ao acúmulo contínuo das conexões, codificadores neurais sequenciais, como

redes neurais recorrentes (RNN), constituem o método apropriado para processar essa dinâmica multiescala e sintetizá-la em representações latentes contínuas (Hochreiter; Schmidhuber, 1997; Schuster; Paliwal, 1997; Lin et al., 2022).

A integração dessa dinâmica relacional multiescala com representações visuais profundas possibilita explorar fontes de informação distintas em uma arquitetura unificada de dupla via. Enquanto investigações na histopatologia comprovaram a viabilidade de combinar descritores estáticos de textura a redes neurais profundas (Huang et al., 2022; Li, 2025), a literatura ainda carece de arquiteturas que integrem representações visuais densas de modelos modernos de visão computacional com sequências topológicas multiescala processadas por redes neurais recorrentes sob restrição amostral (Srinidhi; Ciga; Martel, 2021; Oliveira et al., 2025; Brussee et al., 2025).

1.1 MOTIVAÇÃO E JUSTIFICATIVA

A caracterização de tecidos biológicos por descritores tradicionais de textura, como GLCM, LBP e HOG, produz vetores numéricos tabulares baseados em relações de vizinhança pré-fixadas, desconsiderando a dependência entre diferentes níveis de resolução. A representação de imagens por redes complexas espaço-espectrais supera esse limite ao calcular métricas de grau e força ao longo de raios sucessivos de alcance, estruturando a morfologia tecidual como uma trajetória multiescala (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). O processamento dessa sequência por arquiteturas neurais recorrentes viabiliza a extração de propriedades dependentes de escala que não são capturadas por arranjos estáticos unidimensionais.

A motivação para o desenvolvimento de uma arquitetura de dupla via reside na convergência entre propriedades de naturezas distintas. A via topológica descreve as relações organizacionais do tecido celular com base na topologia de redes complexas, enquanto a via visual extrai padrões visuais e contextuais a partir dos pixels por meio de modelos profundos pré-treinados. A integração dessas duas perspectivas em uma arquitetura de dupla via com fusão em nível de características permite que cada via processe a imagem histopatológica de forma paralela e independente (Simonyan; Zisserman, 2014; Wang et al., 2023), equalizando suas dimensões por projeção linear e normalização por camadas antes da concatenação (Ba; Kiros; Hinton, 2016; Huang et al., 2022). Essa formulação visa investigar se a cooperação entre essas fontes de representação atenua a suscetibilidade ao sobreajuste e melhora a separabilidade diagnóstica sob escassez de imagens anotadas.

Nesse contexto, este trabalho estabelece duas contribuições metodológicas principais:

1. A formulação das medidas extraídas de redes complexas espaço-espectrais como uma sequência multiescala ordenada por raios de conexão, processada por codificadores neurais sequenciais para capturar a dependência entre diferentes níveis de detalhe tecidual;

2. A concepção e avaliação de uma arquitetura de dupla via que integra, por meio de fusão em nível de características com equalização dimensional e normalização, as representações

topológicas sequenciais aos atributos visuais densos extraídos por modelos de visão computacional sob restrição amostral.

A partir desse contexto, a presente pesquisa é guiada pela seguinte questão investigativa:

> **Questão de Pesquisa:** A integração da dinâmica topológica multiescala, modelada por redes complexas e codificada por redes neurais recorrentes, com representações visuais profundas extraídas por modelos de visão computacional em uma arquitetura de dupla via, proporciona ganho preditivo na classificação de imagens histopatológicas quando comparada ao desempenho obtido por cada via isoladamente sob restrição de dados?

Para responder a essa questão, foram formuladas duas hipóteses de trabalho:

1. A sequência de métricas topológicas extraída de redes espaço-espectrais em raios consecutivos de conexão provê atributos discriminativos que viabilizam a classificação de tecidos histopatológicos por meio de redes neurais recorrentes;

2. A integração em dupla via da representação topológica sequencial com representações visuais profundas melhora o desempenho preditivo na classificação histopatológica quando comparada à operação de cada via de forma isolada.

1.2 OBJETIVOS

O objetivo geral deste trabalho é propor e avaliar uma arquitetura de aprendizado profundo de dupla via para a classificação de imagens histopatológicas, composta por uma via topológica e uma via visual, avaliando o ganho preditivo proporcionado pela fusão das duas representações em relação ao desempenho obtido por cada via de forma isolada.

Para cumprir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

- Modelar as imagens histopatológicas como redes espaço-espectrais em raios consecutivos de conexão e avaliar a capacidade preditiva de redes neurais recorrentes no processamento isolado da sequência de atributos topológicos;

- Avaliar o desempenho preditivo de diferentes famílias de modelos de visão computacional (convolucionais, transformadores visuais e modelos híbridos) na classificação das imagens, estabelecendo a linha de base da via visual isolada;

- Desenvolver a arquitetura de dupla via por meio da fusão das representações topológica e visual, mensurando o ganho de desempenho obtido pelo modelo integrado frente a cada via isolada em cenários de restrição de dados.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, os conceitos teóricos que sustentam o desenvolvimento da pesquisa são apresentados. O processo de preparação, coloração e aquisição de imagens histopatológicas é descrito na Seção 2.1. A modelagem de imagens por meio de redes complexas espaço-espectrais é detalhada na Seção 2.2. A codificação sequencial das propriedades topológicas por redes neurais recorrentes é abordada na Seção 2.3. Os modelos profundos de visão computacional empregados na via visual são discutidos na Seção 2.4. A integração entre as representações por meio da fusão em nível de características, os procedimentos de otimização e as métricas de avaliação são examinados na Seção 2.5.

2.1 IMAGENS HISTOPATOLÓGICAS

A análise histopatológica tem como ponto de partida a coleta de fragmentos teciduais obtidos por meio de biópsias ou ressecções cirúrgicas, submetidos à fixação química em formalina para a preservação celular, seguida por processos de desidratação e inclusão em blocos de parafina sólida (Feldman; Wolfe, 2014; Srinidhi; Ciga; Martel, 2021). Em seu estado natural, os tecidos biológicos são translúcidos e apresentam contraste óptico reduzido sob iluminação de campo claro, impedindo a distinção entre compartimentos teciduais (Fischer et al., 2008; Srinidhi; Ciga; Martel, 2021).

Para conferir contraste visual às amostras, as secções recebem coloração histoquímica por H&E (Fischer et al., 2008; Srinidhi; Ciga; Martel, 2021). A hematoxilina cora os ácidos nucleicos no interior do núcleo celular, conferindo aos núcleos coloração azul-arroxeada, enquanto a eosina atua sobre componentes citoplasmáticos e fibras da matriz extracelular, tingindo essas regiões em tonalidades rosadas e avermelhadas (Feldman; Wolfe, 2014; Kumar; Mishra, 2026). A combinação desses corantes permite delimitar as fronteiras celulares, o tamanho e o arranjo dos núcleos, além da organização de glândulas e estromas teciduais (Srinidhi; Ciga; Martel, 2021; Sirinukunwattana et al., 2017), fornecendo a base para a caracterização morfológica e textural do tecido.

Apesar do contraste morfológico obtido, as imagens histopatológicas digitais apresentam particularidades que tornam a classificação automatizada desafiadora (Srinidhi; Ciga; Martel, 2021; Litjens et al., 2017). Variações na concentração de reagentes, tempos de imersão e respostas espectrais de escâneres causam desvios de tonalidade e saturação entre diferentes laboratórios (Bejnordi et al., 2017; Kumar; Mishra, 2026). A presença de artefatos de preparação, como dobras teciduais, bolhas de ar e precipitados de corante, interfere na homogeneidade dos dados (Srinidhi; Ciga; Martel, 2021; Talo, 2019). Em lesões neoplásicas, a distinção diagnóstica é fundamentada em alterações no pleomorfismo nuclear, na aglomeração celular e na perda da conformação glandular, em meio a acentuada variabilidade intra-classe (Sirinukunwattana et

al., 2017; Hussaini et al., 2026). Além de patologias tumorais, a quantificação histológica é estendida à caracterização de padrões biológicos normais, abrangendo o envelhecimento tecidual e o dimorfismo sexual, conforme observado em micrografias hepáticas dos conjuntos LA e LG (Shamir et al., 2008), nas quais a discriminação decorre de variações graduais no arranjo dos hepatócitos e na densidade nuclear. A dependência de anotações especializadas limita o tamanho dos acervos disponíveis, elevando a possibilidade de sobreajuste durante o treinamento de modelos profundos (Kumar; Mishra, 2026; Hussaini et al., 2026) e motivando a investigação de métodos que combinem representações visuais com propriedades relacionais determinísticas extraídas da conectividade tecidual.

2.2 REDES ESPAÇO-ESPECTRAIS

A teoria de redes complexas fornece uma modelagem matemática para representar sistemas constituídos por elementos discretos conectados por relações não triviais (Boccaletti et al., 2006). No processamento de imagens coloridas, os pixels são modelados como vértices de um grafo e as conexões entre eles são determinadas a partir de critérios de distância euclidiana e diferenças de intensidade luminosa, permitindo que medidas topológicas caracterizem a textura do tecido biológico (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024).

Na formulação da rede espaço-espectral proposta por Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020), uma imagem colorida é representada por uma rede direcionada e ponderada $G = (V, E)$. Para cada pixel nas coordenadas (x_i, y_i) em um canal de cor c, é estabelecido um vértice $v_i^{(c)} \in V$. As arestas direcionadas são criadas entre dois vértices $v_i^{(c)}$ e $v_j^{(c_w)}$ quando a distância euclidiana quadrática satisfaz o limite imposto por um raio de conexão r:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 \leq \rho_{ij}^2 \leq r^2. \tag{1}$$

A condição $\rho_{ij}^2 = 0$ interliga vértices de diferentes canais de cor correspondentes às mesmas coordenadas de pixel ($c \neq c_w$), sendo excluídos laços de um vértice consigo mesmo (Ribas et al., 2024). O sentido da aresta direcionada é governado pela diferença de intensidade entre os pixels conectados, partindo do ponto de menor intensidade em direção ao de maior intensidade (Scabini; Ribas; Bruno, 2020). Considerando $I(x_i, y_i, c)$ a intensidade do pixel no respectivo canal, uma aresta é classificada como de saída a partir de v_i e de entrada em v_j quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$. Conexões entre intensidades iguais são computadas em ambos os sentidos.

O peso atribuído a cada conexão pondera conjuntamente a diferença de intensidade $w_{ij} = |I(x_i, y_i, c) - I(x_j, y_j, c_w)|$ e a distância euclidiana ρ_{ij} entre os vértices (Ribas et al., 2024):

$$\omega_{ij}^{(r)} = \frac{(w_{ij} + 1)\,(\rho_{ij} + 1) - 1}{(L + 1)(r + 1) - 1}, \tag{2}$$

em que $L = 255$ representa a intensidade máxima em imagens codificadas em 8 bits por canal, delimitando o peso normalizado no intervalo $[0, 1]$.

As três configurações de conectividade entre as camadas de cor admitidas pelo modelo de rede espaço-espectral são apresentadas na Figura 1, extraída de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). Na porção esquerda da figura é ilustrada a rede *full* ($\mathcal{N}$), na qual são computadas arestas tanto entre vértices de uma mesma camada de cor quanto entre camadas distintas. Ao centro, a rede *within* ($\mathcal{N}_w$) restringe as arestas exclusivamente aos vértices pertencentes ao mesmo canal de cor ($c = c_w$). Na porção direita, a rede *between* ($\mathcal{N}_b$) contempla unicamente conexões que interligam canais de cores diferentes ($c \neq c_w$). Neste trabalho, é adotada exclusivamente a rede *full* ($\mathcal{N}$), integrando simultaneamente os padrões de textura monocromáticos de cada canal e as interações cromáticas entre as diferentes bandas de cor da imagem histopatológica.

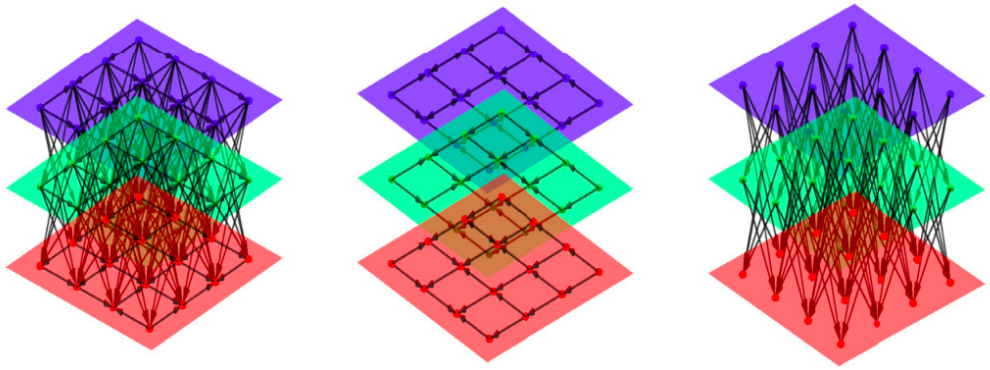


Figura 1 – Topologias de conectividade em redes espaço-espectrais: rede *full* à esquerda, rede *within* ao centro e rede *between* à direita, extraídas de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020).

O fluxo de modelagem, cálculo de medidas nodais e composição de descritores estatísticos sobre a rede espaço-espectral é apresentado na Figura 2, adaptada de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). Sobre a topologia adotada, distribuições de propriedades nodais são computadas para diferentes raios de alcance r e consolidadas pela média e pelo desvio padrão sobre os vértices, gerando os atributos descritores de textura.

A partir da topologia construída, medidas nodais de grau e força são calculadas para cada raio de conexão $r \in \{1, 2, \ldots, r_{\max}\}$. O grau de saída acumulado quantifica a conectividade externa na vizinhança:

$$d_{\text{out}}(v_i, r) = \sum_{k=1}^{r} n_{\text{out}}(v_i, k), \tag{3}$$

em que $n_{\text{out}}(v_i, k)$ representa a quantidade de arestas de saída formadas com raio discreto k. De maneira análoga, a força de saída acumulada integra os pesos normalizados das arestas conectadas:

$$\text{force}_{\text{out}}(v_i, r) = \sum_{v_j \in \mathcal{N}_{\text{out}}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{4}$$

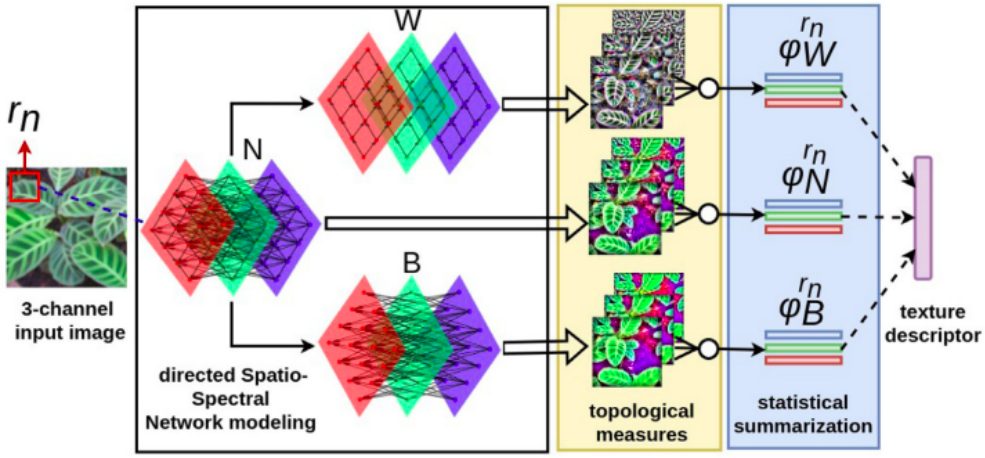


Figura 2 – Fluxo conceitual de modelagem de imagens em redes espaço-espectrais, cálculo de medidas nodais e composição de descritores por sumarização estatística, adaptado de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020).

sendo a força de entrada calculada sobre as arestas que incidem em v_i:

$$\text{force}_{\text{in}}(v_i, r) = \sum_{v_j \in \mathcal{N}_{\text{in}}^{(r)}(v_i)} \omega_{ji}^{(r)}. \tag{5}$$

Em qualquer rede direcionada, a soma de todas as arestas que incidem sobre os vértices é identicamente equivalente à soma de todas as arestas que deles partem, atendendo à identidade $\sum_{v_i \in V} d_{\text{in}}(v_i, r) = \sum_{v_i \in V} d_{\text{out}}(v_i, r) = |E_r|$. Dessa relação decorre que a média global do grau de entrada é numericamente idêntica à média global do grau de saída ao longo da totalidade dos nós da rede. Em decorrência dessa dependência linear exata, a inclusão conjunta das médias de grau de entrada e saída introduz multicolinearidade estrita no espaço de atributos. Por essa razão, o grau de entrada é descartado, preservando unicamente o grau de saída juntamente com as forças de entrada e saída (Ribas et al., 2024). Diferentemente dos graus, as forças direcionadas incorporam a assimetria contínua das intensidades dos pixels, produzindo distribuições estatisticamente desvinculadas entre si.

A expansão progressiva do raio de conexão de $r = 1$ até $r_{\max} = 15$ altera iterativamente o padrão de interligação da rede, integrando interações de vizinhanças sucessivamente mais amplas (Scabini; Ribas; Bruno, 2020; Zerati et al., 2026). Em cada raio, as medidas de grau de saída, força de saída e força de entrada calculadas sobre os vértices são sumarizadas pela média e pelo desvio padrão ao longo dos canais de cor, gerando um vetor de 18 atributos nodais por escala. A sucessão ordenada desses descritores ao longo dos raios compõe uma trajetória multiescala contínua que registra a transição entre a microtextura celular e a organização tecidual macroscópica. Como cada passo dessa sequência retém dependência em relação às escalas de alcance inferior, a modelagem desse padrão como uma série ordenada estabelece a motivação teórica para o emprego de arquiteturas neurais recorrentes, aptas a codificar dependências

sequenciais na diferenciação histopatológica.

2.3 REDES NEURAIS RECORRENTES E CODIFICAÇÃO DE SEQUÊNCIAS

As redes neurais recorrentes são formuladas para o processamento de dados organizados sequencialmente, preservando um estado interno que propaga informações através dos passos temporais (LeCun; Bengio; Hinton, 2015). Em modelos recorrentes simples (Elman, 1990), os estados ocultos são atualizados iterativamente com base na entrada atual e no estado anterior por meio de uma transformação não linear. O treinamento dessas arquiteturas em sequências extensas com o algoritmo de retropropagação através do tempo é afetado pelo desvanecimento ou pela explosão dos gradientes numéricos (Bengio; Simard; Frasconi, 1994).

A arquitetura LSTM soluciona essa restrição por meio de uma célula de memória c_t regulada por portas parametrizadas com funções de ativação sigmoide (Hochreiter; Schmidhuber, 1997; Gers; Schmidhuber; Cummins, 2000):

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \quad i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \quad o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{6}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \quad h_t = o_t \odot \tanh(c_t), \tag{7}$$

em que f_t, i_t e o_t denotam as portas de esquecimento, entrada e saída, e o operador $\odot$ representa a multiplicação elemento a elemento. O controle por portas viabiliza a conservação do gradiente ao longo de passos temporais sucessivos, permitindo que a rede capture dependências de longo alcance na sequência de raios de conexão sem descartar os padrões de textura locais observados nos raios iniciais (Lin et al., 2022; Greff et al., 2017).

A unidade GRU simplifica a dinâmica recorrente ao unificar as portas de controle e prescindir de um estado de célula isolado, mantendo unicamente o estado oculto h_t (Cho et al., 2014):

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)\,, \quad r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)\,, \tag{8}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)\,, \tag{9}$$

em que z_t e r_t representam as portas de atualização e de reinicialização. Ao eliminar a parametrização dedicada da célula de memória, a GRU reduz o volume de parâmetros internos em relação à LSTM, proporcionando menor complexidade paramétrica que atenua a memorização de ruído sob restrição de dados amostrais (Cho et al., 2014; Greff et al., 2017).

Além da escolha do mecanismo interno da célula recorrente, a direção de percurso da sequência de escalas exerce papel determinante na extração de padrões teciduais (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005). No sentido direto ($r = 1 \rightarrow r_{\max}$), o processamento acompanha o acúmulo da microtextura local em direção à organização macroscópica. No sentido reverso ($r = r_{\max} \rightarrow 1$), o contexto tecidual amplo é propagado previamente para contextualizar a interpretação das variações celulares microscópicas. Codificadores bidirecionais (BiLSTM e

BiGRU) processam a sequência temporal em ambas as orientações simultaneamente. O vetor latente unificado $h_{\text{rec}} \in \mathbb{R}^h$ é obtido pela concatenação dos estados terminais dos dois sentidos:

$$h_{\text{rec}} = \left[\overrightarrow{h}_{r_{\max}} \,\|\, \overleftarrow{h}_{1} \right] \in \mathbb{R}^h, \tag{10}$$

sendo $h_{\text{rec}} = h_{r_{\max}}$ adotado nos modelos unidirecionais (Lin et al., 2022; Priyadarshini, 2026). Para viabilizar a exploração de múltiplas capacidades internas ($h \in \{64, 128, 256, 512\}$), uma projeção linear com ativação ReLU equaliza a representação para o espaço padronizado de dimensão fixa $z_{\text{top}} \in \mathbb{R}^{128}$ quando $h \neq 128$:

$$z_{\text{top}} = \text{ReLU}(W_{\text{proj}} h_{\text{rec}} + b_{\text{proj}}), \qquad W_{\text{proj}} \in \mathbb{R}^{128 \times h}, \tag{11}$$

com $z_{\text{top}} = h_{\text{rec}}$ fixado diretamente quando $h = 128$.

Na sequência de raios de conexão, as diferentes escalas não exercem contribuição discriminativa equivalente, pois determinadas faixas de alcance concentram alterações citológicas ou glandulares mais relevantes para a separação diagnóstica. A arquitetura SAC-LSTM incorpora uma camada de autoatenção aos estados da LSTM para atribuir pesos escalares dinâmicos α_t às escalas mais informativas (Shalini; Rathnamala, 2026):

$$u_t = \tanh(W_a h_t + b_a)\,, \qquad \alpha_t = \frac{\exp\left(u_t^\top u_s\right)}{\sum_{k=1}^{T} \exp\left(u_k^\top u_s\right)}, \qquad h_{\text{att}} = \sum_{t=1}^{T} \alpha_t h_t \in \mathbb{R}^h, \tag{12}$$

em que u_s denota um vetor de contexto ajustado durante a otimização. A representação ponderada h_{att} é igualmente mapeada para 128 dimensões quando $h \neq 128$.

Como referencial metodológico de controle, um codificador estático baseado em MLP é investigado paralelamente às arquiteturas recorrentes (Huang et al., 2022; Rumelhart; Hinton; Williams, 1986). Essa arquitetura não atua como mais um modelo recorrente candidato, mas como a linha de base de controle experimental indispensável para isolar a relevância da ordem sequencial. Nesse arranjo estático, os 15 vetores da sequência são unificados em um único vetor plano $\text{vec}(X_{\text{top}}) \in \mathbb{R}^{270}$, processado por uma camada densa com ativação ReLU:

$$h_{\text{mlp}} = \text{ReLU}(W_t \,\text{vec}(X_{\text{top}}) + b_t) \in \mathbb{R}^h, \qquad W_t \in \mathbb{R}^{h \times 270}, \tag{13}$$

seguido por projeção linear para 128 dimensões quando $h \neq 128$. Ao descartar qualquer noção temporal de leitura entre os raios, o MLP processa as características de forma desordenada e estática. A comparação direta entre os codificadores recorrentes e esse referencial permite determinar empiricamente se a dinâmica multiescala ordenada provê ganho discriminativo real em relação à agregação plana dos mesmos 270 atributos.

2.4 MODELOS PROFUNDOS DE VISÃO COMPUTACIONAL

A via visual tem como propósito extrair representações densas diretamente a partir dos pixels da imagem histopatológica colorida. Para contemplar diferentes princípios de extração de atributos, três famílias de arquiteturas de visão computacional são investigadas: redes neurais convolucionais, transformadores visuais e arquiteturas híbridas CNN-ViT (Hussaini et al., 2026; Oliveira et al., 2025).

As redes neurais convolucionais processam a matriz de pixels por meio de bancos de filtros locais repetidos hierarquicamente ao longo de camadas sucessivas (Litjens et al., 2017). Essa formulação impõe invariância a translações e restringe o campo receptivo inicial a vizinhanças imediatas, conferindo alta sensibilidade na detecção de contornos celulares, bordas de núcleos e texturas citológicas microscópicas (He et al., 2016; Tan; Le, 2019). A arquitetura convolucional atua como referência consolidada na análise de padrões histopatológicos locais.

Os transformadores visuais dispensam filtros convolucionais locais e operam pela decomposição da imagem em uma sequência unidimensional de pequenos blocos de pixels projetados linearmente como *tokens* (Dosovitskiy et al., 2020; Shamshad et al., 2023). Mecanismos de autoatenção calculam correlações entre quaisquer regiões da imagem independentemente de sua distância na matriz de pixels. Essa propriedade permite que o modelo capture dependências contextuais globais de longo alcance, modelando interações amplas entre glândulas e estromas distribuídos pela lâmina (Touvron et al., 2021).

As arquiteturas híbridas CNN-ViT unificam as vantagens operacionais das duas abordagens anteriores (Dai et al., 2021; Oliveira et al., 2025). Blocos convolucionais são alocados nos estágios primários para a extração eficiente de bordas celulares e morfologia nuclear, enquanto módulos de autoatenção nos estágios finais modelam a correlação contextual global do tecido biológico. Essa integração proporciona alta capacidade discriminativa com demanda reduzida de parâmetros, propriedade vantajosa para mitigar a memorização sob restrição amostral (Mehta; Rastegari, 2022; Ma et al., 2026).

A obtenção do vetor de características da via visual $z_{\text{vis}} \in \mathbb{R}^D$ ocorre a partir da imagem redimensionada para 256×256 pixels no espaço RGB, normalizada segundo os parâmetros de pré-treinamento de cada modelo. Com a camada original de classificação da ImageNet removida, a condensação das ativações em um vetor denso adota dois mecanismos:

- nas arquiteturas convolucionais e híbridas, o mapa de ativações tridimensional $A \in \mathbb{R}^{C' \times H' \times W'}$ gerado no último bloco é condensado por agrupamento médio global, computando a média de cada canal ao longo das dimensões de altura e largura:

$$z_{\text{vis},c'} = \frac{1}{H'W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} A(c', i, j), \qquad c' \in \{1, 2, \ldots, D\}; \tag{14}$$

- nas arquiteturas de transformadores visuais, a representação é obtida diretamente a partir

do estado oculto associado ao *token* de classificação (*class token*), resultando em um vetor unidimensional de dimensão D.

O vetor resultante $z_{\text{vis}} \in \mathbb{R}^D$ consolida as propriedades visuais extraídas dos pixels, sendo subsequentemente direcionado à etapa de projeção dimensional e fusão com a via topológica.

O treinamento de arquiteturas profundas iniciado a partir de pesos aleatórios exige volumes elevados de dados rotulados para a convergência adequada de filtros e parâmetros internos (Srinidhi; Ciga; Martel, 2021). Na histopatologia computacional, a escassez de amostras anotadas impõe o uso do aprendizado por transferência a partir de modelos pré-treinados em grandes bases visuais genéricas, como a ImageNet-1k (Russakovsky et al., 2015; Talo, 2019). Os filtros das camadas iniciais e intermediárias, especializados na detecção de bordas, cantos e texturas elementares, fornecem representações transferíveis para tecidos biológicos (Litjens et al., 2017). No ajuste fino (*fine-tuning*), os pesos pré-treinados são refinados conjuntamente com as novas camadas terminais de classificação. Para prevenir a perturbação desordenada dos filtros visuais pré-treinados pela retropropagação em conjuntos de dados de dimensões reduzidas, taxas de aprendizado diferenciadas são adotadas. Uma taxa de aprendizado atenuada (η_{bb}) é atribuída ao extrator visual profundo, preservando os padrões gerais consolidados, enquanto uma taxa superior (η_{hd}) é designada à cabeça classificadora para a calibração célere das fronteiras de decisão específicas das classes histopatológicas.

A generalização dos modelos visuais sob restrição amostral é reforçada pela técnica de aumento de dados (*data augmentation*) durante o treinamento (Shorten; Khoshgoftaar, 2019; Perez; Wang, 2017). Em microscopia óptica de secções histológicas, os tecidos biológicos não exibem uma orientação física preferencial sobre a lâmina de vidro. O emprego de transformações que preservam o rótulo da classe, abrangendo reflexões horizontais e rotações ortogonais nos ângulos de 0, 90, 180 e 270 graus, multiplica a diversidade visual apresentada à rede sem distorcer a morfologia celular. Esse procedimento atua como regularizador estocástico, reduzindo a memorização de artefatos posicionais. Na arquitetura unificada de dupla via, essas transformações estocásticas são restritas à via visual, pois as medidas globais extraídas sobre as redes espaço-espectrais já exibem invariância intrínseca a rotações e reflexões da grade de pixels.

2.5 FUSÃO EM NÍVEL DE CARACTERÍSTICAS, OTIMIZAÇÃO E MÉTRICAS DE AVALIAÇÃO

Em problemas com múltiplas fontes de representação, a integração dos dados pode ser realizada em diferentes estágios do fluxo computacional (Baltrušaitis; Ahuja; Morency, 2019). A fusão em nível de decisões processa cada fonte por classificadores isolados e combina as probabilidades de saída (Yousaf; Nawaz; Habib, 2024). Em contrapartida, a fusão em nível de características combina os vetores de representação antes da camada classificadora compartilhada, permitindo que interações entre as diferentes vias sejam aprendidas durante o treinamento supervisionado (Ramachandram; Taylor, 2017; Huang et al., 2022).

Em modelos de dupla via, a execução de ramos paralelos independentes preserva a individualidade de cada representação, evitando interferências nas fases primárias de extração (Simonyan; Zisserman, 2014; Wang et al., 2023; Nawaz et al., 2025). A combinação das duas vias ocorre por meio da concatenação dos respectivos vetores latentes. A integração direta de representações com dimensionalidades acentuadamente desiguais introduz desequilíbrios durante a otimização. Quando um vetor de alta dimensão ($D \in \{192, 640, 768, 1280, 2048\}$) é concatenado diretamente a um vetor de dimensão compacta (128), a modalidade de maior dimensão monopoliza a maior fração dos pesos e dos gradientes na camada de classificação compartilhada, provocando o fenômeno de dominância modal e suprimindo a propagação de gradientes na via minoritária (Baltrušaitis; Ahuja; Morency, 2019; Ramachandram; Taylor, 2017).

A redução dimensional do vetor visual é fundamentada na hipótese da variedade, segundo a qual dados de alta dimensão nominal ocupam uma subvariedade de dimensão intrínseca muito reduzida em tarefas específicas de classificação ($d \ll D$). Como os modelos visuais realizam dezenas de transformações não lineares sobre a matriz de pixels, as representações terminais já expressam propriedades semânticas separáveis. Uma camada linear afim com matriz de pesos $W_p \in \mathbb{R}^{128\times D}$ é suficiente para rotacionar e projetar esses atributos em um subespaço compacto de 128 dimensões sem a introdução de não linearidades adicionais. Além de assegurar paridade dimensional com a via topológica, essa projeção comprime o número de conexões na cabeça de classificação. Sob restrição de dados amostrais, essa redução paramétrica atenua drasticamente o risco de sobreajuste.

Para harmonizar as dimensões das duas modalidades, o vetor visual $z_{\text{vis}} \in \mathbb{R}^D$ é projetado linearmente para 128 dimensões:

$$\tilde{z}_{\text{vis}} = W_p\, z_{\text{vis}} + b_p, \qquad W_p \in \mathbb{R}^{128\times D}, \quad b_p \in \mathbb{R}^{128}. \tag{15}$$

A equalização numérica das escalas de ativação entre as duas fontes é efetuada pela normalização por camadas (Ba; Kiros; Hinton, 2016), aplicada de forma independente sobre z_{top} e $\tilde{z}_{\text{vis}}$:

$$\mathrm{LN}(z) = \frac{z-\mu}{\sqrt{\sigma^2+\varepsilon}}, \qquad \mu = \frac{1}{d}\sum_{k=1}^{d} z_k, \qquad \sigma^2 = \frac{1}{d}\sum_{k=1}^{d}(z_k-\mu)^2, \tag{16}$$

em que ε representa uma constante de estabilidade numérica e $d = 128$. Essa transformação impõe média nula e variância unitária a ambos os vetores, eliminando disparidades nas magnitudes das ativações geradas pelos diferentes modelos.

O vetor integrado fundido é composto pela concatenação direta das representações normalizadas:

$$z_{\text{fus}} = [\,\mathrm{LN}(z_{\text{top}}) \,\|\, \mathrm{LN}(\tilde{z}_{\text{vis}})\,] \in \mathbb{R}^{256}, \tag{17}$$

estabelecendo paridade de contribuição entre as fontes topológica e visual na camada de decisão compartilhada.

A classificação final é efetuada por um MLP dotado de uma camada oculta de 128 neurônios

com ativação ReLU e regularização por desativação aleatória (*dropout*) (Rumelhart; Hinton; Williams, 1986; Srivastava et al., 2014):

$$h = \mathrm{ReLU}(W_1 z_{\mathrm{fus}} + b_1)\,, \tag{18}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{19}$$

em que $W_1 \in \mathbb{R}^{128\times256}$, $b_1 \in \mathbb{R}^{128}$, $W_2 \in \mathbb{R}^{C\times128}$ e $b_2 \in \mathbb{R}^{C}$, denotando C a quantidade de classes da tarefa.

A convergência e a estabilidade numérica da arquitetura de dupla via durante o treinamento de ponta a ponta são asseguradas pelo algoritmo de otimização AdamW (Loshchilov; Hutter, 2019). Em contraposição ao otimizador Adam convencional associado à regularização L_2, no qual o decaimento é modificado pelas médias móveis dos gradientes passados, o AdamW desacopla o decaimento de pesos da atualização adaptativa dos momentos. Uma penalidade multiplicativa direta é aplicada aos pesos a cada iteração, garantindo regularização efetiva contra a memorização de ruído sob restrição amostral. Para conter oscilações numéricas abruptas provocadas pela retropropagação através do tempo nos módulos recorrentes e pelas camadas profundas dos modelos visuais, a norma euclidiana do vetor de gradientes é limitada a um valor máximo fixado em 1,0 antes de cada passo de atualização.

A avaliação da capacidade discriminativa dos classificadores sob desbalanceamento amostral requer métricas desvinculadas da prevalência de classes majoritárias. Embora a acurácia meça a proporção total de predições corretas, sua interpretação é enviesada em conjuntos desiguais, nos quais classificadores triviais obtêm índices elevados ao favorecerem a classe predominante (Sokolova; Lapalme, 2009). O F1-*score* macro contorna essa distorção ao computar a média harmônica entre precisão e sensibilidade isoladamente para cada classe, realizando em seguida a média aritmética simples entre as classes com peso paritário, o que penaliza desempenhos insatisfatórios em categorias minoritárias. A área sob a curva ROC (AUC-ROC), por sua vez, quantifica a capacidade do modelo em ordenar as probabilidades das amostras corretas acima das incorretas ao longo de todos os limiares de decisão possíveis, operando de forma independente do ponto de corte de classificação adotado (Fawcett, 2006).

3 MATERIAIS E MÉTODOS

Neste capítulo, o protocolo metodológico desenvolvido para avaliar a integração de duas vias na classificação de imagens histopatológicas é apresentado. A investigação contemplou cinco bases histopatológicas ao longo de quatro etapas principais: (i) aumento de dados e extração de atributos por redes espaço-espectrais, (ii) treinamento, busca de hiperparâmetros e avaliação de cada via de forma isolada, (iii) treinamento e avaliação da arquitetura de dupla via a partir das melhores configurações de cada modalidade, e (iv) comparação dos desempenhos obtidos entre as vias isoladas e o modelo integrado. Os critérios de particionamento, as métricas de avaliação e a configuração do ambiente computacional também foram formalizados neste capítulo. O fluxo geral dos procedimentos foi ilustrado na Figura 3.

3.1 *DATASETS*

A avaliação foi conduzida em cinco *datasets* de imagens histopatológicas, com 58 a 528 imagens cada. Os conjuntos compreenderam tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, o que permitiu observar o comportamento do modelo em cenários com poucos dados. As características de cada conjunto foram sintetizadas na Tabela 1. Os conjuntos LA e LG não correspondiam a tarefas diagnósticas, pois as classes representavam a idade e o sexo de camundongos. Esses conjuntos foram incluídos como *benchmarks* de textura histológica, nos quais a distinção entre as classes dependia do padrão do tecido hepático e não de uma lesão.

Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**	**Resolução original**
UCSB	Mama (benigno / maligno)	58	2	32 / 26	896×768
CR	Colorretal (benigno / maligno)	165	2	74 / 91	775×522 (14 exceções)
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151	417×312
LG	Sexo (macho / fêmea)	265	2	150 / 115	417×312
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122	1388×1040

As imagens foram mantidas em inteiros de 8 bits por canal e alimentaram as duas vias em resoluções distintas. A via topológica utilizou a imagem na resolução original de cada *dataset* (Tabela 1), sem redimensionamento e sem alteração de intensidades, pois as arestas das redes complexas dependiam da comparação de intensidades inteiras, incluindo os empates, e a interpolação suavizaria essas diferenças. A via visual utilizou uma versão de 256×256 pixels, escala em que os modelos utilizados foram pré-treinados, o que também uniformizou as dimensões dos lotes. Essa versão foi obtida pelo redimensionamento do lado menor para 256 pixels, por interpolação de área e com a proporção preservada, seguido de um recorte central de 256×256 pixels. As imagens de 256×256 pixels foram calculadas uma única

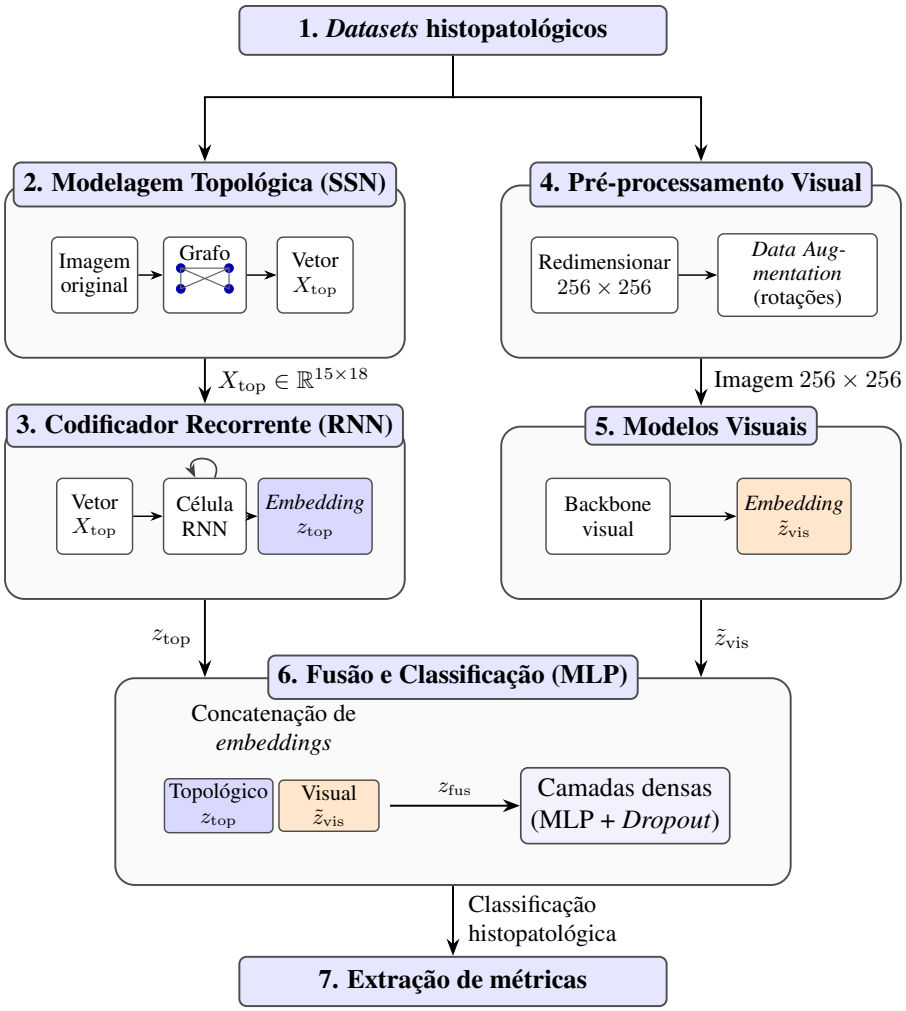
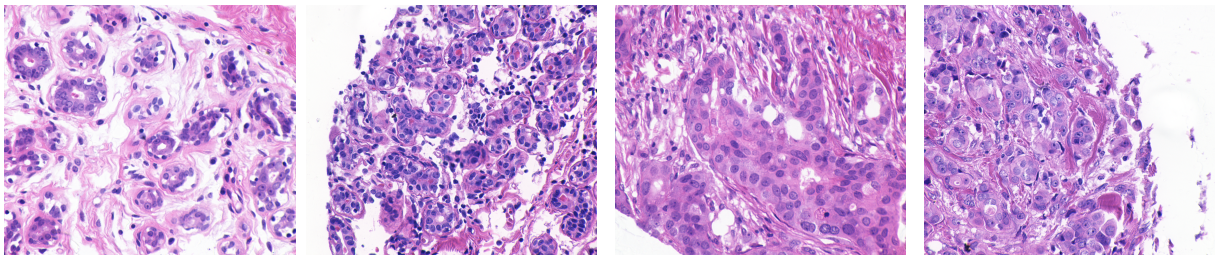


Figura 3 – Pipeline geral da abordagem proposta: os *datasets* histopatológicos alimentam duas vias paralelas. Na via topológica, a imagem original é modelada como um grafo complexo (SSN), gerando a sequência de características X_{top}, que é processada por um codificador recorrente (RNN) para originar o *embedding* topológico z_{top}. Na via visual, a imagem passa por pré-processamento (redimensionamento para 256×256 e aumento de dados por rotação) antes de ser processada pelo *backbone* visual para gerar o *embedding* visual $\tilde{z}_{\text{vis}}$. Ambos os *embeddings* são equalizados, concatenados e classificados por um MLP, gerando as predições finais para extração das métricas.

vez, mantidas como inteiros de 8 bits e armazenadas em cache, com a ordem dos arquivos conferida contra a da via topológica. A conversão para o intervalo $[0, 1]$ e a normalização por canal foram aplicadas a cada lote conforme a configuração de pré-treinamento de cada modelo na biblioteca *timm* (Seção 3.3.2), utilizando a média de $(0{,}485, 0{,}456, 0{,}406)$ e o desvio padrão de $(0{,}229, 0{,}224, 0{,}225)$ da ImageNet para os modelos ResNet-50, EfficientNet-B0, ViT-Tiny, DeiT-Tiny e CoAtNet-0, e padronização sem subtração de média para a MobileViT-S. Esse procedimento preservou as proporções relativas dos compartimentos celulares, embora o recorte central descartasse faixas periféricas em imagens não quadradas.

O conjunto UCSB (Gelasca et al., 2008) compreendeu imagens de tecido epitelial mamário obtidas por microscopia óptica sob aumento de 20× (Figura 4). Entre os conjuntos analisados, essa base reuniu o volume amostral mais reduzido da investigação, impondo severa restrição ao treinamento supervisionado. O desafio da classificação decorreu da diferenciação entre alterações epiteliais benignas, acompanhadas por estroma denso colagenoso, e carcinomas invasivos caracterizados por atipias celulares e desarranjo da conformação tecidual típica, demandando alta capacidade de discriminação sob amostragem restrita.

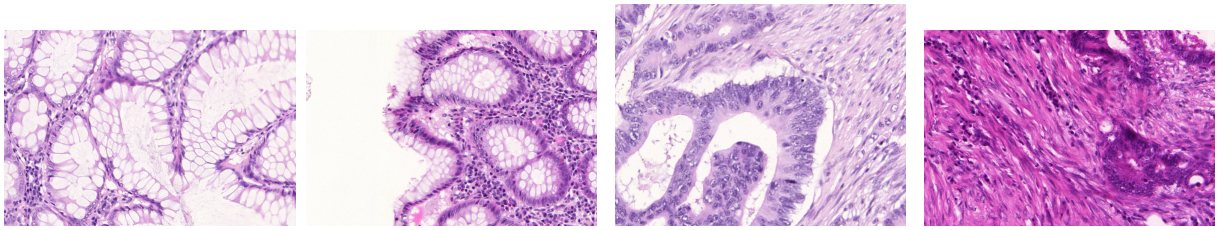
O conjunto CR (Sirinukunwattana et al., 2017) foi obtido a partir de seções histológicas representativas de adenocarcinoma colorretal avançado nos estágios patológicos T3 e T4 (Figura 5). A distinção diagnóstica envolveu a perda da conformação criptal tubular característica do epitélio benigno e a proliferação irregular de células atípicas pelo estroma tecidual. O conjunto exibiu a particularidade de conter 14 imagens capturadas em resoluções atípicas com relações de aspecto distintas das demais amostras, exigindo atenção no procedimento de recorte central padronizado para evitar o descarte de arranjos glandulares atípicos periféricos.



(a) (b) (c) (d)

Figura 4 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.

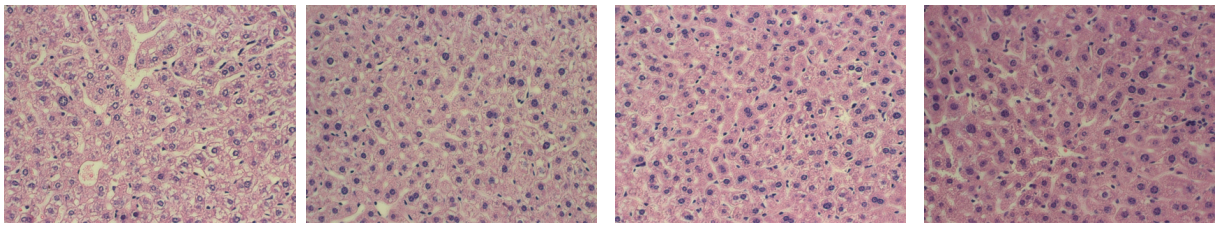
Os conjuntos LA e LG (Shamir et al., 2008) reuniram micrografias de tecido hepático de camundongos voltadas à caracterização quantitativa de padrões biológicos fisiológicos normais, sem presença de lesões neoplásicas (Figura 6 e Figura 7). No conjunto LA, a classificação de quatro faixas etárias permitiu acompanhar o processo contínuo de envelhecimento tecidual, refletido em alterações graduais no parênquima hepático, aumento da variabilidade volumétrica dos hepatócitos e desarranjo progressivo dos cordões celulares. No conjunto LG, a distinção entre fêmeas e machos foi governada por variações na vascularização sinusoidal e na densidade nuclear



(a) (b) (c) (d)

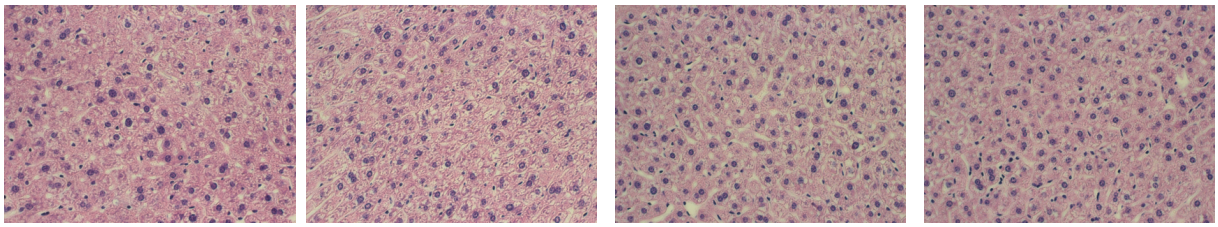
Figura 5 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

média do parênquima. Ambos os conjuntos atuaram como referenciais de textura biológica gradual em condições livres de processos tumorais.



(a) (b) (c) (d)

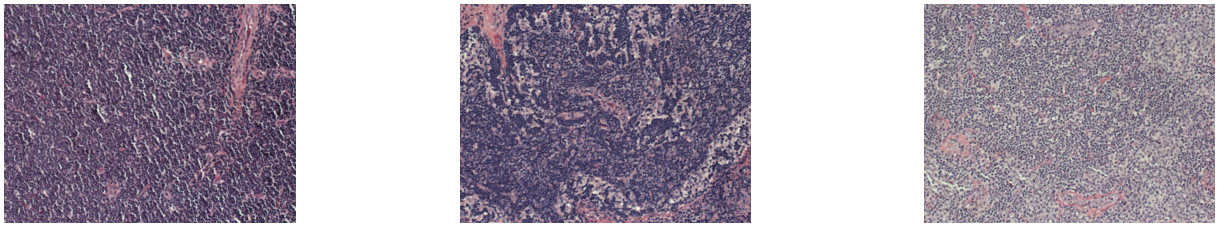
Figura 6 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).



(a) (b) (c) (d)

Figura 7 – Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.

O conjunto NHL (Shamir et al., 2008) contemplou subtipos de linfoma não Hodgkin, abrangendo leucemia linfocítica crônica (CLL), linfoma folicular (FL) e linfoma de células do manto (MCL) (Figura 8). A principal particularidade do conjunto decorreu da aquisição multicêntrica dos espécimes, preparados por diferentes histologistas em diversos hospitais e laboratórios. Esse protocolo heterogêneo introduziu variações acentuadas de saturação, coloração histoquímica e iluminação entre as lâminas, reproduzindo condições operacionais desafiadoras para modelos computacionais. Como as partições de validação e teste foram geradas dentro do próprio acervo sem metadados relativos ao laboratório de origem de cada lâmina, a avaliação não contemplou a transferência direta para centros clínicos não observados durante o desenvolvimento.



(a) (b) (c)

Figura 8 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

3.2 PROTOCOLO EXPERIMENTAL

O protocolo experimental foi delineado para viabilizar a comparação equitativa entre as vias isoladas e mensurar com rigor empírico a contribuição decorrente da integração multimodal sob restrição amostral. Para assegurar a generalização dos resultados e prevenir o vazamento de dados, o procedimento metodológico compreendeu duas fases sequenciais: a exploração por validação cruzada na partição de desenvolvimento e a avaliação confirmatória final no conjunto de teste independente, conforme esquematizado na Figura 9.

As amostras de cada conjunto de dados foram divididas de forma estratificada na proporção de 80% para desenvolvimento e 20% para teste final independente, com semente pseudoaleatória 42. A partição de teste final de 20% foi mantida estritamente isolada durante toda a etapa de desenvolvimento, sem intervenção na seleção de arquiteturas ou no ajuste de hiperparâmetros, atuando unicamente na inferência confirmatória final.

Na partição de desenvolvimento (80%), foi aplicada validação cruzada estratificada em cinco dobras ($k = 5$), também configurada com semente 42. Em cada uma das cinco rodadas, quatro dobras foram destinadas ao treinamento e uma dobra foi reservada para validação. As transformações de padronização foram calibradas estritamente com os parâmetros estatísticos das dobras de treino de cada rodada, prevenindo o vazamento de informações para a validação. O desempenho médio de validação ao longo das cinco dobras, quantificado pelo F1 macro, foi adotado como critério para a seleção dos hiperparâmetros ótimos e dos melhores modelos de cada via.

Concluída a seleção das configurações ótimas em cada modalidade, a fase confirmatória consistiu no treinamento dos modelos sobre a totalidade da partição de desenvolvimento (80%) e na avaliação do desempenho na partição de teste independente (20%). Para mensurar a estabilidade frente a fatores estocásticos (inicialização de pesos das camadas não pré-treinadas, embaralhamento de lotes e transformações de aumento de dados), o treinamento e a inferência no teste independente foram repetidos sob cinco sementes aleatórias pré-fixadas ($s \in \{42, 43, 44, 45, 46\}$), sendo reportados a média e o desvio padrão obtidos.

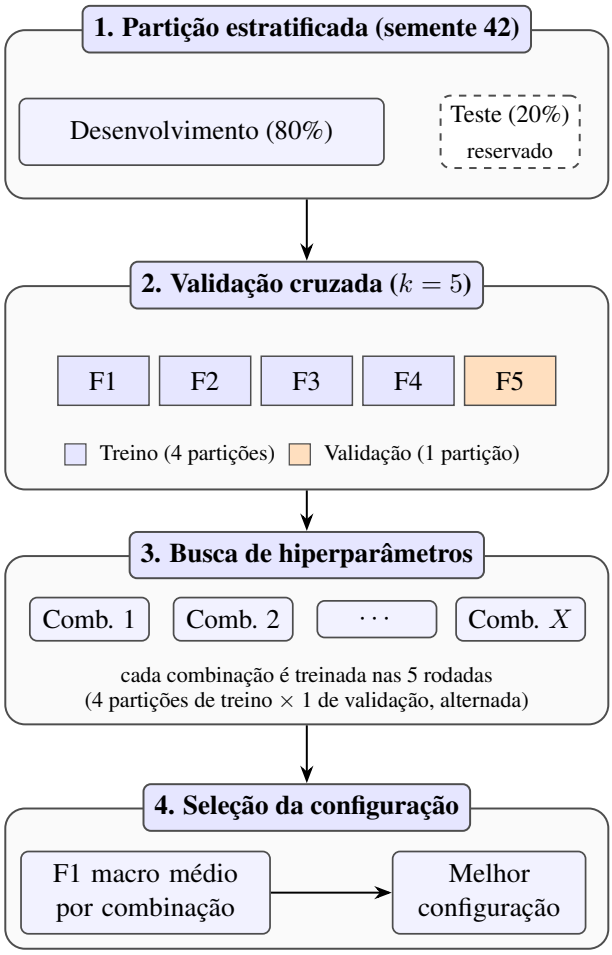


Figura 9 – Protocolo de ablação para o treinamento dos modelos: partição estratificada em 80% para desenvolvimento e 20% para teste final (reservado), validação cruzada com cinco partições sobre os 80%, avaliação de X combinações de hiperparâmetros e seleção da combinação de maior desempenho médio.

3.2.1 Métricas de avaliação

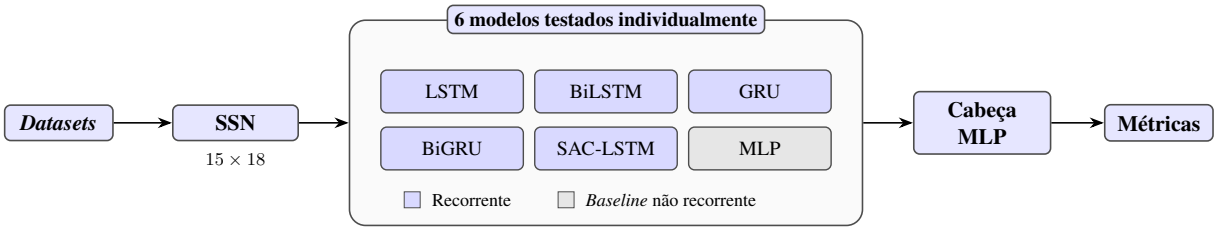
A capacidade preditiva dos modelos foi mensurada pela acurácia, pelo F1-*score* macro e pela AUC-ROC. A acurácia quantificou a proporção global de predições corretas. O F1-*score* macro foi calculado pela média aritmética dos valores de F1 apurados individualmente para cada classe, correspondendo cada F1 à média harmônica entre precisão e sensibilidade:

$$\mathrm{F1}_{\mathrm{macro}} = \frac{1}{C}\sum_{c=1}^{C}\frac{2 \cdot \mathrm{Precisão}_c \cdot \mathrm{Sensibilidade}_c}{\mathrm{Precisão}_c + \mathrm{Sensibilidade}_c}, \tag{1}$$

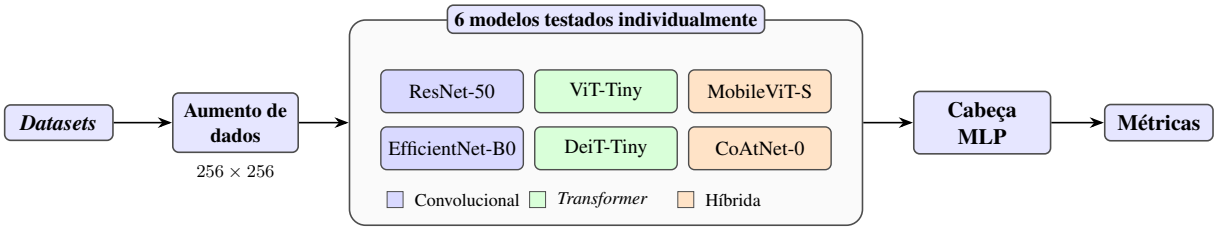
atribuindo peso paritário às classes minoritárias e majoritárias, propriedade relevante em conjuntos desbalanceados. A métrica AUC-ROC foi calculada pela abordagem um-contra-todos com média macro nas tarefas multiclasse (LA e NHL).

3.3 MODELAGEM E EXPLORAÇÃO DAS VIAS ISOLADAS

Com o propósito de determinar as arquiteturas mais adequadas e as combinações ótimas de hiperparâmetros antes da composição do modelo de dupla via, as duas vias foram avaliadas de forma isolada sobre as mesmas partições de dados da validação cruzada. A organização da avaliação das vias isoladas foi ilustrada na Figura 10, abrangendo os modelos avaliados na via topológica e na via visual, acompanhados de suas respectivas cabeças de classificação.



(a) Via topológica



(b) Via visual

Figura 10 – Ablação das vias isoladas. (a) Via topológica: a sequência de características da SSN é processada por seis codificadores (cinco recorrentes e um MLP como *baseline*), cada um testado de forma independente. (b) Via visual: as imagens, após aumento de dados, são processadas por seis modelos (convolucionais, *transformers* e híbridos), também testados individualmente. Cada via possui sua própria cabeça MLP, da qual são extraídas as métricas.

3.3.1 Via topológica

A extração das características da via topológica foi executada por meio de rotinas determinísticas implementadas em C++ com paralelização OpenMP em 16 *threads*. As redes espaço-espectrais foram construídas diretamente sobre as imagens na resolução nativa de 8 bits de cada conjunto de dados (Tabela 1), sem redimensionamento e sem interpolação de intensidades, preservando as comparações numéricas originais entre os pixels (Seção 2.2). Foi adotada a topologia de rede *full* ($\mathcal{N}$) sobre os canais RGB, com raios de conexão discretos variando de $r = 1$ a $r_{\max} = 15$ (Scabini; Ribas; Bruno, 2020).

Para cada raio de alcance r, foram calculadas as distribuições nodais de grau de saída, força de saída e força de entrada sobre a totalidade dos vértices, sendo o grau de entrada descartado por redundância matemática em relação ao grau de saída (Seção 2.2). A sumarização estatística

dessas três medidas pela média e pelo desvio padrão em cada um dos três canais de cor resultou em 18 atributos nodais por escala. A representação da imagem foi organizada como uma sequência ordenada por raios crescentes:

$$X_{\text{top}} = [x_1, x_2, \ldots, x_{15}], \tag{2}$$

na qual cada vetor $x_r \in \mathbb{R}^{18}$ corresponde ao raio r, compondo uma sequência multiescala de dimensão $15 \times 18 = 270$ atributos. Durante a validação cruzada, cada uma das 18 coordenadas foi padronizada com base na média e no desvio padrão apurados exclusivamente na partição de treino da respectiva rodada.

Para avaliar a relevância da ordem sequencial entre as escalas frente a uma projeção estática desordenada, foram investigadas duas abordagens de codificação: cinco arquiteturas de redes neurais recorrentes (LSTM, BiLSTM, GRU, BiGRU e SAC-LSTM), formuladas conceitualmente na Seção 2.3, e um codificador denso baseado em MLP atuando como linha de base de controle experimental (Huang et al., 2022; Rumelhart; Hinton; Williams, 1986).

Nos modelos unidirecionais, a representação latente correspondeu ao estado oculto terminal ($h_{\text{rec}} = h_{15}$). Nos modelos bidirecionais (BiLSTM e BiGRU), a representação latente foi formada pela concatenação dos estados terminais dos dois sentidos de leitura:

$$h_{\text{rec}} = \left[\overrightarrow{h}_{15} \,\|\, \overleftarrow{h}_{1} \right] \in \mathbb{R}^{h}, \tag{3}$$

em que $h \in \{64, 128, 256, 512\}$ denota a capacidade interna avaliada. Quando $h \neq 128$, uma camada linear com ativação ReLU projetou h_{rec} para o descritor padronizado $z_{\text{top}} \in \mathbb{R}^{128}$, sendo $z_{\text{top}} = h_{\text{rec}}$ fixado diretamente para $h = 128$. No codificador de controle MLP, os 15 vetores de X_{top} foram concatenados em um único vetor plano $\text{vec}(X_{\text{top}}) \in \mathbb{R}^{270}$, processado por uma camada densa com ativação ReLU:

$$h_{\text{mlp}} = \text{ReLU}\left(W_t \ \text{vec}(X_{\text{top}}) + b_t\right) \in \mathbb{R}^{h}, \qquad W_t \in \mathbb{R}^{h \times 270}, \tag{4}$$

seguido pela mesma projeção linear para 128 dimensões quando $h \neq 128$.

Na fase de exploração isolada da via topológica, o descritor $z_{\text{top}} \in \mathbb{R}^{128}$ alimentou uma cabeça classificadora composta por normalização por camadas, camada linear de 128 neurônios com ativação ReLU, camada de desativação aleatória (*dropout*) e camada linear de saída com projeção para o número de classes C da tarefa. O treinamento foi conduzido com função de perda de entropia cruzada, otimizador AdamW com decaimento de pesos fixado em $\lambda = 10^{-4}$ e norma euclidiana máxima de gradientes limitada a 1,0. O treinamento foi delimitado a um teto de 100 épocas, com parada antecipada regulada por tolerância de 15 épocas consecutivas sem decréscimo da perda na partição de validação. A grade de busca hiperparamétrica da via topológica foi sintetizada na Tabela 2.

Tabela 2 – Espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica.

Dataset	**Lote** (B)	**Taxa de aprendizado** (η)	**Decaimento** (λ)	***Dropout*** (p)	**Dim. oculta** (h)
UCSB	$\{4, 8, 16\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
CR	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
LG	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
NHL	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
LA	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$

3.3.2 Via visual

A via visual processou atributos diretamente dos pixels da imagem RGB por meio de modelos de visão computacional pré-treinados na base ImageNet-1k (Russakovsky et al., 2015). Foram avaliadas seis arquiteturas distribuídas em três famílias:

- família convolucional: ResNet-50 (He et al., 2016) e EfficientNet-B0 (Tan; Le, 2019);
- família de transformadores visuais: ViT-Tiny (Dosovitskiy et al., 2020) e DeiT-Tiny (Touvron et al., 2021);
- família de arquiteturas híbridas: MobileViT-S (Mehta; Rastegari, 2022) e CoAtNet-0 (Dai et al., 2021).

As imagens de entrada foram redimensionadas para a escala padronizada de 256×256 pixels (Seção 3.1). Durante o treinamento das rodadas, foi aplicado aumento de dados composto por inversão horizontal com probabilidade de 0,5 e rotações ortogonais de 0, 90, 180 ou 270 graus. Cada modelo recebeu a imagem com a camada original de classificação da ImageNet removida, gerando o vetor denso $z_{\text{vis}} \in \mathbb{R}^D$, cuja dimensão D variava conforme a arquitetura ($D = 2048$ na ResNet-50, $D = 1280$ na EfficientNet-B0, $D = 192$ no ViT-Tiny e DeiT-Tiny, $D = 640$ na MobileViT-S e $D = 768$ na CoAtNet-0).

Na avaliação isolada da via visual, a camada original foi substituída pela mesma composição de cabeça classificadora utilizada na via topológica, contendo camada linear adaptada à dimensão D, normalização por camadas, camada oculta de 128 neurônios com ativação ReLU, camada de desativação aleatória e camada linear de saída.

O treinamento foi conduzido com a função de perda de entropia cruzada e o otimizador AdamW, com taxa de decaimento de pesos fixada em $\lambda = 10^{-4}$ e norma máxima dos gradientes limitada a 1,0. As taxas de aprendizado foram calibradas separadamente para o extrator visual (η_{bb}) e para a cabeça de classificação (η_{hd}). O treinamento foi delimitado a 50 épocas, com critério de parada antecipada após 10 épocas consecutivas sem decréscimo da perda na partição de validação. A grade de hiperparâmetros explorada e as dimensões amostrais de cada conjunto de dados na via visual foram sintetizadas na Tabela 3.

Tabela 3 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via visual.

Dataset	Desenv. (80%)	Treino / Val. (rodada)	Lote (B)	Taxa do *backbone* (η_{bb})	Taxa da cabeça (η_{hd})	Decaimento (λ)	*Dropout* (p)
UCSB	46	36 a 37 / 9 a 10	$\{4, 8, 16\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
CR	132	105 a 106 / 26 a 27	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
LG	212	169 a 170 / 42 a 43	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
NHL	299	239 a 240 / 59 a 60	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
LA	422	337 a 338 / 84 a 85	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$

3.4 ARQUITETURA UNIFICADA DE DUPLA VIA

A arquitetura de dupla via integrou as propriedades relacionais multiescala da via topológica às representações visuais profundas extraídas por modelos de visão computacional. As duas vias processaram a imagem de forma paralela e independente. Para compor o modelo unificado de cada conjunto de dados, foram combinados o codificador topológico e o modelo visual que obtiveram o maior F1 macro médio nas etapas de ablação das vias isoladas.

3.4.1 Fusão por concatenação de *embeddings*

Os vetores z_{top} e z_{vis} apresentavam ordens de grandeza e dimensionalidades distintas. Para equalizar as duas modalidades antes da combinação, o vetor visual foi projetado linearmente para 128 dimensões por meio de uma matriz de pesos $W_p \in \mathbb{R}^{128 \times D}$. Em seguida, a normalização por camadas foi aplicada de forma independente a cada uma das representações, equalizando suas escalas numéricas:

$$\tilde{z}_{\text{vis}} = W_p \, z_{\text{vis}} + b_p, \qquad W_p \in \mathbb{R}^{128 \times D}, \tag{5}$$

$$z_{\text{fus}} = [\text{LN}(z_{\text{top}}) \parallel \text{LN}(\tilde{z}_{\text{vis}})] \in \mathbb{R}^{256}. \tag{6}$$

O operador $\parallel$ denota a concatenação vetorial. O vetor unificado z_{fus} reuniu 128 atributos da via topológica e 128 atributos da via visual, totalizando 256 características alimentadas no classificador final.

3.4.2 Classificador MLP

A predição das classes foi executada por um classificador MLP (Rumelhart; Hinton; Williams, 1986) com camada oculta de 128 neurônios e ativação ReLU:

$$h_{\text{cls}} = \text{ReLU}\left(W_1 z_{\text{fus}} + b_1\right), \qquad W_1 \in \mathbb{R}^{128 \times 256}. \tag{7}$$

Sobre o vetor h_{cls} foi aplicada regularização por desativação aleatória com taxa de descarte $p = 0{,}5$ durante o treinamento (Srivastava et al., 2014). A camada linear terminal mapeou os atributos para o número de classes C de cada conjunto de dados ($C \in \{2, 3, 4\}$), permitindo o cálculo das probabilidades preditas pela função *softmax*:

$$\hat{y} = \mathrm{softmax}\left(W_2 h_{\mathrm{cls}} + b_2\right), \qquad W_2 \in \mathbb{R}^{C \times 128}. \tag{8}$$

3.4.3 Treinamento de ponta a ponta e herança de hiperparâmetros

A arquitetura unificada de dupla via foi ajustada de ponta a ponta. Os parâmetros do modelo visual, da camada de projeção linear, do codificador topológico e do classificador MLP foram atualizados simultaneamente por retropropagação dos gradientes gerados pela função de perda de entropia cruzada, utilizando o otimizador AdamW com decaimento de pesos $\lambda = 10^{-4}$ e norma máxima de gradientes limitada a 1,0.

A definição dos hiperparâmetros da arquitetura unificada adotou a estratégia de herança direta dos valores ótimos estabelecidos durante as etapas de ablação das vias isoladas (Seção 3.3), sem a realização de uma nova busca hiperparamétrica na arquitetura integrada. Para cada conjunto de dados, foram combinados o codificador topológico e o modelo visual que obtiveram o maior F1 macro médio na validação cruzada individual. O modelo visual herdou a taxa de aprendizado do extrator (η_{bb}) selecionada na ablação visual. O codificador topológico herdou a taxa de aprendizado da via (η_{top}) e a dimensão oculta (h) selecionadas na ablação topológica. A camada de projeção linear e o classificador MLP foram ajustados com a taxa de aprendizado da cabeça (η_{hd}) selecionada na ablação visual. O tamanho de lote (B) e a taxa de desativação aleatória (*dropout*) foram igualmente herdados das configurações ótimas apuradas em cada conjunto de dados.

A decisão metodológica de não realizar uma nova busca em grade no modelo integrado assegura a integridade da comparação experimental. Ao fixar os componentes nos níveis de melhor desempenho apurados individualmente, qualquer variação nos resultados decorre exclusivamente da integração das representações multiescala e visual, impedindo que ganhos de acurácia sejam mascarados por um sobreajuste assimétrico de hiperparâmetros na fusão.

O treinamento foi delimitado a um teto de 50 épocas, com aplicação de critério de parada antecipada após 10 épocas consecutivas sem decréscimo da perda na partição de validação. A via visual recebeu aumento de dados por inversão horizontal com probabilidade de 0,5 e rotações de 0, 90, 180 ou 270 graus exclusivamente durante o treino, enquanto a via topológica não recebeu transformações adicionais em virtude da invariância rotacional intrínseca às métricas estatísticas globais calculadas sobre a rede.

3.4.4 Avaliação confirmatória no teste independente

A avaliação confirmatória final da arquitetura unificada de dupla via seguiu o protocolo delineado na Seção 3.2. O modelo integrado foi treinado sobre a totalidade da partição de desenvolvimento (80% dos dados) e avaliado na partição de teste independente (20%), sob a mesma sequência de cinco sementes aleatórias ($s \in \{42, 43, 44, 45, 46\}$). Os índices consolidados pela

média e pelo desvio padrão do F1 macro e da AUC-ROC no teste independente forneceram a validação empírica conclusiva da fusão frente às vias isoladas (Capítulo 4).

3.5 CONFIGURAÇÃO DE AMBIENTE

Os experimentos foram executados em uma infraestrutura computacional equipada com um processador *13th Gen Intel(R) Core(TM) i5-13400F* e duas unidades de processamento gráfico NVIDIA, sendo uma RTX 4060 Ti e uma RTX 4070 Ti SUPER. Os pesos pré-treinados dos modelos visuais foram obtidos por meio da biblioteca *timm* (versão 1.0.3). A extração determinística das redes espaço-espectrais foi realizada por implementação própria em C++ com paralelismo OpenMP em 16 *threads*. As bibliotecas de suporte computacional empregadas foram *torch* (versão 2.15), *torchvision* (versão 0.29.2), *scikit-image* (versão 0.26), *scikit-learn* (versão 1.9.1), *pandas* (versão 3.1), *opencv* (versão 5.0) e *pillow* (versão 13.0).

4 RESULTADOS E DISCUSSÃO

Os resultados obtidos no desenvolvimento e na avaliação da arquitetura de dupla via, bem como das vias isoladas que a compõem, são apresentados e discutidos neste capítulo. O capítulo foi organizado em cinco etapas sequenciais. Na Seção 4.1, são detalhados os experimentos de ablação executados sobre a partição de desenvolvimento (80% dos dados) para determinar os codificadores mais adequados e as combinações ótimas de hiperparâmetros na via topológica (Subseção 4.1.1) e na via visual (Subseção 4.1.2). Na Seção 4.2, a capacidade de generalização de cada modalidade isolada sob as configurações selecionadas é mensurada sobre a partição de teste independente (20% dos dados) ao longo da sequência de cinco sementes pré-fixadas (42 a 46). Na Seção 4.3, o desempenho confirmatório da rede unificada de dupla via é comparado diretamente às vias isoladas sobre a mesma partição de teste. Na Seção 4.4, o comportamento dos modelos é analisado sob a perspectiva do diagnóstico patológico por classe e tecido biológico. Por fim, na Seção 4.5, a eficiência paramétrica e o custo de inferência computacional da arquitetura proposta são examinados.

4.1 ABLAÇÃO E SELEÇÃO DE CONFIGURAÇÕES

Nesta seção são apresentados e discutidos os resultados dos experimentos de ablação conduzidos sobre a partição de desenvolvimento sob validação cruzada, em que as duas vias foram avaliadas conforme explicado na Seção 3.3, com o propósito de mensurar a capacidade discriminativa individual de cada modelo e identificar as configurações ótimas para a subsequente composição da arquitetura de dupla via.

4.1.1 Ablação da via topológica

A via topológica foi avaliada sobre os seis codificadores descritos na metodologia, e seus respectivos desempenhos para cada combinação de hiperparâmetros foi mensurado pela média aritmética do F1 macro obtido nas cinco partições de validação interna, sendo a combinação responsável pela maior pontuação média estabelecida como a configuração ótima de cada modelo em cada conjunto de dados. Os valores médios de F1 macro e os respectivos desvios padrão obtidos pelas configurações selecionadas de cada codificador estão consolidados na Tabela 4.

A comparação dos desempenhos na Tabela 4 revela padrões distintos na resposta dos codificadores topológicos conforme a natureza e a complexidade de cada conjunto de dados. Em bases com volume amostral restrito e marcadas por atipias celulares, como o UCSB e o CR, os modelos recorrentes dotados de mecanismos de portas simplificados (BiGRU e GRU) apresentaram maior capacidade de generalização e menor dispersão ($0{,}933 \pm 0{,}061$ no UCSB e $0{,}985 \pm 0{,}034$ no CR) em comparação à LSTM padrão ($0{,}893 \pm 0{,}124$). Esse comportamento sugere que a redução no número de portas internas atenua a memorização de ruído sob restrição de dados. Nas bases

Tabela 4 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados.

Codificador	UCSB	CR	LA	LG	NHL
LSTM	0,893 ± 0,124	0,992 ± 0,017	**1,000** ± 0,000	0,995 ± 0,011	0,938 ± 0,043
BiLSTM	0,870 ± 0,109	0,985 ± 0,034	**1,000** ± 0,000	0,995 ± 0,011	0,956 ± 0,019
GRU	0,892 ± 0,107	**0,993** ± 0,017	**1,000** ± 0,000	0,995 ± 0,011	0,956 ± 0,049
BiGRU	**0,933** ± 0,061	0,985 ± 0,034	**1,000** ± 0,000	**0,995** ± 0,011	0,966 ± 0,021
SAC-LSTM	0,867 ± 0,090	0,977 ± 0,034	**1,000** ± 0,000	0,995 ± 0,011	0,921 ± 0,046
MLP	0,871 ± 0,135	**0,993** ± 0,017	**1,000** ± 0,000	0,995 ± 0,011	**0,973** ± 0,020

hepáticas LA e LG, todos os seis codificadores alcançaram patamares máximos ($1{,}000 \pm 0{,}000$ em LA e índices superiores a $0{,}995$ em LG), indicando que as medidas multiescala de grau e força capturam diretamente os padrões contínuos de senescência e dimorfismo tecidual, permitindo a separação das classes independentemente da complexidade temporal do codificador. No conjunto multiclasse NHL, caracterizado por heterogeneidade decorrente da aquisição em múltiplos centros, o codificador estático MLP alcançou a maior pontuação média ($0{,}973 \pm 0{,}020$), seguido de perto pela BiGRU ($0{,}966 \pm 0{,}021$). Esse resultado evidencia que uma projeção linear densa ampla ($h = 512$) sobre os 270 atributos opera com alta capacidade discriminativa perante variações globais entre lâminas, ao mesmo tempo em que a leitura ordenada dos raios preserva representações informativas.

A análise dos hiperparâmetros selecionados no Apêndice A (Tabela 13) corrobora esses padrões. A expansão da dimensão oculta para $h = 256$ ou $h = 512$ foi selecionada em 21 das 30 configurações avaliadas (70%), indicando que espaços latentes mais amplos preservam com maior fidelidade as trajetórias de conectividade entre os 15 raios sucessivos. As taxas de aprendizado moderadas ou superiores ($\eta \geq 3 \cdot 10^{-3}$) predominaram em 18 configurações, enquanto o tamanho de lote acompanhou a densidade de cada base, com $B = 4$ no conjunto UCSB em razão da amostragem restrita e $B \in \{16, 32\}$ nas demais bases.

As combinações ótimas de hiperparâmetros selecionadas para a composição da via topológica em cada conjunto de dados estão consolidadas na Tabela 5. No conjunto restrito UCSB, a BiGRU foi selecionada com dimensão oculta $h = 256$, taxa de aprendizado $\eta = 3 \cdot 10^{-3}$, taxa de desativação aleatória $p = 0{,}3$ e tamanho de lote $B = 8$. No conjunto CR, a GRU foi selecionada com $\eta = 10^{-2}$, $h = 128$, $p = 0{,}1$ e $B = 16$. Nas bases hepáticas LA e LG, a BiGRU foi fixada com $h = 64$ e $h = 512$, respectivamente. Por fim, na base multiclasse NHL, o MLP foi selecionado com dimensão ampla $h = 512$, taxa de aprendizado $\eta = 3 \cdot 10^{-4}$, regularização $p = 0{,}1$ e lote $B = 16$. O detalhamento completo de todas as 30 configurações avaliadas está documentado na Tabela 13 do Apêndice A.

Tabela 5 – Configurações ótimas de hiperparâmetros e desempenhos dos codificadores selecionados na via topológica por conjunto de dados.

Dataset	**Codificador**	η	h	p	B	**Épocas**	**Acurácia**	**F1 macro**
UCSB	BiGRU	$3 \cdot 10^{-3}$	256	0,3	8	28	0,936	0,933 ± 0,061
CR	GRU	10^{-2}	128	0,1	16	19	0,993	0,993 ± 0,017
LA	BiGRU	$3 \cdot 10^{-4}$	64	0,1	16	85	1,000	1,000 ± 0,000
LG	BiGRU	$3 \cdot 10^{-3}$	512	0,5	32	12	0,995	0,995 ± 0,011
NHL	MLP	$3 \cdot 10^{-4}$	512	0,1	16	24	0,973	0,973 ± 0,020

4.1.2 Ablação da via visual

A ablação da via visual foi conduzida sobre as seis arquiteturas de visão computacional distribuídas nas três famílias conceituais (convolucionais, transformadores e híbridas). O desempenho de cada configuração foi mensurado pelo F1 macro médio nas cinco partições de validação interna, sendo a combinação que atingiu a maior pontuação média definida como a configuração ótima de cada modelo em cada conjunto de dados. Os valores médios de F1 macro e seus respectivos desvios padrão estão reunidos na Tabela 6.

Tabela 6 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via visual isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados.

Família	**Modelo**	**UCSB**	**CR**	**LA**	**LG**	**NHL**
Convolucional	ResNet-50	0,980 ± 0,045	**1,000** ± 0,000	**1,000** ± 0,000	0,995 ± 0,010	0,950 ± 0,052
Convolucional	EfficientNet-B0	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	0,967 ± 0,031
Transformer	ViT-Tiny	0,977 ± 0,052	**1,000** ± 0,000	0,998 ± 0,005	**1,000** ± 0,000	0,921 ± 0,043
Transformer	DeiT-Tiny	0,956 ± 0,060	**1,000** ± 0,000	0,998 ± 0,005	**1,000** ± 0,000	0,938 ± 0,047
Híbrida	MobileViT-S	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	0,969 ± 0,044
Híbrida	CoAtNet-0	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	**1,000** ± 0,000	**0,980** ± 0,026

A análise comparativa na Tabela 6 evidencia comportamentos nitidamente diferenciados entre as famílias arquiteturais de visão computacional em função da complexidade amostral de cada base. Nos conjuntos binários UCSB, CR, LA e LG, a maioria dos modelos alcançou pontuações perfeitas ($1{,}000 \pm 0{,}000$) na melhor combinação hiperparamétrica, refletindo a alta capacidade discriminativa dos extratores pré-treinados na ImageNet perante classes com padrões celulares claramente contrastantes. Em contrapartida, na base multiclasse NHL, caracterizada pela heterogeneidade cromática de lâminas preparadas em diferentes hospitais e laboratórios, emergiu uma separação marcante entre as famílias:

- as arquiteturas puramente baseadas em transformadores visuais (ViT-Tiny com $0{,}921 \pm 0{,}043$ e DeiT-Tiny com $0{,}938 \pm 0{,}047$) registraram os menores desempenhos, indicando maior vulnerabilidade à escassez de dados anotados quando desprovidas de filtros convolucionais locais;

- as arquiteturas híbridas (CoAtNet-0 com $0{,}980 \pm 0{,}026$ e MobileViT-S com $0{,}969 \pm 0{,}044$) e a rede convolucional eficiente (EfficientNet-B0 com $0{,}967 \pm 0{,}031$) alcançaram os maiores índices, demonstrando que a extração convolucional de bordas celulares associada a mecanismos de autoatenção contextual confere maior estabilidade perante a dispersão cromática interlaboratorial.

A calibração dos hiperparâmetros documentada no Apêndice B (Tabela 14) reflete as demandas de regularização de cada modelo. As taxas atenuadas no extrator ($\eta_{bb} \leq 3 \cdot 10^{-5}$) predominaram nos modelos com blocos de autoatenção (CoAtNet-0, DeiT-Tiny e ViT-Tiny), preservando os filtros genéricos pré-treinados contra a desestabilização por retropropagação em dados escassos. A cabeça de classificação demandou taxas superiores ($\eta_{hd} \in \{10^{-4}, 10^{-3}\}$), acelerando o alinhamento das fronteiras de decisão. A regularização por desativação aleatória exigiu valores mais severos ($p = 0{,}3$ e $p = 0{,}5$) nos conjuntos com menor volume amostral relativo (UCSB e NHL), ao passo que taxas brandas ($p = 0{,}1$) foram suficientes nas bases CR e LA.

As configurações selecionadas para a via visual em cada conjunto de dados estão sintetizadas na Tabela 7. O modelo híbrido CoAtNet-0 alcançou a maior pontuação média nas cinco bases avaliadas. No conjunto NHL, a configuração ótima associou taxa atenuada de extrator ($\eta_{bb} = 3 \cdot 10^{-5}$), taxa intermediária de cabeça ($\eta_{hd} = 3 \cdot 10^{-4}$), desativação aleatória $p = 0{,}5$ e tamanho de lote $B = 32$. Nas tarefas binárias CR, LA e LG, a convergência ocorreu sob taxas basais $\eta_{bb} = 10^{-5}$ e $\eta_{hd} = 10^{-4}$ com lote $B = 16$ e $p = 0{,}1$. No conjunto compacto UCSB, uma taxa de cabeça mais agressiva ($\eta_{hd} = 10^{-3}$) acelerou a convergência da projeção em apenas 10 épocas. O detalhamento das 30 configurações da via visual está consolidado na Tabela 14 do Apêndice B.

Tabela 7 – Configurações ótimas de hiperparâmetros e desempenhos dos modelos selecionados na via visual por conjunto de dados.

Dataset	**Família**	**Modelo**	η_{bb}	η_{hd}	p	B	**Épocas**	**Acurácia**	**F1 macro**
UCSB	Híbrida	CoAtNet-0	$3 \cdot 10^{-5}$	10^{-3}	0,3	8	10	1,000	$1{,}000 \pm 0{,}000$
CR	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	45	1,000	$1{,}000 \pm 0{,}000$
LA	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	31	1,000	$1{,}000 \pm 0{,}000$
LG	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	26	1,000	$1{,}000 \pm 0{,}000$
NHL	Híbrida	CoAtNet-0	$3 \cdot 10^{-5}$	$3 \cdot 10^{-4}$	0,5	32	22	0,980	$0{,}980 \pm 0{,}026$

4.1.3 Configurações selecionadas para a composição da dupla via

As configurações ótimas identificadas nas ablações da via topológica e da via visual para a composição da arquitetura unificada de dupla via estão sintetizadas na Tabela 8. O modelo híbrido CoAtNet-0 obteve o maior desempenho médio na via visual em todas as cinco bases avaliadas, sendo associado ao codificador BiGRU nas bases UCSB, LA e LG, ao codificador GRU na base CR e ao codificador MLP na base NHL. Esses conjuntos de parâmetros fornecem

as configurações fixadas para o treinamento de ponta a ponta e a avaliação confirmatória da rede de dupla via frente às modalidades isoladas na partição de teste independente, cujos resultados são analisados nas seções subsequentes deste capítulo.

Tabela 8 – Configurações ótimas selecionadas nas ablações para a composição da rede de dupla via em cada conjunto de dados.

Dataset	**Via Topológica**				**Via Visual (CoAtNet-0)**			
	Codificador	η_{top}	h	p	η_{bb}	η_{hd}	p	B
UCSB	BiGRU	$3 \cdot 10^{-3}$	256	0,3	$3 \cdot 10^{-5}$	10^{-3}	0,3	8
CR	GRU	10^{-2}	128	0,1	10^{-5}	10^{-4}	0,1	16
LA	BiGRU	$3 \cdot 10^{-4}$	64	0,1	10^{-5}	10^{-4}	0,1	16
LG	BiGRU	$3 \cdot 10^{-3}$	512	0,5	10^{-5}	10^{-4}	0,1	16
NHL	MLP	$3 \cdot 10^{-4}$	512	0,1	$3 \cdot 10^{-5}$	$3 \cdot 10^{-4}$	0,5	32

4.2 DESEMPENHO DAS VIAS ISOLADAS NO CONJUNTO DE TESTE INDEPENDENTE

A capacidade de generalização de cada modalidade isolada foi mensurada na partição de teste independente de 20% após o treinamento completo sobre a totalidade do conjunto de desenvolvimento (80% dos dados), utilizando as configurações ótimas estabelecidas na ablação (Seção 4.1). Para quantificar a variabilidade decorrente da inicialização dos pesos e das transformações estocásticas de aumento de dados, o treinamento final nos 80% de desenvolvimento e a inferência no teste foram repetidos sob cinco sementes consecutivas ($s \in \{42, 43, 44, 45, 46\}$), reportando a média e o respectivo desvio padrão das métricas de F1 macro, acurácia e AUC-ROC. O número de épocas de treinamento foi fixado na média das épocas de parada antecipada obtidas na validação cruzada, prevenindo o sobreajuste e mantendo a reprodutibilidade entre as cinco rodadas com sementes distintas. Os desempenhos detalhados e as configurações completas de validação cruzada para a via topológica e para a via visual estão reunidos, respectivamente, no Apêndice A e no Apêndice B, enquanto os desempenhos consolidados obtidos pelos codificadores da via topológica no teste independente estão reunidos na Tabela 9.

Tabela 9 – F1 macro (média $\pm$ desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% dos dados) para os codificadores da via topológica.

Codificador	**UCSB**	**CR**	**LA**	**LG**	**NHL**
LSTM	0,759 $\pm$ 0,097	0,772 $\pm$ 0,060	**1,000** $\pm$ 0,000	0,996 $\pm$ 0,008	0,845 $\pm$ 0,018
BiLSTM	0,757 $\pm$ 0,055	0,888 $\pm$ 0,039	**1,000** $\pm$ 0,000	0,996 $\pm$ 0,008	0,854 $\pm$ 0,006
GRU	**0,916** $\pm$ 0,000	0,907 $\pm$ 0,001	**1,000** $\pm$ 0,000	**1,000** $\pm$ 0,000	**0,894** $\pm$ 0,014
BiGRU	0,864 $\pm$ 0,043	**0,926** $\pm$ 0,015	**1,000** $\pm$ 0,000	**1,000** $\pm$ 0,000	0,879 $\pm$ 0,027
SAC-LSTM	0,825 $\pm$ 0,006	0,864 $\pm$ 0,031	0,998 $\pm$ 0,004	0,981 $\pm$ 0,017	0,847 $\pm$ 0,018
MLP	0,898 $\pm$ 0,064	0,902 $\pm$ 0,012	**1,000** $\pm$ 0,000	**1,000** $\pm$ 0,000	0,881 $\pm$ 0,022

A observação dos resultados da via topológica consolidados na Tabela 9 indica que a GRU e a BiGRU mantiveram a maior estabilidade de generalização entre os modelos recorrentes,

atingindo $0{,}916 \pm 0{,}000$ no conjunto UCSB e $0{,}926 \pm 0{,}015$ no conjunto CR. Em contrapartida, as arquiteturas LSTM padrão sofreram degradação acentuada frente aos índices apurados na validação cruzada (Tabela 4), apresentando quedas superiores a 20 pontos percentuais no conjunto CR, em que a média decresceu de $0{,}992 \pm 0{,}017$ para $0{,}772 \pm 0{,}060$ no teste independente. A maior complexidade paramétrica associada às portas da célula de memória da LSTM constitui uma hipótese plausível para explicar a memorização de ruído dos dados de treino sob restrição amostral. Todos os modelos sustentaram separação quase perfeita nos conjuntos LA e LG ($1{,}000 \pm 0{,}000$ e valores superiores a $0{,}981$), demonstrando que as medidas baseadas em redes complexas capturam distinções teciduais nítidas associadas à senescência e ao sexo do tecido hepático. Os desempenhos individuais registrados por semente para cada codificador na partição de teste estão disponibilizados na Tabela 15 do Apêndice C.

Paralelamente à análise das representações topológicas, a avaliação confirmatória da via visual isolada permitiu verificar como as diferentes famílias de visão computacional pré-treinadas respondem aos desafios morfológicos sob a mesma partição de teste independente. Os índices médios de F1 macro e seus respectivos desvios padrão ao longo das cinco sementes avaliadas estão reunidos na Tabela 10, fornecendo o referencial de comparação para a subsequente etapa de fusão multimodal.

Tabela 10 – F1 macro (média $\pm$ desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% dos dados) para as arquiteturas da via visual.

Família	**Modelo**	**UCSB**	**CR**	**LA**	**LG**	**NHL**
Convolucional	ResNet-50	0,947 ± 0,044	0,969 ± 0,028	0,993 ± 0,014	**1,000** ± 0,000	0,905 ± 0,014
Convolucional	EfficientNet-B0	**1,000** ± 0,000	0,994 ± 0,012	**0,998** ± 0,004	**1,000** ± 0,000	0,953 ± 0,010
Transformer	ViT-Tiny	0,964 ± 0,044	0,988 ± 0,015	0,979 ± 0,011	**1,000** ± 0,000	0,858 ± 0,021
Transformer	DeiT-Tiny	0,982 ± 0,036	**1,000** ± 0,000	0,992 ± 0,012	0,992 ± 0,009	0,912 ± 0,043
Híbrida	MobileViT-S	0,982 ± 0,036	0,994 ± 0,012	**0,998** ± 0,004	**1,000** ± 0,000	0,909 ± 0,046
Híbrida	CoAtNet-0	**1,000** ± 0,000	**1,000** ± 0,000	0,980 ± 0,039	**1,000** ± 0,000	**0,962** ± 0,018

A avaliação confirmatória da via visual isolada na Tabela 10 confirma a prevalência das arquiteturas híbridas e convolucionais compactas sobre os transformadores visuais puros na partição de teste independente. No conjunto multiclasse NHL, a CoAtNet-0 alcançou a pontuação mais elevada ($0{,}962 \pm 0{,}018$), seguida pela EfficientNet-B0 ($0{,}953 \pm 0{,}010$). O modelo ViT-Tiny registrou a menor pontuação no mesmo conjunto ($0{,}858 \pm 0{,}021$), indicando que arquiteturas sem filtros convolucionais locais apresentam maior sensibilidade à escassez amostral em lâminas histopatológicas. Nas tarefas binárias dos conjuntos UCSB, CR e LG, a CoAtNet-0 sustentou a pontuação de $1{,}000 \pm 0{,}000$, mantendo $0{,}980 \pm 0{,}039$ no conjunto LA. O detalhamento das métricas de cada semente para os modelos visuais está registrado na Tabela 15 do Apêndice C.

4.3 COMPARAÇÃO ENTRE AS VIAS ISOLADAS E A REDE DE DUPLA VIA

A investigação central deste trabalho analisa se a integração conjunta das medidas topológicas multiescala com as representações visuais profundas resulta em ganho preditivo frente a cada via

operando de forma isolada. Para cada base de dados, a arquitetura de dupla via foi configurada com o codificador topológico ótimo e o modelo visual de maior desempenho selecionados nas etapas de ablação, sendo ajustada de ponta a ponta sobre os 80% de desenvolvimento e avaliada nos 20% de teste cego ao longo das cinco sementes pré-fixadas ($s \in \{42, 43, 44, 45, 46\}$). Os desempenhos individuais registrados em cada uma das cinco sementes na partição de teste independente estão compilados na Tabela 15 do Apêndice C. A comparação direta consolidada entre as abordagens está registrada na Tabela 11.

Tabela 11 – Comparação de desempenho (média ± desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% das amostras) entre as vias isoladas e a arquitetura unificada de dupla via.

Dataset	Métrica	Via Topológica Isolada	Via Visual Isolada	Rede de Dupla Via
UCSB	F1 macro	0,899 ± 0,039	1,000 ± 0,000	0,964 ± 0,049
UCSB	Acurácia	0,900 ± 0,037	1,000 ± 0,000	0,967 ± 0,046
UCSB	AUC-ROC	0,983 ± 0,016	1,000 ± 0,000	**1,000** ± 0,000
CR	F1 macro	0,926 ± 0,017	1,000 ± 0,000	**1,000** ± 0,000
CR	Acurácia	0,927 ± 0,017	1,000 ± 0,000	**1,000** ± 0,000
CR	AUC-ROC	0,938 ± 0,014	1,000 ± 0,000	**1,000** ± 0,000
LA	F1 macro	1,000 ± 0,000	0,996 ± 0,008	**0,998** ± 0,004
LA	Acurácia	1,000 ± 0,000	0,996 ± 0,008	**0,998** ± 0,004
LA	AUC-ROC	1,000 ± 0,000	1,000 ± 0,000	**1,000** ± 0,000
LG	F1 macro	0,996 ± 0,009	1,000 ± 0,000	**1,000** ± 0,000
LG	Acurácia	0,996 ± 0,008	1,000 ± 0,000	**1,000** ± 0,000
LG	AUC-ROC	1,000 ± 0,000	1,000 ± 0,000	**1,000** ± 0,000
NHL	F1 macro	0,865 ± 0,025	0,922 ± 0,037	**0,938** ± 0,026
NHL	Acurácia	0,864 ± 0,024	0,923 ± 0,037	**0,939** ± 0,026
NHL	AUC-ROC	0,978 ± 0,006	0,995 ± 0,007	0,992 ± 0,005

A comparação pareada registrada na Tabela 11 evidencia que o ganho proporcionado pela arquitetura de dupla via não é uniforme entre os diferentes conjuntos de dados. Em vez de atuar como uma abordagem universalmente superior em qualquer contexto, a integração das duas vias exibe respostas distintas conforme a complexidade taxonômica da tarefa, a presença de heterogeneidade na aquisição e o volume de imagens disponível:

- no conjunto multiclasse NHL, caracterizado por heterogeneidade cromática interlaboratorial e três subtipos diagnósticos com sobreposição morfológica, a rede de dupla via alcançou F1 macro de $0{,}938 \pm 0{,}026$ e acurácia de $0{,}939 \pm 0{,}026$, superando tanto a via visual isolada ($0{,}922 \pm 0{,}037$) quanto a via topológica isolada ($0{,}865 \pm 0{,}025$). O ganho de $1{,}6$ ponto percentual no F1 macro foi acompanhado por uma redução de aproximadamente 30% na dispersão entre as cinco sementes ($0{,}037$ para $0{,}026$), sugerindo um possível efeito de regularização decorrente da agregação de descritores determinísticos de conectividade;

- no conjunto LA, com quatro classes etárias em 106 imagens de teste, a inclusão da via topológica refinou sutilmente a pontuação de $0{,}996 \pm 0{,}008$ para $0{,}998 \pm 0{,}004$, cortando a dispersão amostral pela metade e mantendo AUC-ROC de $1{,}000 \pm 0{,}000$;

- nos conjuntos binários CR e LG, com classes morfológica e histologicamente bem delimitadas, a via visual isolada já alcançou separação completa ($1{,}000 \pm 0{,}000$). Nesses cenários caracterizados por efeito teto, a rede de dupla via sustentou a pontuação máxima nas três métricas avaliadas sem introduzir degradação, confirmando que a inclusão da via topológica preservou as decisões já consolidadas pela representação visual;

- no conjunto UCSB, no qual a via visual isolada atingiu $1{,}000 \pm 0{,}000$, a rede de dupla via obteve F1 macro de $0{,}964 \pm 0{,}049$ e acurácia de $0{,}967 \pm 0{,}046$. Essa redução discreta decorre diretamente da dimensão extremamente restrita da partição de teste (apenas 12 imagens). Em uma amostragem tão limitada, a divergência de classificação em uma única imagem ao longo de duas sementes produz um deslocamento discreto de cerca de 8,3 pontos percentuais na métrica final. Como a partição de desenvolvimento do UCSB reuniu apenas 46 imagens para ajustar conjuntamente os pesos do extrator visual, do codificador topológico e das camadas de projeção e fusão, a arquitetura conjunta exibiu maior sensibilidade estocástica em comparação ao modelo puramente convolucional. A preservação da métrica AUC-ROC no patamar máximo de $1{,}000 \pm 0{,}000$ em todas as sementes indica que a capacidade de ordenação probabilística das predições permaneceu calibrada.

Esse padrão de resultados demonstra que a integração de dupla via é especialmente relevante em tarefas diagnósticas complexas com alta variabilidade cromática e sobreposição morfológica, tornando-se neutra em cenários binários já saturados e exigindo cautela em bases com amostragem excessivamente reduzida.

4.4 ANÁLISE DIAGNÓSTICA POR SUBTIPO PATOLÓGICO E COMPORTAMENTO POR CLASSE

As diferenças de desempenho observadas adquirem significado prático quando contextualizadas perante os desafios morfológicos descritos na literatura médica para cada tecido biológico. Na base NHL, a tarefa diagnóstica abrange três subtipos de linfoma não-Hodgkin de células B: leucemia linfocítica crônica (CLL), linfoma folicular (FL) e linfoma de células do manto (MCL). No exame microscópico de lâminas histopatológicas, a diferenciação entre o linfoma folicular e o linfoma de células do manto impõe desafios frequentes em razão do compartilhamento de atipias citológicas microscópicas, caracterizadas por células linfoides de tamanho pequeno a intermediário com irregularidades nucleares e cromatina condensada. Em recortes padronizados de 256×256 pixels, as representações puramente visuais tornam-se suscetíveis a ambiguidades em virtude dessa similaridade celular em escala local.

Sob a perspectiva histológica, a literatura documenta que esses dois subtipos exibem padrões de crescimento tecidual distintos em escalas mais amplas: o linfoma folicular tende a formar agregados nodulares circunscritos, enquanto o linfoma de células do manto apresenta proliferação difusa ou em manto ao redor de folículos residuais. A formulação de redes espaço-espectrais sobre múltiplos raios de vizinhança ($r = 1$ a $r = 15$) foi delineada teoricamente para mensurar essas relações entre a microtextura celular e a conformação tecidual mais ampla. O ganho observado de $1{,}6$ ponto percentual no F1 macro e a redução de 30% na dispersão entre sementes alcançados pela rede de dupla via no conjunto NHL são compatíveis com a hipótese de que a agregação de propriedades relacionais multiescala provê informações adicionais que auxiliam na separação dessas classes. Deve ser enfatizado, contudo, que na ausência de mapas dedicados de explicabilidade visual (como mapas de calor por autoatenção ou gradientes na imagem), essa correspondência não deve ser interpretada como uma demonstração mecanicista direta de que o modelo identificou explicitamente arranjos foliculares ou mantos celulares, mas sim como uma evidência de que a integração de descritores topológicos produz representações discriminativas compatíveis com a motivação teórica proposta.

No conjunto LA, a tarefa envolve quatro faixas etárias de camundongos. A senescência hepática está associada a alterações graduais no parênquima, abrangendo dilatações sinusoidais e aumento da heterogeneidade no volume nuclear dos hepatócitos. Na avaliação individual das sementes da via visual isolada (Tabela 15 do Apêndice C), a semente 45 registrou queda pontual para F1 macro de $0{,}982$, decorrente de confusões entre faixas etárias adjacentes. A arquitetura de dupla via obteve índice médio de $0{,}998 \pm 0{,}004$ e reduziu a dispersão entre sementes pela metade frente à via visual ($0{,}008$ para $0{,}004$). Essa estabilização é compatível com a capacidade dos descritores nodais em quantificar variações graduais de densidade tecidual, atenuando a sensibilidade a flutuações de preparo histológico.

No conjunto UCSB, a análise das sementes individuais no teste independente de 12 imagens (Tabela 15 do Apêndice C) confirma que a rede de dupla via atingiu predição perfeita ($1{,}000$) em três das cinco execuções (sementes 43, 44 e 46). Nas sementes 42 e 45, o classificador errou a predição em uma única amostra, resultando em acurácia de $0{,}917$. Em decorrência do volume restrito do conjunto de teste, um único erro amostral induz uma variação discreta de $8{,}3$ pontos percentuais na métrica final. A manutenção da AUC-ROC no valor máximo de $1{,}000 \pm 0{,}000$ em todas as cinco sementes indica que a ordenação probabilística entre as classes foi preservada, sem inversões na escala de escores atribuídos às amostras benignas e malignas.

Por fim, nos conjuntos CR e LG, a obtenção de F1 macro de $1{,}000 \pm 0{,}000$ por ambas as vias isoladas e pelo modelo integrado evidencia que tarefas histopatológicas binárias com contraste tecidual acentuado atingem saturação de desempenho. Nessas condições, as representações aprendidas diretamente dos pixels pelos modelos visuais pré-treinados são suficientes para a separação completa das classes, tornando a agregação da via topológica redundante. Esses resultados delimitam o escopo prático da arquitetura de dupla via, evidenciando que sua aplicação é especialmente vantajosa em cenários multiclasse desafiadores com alta variabilidade morfológica

ou cromática, nos quais modelos visuais isolados exibem instabilidade.

4.5 ANÁLISE DA EFICIÊNCIA PARAMÉTRICA E CUSTO COMPUTACIONAL

A viabilidade da implementação de modelos de aprendizado profundo em ambientes de auxílio diagnóstico depende da relação entre o ganho de acurácia obtido e a complexidade computacional introduzida pela arquitetura. A contagem detalhada de parâmetros para os componentes individuais e para a rede de dupla via está apresentada na Tabela 12.

Tabela 12 – Contagem de parâmetros treináveis por componente da arquitetura de dupla via.

Modalidade	**Componente**	**Arquitetura / Função**	**Parâmetros**	**Proporção**
Via Visual	*Backbone* e Projeção	CoAtNet-0 ($D = 768$)	17,8 M	98,7%
Via Visual	*Backbone* e Projeção	ResNet-50 ($D = 2048$)	23,8 M	N/A
Via Visual	*Backbone* e Projeção	EfficientNet-B0 ($D = 1280$)	4,2 M	N/A
Via Visual	*Backbone* e Projeção	MobileViT-S ($D = 640$)	5,0 M	N/A
Via Visual	*Backbone* e Projeção	ViT-Tiny / DeiT-Tiny ($D = 192$)	5,5 M	N/A
Via Topológica	Codificador Recorrente	GRU ($h = 128$)	56,1 mil	0,3%
Via Topológica	Codificador Recorrente	BiGRU ($h = 256$)	145,0 mil	0,8%
Via Topológica	Codificador Denso	MLP ($h = 512$)	189,1 mil	1,0%
Fusão Multimodal	Cabeça de Classificação	MLP com *LayerNorm* ($256 \to 128 \to C$)	33,2 mil	0,2%
Rede de Dupla Via	**Modelo Integrado**	**CoAtNet-0 + MLP + Cabeça de Fusão**	**18,0 M**	**100,0%**

Conforme sintetizado na Tabela 12, a inclusão da via topológica acarreta acréscimo reduzido à capacidade global da arquitetura. Na configuração empregada para a base NHL (CoAtNet-0 acoplada ao codificador MLP com $h = 512$, conforme a Tabela 8), a via visual concentra 17,8 milhões de parâmetros (98,7% do total), enquanto o codificador topológico soma 189 mil parâmetros (1,0% do total) e a camada de fusão multimodal adiciona 33 mil parâmetros (0,2% do total). Mesmo sob o codificador recorrente bidirecional BiGRU empregado nas bases UCSB, LA e LG (Tabela 8), o volume paramétrico da via topológica não ultrapassa 145 mil parâmetros (0,8% da rede integrada).

O procedimento de extração das medidas de redes complexas opera de forma determinística em UCP por meio de algoritmo paralelizado em OpenMP (Seção 3.5), sem consumir memória dedicada da GPU. Durante a etapa de inferência, o vetor topológico de 270 valores numéricos (Equação 2) é processado pelo codificador sequencial em frações de milissegundo, preservando o tempo de resposta da classificação praticamente inalterado frente ao modelo puramente visual. A rede de dupla via estabelece, desse modo, uma relação favorável entre estabilização preditiva e consumo de recursos computacionais, proporcionando ganhos em conjuntos multiclasse sem onerar a infraestrutura de inferência.

5 CONCLUSÃO

Este trabalho propôs uma arquitetura unificada de dupla via para a classificação de imagens histopatológicas sob restrição amostral, integrando a dinâmica topológica multiescala à capacidade representacional de modelos profundos de visão computacional. As imagens foram modeladas como redes complexas ponderadas e direcionadas em raios de conexão crescentes, gerando sequências de atributos de conectividade tecidual que foram codificadas por modelos neurais recorrentes. Paralelamente, modelos de visão computacional pré-treinados extraíram atributos densos diretamente dos pixels. As representações latentes de ambas as modalidades foram equalizadas dimensionalmente por projeção linear e normalização por camadas, alimentando um classificador conjunto ajustado de ponta a ponta. Essa formulação estabeleceu uma alternativa aos descritores tradicionais de escala fixa ao viabilizar a exploração de relações teciduais em diferentes raios de conexão, indicando benefícios preditivos decorrentes da integração multimodal em determinadas tarefas de classificação.

Os experimentos conduzidos sobre o conjunto de teste independente responderam à questão de pesquisa e delimitaram o alcance das hipóteses formuladas a partir de três observações centrais. Primeiro, a via topológica apresentou capacidade discriminativa própria, inclusive quando utilizada isoladamente, como atestado pelo desempenho dos modelos sequenciais no conjunto multiclasse NHL e pela separação quase perfeita nas bases hepáticas LA e LG. Segundo, a integração das modalidades demonstrou benefícios mais evidentes na tarefa multiclasse NHL, caracterizada por elevada sobreposição citológica entre subtipos de linfoma, na qual a arquitetura de dupla via superou a via visual isolada em 1,6 ponto percentual no F1 macro ($0{,}938 \pm 0{,}026$) e reduziu a dispersão entre sementes em 30%. Terceiro, a contribuição da fusão mostrou dependência direta das características da tarefa, não sendo necessariamente vantajosa em todos os conjuntos avaliados: em tarefas binárias com marcante contraste morfológico (CR e LG), as representações visuais puras já atingiram o patamar máximo de desempenho, tornando a fusão neutra, ao passo que em conjuntos com reduzidíssimo volume de teste, a exemplo do UCSB, a maior parametrização da rede integrada introduziu leve sensibilidade a variações estocásticas.

O objetivo geral e os objetivos específicos foram integralmente cumpridos ao longo das etapas metodológicas. As contribuições deste estudo compreendem o estabelecimento de uma abordagem que trata medidas de redes complexas como séries ordenadas por escala acopladas à visão profunda, a comprovação da eficiência paramétrica da via topológica, que acrescentou apenas 189 mil parâmetros (1,0% da rede) sem consumo de memória gráfica, e a caracterização comparativa detalhada de seis codificadores sequenciais e seis modelos visuais em cinco bases histopatológicas, delimitando o impacto da fusão frente a cada modalidade isolada.

Para trabalhos futuros, as investigações foram delineadas em dois eixos principais: o aprimoramento da arquitetura e a ampliação da validação e interpretabilidade. No eixo voltado à arquitetura, a concatenação simples de vetores pode ser substituída por mecanismos de atenção

cruzada para ponderar de forma adaptativa as escalas topológicas e os atributos visuais, somada à investigação de resoluções flexíveis de entrada para mitigar o descarte de bordas teciduais decorrente do recorte central. No eixo referente à validação e interpretabilidade, as propostas contemplam a extensão da abordagem para lâminas inteiras digitalizadas por meio de aprendizado fracamente supervisionado por múltiplas instâncias, a validação em biópsias de novos órgãos sob escassez de dados e o desenvolvimento de mapas de explicabilidade associados às medidas nodais das redes complexas.

REFERÊNCIAS

BA, J. L.; KIROS, J. R.; HINTON, G. E. Layer normalization. **arXiv preprint arXiv:1607.06450**, 2016.

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006.

BRUSSEE, S. et al. Graph neural networks in histopathology: Emerging trends and future directions. **Medical Image Analysis**, v. 101, p. 103444, 2025.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DAI, Z. et al. Coatnet: Marrying convolution and attention for all data sizes. **Advances in neural information processing systems**, v. 34, p. 3965–3977, 2021.

DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: **2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)**. [S.l.: s.n.], 2005. v. 1, p. 886–893.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.

FELDMAN, A. T.; WOLFE, D. Tissue processing and hematoxylin and eosin staining. In: **Histopathology: Methods and Protocols**. [S.l.]: Springer, 2014, (Methods in Molecular Biology, v. 1180). p. 31–43.

FISCHER, A. H. et al. Hematoxylin and eosin staining of tissue and cell sections. **Cold Spring Harbor Protocols**, v. 2008, n. 5, p. pdb.prot4986, 2008.

GELASCA, E. D. et al. Evaluation and benchmark for biological image segmentation. In: **2008 15th IEEE International Conference on Image Processing**. [S.l.: s.n.], 2008. p. 1816–1819.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

GREFF, K. et al. LSTM: A search space odyssey. **IEEE Transactions on Neural Networks and Learning Systems**, v. 28, n. 10, p. 2222–2232, 2017.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-3, n. 6, p. 610–621, nov. 1973.

HE, K. et al. Deep residual learning for image recognition. In: **Proceedings of the IEEE conference on computer vision and pattern recognition**. [S.l.: s.n.], 2016. p. 770–778.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HUANG, X. et al. Fusing hand-crafted and deep-learning features in a convolutional neural network model to identify prostate cancer in pathology images. **Frontiers in Oncology**, v. 12, p. 994950, 2022.

HUSSAINI, H. et al. A clinically grounded review of medical image classification: Quantitative insights into cnns, vision transformers, and hybrid cnn-vit models. **Journal of Imaging Informatics in Medicine**, 2026.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, J. Fusion feature-based hybrid methods for diagnosing oral squamous cell carcinoma in histopathological images. **Frontiers in Oncology**, v. 15, p. 1551876, 2025.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: **International Conference on Learning Representations**. [s.n.], 2019. Disponível em: https://openreview.net/forum?id=Bkg6RiCqY7.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 24, n. 7, p. 971–987, 2002.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PEREZ, L.; WANG, J. The effectiveness of data augmentation in image classification using deep learning. **arXiv preprint arXiv:1712.04621**, 2017.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

RUSSAKOVSKY, O. et al. ImageNet large scale visual recognition challenge. **International Journal of Computer Vision**, v. 115, n. 3, p. 211–252, 2015.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMIR, L. et al. Iicbu 2008: a proposed benchmark suite for biological image analysis. **Medical & biological engineering & computing**, v. 46, n. 9, p. 943–947, 2008.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on image data augmentation for deep learning. **Journal of big data**, Springer, v. 6, n. 1, p. 1–48, 2019.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SIRINUKUNWATTANA, K. et al. Gland segmentation in colon histology images: The glas challenge contest. **Medical Image Analysis**, v. 35, p. 489–502, 2017.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427–437, 2009.

SRINIDHI, C. L.; CIGA, O.; MARTEL, A. L. Deep neural network models for computational histopathology: A survey. **Medical Image Analysis**, Elsevier, v. 67, p. 101813, Jan 2021.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TALO, M. Automated classification of histopathology images using transfer learning. **Artificial Intelligence in Medicine**, v. 101, p. 101743, 2019.

TAN, M.; LE, Q. Efficientnet: Rethinking model scaling for convolutional neural networks. In: PMLR. **International conference on machine learning**. [S.l.], 2019. p. 6105–6114.

TOUVRON, H. et al. Training data-efficient image transformers & distillation through attention. In: PMLR. **International conference on machine learning**. [S.l.], 2021. p. 10347–10357.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.

APÊNDICE A – RESULTADOS COMPLETOS DA VALIDAÇÃO CRUZADA DA VIA TOPOLÓGICA

Os desempenhos obtidos pelos codificadores da via topológica durante o procedimento de validação cruzada estratificada em cinco partições estão reunidos neste apêndice. Para cada conjunto de dados e para cada modelo avaliado, são detalhados os hiperparâmetros ótimos selecionados (η, p, h, B), a média de épocas executadas até a ativação da parada antecipada, a acurácia média e a pontuação de F1 macro acompanhada do desvio padrão.

Tabela 13 – Desempenho detalhado por validação cruzada (5 partições) e configurações ótimas da via topológica.

Dataset	**Codificador**	η	p	h	B	**Épocas**	**Acurácia**	**F1 macro**
CR	BiGRU	$3 \cdot 10^{-3}$	0,5	256	64	27,2	0,985	0,985 ± 0,034
CR	BiLSTM	0,01	0,3	64	32	18,4	0,985	0,985 ± 0,034
CR	GRU	0,01	0,1	128	16	19,0	0,993	0,993 ± 0,017
CR	LSTM	0,03	0,3	128	32	33,4	0,992	0,992 ± 0,017
CR	MLP	$3 \cdot 10^{-3}$	0,3	512	64	18,2	0,993	0,993 ± 0,017
CR	SAC-LSTM	$3 \cdot 10^{-3}$	0,5	64	64	16,2	0,977	0,977 ± 0,034
LA	BiGRU	$3 \cdot 10^{-4}$	0,1	64	16	85,0	1,000	1,000 ± 0,000
LA	BiLSTM	$3 \cdot 10^{-4}$	0,1	512	16	35,4	1,000	1,000 ± 0,000
LA	GRU	$3 \cdot 10^{-4}$	0,1	64	16	77,2	1,000	1,000 ± 0,000
LA	LSTM	$3 \cdot 10^{-4}$	0,1	128	16	41,0	1,000	1,000 ± 0,000
LA	MLP	10^{-3}	0,1	64	16	30,0	1,000	1,000 ± 0,000
LA	SAC-LSTM	$3 \cdot 10^{-4}$	0,1	512	32	35,2	1,000	1,000 ± 0,000
LG	BiGRU	$3 \cdot 10^{-3}$	0,5	512	32	12,2	0,995	0,995 ± 0,011
LG	BiLSTM	$3 \cdot 10^{-3}$	0,1	256	16	7,0	0,995	0,995 ± 0,011
LG	GRU	$3 \cdot 10^{-3}$	0,1	256	32	15,4	0,995	0,995 ± 0,011
LG	LSTM	$3 \cdot 10^{-3}$	0,5	256	16	17,2	0,995	0,995 ± 0,011
LG	MLP	$3 \cdot 10^{-3}$	0,5	256	32	25,0	0,995	0,995 ± 0,011
LG	SAC-LSTM	10^{-3}	0,1	512	32	10,8	0,995	0,995 ± 0,011
NHL	BiGRU	$3 \cdot 10^{-3}$	0,3	256	32	14,6	0,967	0,966 ± 0,021
NHL	BiLSTM	10^{-3}	0,5	512	16	14,2	0,957	0,956 ± 0,019
NHL	GRU	10^{-3}	0,3	256	16	26,6	0,956	0,956 ± 0,049
NHL	LSTM	$3 \cdot 10^{-3}$	0,1	256	64	11,6	0,940	0,938 ± 0,043
NHL	MLP	$3 \cdot 10^{-4}$	0,1	512	16	24,0	0,973	0,973 ± 0,020
NHL	SAC-LSTM	10^{-3}	0,3	512	64	12,4	0,923	0,921 ± 0,046
UCSB	BiGRU	$3 \cdot 10^{-3}$	0,3	256	8	27,6	0,936	0,933 ± 0,061
UCSB	BiLSTM	$3 \cdot 10^{-3}$	0,3	512	4	6,6	0,873	0,870 ± 0,109
UCSB	GRU	10^{-3}	0,1	256	16	13,6	0,893	0,892 ± 0,107
UCSB	LSTM	$3 \cdot 10^{-3}$	0,3	256	4	10,8	0,896	0,893 ± 0,124
UCSB	MLP	0,01	0,5	256	4	16,6	0,873	0,871 ± 0,135
UCSB	SAC-LSTM	0,01	0,3	64	4	19,2	0,871	0,867 ± 0,090

APÊNDICE B – RESULTADOS COMPLETOS DA VALIDAÇÃO CRUZADA DA VIA VISUAL

Os desempenhos obtidos pelas arquiteturas de visão computacional na via visual durante a busca de hiperparâmetros sobre as cinco partições de validação cruzada estão reunidos neste apêndice. Para cada modelo e conjunto de dados, são reportadas as taxas de aprendizado do *backbone* (η_{bb}) e da cabeça linear (η_{hd}), a taxa de *dropout* (p), o tamanho do lote (B), a média de épocas até a convergência, a acurácia média e a pontuação de F1 macro.

Tabela 14 – Desempenho detalhado por validação cruzada (5 partições) e configurações ótimas da via visual.

Dataset	**Família**	**Modelo**	η_{bb}	η_{hd}	p	B	**Épocas**	**Acurácia**	**F1 macro**
CR	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	45,0	1,000	1,000 ± 0,000
CR	*Transformer*	DeiT-Tiny	10^{-5}	10^{-4}	0,1	16	44,8	1,000	1,000 ± 0,000
CR	Convolucional	EfficientNet-B0	10^{-5}	10^{-3}	0,5	32	12,8	1,000	1,000 ± 0,000
CR	Híbrida	MobileViT-S	10^{-4}	10^{-4}	0,1	16	38,2	1,000	1,000 ± 0,000
CR	Convolucional	ResNet-50	10^{-4}	10^{-4}	0,1	16	45,0	1,000	1,000 ± 0,000
CR	*Transformer*	ViT-Tiny	10^{-5}	10^{-4}	0,1	16	48,2	1,000	1,000 ± 0,000
LA	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	31,0	1,000	1,000 ± 0,000
LA	*Transformer*	DeiT-Tiny	10^{-5}	$3 \cdot 10^{-4}$	0,1	32	32,2	0,998	0,998 ± 0,005
LA	Convolucional	EfficientNet-B0	10^{-4}	10^{-4}	0,1	16	38,4	1,000	1,000 ± 0,000
LA	Híbrida	MobileViT-S	$3 \cdot 10^{-5}$	10^{-3}	0,5	16	29,6	1,000	1,000 ± 0,000
LA	Convolucional	ResNet-50	$3 \cdot 10^{-4}$	10^{-4}	0,3	16	32,6	1,000	1,000 ± 0,000
LA	*Transformer*	ViT-Tiny	10^{-4}	$3 \cdot 10^{-4}$	0,1	32	27,2	0,998	0,998 ± 0,005
LG	Híbrida	CoAtNet-0	10^{-5}	10^{-4}	0,1	16	26,2	1,000	1,000 ± 0,000
LG	*Transformer*	DeiT-Tiny	10^{-5}	10^{-4}	0,1	16	37,6	1,000	1,000 ± 0,000
LG	Convolucional	EfficientNet-B0	10^{-4}	10^{-4}	0,1	32	31,8	1,000	1,000 ± 0,000
LG	Híbrida	MobileViT-S	10^{-4}	10^{-4}	0,1	16	40,4	1,000	1,000 ± 0,000
LG	Convolucional	ResNet-50	10^{-4}	$3 \cdot 10^{-4}$	0,5	64	29,2	0,995	0,995 ± 0,010
LG	*Transformer*	ViT-Tiny	10^{-5}	10^{-4}	0,1	32	35,2	1,000	1,000 ± 0,000
NHL	Híbrida	CoAtNet-0	$3 \cdot 10^{-5}$	$3 \cdot 10^{-4}$	0,5	32	21,8	0,980	0,980 ± 0,026
NHL	*Transformer*	DeiT-Tiny	$3 \cdot 10^{-5}$	10^{-4}	0,5	32	24,6	0,940	0,938 ± 0,047
NHL	Convolucional	EfficientNet-B0	$3 \cdot 10^{-4}$	10^{-4}	0,1	32	13,4	0,967	0,967 ± 0,031
NHL	Híbrida	MobileViT-S	$3 \cdot 10^{-4}$	$3 \cdot 10^{-4}$	0,5	16	18,8	0,970	0,969 ± 0,044
NHL	Convolucional	ResNet-50	$3 \cdot 10^{-4}$	10^{-4}	0,5	32	30,2	0,950	0,950 ± 0,052
NHL	*Transformer*	ViT-Tiny	10^{-4}	10^{-4}	0,3	64	23,0	0,923	0,921 ± 0,043
UCSB	Híbrida	CoAtNet-0	$3 \cdot 10^{-5}$	10^{-3}	0,3	8	10,0	1,000	1,000 ± 0,000
UCSB	*Transformer*	DeiT-Tiny	$3 \cdot 10^{-5}$	10^{-4}	0,1	4	16,4	0,958	0,956 ± 0,060
UCSB	Convolucional	EfficientNet-B0	$3 \cdot 10^{-4}$	$3 \cdot 10^{-4}$	0,3	4	11,4	1,000	1,000 ± 0,000
UCSB	Híbrida	MobileViT-S	$3 \cdot 10^{-4}$	10^{-4}	0,5	8	17,2	1,000	1,000 ± 0,000
UCSB	Convolucional	ResNet-50	$3 \cdot 10^{-4}$	$3 \cdot 10^{-4}$	0,5	16	23,8	0,980	0,980 ± 0,045
UCSB	*Transformer*	ViT-Tiny	10^{-4}	10^{-3}	0,3	8	9,6	0,978	0,977 ± 0,052

APÊNDICE C – DESEMPENHO POR SEMENTE NA PARTIÇÃO DE TESTE INDEPENDENTE

O desempenho alcançado em cada uma das cinco sementes pré-fixadas (42 a 46) avaliadas sobre a partição de teste independente (20% dos dados) está registrado neste apêndice. Os valores individuais de F1 macro, acurácia e área sob a curva ROC (AUC-ROC) são discriminados para a via topológica isolada, a via visual isolada e a rede unificada de dupla via em todos os cinco conjuntos de dados analisados.

Tabela 15 – Resultados detalhados por semente e médias consolidadas no teste independente (20% dos dados).

Dataset	Semente	Via Topológica Isolada			Via Visual Isolada			Rede de Dupla Via		
		F1	Acc	AUC	F1	Acc	AUC	F1	Acc	AUC
CR	42	0,908	0,909	0,937	1,000	1,000	1,000	1,000	1,000	1,000
CR	43	0,908	0,909	0,920	1,000	1,000	1,000	1,000	1,000	1,000
CR	44	0,938	0,939	0,943	1,000	1,000	1,000	1,000	1,000	1,000
CR	45	0,938	0,939	0,957	1,000	1,000	1,000	1,000	1,000	1,000
CR	46	0,938	0,939	0,931	1,000	1,000	1,000	1,000	1,000	1,000
	Média	**0,926 ± 0,017**	**0,927 ± 0,017**	**0,938 ± 0,014**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**
LA	42	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LA	43	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LA	44	1,000	1,000	1,000	1,000	1,000	1,000	0,991	0,991	1,000
LA	45	1,000	1,000	1,000	0,982	0,981	1,000	1,000	1,000	1,000
LA	46	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
	Média	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**0,996 ± 0,008**	**0,996 ± 0,008**	**1,000 ± 0,000**	**0,998 ± 0,004**	**0,998 ± 0,004**	**1,000 ± 0,000**
LG	42	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LG	43	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LG	44	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LG	45	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000
LG	46	0,981	0,981	1,000	1,000	1,000	1,000	1,000	1,000	1,000
	Média	**0,996 ± 0,009**	**0,996 ± 0,008**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**
NHL	42	0,867	0,867	0,981	0,915	0,920	0,982	0,918	0,920	0,991
NHL	43	0,895	0,893	0,983	0,907	0,907	0,999	0,920	0,920	0,995
NHL	44	0,870	0,867	0,980	0,907	0,907	0,995	0,973	0,973	0,999
NHL	45	0,869	0,867	0,979	0,987	0,987	0,997	0,959	0,960	0,990
NHL	46	0,826	0,827	0,968	0,896	0,893	1,000	0,920	0,920	0,987
	Média	**0,865 ± 0,025**	**0,864 ± 0,024**	**0,978 ± 0,006**	**0,922 ± 0,037**	**0,923 ± 0,037**	**0,995 ± 0,007**	**0,938 ± 0,026**	**0,939 ± 0,026**	**0,992 ± 0,005**
UCSB	42	0,916	0,917	0,971	1,000	1,000	1,000	0,911	0,917	1,000
UCSB	43	0,916	0,917	0,971	1,000	1,000	1,000	1,000	1,000	1,000
UCSB	44	0,916	0,917	1,000	1,000	1,000	1,000	1,000	1,000	1,000
UCSB	45	0,916	0,917	1,000	1,000	1,000	1,000	0,911	0,917	1,000
UCSB	46	0,829	0,833	0,971	1,000	1,000	1,000	1,000	1,000	1,000
	Média	**0,899 ± 0,039**	**0,900 ± 0,037**	**0,983 ± 0,016**	**1,000 ± 0,000**	**1,000 ± 0,000**	**1,000 ± 0,000**	**0,964 ± 0,049**	**0,967 ± 0,046**	**1,000 ± 0,000**