UNIVERSIDADE ESTADUAL PAULISTA - UNESP

Instituto de Biociências, Letras e Ciências Exatas- campus de São José do Rio Preto - SP

GABRIEL MARTINS BRUM

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

São José do Rio Preto - SP

2026

Gabriel Martins Brum

Classificação de Imagens Médicas via Fusão de Deep Learning e Redes Complexas utilizando Redes Neurais Recorrentes:

Trabalho de Conclusão de Curso, apresentada à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bachareladoem Ciências da Computação.

Área de Concentração: Ciência da Computação

Orientador: Prof. Dr. Leandro Alves Neves

Coorientador:

São José do Rio Preto - SP

2026

GABRIEL MARTINS BRUM

CLASSIFICAÇÃO DE IMAGENS MÉDICAS VIA FUSÃO DE DEEP LEARNING E REDES COMPLEXAS UTILIZANDO REDES NEURAIS RECORRENTES

Trabalho de Conclusão de Curso apresentado(a) à Universidade Estadual Paulista (UNESP), Instituto de Biociências, Letras e Ciências Exatas, São José do Rio Preto - SP, para obtenção do título de Bacharelado em Ciências da Computação.

Área de Concentração: Ciência da Computação

Data de defesa: 03/12/2026

BANCA EXAMINADORA

_____

Prof. Dr. Leandro Alves Neves
UNESP - IBILCE

_____

Prof. Dr. Wallace Correa de Oliveira Casaca
UNESP - IBILCE

_____

Prof. Dr. Guilherme Freire Roberto
UNESP - IBILCE

Aos meus pais e namorada, pelo apoio e incentivo durante toda a graduação.

AGRADECIMENTOS

Gostaria de agradecer ao Prof. Dr. Leandro Alves Neves pela orientação...

"Presentemente, eu posso me considerar um sujeito de sorte
Porque apesar de muito moço, me sinto são, e salvo, e forte"
(Belchior)

RESUMO

O avanço das arquiteturas de aprendizado profundo revolucionou a análise computacional...

Palavras-Chave: Redes Complexas; Redes Neurais Recorrentes; Classificação de Imagens Médicas; Fusão Tardia; Deep Learning.

ABSTRACT

The advancement of deep learning architectures has revolutionized computational analysis...

Keywords: Complex Networks; Recurrent Neural Networks; Medical Image Classification; Late Fusion; Deep Learning.

LISTA DE ILUSTRAÇÕES

Figura 1 Topologias de conectividade em redes espaço-espectrais: rede *full* à esquerda, rede *within* ao centro e rede *between* à direita, extraídas de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). 21

Figura 2 Fluxo conceitual de modelagem de imagens em redes espaço-espectrais, cálculo de medidas nodais e composição de descritores por sumarização estatística, adaptado de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). 21

Figura 3 Pipeline geral da abordagem proposta: os *datasets* histopatológicos alimentam duas vias paralelas, uma topológica (SSN seguida de RNN) e uma visual (modelos CNN, ViT ou híbridos). Os *embeddings* das duas vias são concatenados e classificados por uma MLP, da qual são extraídas as métricas. 27

Figura 4 Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos. 29

Figura 5 Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos. 29

Figura 6 Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d). 29

Figura 7 Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas. 30

Figura 8 Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL. 30

Figura 9 Separação dos dados e protocolo experimental de avaliação. Um conjunto de teste final (*holdout*) de 20% é reservado antes de qualquer treinamento. Os 80% restantes (desenvolvimento) são avaliados por validação cruzada estratificada em cinco partições ($k = 5$), na qual foram conduzidas as ablações das vias isoladas e o treinamento direto da rede de dupla via com os hiperparâmetros fixados. O modelo final é treinado sobre todo o desenvolvimento e avaliado no conjunto de teste final sob múltiplas sementes para confirmação da capacidade de generalização. 35

Figura 10 Ablação das vias isoladas. (a) Via topológica: a sequência de características da SSN é processada por seis codificadores (cinco recorrentes e uma MLP como *baseline*), cada um testado de forma independente. (b) Via visual: as imagens, após aumento de dados, são processadas por seis modelos (convolucionais, *transformers* e híbridos), também testados individualmente. Cada via possui sua própria cabeça MLP, da qual são extraídas as métricas. 38

Figura 11 Protocolo de ablação para o treinamento dos modelos: partição estratificada em 80% para desenvolvimento e 20% para teste final (reservado), validação cruzada com cinco partições sobre os 80%, avaliação de X combinações de hiperparâmetros e seleção da combinação de maior desempenho médio. 40

LISTA DE TABELAS

Tabela 1 – Resumo dos *datasets* utilizados. 28
Tabela 2 – Espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica. 41
Tabela 3 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados. 41
Tabela 4 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo nos cinco conjuntos de dados. 42
Tabela 5 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via visual. 44
Tabela 6 – F1 macro (média ± desvio padrão entre as 5 partições de validação) da via visual isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados. 44
Tabela 7 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo visual nos cinco conjuntos de dados. 45
Tabela 8 – Comparação de desempenho (média ± desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% das amostras) entre as vias isoladas e a arquitetura unificada de dupla via. 47

LISTA DE ABREVIATURAS E SIGLAS

CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
ViT	*Vision Transformer*
CNN-ViT	*Convolutional Neural Network with Vision Transformer*
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
RaNN	*Randomized Neural Network* (Rede Neural Aleatorizada)
RGB	*Red, Green, Blue*
CN	*Complex Network* (Redes Complexas)
DL	*Deep Learning* (Aprendizado Profundo)
BiLSTM	*Bidirectional Long Short-Term Memory* (Memória de Curto e Longo Prazo Bidirecional)
GLCM	*Gray-Level Co-occurrence Matrix* (Matriz de Coocorrência de Níveis de Cinza)
HOG	*Histogram of Oriented Gradients* (Histograma de Gradientes Orientados)
LBP	*Local Binary Patterns* (Padrões Binários Locais)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
LSTM	*Long Short-Term Memory* (Memória de Curto e Longo Prazo)
GRU	*Gated Recurrent Unit* (Unidade Recorrente com Portas)
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve* (Área sob a Curva ROC)
H&E	*Hematoxylin and Eosin* (Hematoxilina e Eosina)
LN	*Layer Normalization* (Normalização de Camada)
SIFT	*Scale-Invariant Feature Transform* (Transformada de Características Invariante à Escala)
SSN	*Spatio-Spectral Network* (Rede Espaço-Espectral)
ReLU	*Rectified Linear Unit* (Unidade Linear Retificada)

SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
RBF	*Radial Basis Function* (Função de Base Radial)
kNN	*k-Nearest Neighbors* (k Vizinhos Mais Próximos)
CNN1D	*One-Dimensional Convolutional Neural Network* (Rede Neural Convolucional Unidimensional)
CPU	*Central Processing Unit* (Unidade Central de Processamento)
GPU	*Graphics Processing Unit* (Unidade de Processamento Gráfico)
UCSB	*University of California, Santa Barbara*
CR	*Colorectal* (Colorretal)
LA	*Liver Aging* (Envelhecimento Hepático)
LG	*Liver Gender* (Sexo Hepático)
NHL	*Non-Hodgkin Lymphoma* (Linfoma Não Hodgkin)
CLL	*Chronic Lymphocytic Leukemia* (Leucemia Linfocítica Crônica)
FL	*Follicular Lymphoma* (Linfoma Folicular)
MCL	*Mantle Cell Lymphoma* (Linfoma de Células do Manto)
UCP	Unidade Central de Processamento

LISTA DE SÍMBOLOS

r	Raio de conexão do grafo
k	Número de partições na validação cruzada (k-Fold)

SUMÁRIO

1 INTRODUÇÃO 15
1.1 Motivação e Justificativa 16
1.2 Objetivos 17

2 FUNDAMENTAÇÃO TEÓRICA 18
2.1 Imagens Histopatológicas e Extração de Características 18
2.2 Redes Complexas Espaço-Espectrais 19
2.3 Redes Neurais Recorrentes e Codificação de Sequências 22
2.4 Modelos Profundos de Visão Computacional 24
2.5 Fusão em Nível de Características e Classificação 25

3 MATERIAIS E MÉTODOS 27
3.1 *Datasets* 28
3.2 *Two-Stream Network* 30
3.2.1 Via topológica 31
3.2.1.1 Codificador BiLSTM 32
3.2.1.2 Codificador MLP 32
3.2.2 Via visual 32
3.2.3 Fusão por concatenação de *embeddings* 33
3.2.4 Classificador MLP 33
3.3 Protocolo de treinamento 34
3.3.1 Validação 35
3.3.2 Métricas 36
3.3.3 Limitações do protocolo 36
3.4 Comparações com os métodos de referência 37
3.5 Configuração de ambiente 37

4 ABLAÇÃO 38
4.1 Ablação da Via Topológica 38
4.2 Ablação da Via Visual 43

5 RESULTADOS E DISCUSSÃO 46
5.1 Comparação entre as Vias Isoladas e a Rede de Dupla Via 46

6 CONCLUSÃO 48

REFERÊNCIAS 49

1 INTRODUÇÃO

A histopatologia atua no diagnóstico precoce de alterações teciduais associadas a neoplasias e a enfermidades inflamatórias e infecciosas. O procedimento analítico convencional é conduzido por médicos patologistas por meio de microscopia óptica, após a extração da amostra biológica, fixação em lâmina e aplicação de reagentes químicos de contraste, tradicionalmente a coloração H&E (Srinidhi; Ciga; Martel, 2021). Esse fluxo de trabalho demanda tempo extensivo de profissionais especializados e está sujeito a variações intraobservador e interobservador decorrentes de diferenças nos protocolos de preparação e digitalização entre laboratórios (Kumar; Mishra, 2026). A adoção de sistemas de patologia computacional baseados em modelos de aprendizado profundo foi proposta como uma alternativa para auxiliar a análise médica e padronizar o processo de triagem diagnóstica (Litjens et al., 2017; Bejnordi et al., 2017).

O desenvolvimento desses modelos enfrenta o obstáculo da disponibilidade restrita de imagens histopatológicas devidamente anotadas por especialistas (Kumar; Mishra, 2026). As restrições éticas e de privacidade, a complexidade da rotulação e a heterogeneidade clínica dificultam a formação de bases de dados com volumes comparáveis aos conjuntos clássicos de visão computacional. Para viabilizar o treinamento e atenuar a ocorrência de sobreajuste em cenários com poucas amostras, estratégias como a transferência de aprendizado e o aumento de dados são rotineiramente empregadas (Hussaini et al., 2026).

A caracterização quantitativa de lâminas histopatológicas foi tradicionalmente fundamentada na extração de atributos representativos do tecido, tais como a densidade e a morfologia celular, os arranjos de núcleos e as variações de textura da matriz extracelular (Kumar; Mishra, 2026). Descritores matemáticos de textura, como GLCM, LBP e HOG, bem como formulações baseadas em grafos e redes complexas (CN), foram desenvolvidos para caracterizar imagens de formas diferentes, sendo possível explorar relações e padrões intrinsícos (Backes; Casanova; Bruno, 2013; Scabini; Ribas; Bruno, 2020). Além da obtenção de descritores tabulares estáticos, a análise morfométrica pode ser formulada como uma sequência de atributos ordenados por escalas de observação. Nesse contexto, arquiteturas RNN são empregadas na histopatologia e na análise de imagens biomédicas como extratoras de representações sequenciais, sendo utilizadas no processamento de padrões dependentes de ordem e de resolução para a detecção de anormalidades celulares e a diferenciação de tecidos tumorais (Mathiyalagi; Ravi, 2026; Priyadarshini, 2026; Shalini; Rathnamala, 2026).

Além da extração de *features* por meio das RNNs, modelos de aprendizado profundo, como CNN e ViT, processam imagens para, por exemplo, classificar tumores como benignoss e malignos. As CNN são redes que aprendem filtros convolucionais locais que discriminam detalhes citológicos, enquanto as arquiteturas ViT introduziram mecanismos de autoatenção capazes de estabelecer relações contextuais de longo alcance entre regiões distintas da imagem (Litjens et al., 2017; Shamshad et al., 2023; Dosovitskiy et al., 2020). As arquiteturas híbridas

CNN-ViT foram desenvolvidas com o propósito de integrar a sensibilidade local das convoluções à visão de longo alcance dos transformadores, alcançando elevado desempenho preditivo na classificação de tecidos patológicos (Mehta; Rastegari, 2022; Oliveira et al., 2025; Kushwah; Punn; Bhattacharya, 2026). Diante desse cenário, a literatura tem evidenciado que a extração explícita de características visuais e de textura pode ser combinada diretamente com essas redes neurais profundas, unindo as propriedades matemáticas dos extratores teciduais à alta capacidade representacional dos modelos profundos. Abordagens híbridas comprovaram a viabilidade dessa união na histopatologia, a exemplo de métodos que integraram descritores de textura a redes convolucionais para a identificação de câncer de próstata (Huang et al., 2022) e a modelos baseados em transformadores para o diagnóstico de carcinoma espinocelular oral (Li, 2025).

1.1 MOTIVAÇÃO E JUSTIFICATIVA

Apesar dos benefícios demonstrados pela integração de descritores matemáticos a redes neurais profundas, as abordagens clássicas de textura atuam sobre vizinhanças locais estáticas com raios e resoluções pré-fixados. Essas técnicas tradicionais não descrevem a transição gradual e contínua das relações teciduais que ocorre quando o raio de observação se expande dos elementos microscópicos até as formações teciduais de larga escala.

A modelagem de imagens baseada em CN contorna essa limitação ao mapear os pixels como vértices conectados conforme raios de distância euclidiana crescentes, gerando uma sequência de métricas topológicas que reflete a evolução relacional do tecido sob múltiplos níveis de detalhe (Scabini; Ribas; Bruno, 2020; Ribas et al., 2024). Pelo fato de as redes formadas em raios menores serem integradas às redes de raios maiores, as propriedades topológicas resultantes possuem dependência estrita de ordem entre as escalas. Nesse arranjo, as redes RNN constituem o método apropriado para processar essa sequência e condensá-la em um vetor de características contínuo (Hochreiter; Schmidhuber, 1997; Schuster; Paliwal, 1997). Contudo, a literatura histopatológica ainda carece de arquiteturas de dupla via (*Two-Stream Network*) que unifiquem representações visuais densas de modelos profundos com representações topológicas sequenciais aprendidas por RNN a partir de CN multiescala.

A exploração dessa integração responde diretamente à restrição de amostras anotadas enfrentada na classificação histopatológica. Modelos de aprendizado profundo treinados exclusivamente a partir de pixels tendem ao sobreajuste aos artefatos de preparação e corte quando as bases dispõem de poucas imagens. A via topológica provê descrições determinísticas da conectividade tecidual que não dependem do ajuste de filtros sobre conjuntos restritos, enquanto a via visual fornece padrões aprendidos a partir do pré-treinamento genérico. A formulação de uma arquitetura de dupla via com fusão em nível de características permite que as duas vias processem a imagem de forma paralela e independente (Simonyan; Zisserman, 2014; Yousaf; Nawaz; Habib, 2024; Wang et al., 2023). A equalização dimensional por projeção linear e a normalização de camadas (LN) equilibram as escalas dos dois vetores antes da concatenação (Baltrušaitis; Ahuja;

Morency, 2019; Huang et al., 2022), direcionando o classificador para atributos informativos e atenuando o sobreajuste nos dados de treino.

A partir desse contexto, a presente pesquisa é guiada pela seguinte questão investigativa:

> **Questão de Pesquisa:** A integração da dinâmica topológica multiescala, modelada por CN e codificada por RNN, com representações visuais profundas extraídas por modelos de visão computacional em uma arquitetura de dupla via (*Two-Stream Network*), proporciona ganho preditivo na classificação de imagens histopatológicas quando comparada ao desempenho obtido por cada via isoladamente sob restrição de dados?

Para responder a essa questão, foram formuladas duas hipóteses de trabalho:

1. A evolução das medidas topológicas de CN ao longo de múltiplos raios de conexão capta propriedades de ordenação tecidual que não são descritas explicitamente por codificadores visuais operando em grades regulares de pixels, adicionando sinal discriminativo independente.

2. A fusão em nível de características por concatenação de representações equalizadas por projeção linear e normalização LN permite que a arquitetura de dupla via supere o desempenho preditivo de cada uma das vias quando executadas de forma isolada, contendo o sobreajuste em conjuntos com volume reduzido de dados.

1.2 OBJETIVOS

O objetivo geral deste trabalho é propor e avaliar uma arquitetura de aprendizado profundo de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas, composta por uma via topológica e uma via visual, avaliando o ganho preditivo proporcionado pela fusão das duas representações em relação ao desempenho obtido por cada via de forma isolada.

Para cumprir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

- Modelar as imagens histopatológicas coloridas como redes complexas espaço-espectrais direcionadas e ponderadas em raios de conexão crescentes, gerando sequências de métricas topológicas multiescala.

- Implementar e avaliar diferentes codificadores recorrentes na via topológica isolada (LSTM, BiLSTM, GRU, BiGRU, Deep LSTM e SAC-LSTM) sob validação cruzada aninhada, determinando as configurações ótimas de hiperparâmetros.

- Implementar e avaliar diferentes famílias de modelos de visão computacional na via visual isolada (convolucionais, transformadores visuais e modelos híbridos) sob validação cruzada aninhada, determinando as configurações ótimas de hiperparâmetros.

- Desenvolver o procedimento de fusão por concatenação com equalização por projeção linear e normalização por camadas, unificando as representações em um classificador treinado de ponta a ponta.
- Avaliar o desempenho preditivo da arquitetura unificada de dupla via frente a cada via isolada em cinco conjuntos de dados histopatológicos (UCSB, CR, LA, LG e NHL), utilizando uma partição de teste final mantida estritamente isolada durante todo o desenvolvimento.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, os conceitos teóricos que sustentam o desenvolvimento da pesquisa são apresentados. O processo de aquisição de imagens histopatológicas e os métodos de extração de características são descritos na Seção 2.1. A modelagem de imagens por meio de redes complexas espaço-espectrais é detalhada na Seção 2.2. A codificação sequencial das propriedades topológicas por redes neurais recorrentes é abordada na Seção 2.3. Os modelos profundos de visão computacional empregados na via visual são discutidos na Seção 2.4. A integração entre as representações por meio da fusão em nível de características é examinada na Seção 2.5.

2.1 IMAGENS HISTOPATOLÓGICAS E EXTRAÇÃO DE CARACTERÍSTICAS

A análise histopatológica tem como ponto de partida a coleta de fragmentos teciduais obtidos por meio de biópsias ou ressecções cirúrgicas. Essas amostras biológicas são submetidas à fixação química em formalina para a preservação da morfologia celular, seguida por processos de desidratação e inclusão em blocos de parafina sólida. Cortes delgados com espessura entre 3 e 5 micrômetros são efetuados com o uso de micrótomos e fixados em lâminas de vidro para análise microscópica. Em seu estado natural, as estruturas biológicas são translúcidas e apresentam contraste de absorção óptica reduzido sob iluminação de campo claro, impedindo a distinção entre os limites celulares e os compartimentos teciduais.

Para conferir contraste visual diferenciado aos componentes celulares, as secções são submetidas à coloração histoquímica por hematoxilina e eosina (H&E). A hematoxilina atua como um corante catiônico básico que possui afinidade por compostos ácidos e aniônicos, denominados basófilos. No tecido celular, sua principal interação ocorre com os grupos fosfato dos ácidos nucleicos no interior do núcleo celular, abrangendo o ácido desoxirribonucleico e o ácido ribonucleico, conferindo aos núcleos coloração azul-arroxeada. A eosina atua como um corante aniônico ácido com afinidade por estruturas básicas e catiônicas, denominadas acidófilas. Sua ligação ocorre predominantemente com radicais proteicos no citoplasma celular e fibras de colágeno da matriz extracelular, tingindo essas regiões em tonalidades rosadas e avermelhadas. A distinção cromática gerada pela combinação H&E evidencia as fronteiras celulares, o tamanho e o arranjo dos núcleos e a integridade da arquitetura de glândulas e estromas teciduais.

A digitalização das lâminas preparadas é executada por microscópios ópticos convencionais ou escâneres digitais de lâminas virtuais, convertendo o tecido corado em matrizes digitais de pixels. Nos conjuntos de dados de referência utilizados nesta pesquisa, diferentes protocolos de aquisição foram empregados:

- no conjunto UCSB (Gelasca et al., 2008), secções de biópsias de tecido mamário coradas por H&E foram digitalizadas por meio de uma câmera óptica acoplada a microscópio sob magnificação de 40 vezes, originando imagens na resolução de 896×768 pixels,

- no conjunto CR (Sirinukunwattana et al., 2017), amostras histológicas de adenocarcinoma colorretal coradas rotineiramente por H&E, provenientes de 16 blocos cirúrgicos, foram digitalizadas por um escâner de lâminas virtuais Zeiss MIRAX MIDI com resolução de $0{,}465\ \mu$m por pixel, correspondente à magnificação óptica de 20 vezes,

- nos conjuntos de envelhecimento hepático (LA), diferenciação de sexo em fígados (LG) e linfoma não Hodgkin (NHL), provenientes do referencial IICBU 2008 (Shamir et al., 2008), secções teciduais coradas por H&E foram digitalizadas em microscopia óptica com iluminação de campo claro e objetivas de 40 vezes. No conjunto NHL (Shamir et al., 2008), as lâminas histológicas foram preparadas por histologistas de múltiplos hospitais e centros de diagnóstico, reunindo variações técnicas provenientes de diferentes instituições.

As imagens histopatológicas digitais reúnem particularidades que tornam a classificação automatizada desafiadora. Variações na concentração dos reagentes químicos, nos tempos de imersão durante a coloração H&E, na espessura do corte tecidual e nas respostas espectrais dos escâneres introduzem desvios de tonalidade e de saturação entre lâminas de diferentes laboratórios. A presença de artefatos físicos de preparação, como dobras no tecido, bolhas de ar sob a lamínula e partículas residuais de corante, interfere na homogeneidade dos dados. A complexidade do tecido neoplásico impõe que a distinção entre padrões benignos e malignos resida frequentemente em alterações sutis no pleomorfismo nuclear, na aglomeração celular e na desorganização de lúmens glandulares, em meio a acentuada variabilidade visual intra-classe. A dependência de anotações manuais fornecidas por médicos patologistas especializados delimita a quantidade de imagens disponíveis em repositórios públicos, elevando a possibilidade de sobreajuste durante o treinamento de modelos de alta capacidade paramétrica.

A extração de características atua diretamente na atenuação dessas limitações, transformando os valores brutos de intensidade dos pixels em representações numéricas compactas e informativas (Dehbozorgi; Ryabchykov; Bocklitz, 2025; Ramos-Soto et al., 2025). A modelagem determinística de texturas por meio de medidas topológicas em redes complexas sumariza as interações de vizinhança entre pixels, produzindo descritores condensados que capturam a organização das células com menor sensibilidade a variações globais de iluminação (Scabini; Ribas; Bruno, 2020). De forma coordenada, modelos profundos de visão computacional aprendem representações hierárquicas a partir dos próprios dados da imagem, atenuando a restrição de bases com poucas amostras por meio do ajuste fino de pesos previamente aprendidos em grandes acervos de imagens naturais (Hussaini et al., 2026; Bejnordi et al., 2017).

2.2 REDES COMPLEXAS ESPAÇO-ESPECTRAIS

A teoria de redes complexas fornece uma modelagem matemática para representar sistemas constituídos por elementos discretos conectados por relações não triviais (Boccaletti et al., 2006). No processamento de imagens coloridas, os pixels são modelados como vértices de um grafo e

as conexões entre eles são determinadas a partir de critérios de distância euclidiana e diferenças de intensidade luminosa, permitindo que medidas topológicas caracterizem a textura do tecido biológico (Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024).

Na formulação da rede espaço-espectral (SSN) proposta por Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020), uma imagem colorida é representada por uma rede direcionada e ponderada $G = (V, E)$. Para cada pixel nas coordenadas (x_i, y_i) em um canal de cor c, é estabelecido um vértice $v_i^{(c)} \in V$. As arestas direcionadas são criadas entre dois vértices $v_i^{(c)}$ e $v_j^{(c_w)}$ quando a distância euclidiana quadrática satisfaz o limite imposto por um raio de conexão r:

$$\rho_{ij}^2 = (x_i - x_j)^2 + (y_i - y_j)^2, \qquad 0 \leq \rho_{ij}^2 \leq r^2. \tag{1}$$

A condição $\rho_{ij}^2 = 0$ interliga vértices de diferentes canais de cor correspondentes às mesmas coordenadas de pixel ($c \neq c_w$), sendo excluídos laços de um vértice consigo mesmo (Ribas et al., 2024). O sentido da aresta direcionada é governado pela diferença de intensidade entre os pixels conectados, partindo do ponto de menor intensidade em direção ao de maior intensidade (Scabini; Ribas; Bruno, 2020). Considerando $I(x_i, y_i, c)$ a intensidade do pixel no respectivo canal, uma aresta é classificada como de saída a partir de v_i e de entrada em v_j quando $I(x_i, y_i, c) < I(x_j, y_j, c_w)$. Conexões entre intensidades iguais são computadas em ambos os sentidos.

O peso atribuído a cada conexão pondera conjuntamente a diferença de intensidade $w_{ij} = |I(x_i, y_i, c) - I(x_j, y_j, c_w)|$ e a distância euclidiana ρ_{ij} entre os vértices (Ribas et al., 2024):

$$\omega_{ij}^{(r)} = \frac{(w_{ij} + 1)\,(\rho_{ij} + 1) - 1}{(L + 1)(r + 1) - 1}, \tag{2}$$

em que $L = 255$ representa a intensidade máxima em imagens codificadas em 8 bits por canal, delimitando o peso normalizado no intervalo $[0, 1]$.

As três configurações de conectividade entre as camadas de cor admitidas pelo modelo de rede espaço-espectral são apresentadas na Figura 1, extraída de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). Na porção esquerda da figura é ilustrada a rede *full* ($\mathcal{N}$), na qual são computadas arestas tanto entre vértices de uma mesma camada de cor quanto entre camadas distintas. Ao centro, a rede *within* ($\mathcal{N}_w$) restringe as arestas exclusivamente aos vértices pertencentes ao mesmo canal de cor ($c = c_w$). Na porção direita, a rede *between* ($\mathcal{N}_b$) contempla unicamente conexões que interligam canais de cores diferentes ($c \neq c_w$). Neste trabalho, é adotada exclusivamente a rede *full* ($\mathcal{N}$), integrando simultaneamente os padrões de textura monocromáticos de cada canal e as interações cromáticas entre as diferentes bandas de cor da imagem histopatológica.

O fluxo geral de modelagem de imagens coloridas em redes espaço-espectrais e de composição de vetores descritores por sumarização estatística é exibido na Figura 2, retirada de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020). Nesse esquema, a imagem de entrada é modelada nas três variantes de rede ($\mathcal{N}$, $\mathcal{N}_w$ e $\mathcal{N}_b$), sobre as quais são calculadas distribuições de medidas

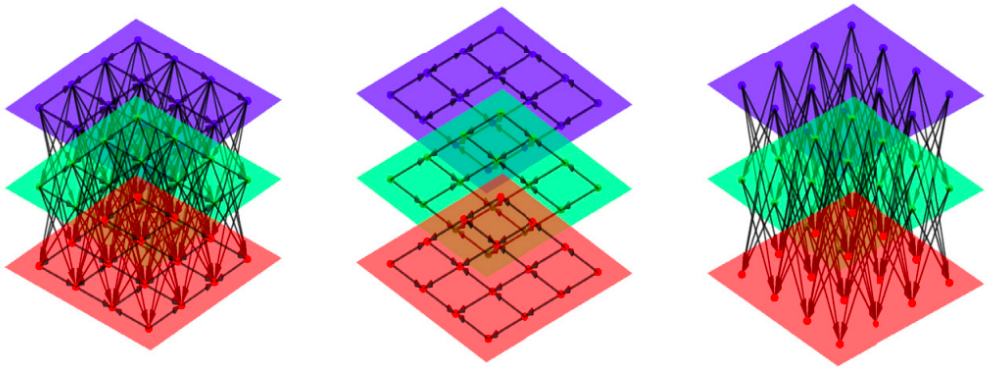


Figura 1 – Topologias de conectividade em redes espaço-espectrais: rede *full* à esquerda, rede *within* ao centro e rede *between* à direita, extraídas de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020).

nodais em diferentes raios de alcance r_n, que são consolidadas por sumarização estatística para formar um descritor de textura global. Neste trabalho, o processamento adota unicamente a rede identificada por $\mathcal{N}$ na referida figura, correspondente à rede *full*. As propriedades nodais extraídas sobre essa rede em cada raio de conexão são sumarizadas pela média e pelo desvio padrão sobre os vértices, gerando uma sequência ordenada de atributos topológicos que descreve a organização tecidual em múltiplas escalas.

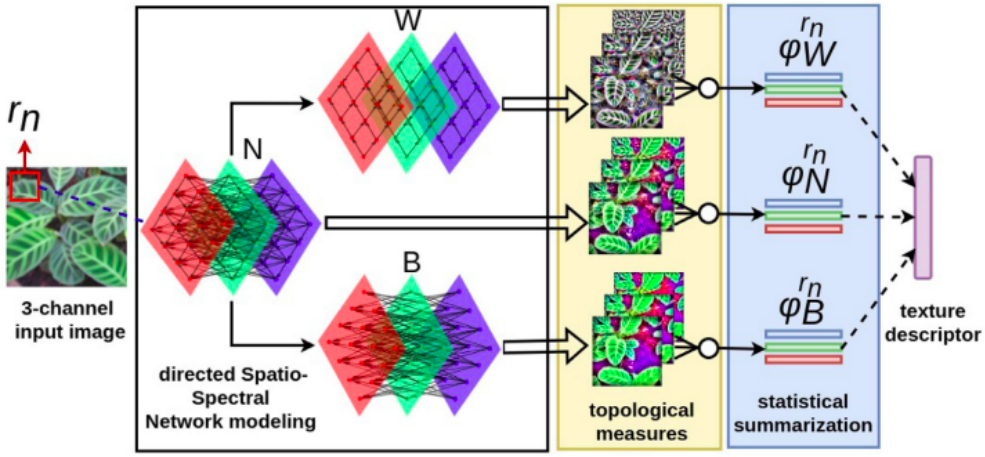


Figura 2 – Fluxo conceitual de modelagem de imagens em redes espaço-espectrais, cálculo de medidas nodais e composição de descritores por sumarização estatística, adaptado de Scabini, Ribas e Bruno (Scabini; Ribas; Bruno, 2020).

A partir da topologia construída, medidas nodais de grau e força são calculadas para cada raio de conexão $r \in \{1, 2, \ldots, r_{\max}\}$. O grau de saída acumulado quantifica a conectividade externa na vizinhança:

$$d_{\text{out}}(v_i, r) = \sum_{k=1}^{r} n_{\text{out}}(v_i, k), \tag{3}$$

em que $n_{\text{out}}(v_i, k)$ representa a quantidade de arestas de saída formadas com raio discreto k. De maneira análoga, a força de saída acumulada integra os pesos normalizados das arestas

conectadas:

$$\text{force}_{\text{out}}(v_i, r) = \sum_{v_j \in \mathcal{N}_{\text{out}}^{(r)}(v_i)} \omega_{ij}^{(r)}, \tag{4}$$

sendo a força de entrada calculada sobre as arestas que incidem em v_i:

$$\text{force}_{\text{in}}(v_i, r) = \sum_{v_j \in \mathcal{N}_{\text{in}}^{(r)}(v_i)} \omega_{ji}^{(r)}. \tag{5}$$

A variação do raio r do valor inicial 1 até $r_{\max} = 15$ acumula interações em vizinhanças progressivamente maiores, produzindo uma sequência ordenada de vetores descritores que registram a transição entre a microtextura celular e a organização tecidual ampla (Scabini; Ribas; Bruno, 2020; Zerati et al., 2026).

2.3 REDES NEURAIS RECORRENTES E CODIFICAÇÃO DE SEQUÊNCIAS

As redes neurais recorrentes são formuladas para o processamento de dados organizados sequencialmente, preservando um estado interno que propaga informações através dos passos temporais (LeCun; Bengio; Hinton, 2015). Em modelos recorrentes simples (Elman, 1990), os estados ocultos são atualizados iterativamente com base na entrada atual e no estado anterior por meio de uma transformação não linear. O treinamento dessas arquiteturas em sequências extensas com o algoritmo de retropropagação através do tempo é afetado pelo desvanecimento ou pela explosão dos gradientes numéricos (Bengio; Simard; Frasconi, 1994).

A arquitetura LSTM soluciona essa restrição por meio de uma célula de memória c_t controlada por portas parametrizadas com funções de ativação sigmoide (Hochreiter; Schmidhuber, 1997). Na formulação com porta de esquecimento (Gers; Schmidhuber; Cummins, 2000), as operações executadas a cada passo t são definidas por:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)\,, \tag{6}$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)\,, \tag{7}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)\,, \tag{8}$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)\,, \tag{9}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{10}$$

$$h_t = o_t \odot \tanh(c_t), \tag{11}$$

em que f_t, i_t e o_t denotam as portas de esquecimento, entrada e saída, $\tilde{c}_t$ expressa o estado candidato de célula e o operador $\odot$ representa a multiplicação elemento a elemento.

A unidade GRU simplifica a dinâmica recorrente ao unificar as portas de controle e prescindir de um estado de célula isolado, mantendo unicamente o estado oculto h_t (Cho et al., 2014). A

dinâmica em cada passo temporal é governada por duas portas:

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)\,, \tag{12}$$

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)\,, \tag{13}$$

em que r_t denota a porta de reinicialização e z_t representa a porta de atualização. O estado candidato $\tilde{h}_t$ e o novo estado oculto h_t são calculados por:

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)\,, \tag{14}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \tag{15}$$

A redução no total de parâmetros gerada pela GRU atenua o risco de sobreajuste durante o treinamento em bases histopatológicas de dimensões amostrais restritas.

O processamento da sequência de escalas de redes complexas é aprimorado por codificadores bidirecionais, abrangendo a BiLSTM e a BiGRU (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005). Nessas arquiteturas, duas camadas recorrentes independentes processam a sequência temporal em orientações opostas:

- o fluxo direto ($r = 1 \rightarrow r_{\max}$) percorre a sequência dos raios menores aos maiores, acompanhando o acúmulo da textura local para a escala global do tecido,
- o fluxo reverso ($r = r_{\max} \rightarrow 1$) propaga o contexto tecidual macroscópico em direção às medidas de alcance celular restrito.

Na classificação de imagens operando sob a configuração de muitas entradas para uma saída, o vetor representativo final $z_{\text{top}} \in \mathbb{R}^{128}$ é obtido pela concatenação dos estados ocultos finais de ambas as direções de leitura:

$$z_{\text{top}} = \left[\overrightarrow{h}_{r_{\max}} \,\|\, \overleftarrow{h}_{1} \right], \tag{16}$$

sintetizando a evolução multiescala em um vetor denso unificado (Lin et al., 2022; Priyadarshini, 2026).

O modelo SAC-LSTM incorpora uma camada de autoatenção aos estados da LSTM para ponderar dinamicamente as escalas com maior poder de discriminação tecidual (Shalini; Rathnamala, 2026). Para a sequência de estados ocultos gerada pela LSTM $\{h_1, h_2, \ldots, h_T\}$, coeficientes escalares normalizados α_t são gerados por:

$$u_t = \tanh(W_a h_t + b_a)\,, \qquad \alpha_t = \frac{\exp\left(u_t^\top u_s\right)}{\sum_{k=1}^{T} \exp\left(u_k^\top u_s\right)}, \tag{17}$$

em que u_s representa um vetor de contexto ajustado durante a otimização. A representação

resultante é obtida pela combinação linear ponderada:

$$z_{\text{top}} = \sum_{t=1}^{T} \alpha_t h_t, \tag{18}$$

atribuindo pesos superiores aos raios de conexão que concentram padrões morfológicos relevantes para a diferenciação diagnóstica.

Como modelo de controle sem recorrência na ablação da via topológica, é empregado um MLP (Huang et al., 2022; Rumelhart; Hinton; Williams, 1986). Nesse arranjo estático, os 15 vetores da sequência são concatenados em um único vetor plano $\text{vec}(X_{\text{top}}) \in \mathbb{R}^{270}$, processado por uma projeção linear seguida de ativação ReLU:

$$z_{\text{top}} = \text{ReLU}(W_t \, \text{vec}(X_{\text{top}}) + b_t) \in \mathbb{R}^{128}, \tag{19}$$

em que $W_t \in \mathbb{R}^{128\times270}$ e $b_t \in \mathbb{R}^{128}$. A avaliação desse modelo permite verificar se a dependência temporal de leitura dos raios fornece ganho preditivo mensurável em relação a uma combinação estática das características topológicas.

2.4 MODELOS PROFUNDOS DE VISÃO COMPUTACIONAL

A via visual tem como propósito extrair representações densas diretamente a partir dos pixels da imagem histopatológica colorida. Três famílias de arquiteturas compõem o estado da arte na análise de imagens médicas: redes neurais convolucionais, transformadores visuais e arquiteturas híbridas CNN-ViT (Hussaini et al., 2026; Oliveira et al., 2025).

As redes neurais convolucionais processam a matriz de pixels aplicando filtros locais repetidos hierarquicamente ao longo de camadas sucessivas, operando com invariância a translações e alta sensibilidade na detecção de bordas celulares (Litjens et al., 2017). A arquitetura ResNet consolidou conexões de atalho residuais que permitem o treinamento de dezenas de camadas sem degradação do fluxo de gradientes, atuando como referência em estudos de histopatologia computacional (He et al., 2016; Kumar; Mishra, 2026). A arquitetura EfficientNet aperfeiçoou o uso de parâmetros por meio do escalonamento uniforme de profundidade, canais e resolução de entrada, incorporando blocos de convolução invertida e módulos de atenção por canal (Tan; Le, 2019; Kushwah; Punn; Bhattacharya, 2026).

Os transformadores visuais decompõem a imagem de entrada em uma sequência unidimensional de pequenos blocos de pixels projetados linearmente, aplicando camadas de autoatenção para computar correlações globais entre quaisquer regiões da imagem sem depender de filtros locais (Dosovitskiy et al., 2020; Shamshad et al., 2023). A arquitetura DeiT introduziu protocolos aprimorados de treinamento e destilação de conhecimento por meio de um *token* dedicado, tornando viável a convergência de transformadores visuais em conjuntos de dados com dimensões amostrais restritas (Touvron et al., 2021; Oliveira et al., 2025).

As arquiteturas híbridas CNN-ViT associam operações convolucionais a blocos de autoatenção para unificar a sensibilidade local a núcleos celulares com a modelagem do contexto tecidual amplo (Ma et al., 2026; Garbaz et al., 2025). A arquitetura MobileViT combina convoluções de profundidade separável com blocos de transformadores visuais em um arranjo compacto, obtendo alta capacidade discriminativa com demanda reduzida de parâmetros (Mehta; Rastegari, 2022; Kabir et al., 2025; Ding et al., 2023). A arquitetura CoAtNet organiza o fluxo de processamento em estágios hierárquicos, alocando blocos convolucionais nas camadas iniciais e blocos de autoatenção relativa nos estágios finais, otimizando o treinamento tanto em bases compactas quanto em grandes acervos (Dai et al., 2021; Oliveira et al., 2025; Zaidkilani; Garcia; Puig, 2024).

A construção do vetor de características da via visual z_{vis} ocorre a partir da imagem de entrada redimensionada para 256×256 pixels no espaço RGB, normalizada segundo os parâmetros de média e desvio padrão de cada modelo pré-treinado. A imagem alimenta o codificador visual com a camada densa original de classificação da ImageNet removida. As representações geradas no estágio terminal do codificador são condensadas em um vetor denso $z_{\text{vis}} \in \mathbb{R}^D$:

- nas arquiteturas convolucionais e híbridas (ResNet-50, EfficientNet-B0, MobileViT-S e CoAtNet-0), o mapa de ativações tridimensional $A \in \mathbb{R}^{C' \times H' \times W'}$ fornecido pelo último bloco é colapsado ao longo das dimensões de altura e largura por meio do agrupamento médio global (GAP), no qual o valor médio de cada canal é computado:

$$z_{\text{vis},c'} = \frac{1}{H'W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} A(c', i, j), \qquad c' \in \{1, 2, \ldots, D\}, \tag{20}$$

  em que a dimensão $D = C'$ corresponde à contagem de canais do estágio de saída da arquitetura, equivalendo a 640 na MobileViT-S, 1280 na EfficientNet-B0 e 2048 na ResNet-50,

- nas arquiteturas de transformadores visuais puros (ViT-Tiny e DeiT-Tiny), a representação é obtida a partir do estado oculto associado ao *token* especial de classificação (*token* de classe), resultando em um vetor de dimensão $D = 192$.

O vetor resultante $z_{\text{vis}} \in \mathbb{R}^D$ expressa as propriedades visuais extraídas dos pixels, sendo subsequentemente direcionado à etapa de projeção dimensional e fusão com a via topológica.

2.5 FUSÃO EM NÍVEL DE CARACTERÍSTICAS E CLASSIFICAÇÃO

Em problemas com múltiplas fontes de representação, a integração dos dados pode ser realizada em diferentes estágios do fluxo computacional (Baltrušaitis; Ahuja; Morency, 2019). A fusão em nível de decisões processa cada fonte por classificadores isolados e combina as probabilidades de saída (Yousaf; Nawaz; Habib, 2024). Em contrapartida, a fusão em nível de

características combina os vetores de representação antes da camada classificadora compartilhada, permitindo que interações entre as diferentes vias sejam aprendidas durante o treinamento supervisionado (Ramachandram; Taylor, 2017; Huang et al., 2022).

Em modelos de dupla via, a execução de ramos paralelos independentes preserva a individualidade de cada representação, evitando interferências nas fases primárias de extração (Simonyan; Zisserman, 2014; Wang et al., 2023; Nawaz et al., 2025). A combinação das duas vias ocorre por meio da concatenação dos respectivos vetores latentes. Quando os vetores exibem dimensões desiguais e ordens de grandeza distintas, as ativações com maior magnitude podem desestabilizar as atualizações de gradiente na primeira camada do classificador (Baltrušaitis; Ahuja; Morency, 2019).

Para harmonizar as representações, o vetor visual $z_{\text{vis}} \in \mathbb{R}^D$ é projetado linearmente para a mesma dimensionalidade adotada na via topológica (128) por meio de uma matriz de pesos $W_p \in \mathbb{R}^{128\times D}$ e um vetor de viés $b_p \in \mathbb{R}^{128}$:

$$\tilde{z}_{\text{vis}} = W_p\, z_{\text{vis}} + b_p. \tag{21}$$

A normalização por camadas (LN) (Baltrušaitis; Ahuja; Morency, 2019) é aplicada de forma independente sobre z_{top} e $\tilde{z}_{\text{vis}}$:

$$\mathrm{LN}(z) = \frac{z-\mu}{\sqrt{\sigma^2+\varepsilon}}, \qquad \mu = \frac{1}{d}\sum_{k=1}^{d} z_k, \qquad \sigma^2 = \frac{1}{d}\sum_{k=1}^{d}(z_k-\mu)^2, \tag{22}$$

em que ε representa uma constante de estabilidade numérica e $d = 128$. Essa normalização impõe média nula e variância unitária a ambos os vetores, eliminando discrepâncias decorrentes das ativações dos diferentes modelos.

O vetor integrado fundido é obtido pela concatenação direta das representações normalizadas:

$$z_{\text{fus}} = [\,\mathrm{LN}(z_{\text{top}}) \,\|\, \mathrm{LN}(\tilde{z}_{\text{vis}})\,] \in \mathbb{R}^{256}, \tag{23}$$

proporcionando balanceamento dimensional entre as fontes topológica e visual.

A classificação final é efetuada por um MLP dotado de uma camada oculta de 128 neurônios com ativação ReLU e regularização por *dropout* (Rumelhart; Hinton; Williams, 1986; Srivastava et al., 2014):

$$h = \mathrm{ReLU}(W_1 z_{\text{fus}} + b_1)\,, \tag{24}$$

$$\hat{y} = \mathrm{softmax}(W_2 h + b_2)\,, \tag{25}$$

em que $W_1 \in \mathbb{R}^{128\times 256}$, $b_1 \in \mathbb{R}^{128}$, $W_2 \in \mathbb{R}^{C\times 128}$ e $b_2 \in \mathbb{R}^{C}$, denotando C a quantidade de classes diagnósticas da tarefa. Os parâmetros de toda a arquitetura integrada são atualizados de ponta a ponta por retropropagação com a função de custo de entropia cruzada.

3 MATERIAIS E MÉTODOS

As imagens utilizadas provêm de cinco *datasets* histopatológicos, descritos na Seção 3.1. A arquitetura proposta extrai características de cada imagem por duas vias, a topológica e a visual (Seção 3.2). Os *embeddings* resultantes são concatenados (Seção 3.2.3) e classificados por um MLP (Seção 3.2.4), e o desempenho é medido pelo protocolo da Seção 3.3. O fluxo completo está apresentado na Figura 3.

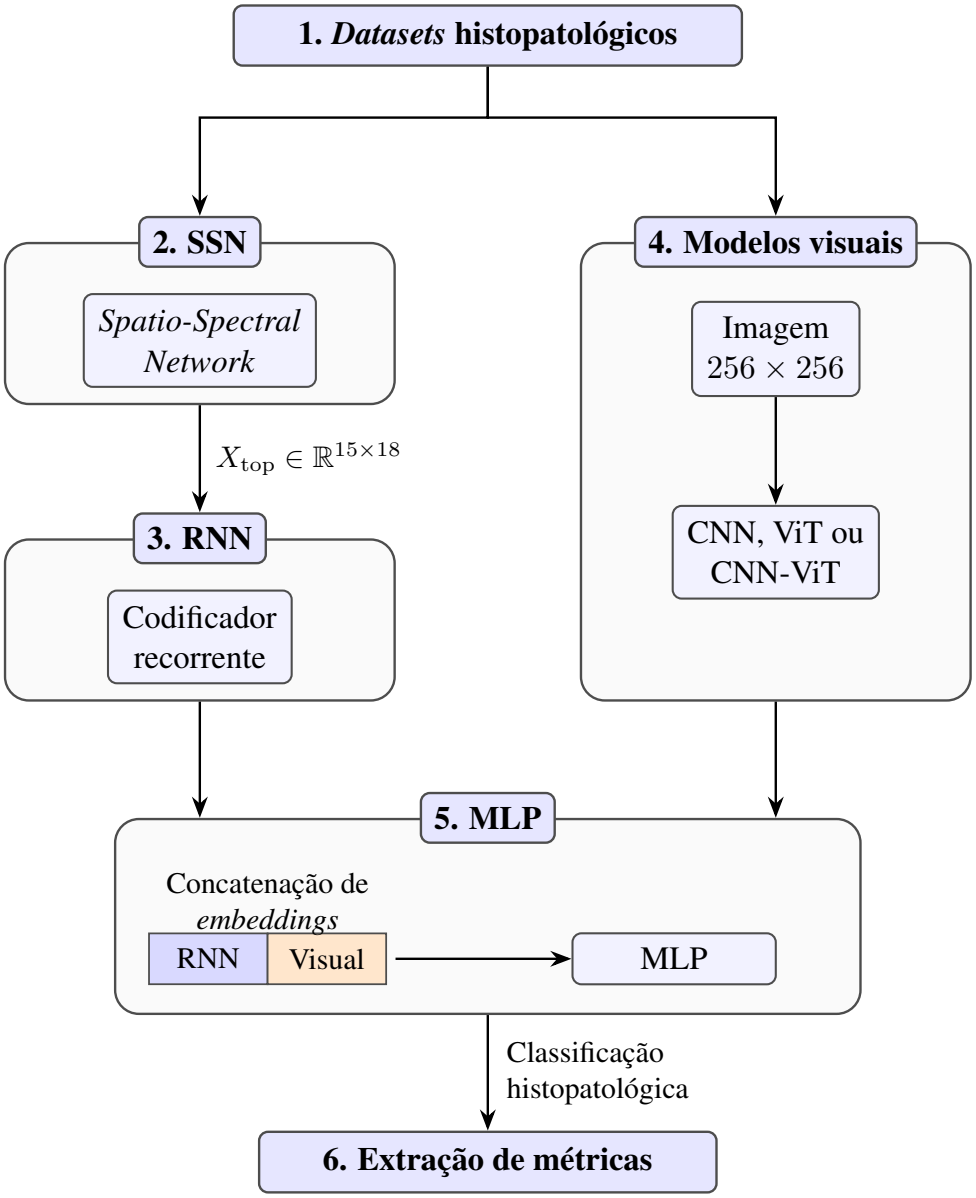


Figura 3 – Pipeline geral da abordagem proposta: os *datasets* histopatológicos alimentam duas vias paralelas, uma topológica (SSN seguida de RNN) e uma visual (modelos CNN, ViT ou híbridos). Os *embeddings* das duas vias são concatenados e classificados por uma MLP, da qual são extraídas as métricas.

3.1 *DATASETS*

A avaliação foi conduzida em cinco *datasets* de imagens histopatológicas, com 58 a 528 imagens cada. Os conjuntos incluem tarefas de classificação binária e multiclasse, com diferentes tamanhos amostrais e graus de desbalanceamento de classes, o que permite observar o comportamento do modelo em cenários com poucos dados. As características de cada conjunto estão resumidas na Tabela 1. Os conjuntos LA e LG não correspondem a tarefas diagnósticas, pois as classes são a idade e o sexo de camundongos. Esses conjuntos foram incluídos como *benchmarks* de textura histológica, nos quais a distinção entre as classes depende do padrão do tecido hepático e não de uma lesão.

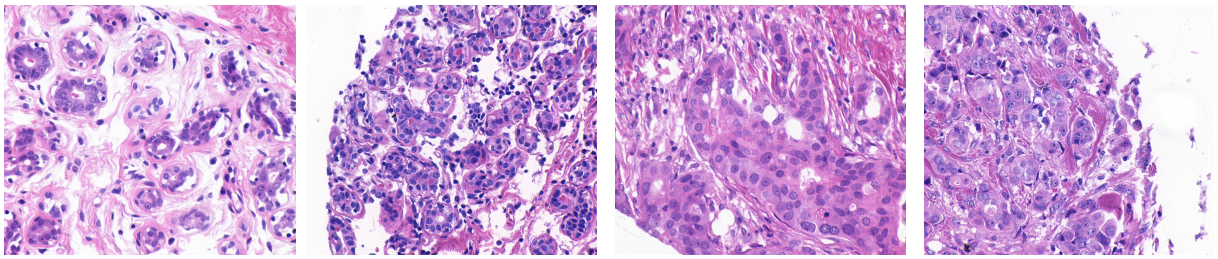
Tabela 1 – Resumo dos *datasets* utilizados.

Dataset	**Tarefa (classes)**	**Imagens**	**Classes**	**Imagens por classe**	**Resolução original**
UCSB	Mama (benigno / maligno)	58	2	32 / 26	896×768
CR	Colorretal (benigno / maligno)	165	2	74 / 91	775×522 (14 exceções)
LA	Idade (1, 6, 16 e 24 meses)	528	4	100 / 115 / 162 / 151	417×312
LG	Sexo (macho / fêmea)	265	2	150 / 115	417×312
NHL	Linfoma (CLL / FL / MCL)	374	3	113 / 139 / 122	1388×1040

As imagens foram mantidas em inteiros de 8 bits por canal e alimentaram as duas vias em resoluções distintas. A via topológica utilizou a imagem na resolução original de cada *dataset* (Tabela 1), sem redimensionamento e sem alteração de intensidades, pois as arestas das redes complexas dependem da comparação de intensidades inteiras, incluindo os empates, e a interpolação suavizaria essas diferenças. A via visual utilizou uma versão de 256×256 pixels, escala em que os modelos utilizados foram pré-treinados, o que também uniformiza as dimensões dos lotes. Essa versão foi obtida pelo redimensionamento do lado menor para 256 pixels, por interpolação de área e com a proporção preservada, seguido de um recorte central de 256×256 pixels. As imagens de 256×256 pixels foram calculadas uma única vez, mantidas como inteiros de 8 bits e armazenadas em cache, com a ordem dos arquivos conferida contra a da via topológica. A conversão para o intervalo $[0, 1]$ e a normalização foram aplicadas a cada lote, com a média e o desvio padrão do pré-processamento de cada *backbone* pré-treinado (Seção 3.2.2): a média de $(0{,}485;\ 0{,}456;\ 0{,}406)$ e o desvio padrão de $(0{,}229;\ 0{,}224;\ 0{,}225)$ da ImageNet para a EfficientNet-B0 e a DeiT-Tiny, e média nula e desvio unitário para a MobileViT-S, cujos pesos foram pré-treinados sem normalização por canal. Esse procedimento evita a distorção de proporção, mas o recorte central descarta as bordas das imagens que não são quadradas.

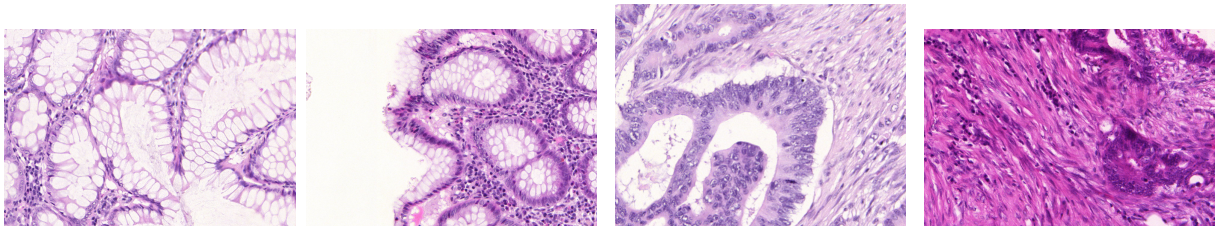
O *dataset* UCSB (Gelasca et al., 2008) é composto por 58 imagens RGB de tecido de câncer de mama (Figura 4), sendo 32 benignas e 26 malignas, e possui o menor número de amostras entre os conjuntos avaliados. O *dataset* CR (Sirinukunwattana et al., 2017) contém 165 imagens RGB de tecido colorretal, obtidas a partir de 16 seções histológicas representativas de câncer colorretal nos estágios T3 e T4. O conjunto é levemente desbalanceado, com 74 imagens de tecido benigno e 91 de tecido maligno, e a resolução original é de 775×522 pixels em 151

imagens, enquanto 14 imagens (7 por classe) têm resoluções menores, de 567×430 a 589×453 pixels, com proporção diferente das demais (Figura 5).



(a) (b) (c) (d)

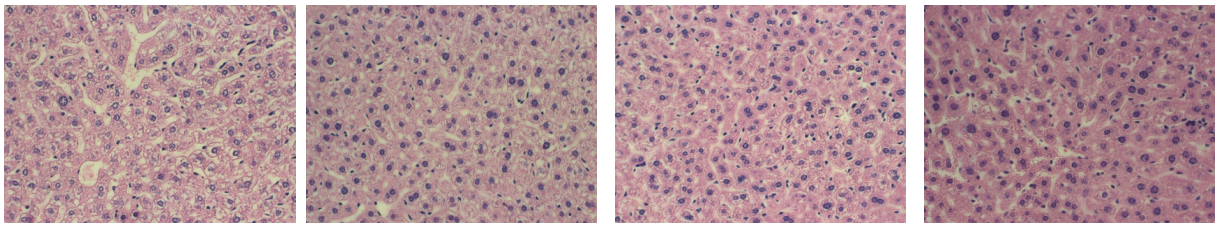
Figura 4 – Imagens exemplares do conjunto UCSB: (a, b) são tumores benignos e (c, d) são tumores malignos.



(a) (b) (c) (d)

Figura 5 – Imagens exemplares do conjunto CR: (a, b) são tecidos benignos e (c, d) são tecidos malignos.

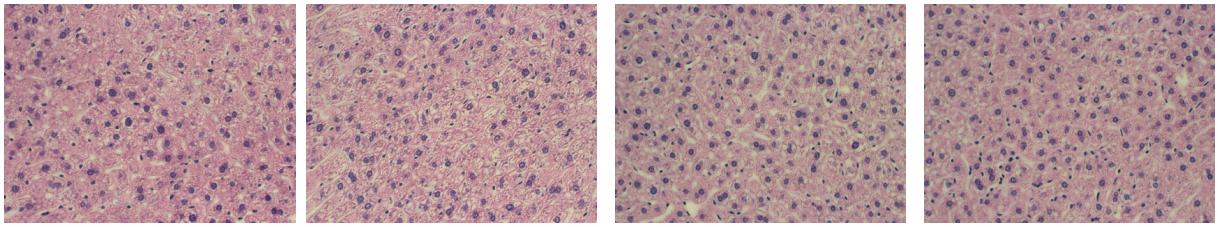
Os *datasets* LA e LG (Shamir et al., 2008) compreendem micrografias RGB de tecido hepático de camundongos. O LA tem como objetivo classificar a idade dos animais fêmeas em quatro grupos, com um mês (100 imagens), seis meses (115), 16 meses (162) e 24 meses (151), totalizando 528 imagens. O LG contém 265 imagens para classificação de sexo, divididas em 150 machos e 115 fêmeas. As amostras dos dois conjuntos estão na Figura 6 e na Figura 7.



(a) (b) (c) (d)

Figura 6 – Imagens de cada faixa etária dos camundongos do conjunto LA: um mês (a), seis meses (b), 16 meses (c) e 24 meses (d).

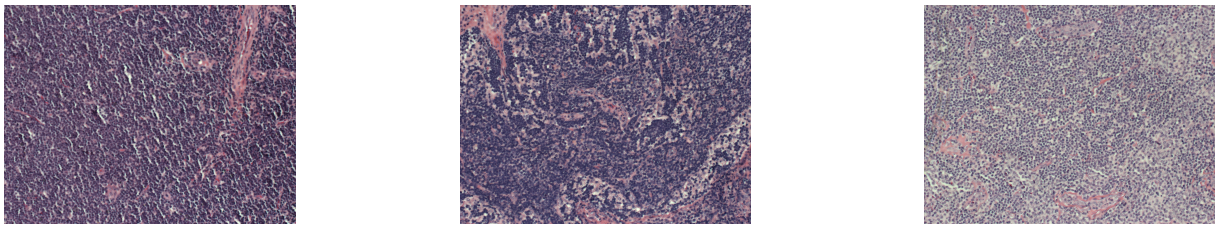
O *dataset* NHL (Shamir et al., 2008) contém 374 imagens RGB de linfoma não Hodgkin, distribuídas em três classes diagnósticas: CLL (113 imagens), FL (139 imagens) e MCL (122 imagens). Diferentemente de aquisições realizadas em um único centro, o NHL reúne espécimes preparados por diferentes histologistas em diversos hospitais e laboratórios, com variações



(a) (b) (c) (d)

Figura 7 – Imagens de cada sexo dos camundongos do conjunto LG: (a, b) machos e (c, d) fêmeas.

marcantes de coloração e iluminação (Figura 8). Essa variabilidade cromática motivou a inclusão do conjunto. Como as partições de validação cruzada e de teste foram obtidas dentro do próprio conjunto e sem metadados de laboratório, o protocolo não avalia a generalização para laboratórios não vistos.



(a) (b) (c)

Figura 8 – Amostras do conjunto NHL: (a) CLL, (b) FL e (c) MCL.

3.2 *TWO-STREAM NETWORK*

A arquitetura proposta, ilustrada na Figura 3, é uma rede de dupla via (*Two-Stream Network*) para a classificação de imagens histopatológicas. A via topológica representa a imagem por medidas de redes complexas processadas por uma BiLSTM ou por um MLP, e a via visual extrai características diretamente da imagem RGB por uma arquitetura híbrida baseada em convoluções e atenção. As duas vias são independentes durante a extração. Os *embeddings* resultantes são projetados para a mesma dimensão, concatenados e classificados por um MLP, e todos os parâmetros são ajustados em conjunto no treinamento (Seção 3.3).

Na arquitetura proposta, a via topológica descreve as relações entre pixels em raios de conexão crescentes, e a via visual aprende representações a partir dos pixels da imagem. O fundamento das arquiteturas de dupla via e da combinação das representações está na Seção 2.5.

O processamento ocorre em quatro etapas. A primeira extrai as características topológicas por redes complexas e as codifica por uma BiLSTM ou por um MLP. A segunda extrai as características visuais pela MobileViT-S. A terceira projeta, normaliza e concatena os dois *embeddings*. A quarta classifica o vetor concatenado por um MLP.

3.2.1 Via topológica

A primeira via descreve a textura da imagem por medidas topológicas de redes complexas (Seção 2.2). Cada imagem foi convertida em uma rede direcionada e ponderada, na qual cada pixel é um vértice e as arestas ligam pixels cuja distância é de no máximo $r_{\max}$. O peso de cada aresta combina a diferença absoluta de intensidade e a distância euclidiana entre os pixels (Seção 2.2), e a direção vai do pixel de menor intensidade para o de maior intensidade (Scabini; Ribas; Bruno, 2020; Backes; Casanova; Bruno, 2013; Ribas et al., 2020; Ribas et al., 2024). As imagens foram modeladas em redes do tipo *full*, que permite a criação tanto entre pixels de mesmo canal de cor quanto entre pixels de diferentes canais de cores (Scabini; Ribas; Bruno, 2020). As conexões intercanais incluem as arestas de distância nula entre os canais de um mesmo pixel, que pertencem ao raio 1 (Ribas et al., 2024). A rede foi construída sobre a imagem original de 8 bits, na resolução nativa de cada *dataset*, sem redimensionamento e sem normalização. As medidas por raio são médias e desvios padrão sobre os vértices, de modo que imagens de tamanhos diferentes geram sequências com a mesma dimensão. Por serem determinísticas, as medidas foram calculadas uma única vez por imagem e reutilizadas em todas as partições.

Para cada vértice foram calculados o grau de saída, a força de saída e a força de entrada, acumulados até cada raio $r \in \{1, 2, \ldots, r_{\max}\}$, e o grau de entrada não foi utilizado por ser uma combinação linear do grau de saída Ribas et al. (2024). Em cada raio, a média global e o desvio padrão global das três medidas foram calculados para cada um dos três canais, o que produz 18 características por raio. A imagem é descrita pela sequência

$$X_{\text{top}} = [x_1, x_2, \ldots, x_{15}], \tag{1}$$

em que cada passo $x_r \in \mathbb{R}^{18}$ corresponde ao raio r, e a sequência completa contém 270 valores. As medidas por raio seguem a SSN (Scabini; Ribas; Bruno, 2020). A sequência é processada por um codificador, a BiLSTM ou o MLP (descritos adiante), cujo vetor de saída forma o descritor topológico $z_{\text{top}} \in \mathbb{R}^{128}$.

O raio de conexão variou de 1 a 15, de modo que $r_{\max} = 15$, intervalo analisado na literatura de redes complexas aplicadas à textura (Zerati et al., 2026). A sensibilidade ao valor de $r_{\max}$ foi verificada na via topológica isolada, com $r_{\max} \in \{4, 7, 10, 15\}$ (Seção 4.1). Como o raio é medido em pixels, $r_{\max} = 15$ cobre uma fração maior da imagem nos conjuntos de menor resolução (LA e LG) e menor nos de maior resolução (NHL), o que altera a extensão tecidual descrita pelas medidas.

As medidas são acumuladas e crescem de forma monotônica com r, assumindo magnitudes mais elevadas nos raios maiores. Cada uma das 270 coordenadas de X_{top} foi padronizada pela média e pelo desvio padrão calculados sobre o conjunto de treino de cada rodada da validação cruzada e do treinamento final, sendo os parâmetros de padronização replicados nas partições de validação e de teste. Na ablação da via topológica isolada (Seção 4.1), foram avaliadas diferentes arquiteturas recorrentes e uma linha de base sem recorrência para determinar os

melhores hiperparâmetros de cada base de dados.

A BiLSTM foi adotada como o codificador recorrente principal, pela capacidade de processar a sequência nos sentidos direto e inverso, enquanto o MLP atua como modelo de controle estático sem recorrência. A arquitetura de dupla via integra a representação topológica z_{top} com a representação visual, mantendo a fusão (Seção 3.2.3) e o classificador (Seção 3.2.4) unificados para verificar o ganho preditivo ao unir as vias (Seção 3.4).

3.2.1.1 Codificador BiLSTM

A sequência padronizada foi processada por uma BiLSTM (Hochreiter; Schmidhuber, 1997; Schuster; Paliwal, 1997). Na configuração adotada, a rede possui uma camada e unidades ocultas configuradas conforme a dimensão selecionada na ablação da via topológica (Seção 4.1), produzindo um vetor de características $z_{\text{top}} \in \mathbb{R}^{128}$. A rede opera no formato *many-to-one*, e o *embedding* topológico é a concatenação do estado final da leitura direta, do raio 1 ao 15, com o estado final da leitura inversa:

$$z_{\text{top}} = \left[\overrightarrow{h}_{15} \,\|\, \overleftarrow{h}_{1} \right] \in \mathbb{R}^{128}. \tag{2}$$

A leitura direta acumula progressivamente a informação dos raios menores nos raios maiores, enquanto a leitura inversa fornece a cada raio o acesso ao contexto das escalas maiores, capturando a transição das propriedades teciduais (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005).

3.2.1.2 Codificador MLP

No segundo codificador, os 15 vetores de X_{top} são concatenados em um único vetor de 270 valores, $\text{vec}(X_{\text{top}}) \in \mathbb{R}^{270}$, processado por um MLP (Rumelhart; Hinton; Williams, 1986). Na configuração padrão, o codificador possui uma camada linear de 128 neurônios seguida da função de ativação ReLU, resultando em um *embedding* de 128 dimensões:

$$z_{\text{top}} = \text{ReLU}\left(W_t \ \text{vec}(X_{\text{top}}) + b_t\right) \in \mathbb{R}^{128}, \qquad W_t \in \mathbb{R}^{128\times 270}. \tag{3}$$

Diferentemente da BiLSTM, o MLP não compartilha pesos entre os raios nem impõe uma ordem de leitura, de modo que cada coordenada possui pesos próprios. A dimensão oculta e a taxa de *dropout* foram determinadas na ablação da via topológica (Seção 4.1). A normalização LN aplicada antes da concatenação (Seção 3.2.3) uniformiza a escala das ativações topológicas com as representações da via visual.

3.2.2 Via visual

A via visual extrai atributos diretamente da imagem RGB por meio de modelos profundos de visão computacional. Foram avaliadas seis arquiteturas distribuídas nas famílias convolucional

(ResNet-50 e EfficientNet-B0), transformadores visuais (ViT-Tiny e DeiT-Tiny) e híbridas (MobileViT-S e CoAtNet-0), conforme detalhado no Capítulo 4. Cada arquitetura recebeu a versão de 256×256 pixels da imagem (Seção 3.1), normalizada pelos parâmetros de média e desvio padrão do pré-treinamento da ImageNet-1k, tendo a camada densa original de classificação removida. Os pesos foram obtidos da biblioteca *timm*.

As ativações do último estágio de extração de características foram agregadas por agrupamento médio global (*Global Average Pooling*) ou pelo *token* de classificação, reduzindo a representação a um vetor denso. Sendo I a imagem processada e $f_{\text{vis}}(\cdot)$ o codificador visual, o mapeamento é dado por

$$z_{\text{vis}} = f_{\text{vis}}(I), \tag{4}$$

em que $z_{\text{vis}} \in \mathbb{R}^D$ representa o vetor de características visuais, com dimensão D dependente de cada arquitetura. No modelo de dupla via, a via visual recebeu aumento de dados por inversão horizontal e rotações de 90 graus aplicadas exclusivamente durante o treinamento (Seção 3.3).

3.2.3 Fusão por concatenação de *embeddings*

Os *embeddings* das duas vias foram combinados em nível de características, antes do classificador, na estratégia denominada fusão por concatenação de *embeddings* (Seção 2.5). Como o modelo é treinado de ponta a ponta, as duas vias são ajustadas em conjunto, e a separação entre elas se limita à extração das representações.

Os dois vetores têm escalas e dimensões distintas. Os valores de z_{top} da BiLSTM são limitados ao intervalo $(-1, 1)$ pela tangente hiperbólica da célula de memória, e os do MLP são não negativos e sem limite superior, por saírem de uma ReLU. Já z_{vis} resulta de ativações sem limitação, e a diferença de escala pode fazer as características de maior magnitude predominarem na primeira camada do classificador. O vetor visual, com dimensão D dependente do modelo empregado, também difere do vetor topológico de 128 dimensões. Por esse motivo, z_{vis} foi projetado para 128 dimensões por uma camada linear, e cada vetor foi normalizado por LN antes da concatenação:

$$\tilde{z}_{\text{vis}} = W_p\, z_{\text{vis}} + b_p, \qquad W_p \in \mathbb{R}^{128 \times D}, \tag{5}$$

$$z_{\text{fus}} = [\text{LN}(z_{\text{top}}) \,\|\, \text{LN}(\tilde{z}_{\text{vis}})] \in \mathbb{R}^{256}. \tag{6}$$

O símbolo $\|$ indica a concatenação dos vetores, e z_{top} é o *embedding* da BiLSTM (Equação 2) ou do MLP (Equação 3), conforme a variante da via topológica, de modo que a fusão é idêntica nos dois casos. O vetor z_{fus} contém 128 dimensões de cada via e é a entrada do classificador.

3.2.4 Classificador MLP

A classificação foi realizada por um MLP (Rumelhart; Hinton; Williams, 1986), distinto do MLP usado como codificador topológico (Seção 3.2.1.2), com uma camada oculta de 128 neurônios, o que resulta em cerca de 33 mil parâmetros na primeira camada. A camada oculta é dada por

$$h = \mathrm{ReLU}\left(W_1 z_{\mathrm{fus}} + b_1\right), \tag{7}$$

em que a ReLU introduz a não linearidade. Sobre h foi aplicada uma camada de *Dropout* com probabilidade de desativação de $0{,}5$ durante o treinamento (Srivastava et al., 2014), como regularização para os conjuntos com poucas imagens, como UCSB e CR. A camada de saída tem C neurônios, com C igual ao número de classes de cada *dataset* (de 2 a 4), e as probabilidades são obtidas por

$$\hat{y} = \mathrm{softmax}\left(W_2 h + b_2\right). \tag{8}$$

3.3 PROTOCOLO DE TREINAMENTO

A arquitetura de dupla via (*Two-Stream Network*) foi treinada de ponta a ponta (*end-to-end*). Os parâmetros do modelo de visão computacional da via visual, da camada de projeção linear, do codificador da via topológica e do classificador MLP foram atualizados conjuntamente por meio da minimização da função de perda de entropia cruzada, com o otimizador AdamW e norma máxima dos gradientes limitada a 1,0.

A definição dos hiperparâmetros da arquitetura unificada adotou a estratégia direta de herança dos valores ótimos estabelecidos durante as etapas de ablação das vias isoladas (Capítulo 4). O *backbone* visual foi inicializado com pesos pré-treinados na ImageNet-1k e ajustado com a taxa de aprendizado ótima (η_{bb}) selecionada na ablação da via visual (Seção 4.2). O codificador topológico foi inicializado aleatoriamente e ajustado com a taxa de aprendizado ótima (η_{top}) e a dimensão oculta (h) selecionadas na ablação da via topológica (Seção 4.1). A camada de projeção linear e a cabeça de classificação MLP foram ajustadas com a taxa de aprendizado de cabeça (η_{hd}) obtida na ablação visual. O tamanho de lote (B), o decaimento de pesos ($\lambda = 10^{-4}$) e a taxa de *dropout* foram igualmente fixados nos valores ótimos correspondentes a cada conjunto de dados. Essa formulação elimina a necessidade de novas buscas hiperparamétricas na via dupla, permitindo isolar o efeito da união das representações frente a cada via operando de forma isolada.

O treinamento foi delimitado ao teto de 50 épocas, com critério de parada antecipada regulado por uma tolerância de 10 épocas consecutivas sem decréscimo da perda na partição de validação e restauração dos melhores pesos. A via visual recebeu aumento de dados composto por inversão horizontal (probabilidade 0,5) e rotações de 0, 90, 180 ou 270 graus aplicadas exclusivamente

durante o treino. A via topológica não recebeu transformações adicionais, uma vez que as medidas topológicas globais (médias e desvios padrão calculados sobre os vértices da rede) são computadas sobre a imagem original e preservam a invariância rotacional de 90 graus e inversões.

3.3.1 Validação

A avaliação do desempenho foi organizada em duas fases distintas sobre a mesma separação amostral (Figura 9):

Inicialmente, 20% das imagens de cada conjunto de dados foram separadas de forma estratificada (semente 42) como partição de teste final (*holdout*) e mantidas totalmente isoladas de todos os procedimentos de ajuste e ablação. As 80% das imagens restantes formaram o conjunto de desenvolvimento.

Sobre os 80% de desenvolvimento, foi conduzida a avaliação por validação cruzada estratificada em cinco partições ($k = 5$) com semente 42:

1. Em cada rodada, quatro partições foram destinadas ao treinamento conjunto dos parâmetros e uma partição foi utilizada para a validação.

2. Para as vias isoladas (topológica e visual), essa validação cruzada serviu para a exploração da grade de hiperparâmetros e identificação das configurações ótimas (Capítulo 4).

3. Para a rede de dupla via, os hiperparâmetros fixados foram herdados diretamente das configurações ótimas identificadas nas ablações isoladas (Capítulo 4), dispensando novas etapas de busca combinatória.

4. O desempenho de cada abordagem no desenvolvimento foi quantificado pela média aritmética e pelo desvio padrão do F1 macro entre as cinco partições de validação.

Para a avaliação confirmatória final, o modelo unificado de dupla via com os hiperparâmetros fixados foi treinado sobre a totalidade da partição de desenvolvimento (80% das imagens) e avaliado na partição de teste final (*holdout*, 20%). O ajuste final foi repetido sob cinco sementes aleatórias distintas para quantificar a dispersão associada à inicialização estocástica dos pesos e ao aumento de dados, reportando a média e o desvio padrão obtidos em dados nunca observados durante o desenvolvimento (Capítulo 5).

3.3.2 Métricas

A capacidade preditiva dos modelos foi mensurada pela acurácia, pelo F1-*score* macro e pela área sob a curva ROC (AUC-ROC). A acurácia expressa a proporção global de acertos do classificador. O F1-*score* macro é definido como a média aritmética harmônica entre precisão e sensibilidade calculada individualmente para cada classe, atribuindo peso equivalente às classes minoritárias e majoritárias, aspecto relevante em conjuntos com desbalanceamento amostral

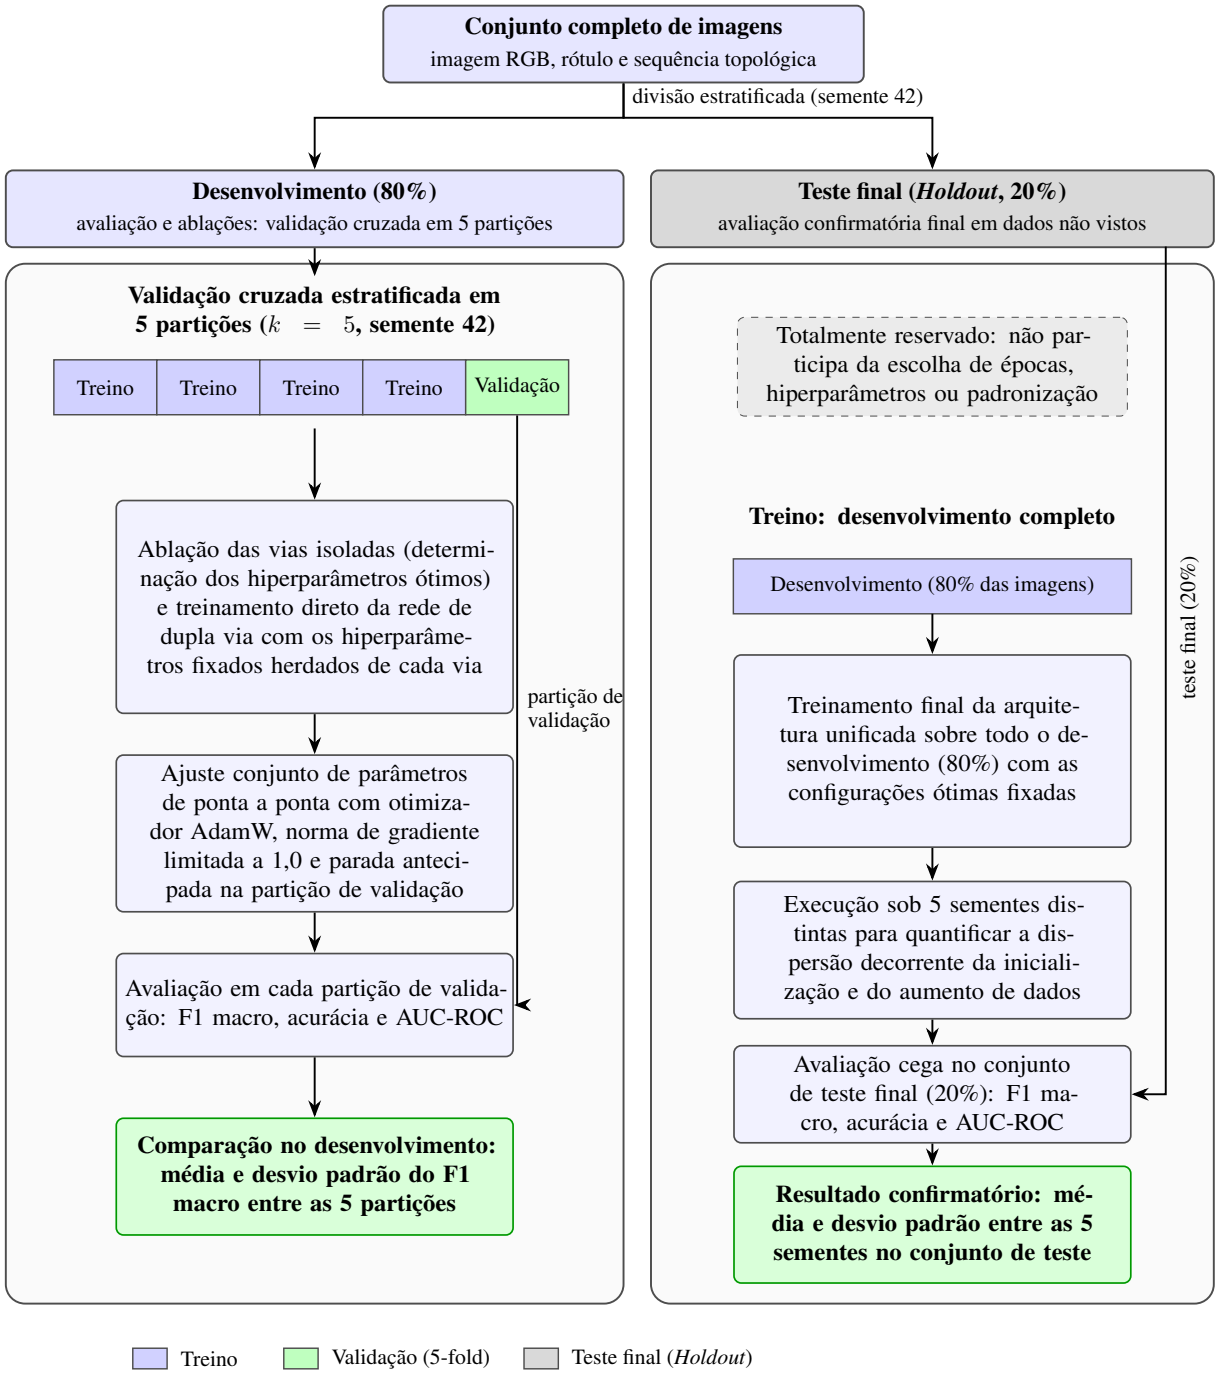


Figura 9 – Separação dos dados e protocolo experimental de avaliação. Um conjunto de teste final (*holdout*) de 20% é reservado antes de qualquer treinamento. Os 80% restantes (desenvolvimento) são avaliados por validação cruzada estratificada em cinco partições ($k = 5$), na qual foram conduzidas as ablações das vias isoladas e o treinamento direto da rede de dupla via com os hiperparâmetros fixados. O modelo final é treinado sobre todo o desenvolvimento e avaliado no conjunto de teste final sob múltiplas sementes para confirmação da capacidade de generalização.

como o CR. A métrica AUC-ROC foi calculada pela abordagem um-contra-todos (*one-vs-rest*) com média macro para tarefas multiclasse (LA e NHL). As métricas foram calculadas tanto nas cinco partições de validação do desenvolvimento quanto no conjunto de teste final.

3.3.3 Limitações do protocolo

O protocolo delineado apresenta limitações metodológicas consideradas na interpretação dos resultados. Em conjuntos com volume reduzido, como o UCSB (58 imagens no total), a partição de teste final contém 12 imagens e cada partição de validação do desenvolvimento abriga entre 9 e 10 amostras, o que torna as pontuações discretas e sensíveis a oscilações em poucas predições. As partições foram organizadas por imagem em virtude da ausência de identificadores de paciente ou lâmina em algumas bases públicas, de modo que recortes de um mesmo bloco de tecido podem ocorrer em partições distintas. Adicionalmente, a via visual processa um recorte central com redimensionamento para 256×256 pixels, descartando margens periféricas em imagens não quadradas, enquanto a via topológica é extraída sobre a resolução integral da imagem original. Por fim, o raio máximo de conexão fixado em 15 pixels abrange proporções de tecido distintas conforme a resolução de digitalização de cada base de dados.

3.4 COMPARAÇÕES COM OS MÉTODOS DE REFERÊNCIA

A avaliação da arquitetura de dupla via foi estruturada para verificar se a união das representações supera o desempenho alcançado por cada modalidade de forma isolada e por métodos de referência da literatura:

- a via topológica isolada, avaliada com os diferentes codificadores sequenciais (Capítulo 4),
- a via visual isolada, avaliada com diferentes famílias de modelos de visão computacional (Capítulo 4),
- a rede de dupla via (*Two-Stream Network*), combinando os melhores modelos de cada via por projeção linear, normalização por camadas e concatenação,
- descritores clássicos de textura (GLCM, LBP e HOG) combinados a classificadores densos, servindo de controle para a caracterização tecidual multiescala.

A avaliação confirmatória da rede de dupla via frente às vias isoladas e aos métodos de referência sobre o conjunto de teste independente compõe o Capítulo 5.

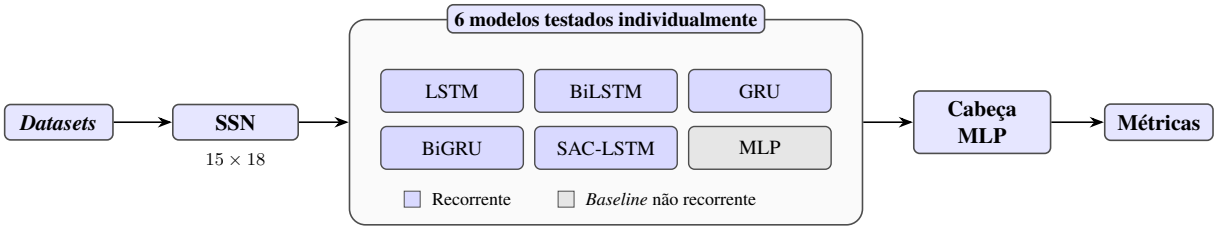
3.5 CONFIGURAÇÃO DE AMBIENTE

Os experimentos foram executados em uma infraestrutura com uma UCP *13th Gen Intel(R) Core(TM) i5-13400F* com duas placas de vídeo NVIDIA, sendo uma RTX 4060 Ti e a outra uma RTX 4070 Ti SUPER. Os pesos pré-treinados de todos os modelos foram obtidos da

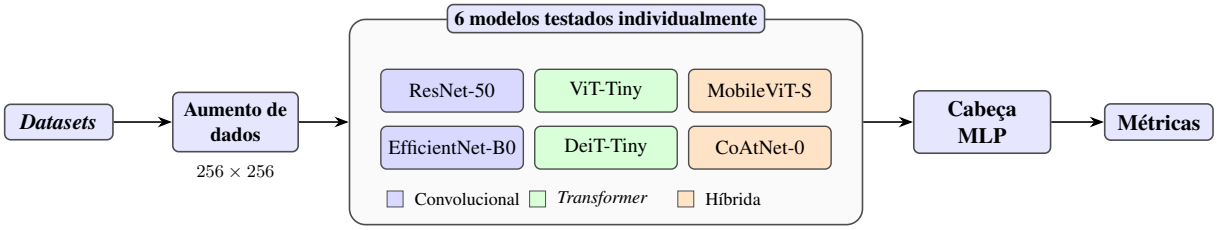
biblioteca *timm* (versão **1.0.3**), e as imagens de 256×256 pixels foram preparadas com a biblioteca OpenCV. As redes complexas foram construídas por uma implementação em C++ com paralelismo OpenMP em 16 *threads*. As bibliotecas utilizadas foram *torch* (versão **2.15**), *torchvision* (versão **0.29.2**), *scikit-image* (versão **0.26**), scikit-learn (versão **1.9.1**), *pandas* (versão **3.1**), *opencv* (versão **5.0**) e *pillow* (versão **13.0**).

4 ABLAÇÃO

Neste capítulo são detalhados os experimentos de ablação conduzidos para determinar as arquiteturas e os hiperparâmetros da via topológica e da via visual antes da composição do modelo de dupla via. As duas vias foram avaliadas de forma isolada sobre as mesmas partições de dados, com o propósito de selecionar as melhores configurações sem utilizar o conjunto de teste final reservado. A organização conceitual da avaliação das vias isoladas está ilustrada na Figura 10, abrangendo os modelos avaliados na via topológica e na via visual, com suas respectivas cabeças de classificação e extração de métricas.



(a) Via topológica



(b) Via visual

Figura 10 – Ablação das vias isoladas. (a) Via topológica: a sequência de características da SSN é processada por seis codificadores (cinco recorrentes e uma MLP como *baseline*), cada um testado de forma independente. (b) Via visual: as imagens, após aumento de dados, são processadas por seis modelos (convolucionais, *transformers* e híbridos), também testados individualmente. Cada via possui sua própria cabeça MLP, da qual são extraídas as métricas.

4.1 ABLAÇÃO DA VIA TOPOLÓGICA

A via topológica recebe a sequência de características calculada a partir de redes complexas sobre 15 raios de conexão, denotada por $X_{\text{top}} \in \mathbb{R}^{15\times 18}$, em que cada passo contém 18 medidas descritoras. Para verificar a capacidade de aprendizado sobre essa sequência e avaliar a contribuição da dependência de ordem entre as escalas, foram selecionados cinco modelos de redes neurais recorrentes e um modelo não recorrente como *baseline* (Figura 10a):

- a LSTM padrão (Hochreiter; Schmidhuber, 1997; Gers; Schmidhuber; Cummins, 2000), modelo com portas de esquecimento, entrada e saída, empregado como referência no processamento de sequências multiescala (Lin et al., 2022) e diagnósticos médicos (Mathiyalagi; Ravi, 2026),
- a BiLSTM (Schuster; Paliwal, 1997; Graves; Schmidhuber, 2005), que processa os raios nos sentidos direto e inverso para integrar informação de micro e macrotextura, com precedentes na detecção de alterações celulares neoplásicas (Priyadarshini, 2026) e em modelos de dupla via (Yousaf; Nawaz; Habib, 2024),
- a GRU (Cho et al., 2014), que unifica as portas e dispensa o estado de célula separado, resultando em menor custo paramétrico para conter o risco de sobreajuste em conjuntos com volume reduzido de imagens,
- a BiGRU (Schuster; Paliwal, 1997; Cho et al., 2014), que combina o fluxo de informação bidirecional entre as escalas à redução paramétrica da unidade GRU,
- a SAC-LSTM (*Self-Attention Coupled LSTM*) (Shalini; Rathnamala, 2026), modelo desenvolvido para classificação histopatológica de câncer de mama, que adiciona uma camada de autoatenção aos estados da LSTM para ponderar dinamicamente os raios de conexão mais discriminativos,
- o MLP (*Multi-Layer Perceptron*) (Huang et al., 2022), rede de alimentação direta que processa as 270 características de forma estática sobre o vetor achatado, avaliada como linha de base de controle para verificar se a modelagem sequencial traz ganho efetivo frente a uma projeção densa sem recorrência.

Todos os seis codificadores produzem um vetor de características com a mesma dimensão oculta, conectado à mesma cabeça de classificação, formada por normalização por camadas, camada linear de 128 neurônios com ativação ReLU, camada de *dropout* e camada linear de saída com projeção para o número de classes de cada tarefa.

O protocolo experimental de particionamento, validação cruzada, busca em grade e seleção de hiperparâmetros dos modelos em ablação está esquematizado na Figura 11. O procedimento foi executado exclusivamente sobre a partição de desenvolvimento de cada conjunto de dados. Inicialmente, as imagens de cada conjunto foram divididas de forma estratificada, com semente 42, na proporção de 80% para desenvolvimento e 20% para teste final, permanecendo a partição de teste totalmente reservada e sem qualquer participação no processo de ablação. Sobre os 80% de desenvolvimento, foi aplicada uma validação cruzada estratificada em cinco partições ($k = 5$). Para cada modelo e para cada combinação de hiperparâmetros, o treinamento foi conduzido em cinco rodadas independentes, nas quais quatro partições foram destinadas ao ajuste dos pesos e uma partição foi utilizada para a validação, alternando a partição de validação a cada rodada. As 18 medidas descritoras foram padronizadas em cada rodada por escore padrão

calculado exclusivamente sobre as partições de treino, prevenindo vazamento de dados para a validação. A grade de hiperparâmetros explorada para cada conjunto de dados na via topológica está sintetizada na Tabela 2.

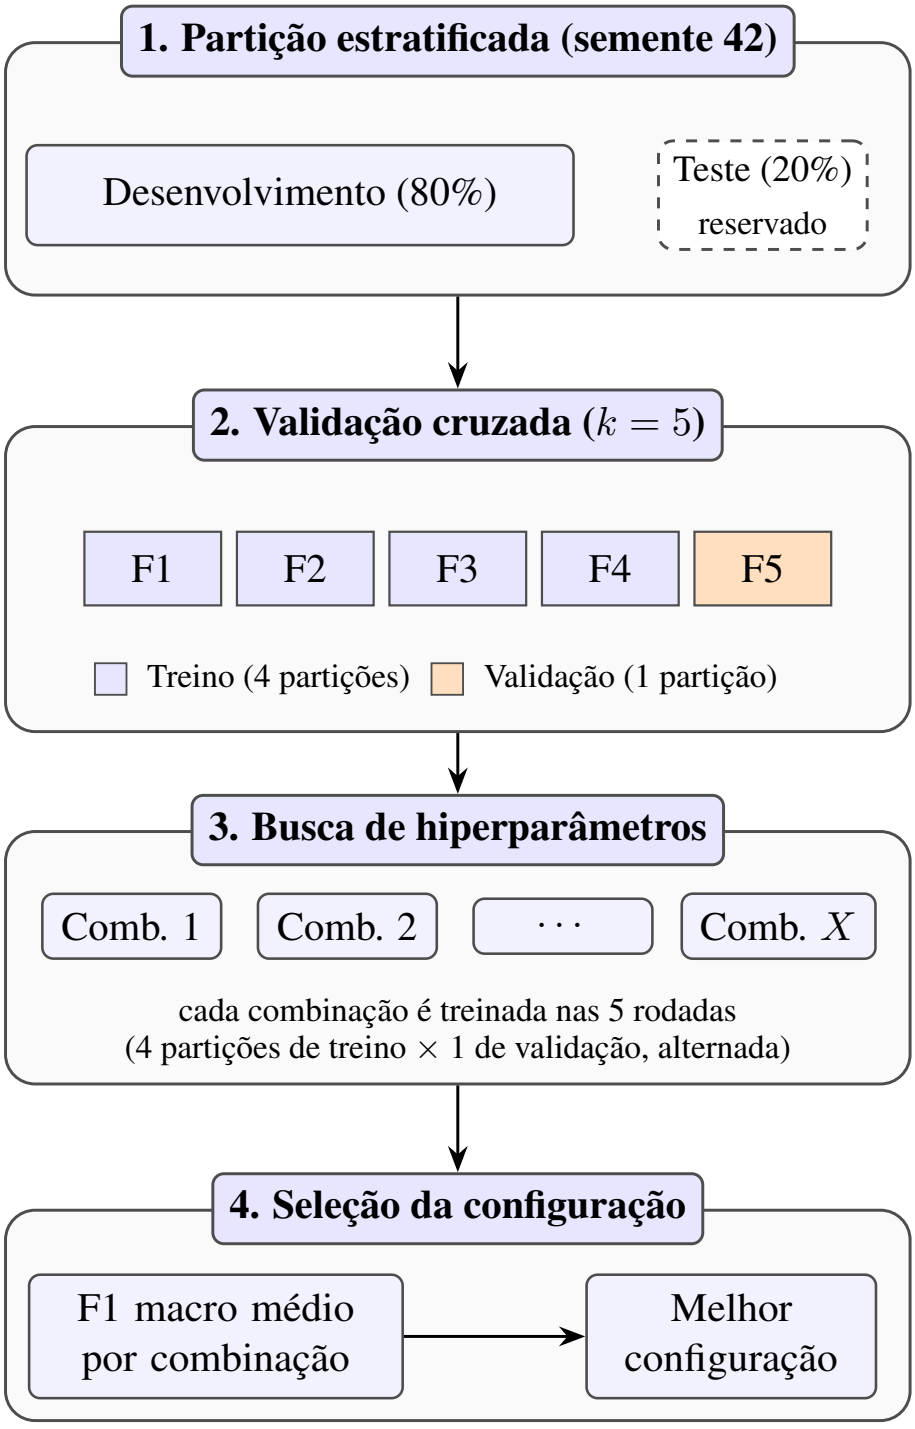


Figura 11 – Protocolo de ablação para o treinamento dos modelos: partição estratificada em 80% para desenvolvimento e 20% para teste final (reservado), validação cruzada com cinco partições sobre os 80%, avaliação de X combinações de hiperparâmetros e seleção da combinação de maior desempenho médio.

O processo de treinamento foi conduzido com a função de perda de entropia cruzada, otimizador AdamW e norma de gradiente limitada ao valor 1,0 para conter oscilações numéricas.

Tabela 2 – Espaço de busca de hiperparâmetros estratificado por conjunto de dados na via topológica.

Dataset	Lote (B)	Taxa de aprendizado (η)	Decaimento (λ)	*Dropout* (p)	Dim. oculta (h)
UCSB	$\{4, 8, 16\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
CR	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
LG	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
NHL	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$
LA	$\{16, 32, 64\}$	$\{3 \cdot 10^{-4}, 10^{-3}, 3 \cdot 10^{-3}, 10^{-2}, 3 \cdot 10^{-2}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$	$\{64, 128, 256, 512\}$

O coeficiente de decaimento de pesos foi fixado no valor $\lambda = 10^{-4}$. Em decorrência do tamanho das representações e dos volumes de dados, o treinamento foi delimitado ao teto de 100 épocas, com parada antecipada regulada por uma tolerância de 15 épocas consecutivas sem decrescimento da perda na partição de validação, sendo os pesos da melhor época restaurados ao término de cada rodada.

O desempenho de cada combinação foi computado pela média aritmética do F1 macro obtido nas cinco partições de validação, selecionando a combinação responsável pela maior pontuação média como a configuração de referência de cada arquitetura em cada conjunto de dados. Os desempenhos obtidos pelas configurações selecionadas de cada codificador, acompanhados do respectivo desvio padrão, estão registrados na Tabela 3, enquanto as combinações de hiperparâmetros responsáveis por esses resultados estão discriminadas na Tabela 4.

Tabela 3 – F1 macro (média $\pm$ desvio padrão entre as 5 partições de validação) da via topológica isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados.

Codificador	UCSB	CR	LA	LG	NHL
LSTM	0,893 $\pm$ 0,124	0,992 $\pm$ 0,017	**1,000** $\pm$ 0,000	0,995 $\pm$ 0,011	0,938 $\pm$ 0,043
BiLSTM	0,870 $\pm$ 0,109	0,985 $\pm$ 0,034	**1,000** $\pm$ 0,000	0,995 $\pm$ 0,011	0,956 $\pm$ 0,019
GRU	0,892 $\pm$ 0,107	**0,993** $\pm$ 0,017	**1,000** $\pm$ 0,000	0,995 $\pm$ 0,011	0,956 $\pm$ 0,049
BiGRU	**0,933** $\pm$ 0,061	0,985 $\pm$ 0,034	**1,000** $\pm$ 0,000	**0,995** $\pm$ 0,011	0,966 $\pm$ 0,021
SAC-LSTM	0,867 $\pm$ 0,090	0,977 $\pm$ 0,034	**1,000** $\pm$ 0,000	0,995 $\pm$ 0,011	0,921 $\pm$ 0,046
MLP	0,871 $\pm$ 0,135	**0,993** $\pm$ 0,017	**1,000** $\pm$ 0,000	0,995 $\pm$ 0,011	**0,973** $\pm$ 0,020

As combinações ótimas de hiperparâmetros responsáveis pelos maiores índices de F1 macro em cada conjunto de dados estão discriminadas na Tabela 4.

A análise dos desempenhos aponta pontuações elevadas em todos os seis codificadores avaliados na validação cruzada. A BiGRU alcançou a maior pontuação média global nas partições de validação ($0{,}976$), com o melhor resultado registrado no conjunto UCSB ($0{,}933 \pm 0{,}061$), onde o volume amostral é mais restrito. A GRU e o MLP alcançaram as maiores pontuações no conjunto CR ($0{,}993 \pm 0{,}017$), enquanto o MLP obteve o maior índice no conjunto NHL ($0{,}973 \pm 0{,}020$). Todos os modelos alcançaram separação perfeita ($1{,}000 \pm 0{,}000$) no conjunto LA e índices superiores a $0{,}995$ no conjunto LG, evidenciando que as variações multiescala das medidas descritoras capturam de forma discriminativa a progressão tecidual associada à idade e

Tabela 4 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo nos cinco conjuntos de dados.

Dataset	Modelo	Taxa de aprend.	*Weight Decay*	*Dropout*	Dim. oculta	Lote
UCSB	LSTM	$3 \cdot 10^{-3}$	10^{-4}	0,3	256	4
UCSB	BiLSTM	$3 \cdot 10^{-3}$	10^{-4}	0,3	512	4
UCSB	GRU	10^{-3}	10^{-4}	0,1	256	16
UCSB	BiGRU	$3 \cdot 10^{-3}$	10^{-4}	0,3	256	8
UCSB	SAC-LSTM	10^{-2}	10^{-4}	0,3	64	4
UCSB	MLP	10^{-2}	10^{-4}	0,5	256	4
CR	LSTM	$3 \cdot 10^{-2}$	10^{-4}	0,3	128	32
CR	BiLSTM	10^{-2}	10^{-4}	0,3	64	32
CR	GRU	10^{-2}	10^{-4}	0,1	128	16
CR	BiGRU	$3 \cdot 10^{-3}$	10^{-4}	0,5	256	64
CR	SAC-LSTM	$3 \cdot 10^{-3}$	10^{-4}	0,5	64	64
CR	MLP	$3 \cdot 10^{-3}$	10^{-4}	0,3	512	64
LA	LSTM	$3 \cdot 10^{-4}$	10^{-4}	0,1	128	16
LA	BiLSTM	$3 \cdot 10^{-4}$	10^{-4}	0,1	512	16
LA	GRU	$3 \cdot 10^{-4}$	10^{-4}	0,1	64	16
LA	BiGRU	$3 \cdot 10^{-4}$	10^{-4}	0,1	64	16
LA	SAC-LSTM	$3 \cdot 10^{-4}$	10^{-4}	0,1	512	32
LA	MLP	10^{-3}	10^{-4}	0,1	64	16
LG	LSTM	$3 \cdot 10^{-3}$	10^{-4}	0,5	256	16
LG	BiLSTM	$3 \cdot 10^{-3}$	10^{-4}	0,1	256	16
LG	GRU	$3 \cdot 10^{-3}$	10^{-4}	0,1	256	32
LG	BiGRU	$3 \cdot 10^{-3}$	10^{-4}	0,5	512	32
LG	SAC-LSTM	10^{-3}	10^{-4}	0,1	512	32
LG	MLP	$3 \cdot 10^{-3}$	10^{-4}	0,5	256	32
NHL	LSTM	$3 \cdot 10^{-3}$	10^{-4}	0,1	256	64
NHL	BiLSTM	10^{-3}	10^{-4}	0,5	512	16
NHL	GRU	10^{-3}	10^{-4}	0,3	256	16
NHL	BiGRU	$3 \cdot 10^{-3}$	10^{-4}	0,3	256	32
NHL	SAC-LSTM	10^{-3}	10^{-4}	0,3	512	64
NHL	MLP	$3 \cdot 10^{-4}$	10^{-4}	0,1	512	16

ao tipo de tecido.

A distribuição dos hiperparâmetros selecionados evidencia a relevância da expansão da dimensão oculta. As dimensões ocultas ampliadas de $h = 256$ ou $h = 512$ foram selecionadas em 21 das 30 configurações ótimas (70%), confirmando que espaços latentes mais amplos preservam com maior fidelidade as dinâmicas de conexão entre os raios. As taxas de aprendizado iguais ou superiores a $\eta = 3 \cdot 10^{-3}$ prevaleceram em 18 configurações, atingindo até $3 \cdot 10^{-2}$ no conjunto CR, sendo mantidas estáveis pela limitação da norma do gradiente. O tamanho de lote reduzido $B = 4$ foi o mais selecionado no conjunto UCSB em decorrência do volume restrito

de imagens, enquanto tamanhos de $B = 16$ e $B = 32$ prevaleceram nos conjuntos com maior quantidade de amostras.

4.2 ABLAÇÃO DA VIA VISUAL

A via visual processa diretamente as imagens histopatológicas no formato de 256×256 pixels, obtidas pela preservação da proporção original com recorte central. Para aumentar a diversidade amostral durante o treinamento, foi aplicado aumento de dados rotacional composto por inversões horizontais e rotações ortogonais de 90 graus. A ablação da via visual foi conduzida com o propósito de avaliar o comportamento de diferentes abordagens de visão computacional e determinar as combinações ótimas de hiperparâmetros de cada modelo para a subsequente integração na arquitetura de dupla via. Foram avaliadas seis arquiteturas distribuídas em três famílias (Figura 10b):

- a ResNet-50 (He et al., 2016), rede convolucional profunda com conexões residuais, empregada como referência padrão na classificação de tecidos histopatológicos (Litjens et al., 2017; Kumar; Mishra, 2026),
- a EfficientNet-B0 (Tan; Le, 2019), arquitetura convolucional compacta baseada em escalonamento composto uniforme e blocos invertidos com mecanismo de atenção por canal (Kushwah; Punn; Bhattacharya, 2026; Yousaf; Nawaz; Habib, 2024),
- o ViT-Tiny (Dosovitskiy et al., 2020), modelo que processa a imagem como uma sequência unidimensional de projeções lineares de *patches* por meio de camadas de autoatenção (Shamshad et al., 2023; Hussaini et al., 2026),
- o DeiT-Tiny (Touvron et al., 2021), transformador visual projetado com técnicas de destilação e regularização voltadas ao treinamento com menor dependência de grandes volumes de dados (Oliveira et al., 2025),
- a MobileViT-S (Mehta; Rastegari, 2022), arquitetura híbrida leve que intercala convoluções locais com blocos transformadores para equilibrar detalhamento celular e contexto amplo com baixo consumo paramétrico (Kabir et al., 2025; Ding et al., 2023),
- a CoAtNet-0 (Dai et al., 2021), modelo híbrido hierárquico que unifica convoluções nos primeiros estágios com autoatenção relativa nos estágios finais (Oliveira et al., 2025; Zaidkilani; Garcia; Puig, 2024).

Todos os seis modelos foram inicializados com pesos pré-treinados na base ImageNet-1k e ajustados de ponta a ponta. A camada original de classificação foi substituída por uma cabeça linear adaptada à dimensão de saída de cada arquitetura, composta por camada linear, normalização por camadas, camada oculta de 128 neurônios com ativação ReLU, camada de *dropout* e camada final para o número de classes de cada conjunto de dados.

O protocolo experimental seguiu a mesma divisão e metodologia adotadas na via topológica (Figura 11). A partição de teste final de 20% foi mantida totalmente reservada e isolada do procedimento de busca. Sobre a partição de desenvolvimento de 80%, foi executada uma validação cruzada estratificada em cinco partições ($k = 5$), com semente 42. Para cada modelo e para cada combinação de hiperparâmetros, foram executadas cinco rodadas nas quais quatro partições foram destinadas ao ajuste dos parâmetros e uma foi utilizada para a validação. A grade de hiperparâmetros explorada e as dimensões amostrais de cada conjunto de dados estão sintetizadas na Tabela 5.

Tabela 5 – Dimensões amostrais e espaço de busca de hiperparâmetros estratificado por conjunto de dados na via visual.

Dataset	**Desenv. (80%)**	**Treino / Val. (rodada)**	**Lote (B)**	**Taxa do *backbone* (η_{bb})**	**Taxa da cabeça (η_{hd})**	**Decaimento (λ)**	***Dropout* (p)**
UCSB	46	36 a 37 / 9 a 10	$\{4, 8, 16\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
CR	132	105 a 106 / 26 a 27	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
LG	212	169 a 170 / 42 a 43	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
NHL	299	239 a 240 / 59 a 60	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$
LA	422	337 a 338 / 84 a 85	$\{16, 32, 64\}$	$\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$	$\{10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\}$	10^{-4}	$\{0{,}1, 0{,}3, 0{,}5\}$

O treinamento foi conduzido com a função de perda de entropia cruzada e o otimizador AdamW. O decaimento de pesos foi fixado em 10^{-4} e a norma máxima dos gradientes foi limitada a 1,0. O processo foi limitado a 50 épocas, com parada antecipada estabelecida em 10 épocas consecutivas sem decréscimo da perda na partição de validação.

O desempenho de cada configuração foi mensurado pelo F1 macro médio nas cinco partições de validação interna. A combinação que atingiu a maior pontuação média foi definida como a configuração ótima de cada modelo em cada conjunto de dados. Os valores de F1 macro obtidos pelas melhores configurações de cada arquitetura estão reunidos na Tabela 6.

Tabela 6 – F1 macro (média $\pm$ desvio padrão entre as 5 partições de validação) da via visual isolada, na melhor combinação de hiperparâmetros de cada modelo. Em negrito, o maior valor médio de cada conjunto de dados.

Família	**Modelo**	**UCSB**	**CR**	**LA**	**LG**	**NHL**
Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Transformer	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Transformer	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

As combinações ótimas de hiperparâmetros responsáveis pelos maiores índices de F1 macro em cada conjunto de dados estão detalhadas na Tabela 7.

As configurações ótimas identificadas nas ablações da via topológica e da via visual fornecem os parâmetros fixos para a composição da arquitetura unificada de dupla via. O treinamento da rede de dupla via com os modelos selecionados e a avaliação do ganho preditivo frente às vias isoladas e aos métodos de referência no conjunto de teste independente são apresentados no Capítulo 5.

Tabela 7 – Melhores combinações de hiperparâmetros obtidas na validação cruzada para cada modelo visual nos cinco conjuntos de dados.

Dataset	**Família**	**Modelo**	η_{bb}	η_{hd}	***Dropout***	**Lote**	**F1 macro**
UCSB	Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	*Transformer*	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	*Transformer*	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	*Transformer*	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	*Transformer*	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	*Transformer*	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	*Transformer*	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	*Transformer*	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	*Transformer*	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	Convolucional	ResNet-50	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	Convolucional	EfficientNet-B0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	*Transformer*	ViT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	*Transformer*	DeiT-Tiny	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	Híbrida	MobileViT-S	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	Híbrida	CoAtNet-0	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**	**[a preencher]**

5 RESULTADOS E DISCUSSÃO

Neste capítulo são apresentados e discutidos os resultados finais obtidos pela arquitetura proposta de dupla via (*Two-Stream Network*) em comparação com as vias individuais e com métodos clássicos de caracterização tecidual. As avaliações foram conduzidas sobre a partição de teste independente (20% dos dados), mantida sem qualquer contato com as etapas anteriores de ajuste e seleção de hiperparâmetros. Para atenuar a variabilidade decorrente da inicialização dos pesos e das transformações estocásticas de aumento de dados, o treinamento final nos 80% de desenvolvimento e a inferência no teste foram repetidos sob cinco sementes aleatórias distintas, reportando a média e o respectivo desvio padrão das métricas.

5.1 COMPARAÇÃO ENTRE AS VIAS ISOLADAS E A REDE DE DUPLA VIA

A avaliação central deste trabalho investiga se a integração conjunta das representações topológicas multiescala com as representações visuais profundas resulta em ganho preditivo frente ao processamento isolado de cada modalidade. Para cada conjunto de dados, a rede de dupla via foi configurada com o codificador topológico ótimo determinado no Capítulo 4 e com a melhor arquitetura de visão computacional selecionada na ablação correspondente. O desempenho preditivo alcançado pelas vias isoladas e pela rede unificada de dupla via na partição de teste independente está sintetizado na Tabela 8.

Tabela 8 – Comparação de desempenho (média $\pm$ desvio padrão ao longo de 5 sementes) no conjunto de teste independente (20% das amostras) entre as vias isoladas e a arquitetura unificada de dupla via.

Dataset	**Métrica**	**Via Topológica Isolada**	**Via Visual Isolada**	**Rede de Dupla Via**
UCSB	F1 macro	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	Acurácia	**[a preencher]**	**[a preencher]**	**[a preencher]**
UCSB	AUC-ROC	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	F1 macro	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	Acurácia	**[a preencher]**	**[a preencher]**	**[a preencher]**
CR	AUC-ROC	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	F1 macro	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	Acurácia	**[a preencher]**	**[a preencher]**	**[a preencher]**
LA	AUC-ROC	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	F1 macro	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	Acurácia	**[a preencher]**	**[a preencher]**	**[a preencher]**
LG	AUC-ROC	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	F1 macro	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	Acurácia	**[a preencher]**	**[a preencher]**	**[a preencher]**
NHL	AUC-ROC	**[a preencher]**	**[a preencher]**	**[a preencher]**

6 CONCLUSÃO

REFERÊNCIAS

BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Texture analysis and classification: A complex network-based approach. **Information Sciences**, v. 219, p. 168–180, 2013. ISSN 0020-0255.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L.-P. Multimodal machine learning: A survey and taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

BEJNORDI, B. E. et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. **Jama**, American Medical Association, v. 318, n. 22, p. 2199–2210, 2017.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BOCCALETTI, S. et al. Complex networks: Structure and dynamics. **Physics Reports**, v. 424, n. 4, p. 175–308, 2006.

CHO, K. et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation. **arXiv preprint arXiv:1406.1078**, 2014.

DAI, Z. et al. Coatnet: Marrying convolution and attention for all data sizes. **Advances in neural information processing systems**, v. 34, p. 3965–3977, 2021.

DEHBOZORGI, P.; RYABCHYKOV, O.; BOCKLITZ, T. W. A comparative study of statistical, radiomics, and deep learning feature extraction techniques for medical image classification in optical and radiological modalities. **Computers in Biology and Medicine**, v. 187, p. 109768, 2025.

DING, Y. et al. HI-MViT: A lightweight model for explainable skin disease classification based on modified MobileViT. **Digital Health**, v. 9, p. 1–30, 2023.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179–211, 1990.

GARBAZ, A. et al. GSAC-UFormer: Groupwise self-attention convolutional transformer-based UNet for medical image segmentation. **Cognitive Computation**, v. 17, n. 69, 2025.

GELASCA, E. D. et al. Evaluation and benchmark for biological image segmentation. In: **2008 15th IEEE International Conference on Image Processing**. [S.l.: s.n.], 2008. p. 1816–1819.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINS, F. Learning to forget: Continual prediction with LSTM. **Neural Computation**, v. 12, n. 10, p. 2451–2471, 2000.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. **Neural Networks**, v. 18, n. 5–6, p. 602–610, 2005.

HE, K. et al. Deep residual learning for image recognition. In: **Proceedings of the IEEE conference on computer vision and pattern recognition**. [S.l.: s.n.], 2016. p. 770–778.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT press, v. 9, n. 8, p. 1735–1780, 1997.

HUANG, X. et al. Fusing hand-crafted and deep-learning features in a convolutional neural network model to identify prostate cancer in pathology images. **Frontiers in Oncology**, v. 12, p. 994950, 2022.

HUSSAINI, H. et al. A clinically grounded review of medical image classification: Quantitative insights into cnns, vision transformers, and hybrid cnn-vit models. **Journal of Imaging Informatics in Medicine**, 2026.

KABIR, M. F. et al. Accurate and lightweight oral cancer detection using SE-MobileViT on clinically validated image dataset. **Discover Artificial Intelligence**, v. 5, n. 173, 2025.

KUMAR, S.; MISHRA, P. K. Histopathology image analysis for colorectal cancer using deep learning techniques: A comprehensive survey. **Engineering Applications of Artificial Intelligence**, v. 172, p. 114262, 2026.

KUSHWAH, S. S.; PUNN, N. S.; BHATTACHARYA, M. EVC-Net: A hybrid deep learning network for breast cancer classification from histopathological images. **ACM Transactions on Intelligent Systems and Technology**, v. 17, n. 4, p. 87, 2026.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, J. Fusion feature-based hybrid methods for diagnosing oral squamous cell carcinoma in histopathological images. **Frontiers in Oncology**, v. 15, p. 1551876, 2025.

LIN, R. et al. Remaining useful life prediction in prognostics using multi-scale sequence and long short-term memory network. **Journal of Computational Science**, v. 57, p. 101508, 2022.

LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.

MA, Y. et al. CIHM: Context-insight hybrid Mamba for efficient medical image segmentation. **Visual Intelligence**, v. 4, n. 12, 2026.

MATHIYALAGI, L.; RAVI, R. Revolutionizing lung cancer detection using hybrid CNN-LSTM (HCLSTM) for accurate diagnosis and enhanced nodule classification. **Biomedical Signal Processing and Control**, v. 111, p. 108369, 2026.

MEHTA, S.; RASTEGARI, M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2022.

NAWAZ, W. et al. Acute respiratory distress identification via multi-modality using deep learning. **Applied Sciences**, v. 15, n. 3, p. 1512, 2025.

OLIVEIRA, D. L. L. de et al. Hybrid CNN-Transformer models in histopathology image analysis: A scoping review. **IEEE Access**, v. 13, p. 212887–212919, 2025.

PRIYADARSHINI, I. A firefly algorithm-optimized CNN–BiLSTM model for automated detection of bone cancer and marrow cell abnormalities. **Computers, Materials & Continua**, v. 86, n. 3, p. 64, 2026.

RAMACHANDRAM, D.; TAYLOR, G. W. Deep multimodal learning: A survey on recent advances and trends. **IEEE Signal Processing Magazine**, v. 34, n. 6, p. 96–108, 2017.

RAMOS-SOTO, O. et al. MIAFEx: An attention-based feature extraction method for medical image classification. **Knowledge-Based Systems**, v. 330, p. 114468, 2025.

RIBAS, L. C. et al. Color-texture classification based on spatio-spectral complex network representations. **Physica A: Statistical Mechanics and its Applications**, v. 635, p. 129518, 2024.

RIBAS, L. C. et al. Fusion of complex networks and randomized neural networks for texture analysis. **Pattern Recognition**, v. 103, p. 107189, 2020. ISSN 0031-3203.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, 1986.

SCABINI, L. F.; RIBAS, L. C.; BRUNO, O. M. Spatio-spectral networks for color-texture analysis. **Information Sciences**, v. 515, p. 64–79, 2020.

SCHUSTER, M.; PALIWAL, K. K. Bidirectional recurrent neural networks. **IEEE Transactions on Signal Processing**, v. 45, n. 11, p. 2673–2681, 1997.

SHALINI, T. G.; RATHNAMALA, S. An optimal CSBO-based detection and classification of breast cancer using deep SAC-LSTM design from histopathological image. **International Journal of Data Science and Analytics**, v. 22, p. 227, 2026.

SHAMIR, L. et al. Iicbu 2008: a proposed benchmark suite for biological image analysis. **Medical & biological engineering & computing**, v. 46, n. 9, p. 943–947, 2008.

SHAMSHAD, F. et al. Transformers in medical imaging: A survey. **Medical Image Analysis**, Elsevier, v. 88, p. 102802, 2023.

SIMONYAN, K.; ZISSERMAN, A. Two-stream convolutional networks for action recognition in videos. **Advances in neural information processing systems**, v. 27, 2014.

SIRINUKUNWATTANA, K. et al. Gland segmentation in colon histology images: The glas challenge contest. **Medical Image Analysis**, v. 35, p. 489–502, 2017.

SRINIDHI, C. L.; CIGA, O.; MARTEL, A. L. Deep neural network models for computational histopathology: A survey. **Medical Image Analysis**, Elsevier, v. 67, p. 101813, Jan 2021.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

TAN, M.; LE, Q. Efficientnet: Rethinking model scaling for convolutional neural networks. In: PMLR. **International conference on machine learning**. [S.l.], 2019. p. 6105–6114.

TOUVRON, H. et al. Training data-efficient image transformers & distillation through attention. In: PMLR. **International conference on machine learning**. [S.l.], 2021. p. 10347–10357.

WANG, X. et al. STNet: Shape and texture joint learning through two-stream network for knowledge-guided image recognition. **Frontiers in Neuroscience**, v. 17, p. 1212049, 2023.

YOUSAF, K.; NAWAZ, T.; HABIB, A. Using two-stream EfficientNet-BiLSTM network for multiclass classification of disturbing YouTube videos. **Multimedia Tools and Applications**, v. 83, n. 12, p. 36519–36546, 2024.

ZAIDKILANI, N.; GARCIA, M. A.; PUIG, D. Dual-stream CoAtNet models for accurate breast ultrasound image segmentation. **Neural Computing and Applications**, v. 36, p. 16427–16443, 2024.

ZERATI, A. B. S. et al. Cnt: An image transform based on complex networks for enhanced texture characterization. **Physica A: Statistical Mechanics and its Applications**, v. 701, p. 132044, 2026.